ANALISTA APROVADO · CÂMARA DOS DEPUTADOS 2026

Reconhecimento de Fala, Transcrição e Inteligência Artificial

Apostila completa da matéria
20 temas · 1.122 perguntas no app
0 temas que mais caem, em dourado

Analista Legislativo – Registro e Redação (cargo 11) · Cebraspe · itens de Certo ou Errado
Versão de 10/11/2026

Como usar esta apostila

Cada tema do app tem aqui um capítulo, na mesma ordem em que aparece na tela da matéria. Os temas em **dourado** são os que mais caem nas provas: comece por eles.

Todo capítulo segue o mesmo roteiro:

- **O que cai**: onde a banca põe a atenção naquele tema.
- **Entenda o tema**: a explicação do zero, em linguagem simples.
- **Quadros para memorizar**: prazos, números e comparações lado a lado.
- **Lei seca que cai** (ou **Conceitos e autores que caem**): o texto literal que a banca cobra, com a palavra-chave em negrito.
- **Pegadinhas da banca**: as trocas que transformam um item certo em errado.
- **Itens comentados**: exemplos no formato Certo ou Errado, com o porquê.
- **Resumo para revisar**: o essencial para ler antes de jogar.

As caixas coloridas marcam o que merece cuidado:

> **Atenção:** regra que confunde ou exceção importante.

> **Pegadinha:** ponto em que a banca costuma trocar a palavra.

> **Lei seca:** texto literal da norma vigente.

> **Exemplo:** caso prático, com nomes fictícios.

Leia o capítulo e, em seguida, jogue o tema no app. As leis citadas foram conferidas com o texto oficial vigente.

Sumário

1 Reconhecimento automático de fala (ASR) e modelos end-to-end 4

2 LLMs multimodais de áudio nativo 18

3 Diarização: identificação e separação de oradores 30

4 Pontuação automática e capitalização 41

5 Desafios do ASR em português: sotaques e vocabulário parlamentar 53

6 Transcrição em tempo real 65

7 Ferramentas e APIs: Whisper, Google, Azure e AWS 77

8 Transcrição automática, degravação e revisão humana 89

9 Degravação assistida por IA (human in the loop) 100

10 Revisão, fidelidade e controle de qualidade (revisão em dupla, auditorias, SLA) 110

11 Formatação de transcrições parlamentares 120

12 Normalização de números, siglas, abreviações e termos técnicos 132

13 Ferramentas CAT e vocabulário parlamentar adaptado 143

14 IA em parlamentos: transcrição, sumarização, indexação e busca 153

15 Busca semântica em acervos parlamentares 164

16 Geração automática de atas e resumos 175

17 Modelos multilíngues e especializados em português 186

18 LGPD em sistemas de transcrição e IA 197

19 Direitos autorais e ética no conteúdo gerado por IA 212

20 Segurança da informação em pipelines de áudio 224

TEMA 1 DE 20

Reconhecimento automático de fala (ASR) e modelos end-to-end

56 perguntas no app · Reconhecimento de fala

O que cai

O edital pede "Reconhecimento automático de fala (ASR – Automatic Speech Recognition)" e "Modelos de fala end-to-end". As perguntas deste tema giram em torno de cinco blocos:

- **Arquitetura clássica**: as quatro peças (modelo acústico, léxico de pronúncia, modelo de linguagem e decodificador) e o papel de cada uma. A pegadinha campeã é **trocar os papéis** do modelo acústico e do modelo de linguagem.
- **Modelos end-to-end**: uma rede só, do áudio ao texto; os três esquemas (**CTC**, **atenção** e **RNN-Transducer**); o que cada um supõe; quem serve melhor para tempo real.
- **WER (taxa de erro de palavras)**: a fórmula, o denominador (a **referência**), por que pode passar de 100%, a conta com números e a normalização antes da conta.
- **Whisper**: tipo de modelo, 680 mil horas, supervisão fraca, janelas de 30 segundos, espectrograma log-Mel, tokens especiais, o que foi liberado e o que não foi, o turbo, as falhas (alucinação, repetição).
- **Detalhes de pesquisa**: wav2vec 2.0 e HuBERT (autossupervisão), compressão da sequência acústica, perda combinada CTC + atenção, LibriSpeech, Common Voice e OWSM.

Entenda o tema

O que é ASR

ASR (*Automatic Speech Recognition*, reconhecimento automático de fala) é a tecnologia que **converte o sinal de áudio da fala em texto**. É o que faz o celular escrever a mensagem que você dita.

A saída típica de um sistema de ASR é a **transcrição bruta**: o texto cru, como saiu da máquina. Em geral ela vem acompanhada de:

- **marcas de tempo** (*timestamps*): em que segundo cada palavra ou trecho foi dito;
- **pontuações de confiança** (*confidence scores*): um número que diz o quanto o sistema está seguro de cada palavra.

Essa transcrição bruta **não é** o registro oficial. Para virar, por exemplo, as notas taquigráficas de uma sessão da Câmara, o texto precisa seguir as **convenções editoriais do órgão** e passar por **revisão humana**.

> **Pegadinha:** "A saída do ASR já corresponde ao texto final revisado de um registro oficial." Errado. O que sai da máquina é texto cru; as regras do órgão e a revisão vêm depois.

Alguns termos básicos

- **Fonema**: a menor unidade de som que distingue palavras. "Pato" e "bato" diferem só no primeiro fonema.
- **Quadro** (*frame*): o áudio é picado em fatias minúsculas, em geral de 25 milissegundos, que andam de 10 em 10 milissegundos. Cada fatia é um quadro.
- **Características acústicas**: números extraídos de cada quadro que descrevem o som (por exemplo, quanto de energia há em cada faixa de frequência).
- **Espectrograma**: uma "fotografia" do som ao longo do tempo: no eixo horizontal, o tempo; no vertical, as frequências; a cor, a intensidade. O **espectrograma log-Mel** usa uma escala de frequências parecida com a do ouvido humano (escala Mel) e uma escala logarítmica de intensidade.
- **Rótulo** ou **token**: a unidade de saída do sistema (letra, pedaço de palavra ou palavra).

A arquitetura clássica: quatro peças

Antes das redes neurais de ponta a ponta, o ASR era montado como uma linha de produção, com peças **construídas e treinadas separadamente**:

1. **Modelo acústico**: ouve o som. Relaciona as **características do sinal de áudio aos fonemas**. Responde: "este pedacinho de som parece qual fonema?". Tradicionalmente usava **modelos ocultos de Markov** (HMM), depois combinados com redes neurais.
2. **Léxico de pronúncia**: é um **dicionário de pronúncia**. Associa **cada palavra à sua sequência de fonemas** ("casa" = /k/ /a/ /z/ /a/). Faz a **ponte entre o modelo acústico** (que fala em fonemas) **e o modelo de linguagem** (que fala em palavras).
3. **Modelo de linguagem**: conhece a língua escrita. **Estima a probabilidade de sequências de palavras**, favorecendo as frases plausíveis. Ele **não mexe com o som**. Quando o áudio deixa dúvida entre "concerto" e "conserto", ele empurra para a opção que faz sentido na frase ("conserto do carro").
4. **Decodificador**: **combina** as três peças e procura a **sequência de palavras mais provável**. Ele não substitui o modelo acústico; só junta o trabalho de todos no final.

> **Dica:** pense numa equipe de tradução de um áudio difícil. O modelo acústico é quem tem bom ouvido; o léxico é o dicionário de pronúncia na mesa; o modelo de linguagem é o revisor que sabe como as frases costumam ser; o decodificador é o chefe que junta tudo e decide o texto.
>
> **Pegadinha:** a banca troca os papéis. "O modelo de linguagem relaciona o áudio aos fonemas e o modelo acústico estima a probabilidade das palavras." Errado: é o contrário. Som é com o **acústico**; frase plausível é com o **de linguagem**; palavra-para-fonemas é com o **léxico**.

Modelos end-to-end (de ponta a ponta)

Nos modelos **end-to-end**, **uma única rede neural** é treinada para **mapear diretamente o áudio para o texto**. Tudo é aprendido **em conjunto**, de uma vez. Por isso eles, **em regra, dispensam o léxico de pronúncia explícito**: a rede aprende sozinha como os sons viram letras.

Duas observações que a banca adora:

- "Em regra" não é "nunca": modelos end-to-end **podem receber um modelo de linguagem externo** como reforço, por exemplo para **reordenar** as hipóteses de texto ou para melhorar a precisão em uma área específica (vocabulário jurídico, parlamentar). Dizer que eles "não admitem, em nenhuma hipótese" esse acoplamento é errado.
- Peças treinadas separadamente e combinadas só na decodificação são marca do sistema **clássico**, não do end-to-end.

Os três esquemas end-to-end principais são:

1. **CTC** (*Connectionist Temporal Classification*);
2. **Modelos sequência a sequência com atenção** (codificador-decodificador com atenção);
3. **RNN-Transducer** (RNN-T).

> **Atenção:** "modelos ocultos de Markov com léxico de pronúncia explícito" **não** são end-to-end. São a base do sistema clássico.

CTC: escrever sem saber onde cada letra começa

O problema de fundo: o áudio tem muito mais quadros do que o texto tem letras. Uma fala de 1 segundo tem 100 quadros (de 10 em 10 ms), mas a palavra "sim" tem 3 letras. Para treinar a rede, seria preciso dizer em que quadro está cada letra, o que é caríssimo de anotar.

O **CTC** resolve isso. Ele permite **treinar a rede sem alinhamento prévio** entre cada quadro de áudio e cada rótulo. Como:

- A rede emite **um rótulo por quadro**, e pode emitir um **símbolo especial chamado branco** (*blank*), que quer dizer "nada novo aqui".
- Para obter o texto final, **colapsam-se as repetições consecutivas** e **removem-se os brancos**.

> **Exemplo:** a rede emite, quadro a quadro, "s s _ i i i _ m m". Juntando as repetições: "s _ i _ m". Tirando os brancos (_): "sim". O branco também serve para separar letras que se repetem de verdade: "c a r _ r o" vira "carro", e não "caro".

No treinamento, existem **muitos alinhamentos possíveis** que, após o colapso e a remoção dos brancos, dão a mesma transcrição. A probabilidade da transcrição é a **soma das probabilidades de todos esses alinhamentos**. Somar um por um seria inviável; isso é feito de modo eficiente por **programação dinâmica** (um truque de cálculo que reaproveita contas parciais).

A grande limitação: o CTC **supõe independência condicional entre as saídas**. Cada letra é escolhida **sem olhar as que já foram escritas**. Consequências:

- costuma ser **menos preciso** que os modelos com atenção;
- **melhora bastante quando se acopla um modelo de linguagem externo**, que dá coerência ao texto. Dizer que o CTC "dispensa por completo" o modelo de linguagem é errado;
- em compensação, como vai emitindo rótulos quadro a quadro, **adapta-se com facilidade ao reconhecimento em fluxo** (*streaming*).

Modelos com atenção (codificador-decodificador)

No modelo **sequência a sequência com atenção**, há duas partes:

- o **codificador** lê o áudio da janela e cria uma representação dele;
- o **decodificador** escreve o texto **token a token** (de forma **autorregressiva**: cada token depende dos anteriores), consultando o áudio por meio da **atenção**, um mecanismo que deixa o decodificador "olhar" para as partes do áudio mais relevantes a cada passo.

Esses reconhecedores **costumam alcançar maior acurácia**. O preço: **precisam processar a sequência de entrada inteira antes de decodificar**. Por isso são menos naturais para tempo real.

> **Atenção:** quem condiciona cada saída às saídas anteriores é o modelo com atenção (e o RNN-T), **não** o CTC. Dizer que o CTC é mais preciso "porque cada saída é condicionada ao histórico" está errado duas vezes.

RNN-Transducer

O **RNN-Transducer** (RNN-T) nasceu para corrigir a limitação do CTC. Além do codificador do áudio, ele tem uma **rede de predição**, que **olha os rótulos já emitidos** e ajuda a prever o próximo. Funciona como um **modelo de linguagem interno**. Uma terceira peça (a rede de junção) combina as duas informações.

Assim, o RNN-T **não** supõe independência entre as saídas (quem supõe é o CTC) e continua apto ao **tempo real**. Por isso é **comum em transcrição ao vivo** e em assistentes de voz.

> **Pegadinha:** "O RNN-T se distingue do CTC por não ter componente que modele os rótulos já emitidos." Errado: é justamente o RNN-T que tem esse componente.

Combinar CTC e atenção

É possível, e comum, **combinar no mesmo treinamento** a função de perda do codificador-decodificador com a do CTC: as duas perdas são **somadas com pesos**. A mistura aproveita o melhor dos dois: o **alinhamento monotônico** do CTC (o texto anda para a frente junto com o áudio) e a **precisão** da atenção. Dizer que as perdas são incompatíveis e "se anulam" é errado.

Transformer e Conformer: o motor dentro do esquema

Não confunda **esquema** com **arquitetura**:

- **CTC, atenção e RNN-T** são **esquemas**: o jeito de treinar e de gerar o texto.

- **Transformer** e **Conformer** são **arquiteturas de rede**: o motor que processa o áudio. O Conformer é um Transformer acrescido de convoluções, bom para captar padrões locais do som.

Transformers e Conformers são **usados como codificadores dentro** do CTC e do RNN-T. Não são rivais desses esquemas.

Encurtar a sequência acústica

O sinal em quadros de 10 ms é **várias vezes mais longo** do que o texto correspondente. Por isso, nos reconhecedores de ponta a ponta, é comum **comprimir a sequência de características acústicas antes do codificador** (ou no começo dele). Isso deixa o sistema mais rápido e leve.

O motivo técnico: o custo da **atenção do Transformer cresce com o quadrado do comprimento** da sequência. Sequência duas vezes maior custa quatro vezes mais. No **Whisper**, uma **camada convolucional com passo (stride) 2 reduz pela metade** o número de quadros que entram no Transformer.

Streaming: transcrever enquanto a pessoa fala

Reconhecimento em fluxo (*streaming*) é aquele em que o sistema **produz palavras enquanto o locutor fala**, sem esperar a frase acabar. É o que torna possíveis **legendas ao vivo, ditado e comandos de voz** sem espera. Dizer que no streaming o sistema só começa depois que a pessoa termina a frase é errado: isso é o contrário de streaming.

Resumo da adequação:

- **CTC** e **RNN-T**: adaptam-se bem ao streaming.
- **Atenção** (como o Whisper): precisa do trecho inteiro; maior acurácia, mais atraso.

Modelos autossupervisionados: wav2vec 2.0 e HuBERT

Transcrever áudio à mão é caro. Os modelos **autossupervisionados** contornam isso em duas fases:

1. **Pré-treinamento com áudio sem transcrição**: o modelo ouve muito áudio cru e aprende a **adivinhar partes mascaradas** (escondidas) do próprio sinal. Nessa fase **não há texto nenhum**: o alvo é o próprio som.
2. **Ajuste fino** (*fine-tuning*) com **uma quantidade menor de áudio transcrito**, geralmente usando a **função de perda CTC**.

Os exemplos clássicos são o **wav2vec 2.0** e o **HuBERT**.

> **Pegadinha:** "O pré-treinamento do wav2vec 2.0 depende de grandes volumes de áudio com transcrição manual." Errado: as transcrições só entram no ajuste final.

A taxa de erro de palavras (WER)

A **WER** (*Word Error Rate*) é a medida padrão de qualidade do ASR. Compara a **hipótese** (o que o sistema escreveu) com a **referência** (a transcrição correta, feita por gente).

Contam-se três tipos de erro:

- **Substituição (S)**: o sistema trocou uma palavra ("sessão" virou "seção");
- **Exclusão ou deleção (D)**: o sistema deixou de fora uma palavra dita;
- **Inserção (I)**: o sistema escreveu uma palavra que não foi dita.

A fórmula:

WER = (S + D + I) / N, em que **N é o número de palavras da referência**.

O denominador é sempre a **referência**, nunca a hipótese. Se fosse a hipótese, quem escreve demais pareceria errar menos.

> **Exemplo:** a referência tem 20 palavras. O sistema fez 2 substituições, 1 exclusão e 1 inserção. Erros: 2 + 1 + 1 = 4. WER = 4 / 20 = **20%**.

A WER pode passar de 100%. Como as **inserções também contam**, um sistema que escreve muito mais do que foi dito pode somar mais erros do que palavras na referência. Ex.: referência de 5 palavras, sistema erra as 5 e ainda inventa outras 3: WER = 8 / 5 = 160%.

> **Pegadinha:** "A WER considera apenas substituições e exclusões, por isso nunca ultrapassa 100%." Errado: inserções contam e a WER pode passar de 100%.

Normalização antes da conta. A WER, crua, pune **qualquer** diferença entre os textos, até as sem importância: escrever "2" em vez de "dois", "pro" em vez de "para o", uma vírgula a mais. Por isso é comum **normalizar a referência e a hipótese** antes de calcular: remover hesitações ("uh", "hmm", "é..."), padronizar números e contrações, tirar pontuação e maiúsculas. Assim a nota reflete só os erros de reconhecimento de verdade. Os autores do Whisper criaram um **normalizador de texto** justamente porque a WER penaliza diferenças de pontuação, formatação e estilo.

Bases de dados que caem

- **LibriSpeech**: cerca de mil horas de **audiolivros lidos** em inglês. É dividido em partes **clean** (mais fácil) e **other** (mais difícil). A divisão **não** foi feita por ouvintes humanos: foi feita **por um sistema de reconhecimento**. Os falantes com quem ele errava menos foram para "clean"; os com quem errava mais, para "other".
- **Common Voice** (Mozilla): voluntários **leem frases prontas** em dezenas de línguas, incluindo o português. É **fala lida**, planejada, gravada pelo próprio voluntário (não em estúdio por profissionais). **Não** é corpus de fala espontânea e não é a referência para avaliar reuniões e debates.

Whisper, da OpenAI

O **Whisper** (OpenAI, 2022, artigo de Radford et al., "Robust Speech Recognition via Large-Scale Weak Supervision") é o modelo de ASR mais cobrado.

Tipo de modelo. É um modelo **end-to-end** do tipo **sequência a sequência com atenção**, baseado em **Transformer codificador-decodificador**. **Não** é RNN-Transducer.

Entrada. O áudio é **reamostrado a 16.000 Hz** e convertido em **espectrograma log-Mel**, calculado em **janelas de 25 ms** com **deslocamento de 10 ms**. No codificador, camadas convolucionais (a segunda com passo 2) encurtam a sequência pela metade antes do Transformer.

Janela de 30 segundos. O Whisper foi treinado com **pedaços de 30 segundos** e processa **um pedaço de cada vez**. O decodificador ser autorregressivo **não** significa que ele aceita áudio de qualquer duração de uma vez. Para **áudios longos**, ele processa **segmentos consecutivos de 30 s** e **desloca a janela de acordo com os carimbos de tempo previstos pelo próprio modelo**. Nessa transcrição longa, são importantes a **busca em feixe** (*beam search*, que mantém várias hipóteses em paralelo e escolhe a melhor) e o **escalonamento de temperatura** (tentar de novo com mais aleatoriedade quando a saída parece ruim), para **evitar laços de repetição**.

Tokens especiais (multitarefa). A tarefa é indicada ao decodificador por **tokens especiais** no começo da saída: o **idioma** da fala e a instrução de **transcrever** ou **traduzir** (para o inglês), além de marcas de tempo. Com isso, **um único modelo substitui várias etapas** de um sistema tradicional (detectar idioma, detectar voz, transcrever, traduzir).

Dados de treino. Cerca de **680 mil horas** de áudio, **em vários idiomas** (não só inglês), incluindo exemplos de tradução para o inglês. O português está entre as línguas transcritas.

Supervisão fraca. O Whisper foi treinado com **supervisão fraca em grande escala**: um **enorme volume de pares de áudio e transcrição coletados da internet**, nem sempre perfeitos, em vez de um conjunto menor transcrito com rigor por especialistas. A quantidade e a variedade compensam as imperfeições.

Robustez. Em avaliação **zero-shot** (sem ajuste fino para cada conjunto de teste), os modelos Whisper cometem, em média, **muito menos erros** (os autores falam em cerca de 55% menos) do que um modelo supervisionado só no LibriSpeech que tenha desempenho equivalente no LibriSpeech. Ou seja: mesma nota no teste fácil, desempenho bem melhor em gravações diferentes. É isso que os autores chamam de **robustez**.

Vocabulário. Os modelos **só em inglês** usam o mesmo vocabulário de tokens do **GPT-2**. Nos **multilíngues**, o vocabulário foi **refeito** (com o mesmo tamanho), para que palavras de outras línguas não sejam quebradas em pedaços demais.

O que foi liberado. A OpenAI disponibilizou os **modelos** (os pesos) e o **código de inferência** (para usar o modelo). **Não** liberou o **código de treinamento** nem os **dados de treino**.

OWSM (*Open Whisper-style Speech Model*): criado por **outros pesquisadores** (academia), como **alternativa aberta** ao Whisper, com **código de treinamento e dados públicos**. Não é versão comercial da OpenAI.

Tamanhos. A família vem em vários tamanhos (tiny, base, small, medium, large e turbo). O compromisso é o de sempre: **maiores erram menos, mas usam mais memória e são mais lentos**. O **turbo** é uma **versão otimizada do large-v3**: troca uma **pequena perda de acurácia** por **muito mais velocidade**. O turbo **não foi treinado para tradução**: se receber a instrução de traduzir, devolve o texto **na língua original**, e não em inglês.

Falhas admitidas pelos autores. O próprio artigo descreve:

- **laços de repetição** (repetir a mesma frase várias vezes);

- **omissão das primeiras ou das últimas palavras** de um segmento de áudio;
- **alucinação completa**: texto que **não guarda relação nenhuma com o áudio**.

É por isso que a transcrição automática precisa de revisão humana.

Quadros para memorizar

As peças da arquitetura clássica

Peça	O que faz	Liga o quê
Modelo acústico	Ouve o som	Características do áudio → fonemas
Léxico de pronúncia	Dicionário de pronúncia	Palavra → sequência de fonemas (ponte entre acústico e linguagem)
Modelo de linguagem	Avalia frases	Probabilidade de sequências de palavras
Decodificador	Junta tudo	Busca a sequência de palavras mais provável

Clássico x end-to-end

	Clássico	End-to-end
Estrutura	Várias peças	Uma única rede neural
Treino	Peças treinadas separadamente, combinadas na decodificação	Tudo treinado em conjunto
Léxico de pronúncia	Explícito	Em regra, dispensado
Modelo de linguagem	Peça obrigatória	Opcional, pode ser acoplado como reforço externo
Exemplos	HMM + léxico + modelo de linguagem	CTC, atenção, RNN-T (Whisper é de atenção)

Os três esquemas end-to-end

Esquema	Ideia central	Olha as saídas anteriores?	Streaming	Acurácia
CTC	Símbolo branco; colapsa repetições e tira brancos; soma todos os alinhamentos	Não (independência condicional)	Adapta-se bem	Menor; melhora com modelo de linguagem externo
Atenção (codificador-decodificador)	Codificador lê tudo; decodificador escreve token a token consultando o áudio	Sim (autorregressivo)	Difícil: precisa da entrada inteira	Costuma ser maior

Esquema	Ideia central	Olha as saídas anteriores?	Streaming	Acurácia
RNN-Transducer	CTC + rede de predição (modelo de linguagem interno)	Sim	Adapta-se bem; comum ao vivo	Boa

WER

Ponto	Regra
Fórmula	(S + D + I) / N
N	Palavras da **referência** (texto correto)
Erros contados	Substituição, exclusão (deleção) e inserção
Pode passar de 100%?	Sim, por causa das inserções
Exemplo	20 palavras; 2 S + 1 D + 1 I = 4 erros → 20%
Normalização	Antes da conta: tirar hesitações, padronizar números, contrações, pontuação

Whisper em números

Item	Valor
Autor e ano	OpenAI, 2022 (Radford et al.)
Tipo	Transformer codificador-decodificador, sequência a sequência com atenção
Dados de treino	~680 mil horas, vários idiomas, supervisão fraca
Áudio de entrada	16.000 Hz, espectrograma log-Mel
Janela do espectrograma	25 ms, deslocamento de 10 ms
Trecho por vez	30 segundos
Redução no codificador	Convolução com passo 2 (metade dos quadros)
Tarefas	Transcrever, traduzir para o inglês, identificar idioma, marcar tempo (por tokens especiais)
Liberado	Pesos dos modelos e código de inferência
Não liberado	Código de treino e dados
Turbo	Versão otimizada do large-v3; mais rápido, pouca perda; não traduz

Bases de dados

Base	O que é	Detalhe cobrado
LibriSpeech	~1.000 h de audiolivros lidos em inglês	clean x other separados por um reconhecedor, não por ouvintes
Common Voice	Voluntários leem frases, muitas línguas	Fala lida, não espontânea; não serve de referência para debates

Conceitos e autores que caem

- **ASR (Automatic Speech Recognition)**: conversão do sinal de fala em texto. Saída: transcrição bruta com marcas de tempo e confiança.
- **Fonema**: menor unidade sonora que distingue palavras.
- **Modelo acústico / léxico / modelo de linguagem / decodificador**: as quatro peças do sistema clássico.
- **HMM (modelos ocultos de Markov)**: base estatística dos modelos acústicos clássicos.
- **End-to-end**: uma rede só, do áudio ao texto, treinada em conjunto.
- **CTC (Connectionist Temporal Classification)**: Graves et al., 2006. Treina sem alinhamento; usa o **branco** (*blank*); supõe independência condicional.
- **Atenção**: mecanismo que deixa o decodificador consultar as partes relevantes da entrada.
- **RNN-Transducer (RNN-T)**: CTC + rede de predição que modela os rótulos já emitidos.
- **Transformer / Conformer**: arquiteturas usadas como codificador dentro dos esquemas.
- **Autorregressivo**: cada token gerado depende dos anteriores.
- **Streaming**: transcrição enquanto a pessoa fala.
- **wav2vec 2.0 / HuBERT**: autossupervisão com áudio sem texto (partes mascaradas) + ajuste fino com CTC.
- **WER (Word Error Rate)**: (S + D + I) / palavras da referência.
- **Zero-shot**: avaliar sem ajuste fino para aquele conjunto de teste.
- **Supervisão fraca**: muitos dados imperfeitos em vez de poucos dados perfeitos.
- **Beam search (busca em feixe)**: mantém várias hipóteses em paralelo para escolher a melhor.
- **Escalonamento de temperatura**: refazer a decodificação com mais aleatoriedade quando a saída sai ruim (repetitiva).
- **Alucinação**: texto que não corresponde ao áudio.
- **Whisper** (OpenAI, Radford et al., 2022); **OWSM** (alternativa aberta, de pesquisadores); **LibriSpeech**; **Common Voice** (Mozilla).
- Referência acadêmica citada: **Jurafsky e Martin**, *Speech and Language Processing*, capítulo sobre ASR.

Pegadinhas da banca

- **Papéis trocados na arquitetura clássica.** O item diz que o modelo de linguagem liga o áudio aos fonemas e o acústico estima frases. Errado: é o inverso.
- **Modelo de linguagem como dicionário de pronúncia.** Errado: quem associa palavra a fonemas é o **léxico**.
- **Decodificador que dispensa o modelo acústico.** Errado: o decodificador só combina as peças; o som é com o modelo acústico.
- **"End-to-end não admite, em nenhuma hipótese, modelo de linguagem externo."** Errado: pode ser acoplado como reforço.

- **"No end-to-end as peças continuam treinadas separadamente."** Errado: isso é o clássico.
- **HMM com léxico listado entre os end-to-end.** Errado: os end-to-end são CTC, atenção e RNN-T.
- **RNN-T e CTC trocados.** Quem supõe independência entre as saídas é o **CTC**; o RNN-T tem a rede de predição.
- **"O CTC não supõe independência e por isso dispensa modelo de linguagem."** Errado nas duas partes.
- **"O CTC é mais preciso que a atenção porque olha o histórico."** Errado: o CTC não olha o histórico e costuma ser menos preciso.
- **Whisper como RNN-T.** Errado: é sequência a sequência com atenção.
- **Transformer e Conformer como rivais do CTC e do RNN-T.** Errado: são codificadores usados dentro deles.
- **Denominador da WER na hipótese.** Errado: é na **referência**.
- **"A WER nunca passa de 100%."** Errado: as inserções podem levá-la além.
- **"A WER ignora pontuação e formato, então não precisa normalizar."** Errado: ela pune tudo; por isso se normaliza.
- **"O Whisper processa áudio de qualquer duração de uma vez."** Errado: janelas de 30 s.
- **"680 mil horas, todas em inglês."** Errado: vários idiomas, inclusive português.
- **"A OpenAI liberou também o código de treino e os dados."** Errado: só modelos e código de inferência.
- **"OWSM é versão comercial da OpenAI."** Errado: é alternativa aberta, de outros pesquisadores.
- **"O turbo traduz para o inglês."** Errado: não foi treinado para traduzir.
- **"Os multilíngues usam o vocabulário do GPT-2 sem adaptação."** Errado: só os modelos em inglês usam; nos multilíngues o vocabulário foi refeito.
- **"wav2vec 2.0 e HuBERT pré-treinam com transcrição manual."** Errado: pré-treino só com áudio.
- **"Perdas de CTC e atenção são incompatíveis."** Errado: são somadas com pesos.
- **"LibriSpeech clean/other separado por ouvintes."** Errado: por um reconhecedor automático.
- **"Common Voice é fala espontânea de estúdio."** Errado: frases lidas por voluntários.
- **"No streaming, o sistema espera a frase acabar."** Errado: escreve enquanto a pessoa fala.

Itens comentados

- **Item:** Na arquitetura clássica de ASR, cabe ao modelo de linguagem relacionar o sinal acústico aos fonemas, enquanto o modelo acústico estima a probabilidade de sequências de palavras. **Errado.** Os papéis estão invertidos. O modelo acústico liga o áudio aos fonemas; o modelo de linguagem avalia as sequências de palavras.
- **Item:** Na arquitetura clássica de ASR, o léxico de pronúncia associa cada palavra à sua sequência de fonemas, fazendo a ligação entre o modelo acústico e o modelo de linguagem.

Certo. O léxico é o dicionário de pronúncia e serve de ponte entre quem fala em fonemas (acústico) e quem fala em palavras (linguagem).

- **Item:** Os modelos end-to-end de ASR não admitem, em nenhuma hipótese, o acoplamento de um modelo de linguagem externo para melhorar o reconhecimento. **Errado.** Um modelo de linguagem externo pode ser acoplado, por exemplo para reordenar hipóteses ou reforçar um vocabulário específico.
- **Item:** O RNN-Transducer se distingue do CTC por não possuir componente que modele os rótulos já emitidos, pois supõe independência condicional entre as saídas. **Errado.** Quem supõe independência é o CTC. O RNN-T tem a rede de predição, que olha os rótulos já emitidos.
- **Item:** No CTC, utiliza-se um símbolo especial chamado branco (blank) e a sequência final é obtida colapsando as repetições consecutivas e removendo os brancos. **Certo.** É o mecanismo do CTC: um rótulo por quadro, com o branco preenchendo os intervalos; depois junta-se o repetido e apaga-se o branco.
- **Item:** Em uma avaliação de reconhecimento de fala, a transcrição de referência tem 20 palavras e a hipótese do sistema apresenta 2 substituições, 1 exclusão e 1 inserção; a taxa de erro de palavras (WER) é, portanto, de 20%. **Certo.** São 4 erros sobre 20 palavras da referência: 20%.
- **Item:** No cálculo da taxa de erro de palavras (WER), o denominador é o número de palavras da hipótese produzida pelo reconhecedor, e não o da transcrição de referência. **Errado.** O denominador é o número de palavras da referência.
- **Item:** Como a taxa de erro de palavras (WER) considera apenas substituições e exclusões, seu valor nunca ultrapassa 100%, ainda que o sistema acrescente palavras que não foram ditas. **Errado.** As inserções também contam, e a WER pode passar de 100%.
- **Item:** O Whisper, da OpenAI, é um modelo de reconhecimento de fala do tipo RNN-Transducer, e não um modelo sequência a sequência com atenção. **Errado.** O Whisper é um Transformer codificador-decodificador, da família sequência a sequência com atenção.
- **Item:** Por utilizar um decodificador autorregressivo, o Whisper processa de uma só vez áudios de qualquer duração, sem necessidade de dividi-los em janelas. **Errado.** O Whisper trabalha com trechos de 30 segundos e, em áudios longos, avança janela a janela guiado pelos próprios carimbos de tempo.
- **Item:** Ao divulgar o Whisper, a OpenAI disponibilizou os modelos e o código de inferência, bem como o código de treinamento e os dados usados para treinar os modelos. **Errado.** Foram liberados só os modelos e o código de inferência. Código de treino e dados ficaram fechados (daí o OWSM, alternativa aberta).
- **Item:** O Whisper turbo, versão otimizada do large-v3, foi treinado também para a tarefa de tradução e, por isso, ao receber a instrução de traduzir, produz o texto em inglês. **Errado.** O turbo não foi treinado para traduzir; com essa instrução, devolve o texto na língua original.
- **Item:** O pré-treinamento do wav2vec 2.0 e do HuBERT depende de grandes volumes de áudio com transcrição manual, pois o texto correspondente é o alvo da tarefa de prever as partes mascaradas do sinal. **Errado.** O pré-treino usa só áudio; o alvo é o próprio som mascarado. A transcrição entra no ajuste fino.

- **Item:** A divisão do conjunto LibriSpeech em partes clean e other foi feita por avaliação subjetiva de ouvintes humanos, que classificaram a qualidade de cada gravação. **Errado.** A divisão foi feita por um reconhecedor automático, conforme a taxa de erro que ele tinha com cada falante.
- **Item:** No reconhecimento em fluxo (streaming), o sistema só começa a produzir palavras depois que o locutor termina a frase, razão pela qual esse modo é inadequado para ditado e comandos de voz. **Errado.** Streaming é transcrever enquanto a pessoa fala; é o que viabiliza ditado, comandos de voz e legendas ao vivo.

Resumo para revisar

- ASR converte fala em texto; a saída é transcrição bruta, com marcas de tempo e confiança, ainda sem revisão nem convenções do órgão.
- Clássico: modelo acústico (som → fonemas), léxico (palavra → fonemas, ponte), modelo de linguagem (probabilidade de frases), decodificador (junta e acha a frase mais provável).
- Peças clássicas são construídas e treinadas separadamente; HMM é a base do clássico.
- End-to-end: uma rede só, treinada em conjunto, em regra sem léxico; modelo de linguagem externo pode ser acoplado.
- Três esquemas end-to-end: CTC, atenção, RNN-T.
- CTC: branco + colapso de repetições + remoção de brancos; treina sem alinhamento; soma todos os alinhamentos por programação dinâmica; supõe independência; melhora com modelo de linguagem; bom para streaming.
- Atenção: codificador lê tudo, decodificador escreve token a token; mais preciso, mas precisa da entrada inteira.
- RNN-T: rede de predição olha o que já foi escrito; bom para tempo real.
- Perdas de CTC e atenção podem ser somadas com pesos.
- Transformer e Conformer são codificadores dentro dos esquemas, não rivais.
- A sequência acústica (quadros de 10 ms) é comprimida antes do codificador; atenção custa o quadrado do comprimento; no Whisper, convolução com passo 2.
- Streaming: escrever enquanto a pessoa fala (ditado, comandos de voz, legendas).
- wav2vec 2.0 e HuBERT: pré-treino só com áudio (partes mascaradas), ajuste com pouco texto e perda CTC.
- WER = (S + D + I) / palavras da referência; pode passar de 100%; normalizar antes de calcular.
- Whisper: OpenAI, 2022; Transformer codificador-decodificador com atenção; 680 mil horas multilíngues; supervisão fraca.
- Whisper: 16 kHz, log-Mel, janelas de 25 ms com passo de 10 ms; trechos de 30 s; áudio longo janela a janela pelos carimbos de tempo; beam search e temperatura contra repetição.
- Whisper: tokens especiais indicam idioma e tarefa (transcrever ou traduzir).
- Whisper: liberou pesos e código de inferência, não código de treino nem dados; OWSM é a alternativa aberta.
- Whisper: zero-shot, erra bem menos que modelo do LibriSpeech com a mesma nota (robustez).

- Whisper multilíngue tem vocabulário refeito; só o de inglês usa o do GPT-2.
- Tamanhos: maior erra menos, mas é mais lento e pesado; turbo = large-v3 otimizado, rápido, não traduz.
- Falhas do Whisper: laços de repetição, perda de palavras no início ou no fim, alucinação completa.
- LibriSpeech: audiolivros; clean/other separados por reconhecedor. Common Voice: frases lidas por voluntários.

TEMA 2 DE 20

LLMs multimodais de áudio nativo

53 perguntas no app · Reconhecimento de fala

O que cai

O edital pede "LLMs multimodais de áudio nativo". As perguntas deste tema cobram:

- **A ideia central**: o modelo de áudio nativo **ouve o áudio direto**, sem transcrever antes, e por isso **preserva informação paralinguística** (tom, ênfase, emoção). O oposto é o **sistema em cascata** (ASR → LLM → síntese de voz), mais lento e que descarta essas informações.
- **A arquitetura típica**: codificador de áudio (muitas vezes herdado do Whisper) + camada adaptadora (que **encurta** a sequência) + modelo de linguagem.
- **Modelos e o que cada um tem de marcante**: Voxtral (Mistral, Apache 2.0, chamada de funções por voz), Qwen2-Audio (dois modos sem prompt de sistema, DPO), GPT-4o (uma rede para tudo, 232 ms e 320 ms), Moshi (full-duplex, monólogo interior), AudioPaLM (PaLM-2 + AudioLM, tradução zero-shot).
- **Gemini**: tokens por segundo de áudio, envio por serviço de arquivos, mistura dos canais, redução para 16 Kbps, sons não verbais, Live API (PCM, VAD, sessões com limite, vocabulário personalizado, áudio proativo, diálogo afetivo).
- **Riscos e uso na Câmara**: alucinação (estudo *Careless Whisper*), cuidados do System Card do GPT-4o, e a experiência da Câmara (Azure em 2023, Whisper large-v3 no Escriba, WER média de 25%, revisão humana obrigatória).

Entenda o tema

Cascata x áudio nativo

Há dois jeitos de fazer uma IA "entender" fala.

Sistema em cascata (encadeado). Peças em fila:

1. um **ASR** transforma o áudio em texto;
2. um **LLM** (modelo de linguagem de grande porte, como os que conversam por texto) lê esse texto e pensa a resposta;
3. se a resposta for falada, um sistema de **síntese de voz** (TTS, *text-to-speech*) transforma o texto em som.

Em sistemas de conversa, antes de tudo isso costuma vir ainda a **detecção de atividade de voz** (VAD, *voice activity detection*), que percebe quando a pessoa começou e parou de falar.

Problemas da cascata: os **atrasos se somam** (cada etapa demora um pouco, e no total podem ser segundos) e, quando o áudio vira texto, **perde-se tudo o que não é palavra**: tom de voz, ênfase, ironia, emoção, quem está falando.

LLM multimodal de áudio nativo. O modelo **recebe o áudio diretamente** e o processa **sem etapa prévia de transcrição**. "Multimodal" quer dizer que lida com mais de um tipo de dado (texto, áudio, imagem). Como "ouve" o som, preserva a **informação paralinguística**: entonação, ênfase, emoção, identidade de quem fala, que a cascata em grande parte descarta.

> **Pegadinha:** "Os LLMs de áudio nativo precisam, obrigatoriamente, converter o áudio em texto por um ASR independente antes de raciocinar." Errado: isso é a cascata. O nativo entende o som direto.
>
> **Dica:** a cascata é como pedir a um amigo que ouça um áudio e lhe mande por escrito o que foi dito. Você recebe as palavras, mas não sabe se a pessoa estava brava ou brincando. O modelo nativo é como ouvir o áudio você mesmo.

Cuidado: nativo não quer dizer literal

Por processar o áudio direto, esses modelos podem **reescrever, resumir ou "melhorar"** o que ouviram, em vez de copiar palavra por palavra. Eles também podem **inventar trechos** (alucinar). Para **registro oficial**, isso exige **cautela redobrada** e conferência com o áudio. Dizer que eles "sempre transcrevem de forma literal" é errado.

Quando a cascata é melhor

A cascata não é sempre pior. Segundo o **guia de agentes de voz da OpenAI**, a arquitetura encadeada (reconhecimento de fala → modelo de texto → síntese de voz) é indicada quando **cada etapa precisa ser visível ou substituível**, porque permite **inspecionar o texto intermediário**. Como a **transcrição é o primeiro passo**, ela existe **antes** de o agente responder e pode ser **armazenada** antes da resposta.

O mesmo guia orienta, para **avaliar agentes de voz**, a **salvar o áudio, os eventos, os resultados das ferramentas e o estado da aplicação** necessários para verificar cada resultado. Sem esses registros, não dá para conferir depois o que aconteceu.

A arquitetura típica de um modelo de áudio-linguagem

A maioria dos modelos de áudio-linguagem tem três peças:

1. **Codificador de áudio**: o "ouvido". Transforma o som em números (representações). Muitas vezes é **herdado de um reconhecedor de fala já existente, como o Whisper**.
2. **Camada adaptadora** (adaptador ou projetor): o "tradutor de formato". **Encurta a sequência** de quadros de áudio (reduz quantos quadros por segundo seguem adiante) e ajusta o formato dos números para o que o modelo de linguagem entende. Fila menor cabe melhor no contexto e custa menos.
3. **Decodificador de linguagem** (um LLM): o "cérebro". Recebe as representações do áudio **como se fossem parte da entrada de texto** e gera a resposta.

> **Pegadinha:** "A camada adaptadora aumenta a quantidade de quadros por segundo, alongando a sequência." Errado: ela **encurta**.

Janela de contexto e duração do áudio. O LLM tem um limite de tokens que consegue considerar de uma vez (a **janela de contexto**). Cada segundo de áudio vira certo número de tokens. Logo, a **duração máxima de áudio** processável de uma vez depende de **duas coisas**: o **tamanho da janela de contexto** e **quantos tokens cada segundo de áudio ocupa**.

Voxtral (Mistral AI, 2025)

- Segue a arquitetura de três peças: **codificador de áudio + adaptador + decodificador de linguagem**.
- O codificador **reaproveita o do Whisper** (não foi treinado do zero); a parte que entende e responde vem de um modelo de linguagem da própria Mistral.
- O adaptador **reduz** a sequência de áudio antes do decodificador.
- Licença **aberta, Apache 2.0**: os modelos podem ser **executados em infraestrutura própria**, sem depender de API paga. Isso interessa a um órgão público que não quer mandar áudio para fora.
- Janela de contexto longa (32 mil tokens), o que permite trabalhar com áudios de dezenas de minutos de uma vez.
- Foi treinado também para **chamada de funções a partir de entrada de áudio**: um comando falado pode acionar uma ferramenta externa **direto**, sem transcrição separada.

Qwen2-Audio (Alibaba, 2024)

- Acopla um **codificador de áudio herdado do Whisper** a um **modelo de linguagem de grande porte**, que recebe as representações do áudio e gera texto.
- Tem dois usos: **conversa por voz** (o usuário fala e o modelo responde) e **análise de áudio** (o usuário manda um áudio e uma instrução em texto). O modelo **distingue sozinho** os dois usos, conforme o que recebe; **não é preciso prompt de sistema** para alternar.
- Foi refinado com **DPO** (*Direct Preference Optimization*, otimização direta de preferências).

O que é DPO. O modelo vê, para a mesma pergunta, **uma resposta preferida e outra não preferida** e aprende a se aproximar da preferida. A vantagem: **não precisa treinar um modelo de recompensa separado** (um "juiz" que dá notas), como acontece no método mais antigo de reforço com feedback humano.

GPT-4o (OpenAI, 2024)

- Foi **treinado de ponta a ponta com texto, imagem e áudio**: **todas as entradas e saídas passam pela mesma rede neural**.
- **Entradas**: texto, áudio, imagem e vídeo. **Saídas**: texto, áudio e imagem. Não é modelo "só de áudio para texto".
- **Latência**: responde a áudio em **até 232 milissegundos**, com **média de 320 milissegundos**, tempo semelhante ao da resposta humana numa conversa.

- É rápido **justamente porque não usa a fila** ASR → texto → síntese. Dizer que ele é rápido "porque transcreve primeiro com um modelo separado" é errado.

Cuidados descritos no System Card do GPT-4o (o documento em que a OpenAI expõe riscos e mitigações):

- **Inferência não fundamentada sobre quem fala**: o modelo foi pós-treinado para **recusar** pedidos como avaliar a **inteligência** ou a **ocupação** do falante só pela voz, porque o áudio não prova isso.
- **Atribuição de traços sensíveis**: pedidos como identificar o **sotaque** são atendidos, mas **com ressalvas** (respostas cautelosas, deixando claro que é uma impressão).
- **Geração de voz não autorizada**: além da **moderação sobre as transcrições textuais**, há um **classificador de saída que escuta o áudio gerado** e confere se a voz é uma das **vozes predefinidas aprovadas**; se não for, **bloqueia a saída**. Não depende só de filtros de texto.
- **Limite das avaliações**: testes feitos com **áudio sintetizado a partir de texto** podem não captar **entonação, ruído de fundo e fala simultânea**, que alteram o comportamento do modelo no uso real.

Moshi (Kyutai, 2024)

- Modelo de diálogo **de fala para fala**. Dispensa a cadeia tradicional **VAD → ASR → diálogo em texto → síntese de voz**, que **acrescenta segundos de atraso** e **descarta sinais não verbais**, como a emoção.
- Opera em **full-duplex**: **ouve e fala ao mesmo tempo**, como numa conversa natural, e lida com interrupções e falas sobrepostas. **Não** é meio-duplex (em que um espera o outro terminar) e **não depende de delimitar turnos** de fala.

> **Dica:** meio-duplex é walkie-talkie ("câmbio"); full-duplex é telefone.

- **Monólogo interior** (*Inner Monologue*): antes de gerar os tokens de áudio, o Moshi **prevê tokens de texto alinhados no tempo**, uma espécie de rascunho interno do que vai dizer. Isso **melhora a qualidade da fala produzida**.
- Por ir direto de fala para fala, tem **latência menor** que os sistemas encadeados. Dizer que a cascata é mais rápida "porque cada etapa é especializada" é errado: os atrasos se somam.

AudioPaLM (Google, 2023)

- Une um modelo de linguagem de texto, o **PaLM-2**, a um modelo de fala, o **AudioLM**, numa **única arquitetura**.
- Preserva **informações paralinguísticas**, como a **identidade do falante** e a **entonação**.
- Os autores mostraram que **partir dos pesos de um modelo de texto já treinado** melhora o desempenho de fala, em comparação com começar de **pesos aleatórios**. O conhecimento da língua aprendido em textos é reaproveitado.
- Faz **tradução de fala para texto em modo zero-shot** em muitos pares de idiomas **que não estavam no treinamento**.

Gemini: compreensão de áudio pela API

A documentação do Gemini (Google) traz várias regras práticas:

- **Tokens por duração.** O áudio é convertido em tokens a uma **taxa fixa por segundo** (32 tokens por segundo). O consumo de contexto e o custo crescem **na proporção da duração**. O que conta é o **tempo**, não as palavras: **um minuto de silêncio gasta tantos tokens quanto um minuto de discurso**.
- **Envio de arquivos grandes.** Áudio pequeno pode ir **embutido** (*inline*) no próprio pedido, mas o envio embutido tem **limite de tamanho**. Áudio grande deve ser enviado por um **serviço de arquivos** e apenas **referenciado** na requisição.
- **Canais misturados.** Se o áudio tiver vários canais (por exemplo, um microfone por canal), o Gemini **combina todos em um só**. A separação por canal **se perde**; não dá para contar com ela para saber quem falou.
- **Redução de qualidade.** O Gemini **reduz o áudio para 16 Kbps** antes de processar. O que ele "escuta" não é idêntico ao arquivo original.
- **Capacidades declaradas**: **transcrever** fala, **identificar diferentes falantes**, **detectar emoções** e analisar **trechos específicos** por marcações de tempo no formato **MM:SS** (ex.: "o que é dito entre 02:30 e 03:10?"). Capacidade não é garantia de acerto.
- **Sons não verbais**: entende também sons que não são fala, como **canto de pássaros e sirenes**.
- **Tempo real**: para **transcrição de voz em tempo real**, a própria documentação de compreensão de áudio recomenda o **Google Cloud Speech-to-Text**, não ela mesma. A compreensão de áudio é voltada a arquivos gravados.

Gemini Live API (conversa em tempo real)

A **Live API** é a parte do Gemini para conversas ao vivo por voz.

- **Modalidade de resposta.** Os modelos de **áudio nativo** aceitam **apenas resposta em áudio**. Para ter o texto, é preciso **habilitar a transcrição do áudio de saída**.
- **Formato de entrada.** A API pede **áudio cru, em PCM** (o formato "sem compressão" do som, de 16 bits). **Não** aceita qualquer formato compactado como MP3; quem desenvolve o sistema precisa converter.
- **Detecção automática de atividade de voz (VAD)**: vem **habilitada por padrão**. Quando o usuário **interrompe** o modelo, a **geração em andamento é cancelada**.
- **Duração da sessão**: as sessões **têm tempo máximo**. Uma sessão plenária longa exige que a aplicação **gerencie a sessão** (renove a conexão, retome a sessão, comprima o contexto). Não duram indefinidamente.
- **Vocabulário personalizado** na transcrição de entrada: dá para informar uma lista de termos, recurso semelhante às **listas de frases** de outros serviços de ASR. **Listas curtas e focadas** funcionam **melhor** do que listas muito extensas.
- **Áudio proativo**: permite ao modelo **não responder** ao que for **irrelevante** para a conversa (ficar quieto quando a fala não é com ele). Não obriga a responder a tudo.
- **Diálogo afetivo** (*affective dialog*): o modelo **percebe a expressão e o tom do usuário** e **adapta o estilo da resposta**. Não é para manter um tom sempre neutro.

Alucinação: o risco principal no registro oficial

Modelos que geram texto de forma **autorregressiva** a partir do áudio (palavra por palavra, cada uma dependendo das anteriores), como o **Whisper** e os LLMs de áudio, podem **inserir trechos que não foram falados**. Quando o produto é um **registro oficial**, é obrigatório **conferir o texto com o áudio**.

O estudo **Careless Whisper** (Koenecke et al., FAccT 2024) analisou alucinações do Whisper e observou que elas eram **mais frequentes nas falas de pessoas com afasia** (distúrbio de linguagem), **associadas a pausas longas e períodos sem vocalização**. Conclusão: os riscos do sistema **recaem de modo desigual** sobre grupos de falantes. Dizer que as alucinações foram uniformes entre os grupos é errado.

A experiência da Câmara dos Deputados

Em apresentação à **ParlAmericas**, em **2026**, a Câmara relatou:

- **Primeira adesão** à transcrição automática: **2023**, com a **Azure** (Microsoft). Não foi com a Amazon (AWS).
- **Motor atual**: o **Whisper large-v3**, integrado ao sistema interno **Escriba**.
- Nos testes, a **WER média foi de cerca de 25%**, com **grande variação conforme o contexto**: de **8% a 50%**.
- **Todo texto transcrito passa por revisão humana obrigatória** dos analistas de registro e redação. A automação **apoia, mas não substitui** a redação humana qualificada.

Quadros para memorizar

Cascata x áudio nativo

	Cascata (encadeado)	Áudio nativo
Caminho	VAD → ASR → LLM de texto → síntese de voz	Áudio direto no modelo
Latência	Maior (atrasos se somam)	Menor
Tom, emoção, ênfase	Perdidos em grande parte	Preservados
Texto intermediário	Existe; dá para inspecionar e guardar antes da resposta	Não necessariamente
Quando usar	Etapas precisam ser visíveis ou substituíveis	Conversa natural, rápida

Arquitetura típica

Peça	Função	Detalhe cobrado
Codificador de áudio	Transforma som em representações	Muitas vezes herdado do Whisper (Voxtral, Qwen2-Audio)
Adaptador	Encurta a sequência e ajusta o formato	Reduz, não aumenta, os quadros por segundo

Peça	Função	Detalhe cobrado
Decodificador de linguagem (LLM)	Lê as representações como entrada e gera texto	Limite de áudio = janela de contexto ÷ tokens por segundo

Modelos e marcas registradas

Modelo	Empresa e ano	O que cai
Voxtral	Mistral AI, 2025	Codificador do Whisper + adaptador + LLM; Apache 2.0 (roda em casa); chamada de funções por voz
Qwen2-Audio	Alibaba, 2024	Codificador do Whisper + LLM; conversa por voz e análise de áudio sem prompt de sistema; DPO
GPT-4o	OpenAI, 2024	Uma rede para texto, imagem e áudio; entra texto, áudio, imagem, vídeo; sai texto, áudio, imagem; 232 ms (mínimo) e 320 ms (média)
Moshi	Kyutai, 2024	Fala para fala; full-duplex; monólogo interior (texto alinhado antes do áudio)
AudioPaLM	Google, 2023	PaLM-2 + AudioLM; preserva identidade e entonação; partir de modelo de texto ajuda; tradução zero-shot
Whisper large-v3	OpenAI	Motor atual da Câmara, no Escriba

Gemini: regras da API

Ponto	Regra
Tokens	Taxa fixa por segundo de áudio; silêncio também gasta
Áudio grande	Serviço de arquivos + referência; inline tem limite de tamanho
Vários canais	Misturados em um só
Qualidade	Reduzida para 16 Kbps
Capacidades	Transcrever, separar falantes, emoções, trechos por MM:SS, sons não verbais
Tempo real	Recomenda o Google Cloud Speech-to-Text
Live API: saída	Modelos de áudio nativo só respondem em áudio; texto via transcrição da saída
Live API: entrada	PCM cru, não MP3
Live API: VAD	Ligado por padrão; interrupção cancela a geração
Live API: sessão	Tem duração máxima; a aplicação gerencia
Live API: vocabulário	Lista personalizada; curta e focada é melhor
Áudio proativo	Pode ignorar o irrelevante
Diálogo afetivo	Adapta-se ao tom do usuário

Câmara dos Deputados (apresentação à ParlAmericas, 2026)

Ponto	Fato
Primeira adesão	2023, Azure (Microsoft)
Motor atual	Whisper large-v3
Sistema interno	Escriba
WER média nos testes	~25% (de 8% a 50%, conforme o contexto)
Revisão	Humana obrigatória, por analistas de registro e redação

Conceitos e autores que caem

- **LLM** (*Large Language Model*): modelo de linguagem de grande porte.
- **Multimodal**: que trabalha com mais de um tipo de dado (texto, áudio, imagem, vídeo).
- **Áudio nativo**: o modelo recebe o áudio direto, sem transcrição prévia.
- **Informação paralinguística**: o que vai além das palavras: entonação, ênfase, emoção, identidade do falante.
- **Cascata / arquitetura encadeada**: ASR → LLM → TTS (com VAD antes).
- **VAD** (*voice activity detection*): detecção de quando há fala.
- **TTS** (*text-to-speech*): síntese de voz a partir de texto.
- **Codificador, adaptador, decodificador**: as três peças do modelo de áudio-linguagem.
- **Janela de contexto**: quantos tokens o modelo considera de uma vez.
- **Chamada de funções** (*function calling*): o modelo aciona ferramentas externas.
- **DPO** (*Direct Preference Optimization*): aprende com pares resposta preferida x não preferida, sem modelo de recompensa separado.
- **Full-duplex x meio-duplex**: falar e ouvir ao mesmo tempo x um de cada vez.
- **Monólogo interior** (*Inner Monologue*, Moshi): tokens de texto alinhados no tempo antes dos de áudio.
- **Zero-shot**: fazer uma tarefa (ou par de idiomas) sem exemplos dela no treino.
- **PCM**: áudio cru, sem compressão.
- **System Card**: documento em que a empresa descreve riscos e mitigações do modelo.
- **Alucinação**: texto que não corresponde ao áudio.
- **Careless Whisper** (Koenecke et al., FAccT 2024): alucinações do Whisper mais frequentes em falantes com afasia, ligadas a pausas longas.
- **ParlAmericas**: rede de parlamentos das Américas, onde a Câmara apresentou sua experiência em 2026.
- **Escriba**: sistema interno da Câmara que recebe a transcrição automática.

Pegadinhas da banca

- **"Áudio nativo exige ASR independente antes."** Errado: isso é a cascata.
- **"Áudio nativo sempre transcreve literalmente; dispensa cautela."** Errado: pode reescrever, resumir e alucinar.
- **"O adaptador alonga a sequência."** Errado: encurta.
- **"O codificador do Voxtral foi treinado do zero, sem relação com o Whisper."** Errado: vem do Whisper.
- **"Voxtral é proprietário, só por API paga."** Errado: Apache 2.0, roda em infraestrutura própria.
- **"Voxtral não chama funções a partir do áudio."** Errado: foi treinado para isso.
- **"No Qwen2-Audio é preciso prompt de sistema para trocar de modo."** Errado: o modelo distingue sozinho.
- **"GPT-4o aceita só áudio e produz só texto."** Errado: texto, áudio, imagem e vídeo na entrada; texto, áudio e imagem na saída.
- **"GPT-4o é rápido porque transcreve com modelo separado e sintetiza com outro."** Errado: uma rede só.
- **"GPT-4o atende sem ressalvas a pedidos sobre inteligência ou ocupação do falante."** Errado: recusa.
- **"A prevenção de voz não autorizada depende só de filtros de texto."** Errado: há um classificador que analisa o áudio gerado.
- **"Moshi é meio-duplex e depende de turnos."** Errado: full-duplex.
- **"A cascata tem latência menor que o Moshi."** Errado: os atrasos somam.
- **"AudioPaLM vai melhor começando de pesos aleatórios."** Errado: partir do modelo de texto ajuda.
- **"Gemini cobra tokens pelas palavras; silêncio não gasta."** Errado: cobra pela duração.
- **"Gemini preserva os canais separados."** Errado: mistura em um.
- **"Gemini preserva a resolução original do áudio."** Errado: reduz para 16 Kbps.
- **"Gemini ignora sons não verbais."** Errado: entende pássaros, sirenes etc.
- **"Para tempo real, use a compreensão de áudio do Gemini."** Errado: a documentação indica o Cloud Speech-to-Text.
- **"Live API aceita MP3 e ajusta sozinha."** Errado: exige PCM.
- **"Sessões da Live API duram indefinidamente."** Errado: têm limite.
- **"Áudio proativo obriga a responder a tudo."** Errado: permite ignorar o irrelevante.
- **"Diálogo afetivo mantém tom neutro."** Errado: adapta-se ao tom do usuário.
- **"Na cascata, a transcrição só existe depois da síntese."** Errado: é o primeiro passo.
- **"Câmara começou com a AWS em 2023."** Errado: Azure.
- **"A automação substituiu a redação humana na Câmara."** Errado: revisão humana obrigatória.
- **"No Careless Whisper as alucinações foram uniformes."** Errado: mais frequentes em falantes com afasia.

Itens comentados

- **Item:** Os LLMs multimodais de áudio nativo necessitam, obrigatoriamente, converter o áudio em texto por meio de um módulo de ASR independente antes de qualquer raciocínio sobre o conteúdo falado. **Errado.** Converter antes é a cascata. O modelo nativo processa o áudio diretamente.
- **Item:** Um LLM multimodal de áudio nativo recebe o áudio diretamente e o processa sem etapa prévia de transcrição, preservando informação paralinguística que o encadeamento de ASR seguido de LLM em grande parte descarta. **Certo.** É a definição: áudio direto, com tom, ênfase e emoção preservados.
- **Item:** Em modelos de áudio-linguagem como o Voxtral, a camada adaptadora entre o codificador de áudio e o decodificador de linguagem aumenta a quantidade de quadros por segundo, alongando a sequência para que o decodificador receba mais detalhe acústico. **Errado.** O adaptador encurta a sequência, para caber no contexto e custar menos.
- **Item:** O Voxtral foi lançado com licença proprietária, disponível apenas por meio de API paga, o que impede a execução dos modelos em infraestrutura própria. **Errado.** A licença é Apache 2.0, aberta; os modelos podem rodar em servidores próprios.
- **Item:** No Qwen2-Audio, o usuário precisa informar um prompt de sistema para alternar entre o modo de conversa por voz e o modo de análise de áudio, pois o modelo não distingue sozinho esses dois usos. **Errado.** O modelo distingue sozinho os dois usos, sem prompt de sistema.
- **Item:** Segundo o System Card do GPT-4o, o modelo pode responder a entradas de áudio em até 232 milissegundos, com média de 320 milissegundos, tempo semelhante ao da resposta humana em uma conversa. **Certo.** São os números do System Card.
- **Item:** O Moshi opera em regime de meio-duplex, em que o sistema só fala depois que o usuário conclui a sua vez, razão pela qual depende de uma delimitação explícita dos turnos de fala. **Errado.** O Moshi é full-duplex: ouve e fala ao mesmo tempo.
- **Item:** Na API do Gemini, o número de tokens consumidos por um áudio depende da quantidade de palavras faladas, de modo que trechos longos de silêncio não consomem contexto. **Errado.** Os tokens são calculados por segundo de áudio; o silêncio também consome.
- **Item:** Ao receber áudio com vários canais, o Gemini preserva a separação entre eles, o que permite atribuir cada canal a um falante diferente sem qualquer pós-processamento. **Errado.** O Gemini combina os canais em um só.
- **Item:** Na Live API do Gemini, os modelos de áudio nativo aceitam apenas a modalidade de resposta em áudio, de modo que, para obter texto, é preciso habilitar a transcrição do áudio de saída. **Certo.** A resposta é em áudio; o texto vem pela transcrição da saída.
- **Item:** Na arquitetura encadeada de agentes de voz, não é possível armazenar a transcrição antes de o agente responder, pois o texto só passa a existir depois da síntese da resposta em voz. **Errado.** A transcrição é o primeiro passo da cadeia; existe antes da resposta e pode ser guardada.

- **Item:** Segundo a apresentação da Câmara dos Deputados à ParlAmericas, a primeira adesão à transcrição automática, em 2023, foi feita por meio dos serviços da Amazon Web Services. **Errado.** A primeira adesão foi com a Azure, da Microsoft. Hoje o motor é o Whisper large-v3.
- **Item:** No estudo Careless Whisper, as alucinações do Whisper ocorreram de maneira uniforme entre os grupos de falantes, inclusive os com afasia, sem associação com características da fala, como longos períodos sem vocalização. **Errado.** Foram mais frequentes em falantes com afasia, ligadas a pausas longas.
- **Item:** Para transcrição de voz em tempo real, a documentação do Gemini API de compreensão de áudio recomenda a própria API de compreensão de áudio, e não o Google Cloud Speech-to-Text. **Errado.** A documentação recomenda o Google Cloud Speech-to-Text para tempo real.

Resumo para revisar

- Áudio nativo: o modelo ouve o áudio direto, sem transcrição prévia, e preserva tom, ênfase, emoção e identidade do falante.
- Cascata: VAD → ASR → LLM → TTS; atrasos somados e perda do paralinguístico; útil quando cada etapa precisa ser visível ou substituível; a transcrição vem primeiro e pode ser guardada.
- Para avaliar agente de voz: salvar áudio, eventos, resultados de ferramentas e estado da aplicação.
- Áudio nativo não é literal: pode reescrever, resumir e alucinar; registro oficial exige conferência.
- Arquitetura: codificador de áudio (muitas vezes do Whisper) + adaptador (encurta) + LLM.
- Duração máxima do áudio depende da janela de contexto e dos tokens por segundo.
- Voxtral: Mistral, codificador do Whisper, Apache 2.0, roda em casa, chama funções pela voz.
- Qwen2-Audio: Alibaba, codificador do Whisper, dois modos sem prompt de sistema, DPO.
- DPO: pares preferida x não preferida, sem modelo de recompensa separado.
- GPT-4o: uma rede para texto, imagem e áudio; entrada texto, áudio, imagem e vídeo; 232 ms mínimo, 320 ms média.
- System Card do GPT-4o: recusa inferir inteligência ou ocupação; responde sotaque com ressalvas; classificador de voz aprovada sobre o áudio + moderação do texto; testes com voz sintética não captam ruído, entonação e fala simultânea.
- Moshi: Kyutai, fala para fala, full-duplex, monólogo interior, latência menor que a cascata.
- AudioPaLM: Google, PaLM-2 + AudioLM, preserva voz e entonação, partir de modelo de texto ajuda, tradução zero-shot.
- Gemini: tokens por segundo (silêncio gasta), arquivo grande pelo serviço de arquivos, canais misturados, 16 Kbps, entende sons não verbais, trechos por MM:SS.
- Gemini para tempo real: Cloud Speech-to-Text.
- Live API: resposta só em áudio nos modelos nativos (texto via transcrição da saída), PCM, VAD ligado e interrupção cancela, sessão com limite, vocabulário curto e focado, áudio proativo ignora o irrelevante, diálogo afetivo adapta o tom.
- Careless Whisper: alucinações desiguais, mais em falantes com afasia e pausas longas.

- Câmara: Azure em 2023; hoje Whisper large-v3 no Escriba; WER média ~25% (8% a 50%); revisão humana obrigatória.

TEMA 3 DE 20

Diarização: identificação e separação de oradores

56 perguntas no app · Reconhecimento de fala

O que cai

O edital pede "Diarização de falantes: identificação e separação de múltiplos oradores". As perguntas deste tema cobram:

- **O conceito**: diarização responde a **"quem falou quando"** com **rótulos anônimos** (Falante 1, Falante 2). Ela **não descobre o nome** de ninguém. A pegadinha campeã é trocar diarização por **identificação de falante**.
- **O pipeline por agrupamento**: detecção de atividade de voz → segmentação → **embeddings de voz** → **agrupamento** (clustering). Agrupa-se pela **voz**, nunca pelo **assunto** do que foi dito.
- **Sobreposição de falas**: sistemas clássicos dão um rótulo por trecho e perdem uma das vozes; sistemas neurais mais novos conseguem marcar dois falantes no mesmo instante.
- **A métrica DER**: falso alarme + detecção perdida + confusão de falantes, divididos pela duração total da fala. Não confundir com a WER.
- **Ferramentas**: pyannote 3.1 e community-1 (16 kHz mono, num_speakers, RTTM, token do Hugging Face, CC-BY-4.0), Google (min_speaker_count, último resultado), Amazon (até 30 falantes, spk_0 a spk_29, identificação de canais), Azure (Guest-1, lote só em mono), Whisper (não faz diarização).
- **Tempo real**: menos preciso, falante "desconhecido" no começo.

Entenda o tema

O que é diarização

Diarização de falantes (*speaker diarization*) é a tarefa de **dividir o áudio em segmentos e atribuí-los a cada falante**, respondendo à pergunta **"quem falou quando"**. O resultado são **rótulos anônimos**: Falante 1, Falante 2, Falante 3.

A diarização **não revela a identidade real** de cada voz. Ela sabe que o trecho de 0 a 12 segundos e o de 40 a 55 segundos são da **mesma pessoa**, mas não sabe **quem** é essa pessoa. Para descobrir que o "Falante 2" é a Deputada Fulana, é preciso **informação adicional**: a lista de oradores inscritos, o roteiro da sessão, o vídeo, ou outra ferramenta.

> **Exemplo:** na reunião da comissão, o sistema entrega: "Falante 1 (00:00–02:10), Falante 2 (02:10–05:30), Falante 1 (05:30–06:00)". O revisor, olhando a lista de oradores, conclui que o Falante 1 é o presidente da comissão e o Falante 2, o Deputado Marcos Lima, primeiro inscrito.

Diarização x identificação de falante

São tarefas diferentes, e a banca adora trocá-las:

- **Diarização**: **separa e numera** as vozes. Não usa cadastro de voz. Resultado anônimo.
- **Identificação de falante** (*speaker identification*): **compara a voz com vozes previamente cadastradas** para dizer **quem é** a pessoa. Precisa de um "modelo de voz" de cada pessoa registrado antes.

> **Pegadinha:** "A diarização confirma, a partir de modelo de voz cadastrado, a identidade do parlamentar; a identificação de falante apenas agrupa em rótulos anônimos." Errado: os conceitos estão trocados.

Identificação de canais x diarização

Outra confusão possível. Às vezes cada pessoa está num **canal separado** da gravação (por exemplo, numa ligação telefônica gravada em estéreo, cliente num canal e atendente no outro, ou cada microfone gravado numa faixa).

- **Identificação de canais** (*channel identification*): **transcreve separadamente cada canal** de uma gravação multicanal. Não precisa analisar a voz: a separação **já veio pronta** pelos canais. No Amazon Transcribe, cada canal é transcrito de forma independente e os resultados são **reunidos numa só transcrição**; se pessoas em canais diferentes falam ao mesmo tempo, **os tempos de cada canal se sobrepõem** no resultado, sem que uma voz apague a outra.
- **Diarização** (no Amazon, "particionamento de falantes"): **separa vozes misturadas em um mesmo canal**, pela **análise das características da voz**.

São **recursos distintos**, com usos diferentes.

O pipeline clássico: diarização por agrupamento

A diarização tradicional segue quatro etapas, nesta ordem:

1. **Detecção de atividade de voz** (VAD, *voice activity detection*): é o **primeiro passo**. **Separa a fala do silêncio e do ruído**. Não dá nome a ninguém.
2. **Segmentação**: corta a fala em trechos e **detecta quando há fala e quando muda o falante** (os pontos de troca).
3. **Extração de embeddings de voz**: cada trecho é convertido num **embedding de voz**, um **vetor (lista de números) que resume as características da voz** daquele trecho: timbre, altura, jeito de soar. É como uma **"impressão digital" da voz**.
4. **Agrupamento** (*clustering*): os embeddings **semelhantes são reunidos**, formando **um grupo por falante**. Cada grupo recebe um **rótulo anônimo**.

O ponto que a banca explora: o agrupamento é feito pelas **características acústicas da voz**, e **não pelo conteúdo das palavras**. A diarização **não transcreve** os trechos para comparar textos. Dois deputados falando do mesmo tema continuam sendo **dois falantes**; o mesmo deputado mudando de assunto continua sendo **um falante**. Separar por **tema** seria outra tarefa, feita sobre o texto.

> **Pegadinha:** "Cada trecho é convertido em texto pelo ASR e os textos de conteúdo semelhante são reunidos, um grupo por falante." Errado: agrupa-se pela voz. E "cada grupo corresponde a um tema" também é errado: cada grupo é uma **pessoa**.
>
> **Dica:** pense num funcionário separando cartas por **letra** (caligrafia), sem ler o conteúdo. Ele sabe que as cartas do monte 1 foram escritas pela mesma mão, mas não sabe de quem é a mão. Isso é a diarização.

Sobreposição de falas (fala simultânea)

Quando duas pessoas falam **ao mesmo tempo** (apartes, interrupções), a diarização sofre.

- **Sistemas clássicos** dão **um único rótulo por trecho**. Na sobreposição, **uma das vozes tende a ser perdida ou atribuída de forma errada**.
- **Sistemas neurais mais novos** conseguem **tratar a sobreposição** e marcar **dois falantes no mesmo instante**.

Por isso é errado dizer que "**nenhuma** abordagem consegue atribuir mais de um falante ao mesmo instante" ou que a sobreposição "**sempre**" se resolve com um único rótulo.

A sobreposição também **atrapalha o reconhecimento das palavras** (os sons se misturam). Em reuniões com **muitos apartes**, a **revisão humana dos rótulos** de falante continua **necessária**. Concluir que ela é dispensável porque "a diarização acerta inclusive os trechos sobrepostos" é errado.

Diarização em tempo real

Na diarização **ao vivo**, o sistema precisa atribuir o falante **sem conhecer o áudio futuro**. Na gravação completa, ele pode olhar o áudio todo antes de decidir. Por isso a diarização em tempo real **tende a ser menos precisa**.

Além disso, ao vivo, o sistema **precisa ouvir certa quantidade de fala** para distinguir uma voz. Nos **primeiros resultados intermediários**, o falante pode aparecer como **ainda não identificado** (desconhecido). Dizer que a identidade do falante é "sempre determinada com certeza desde a primeira palavra" é errado.

A métrica DER

A **DER** (*Diarization Error Rate*, taxa de erro de diarização) mede o quanto a diarização errou, **em tempo**, e não em palavras.

DER = (falso alarme + detecção perdida + confusão de falantes) / **duração total da fala** na gravação.

Os três erros:

- **Falso alarme**: o sistema **detecta fala onde não há fala** (só silêncio ou ruído).
- **Detecção perdida** (*missed detection*): o sistema **deixa de detectar um trecho de fala**. Inclui a **fala simultânea em que só uma das duas pessoas é detectada**: a voz que ficou de fora conta como **detecção perdida**.

- **Confusão de falantes**: a fala **foi detectada**, mas foi **atribuída à pessoa errada**.

Quanto **menor** a DER, melhor.

> **Pegadinha:** "A confusão de falantes é o erro em que o sistema deixa de detectar um trecho." Errado: isso é **detecção perdida**. Confusão é detectar e pôr na conta da pessoa errada.
>
> **Atenção: DER ≠ WER**. A WER conta **palavras** inseridas, omitidas e substituídas, dividindo pelas palavras da referência. A DER conta **tempo** de fala mal atribuído.

pyannote: a ferramenta aberta mais conhecida

O **pyannote** é uma biblioteca aberta (pyannote.audio) com pipelines prontos de diarização, distribuídos pelo **Hugging Face** (um site que hospeda modelos de IA).

pyannote/speaker-diarization-3.1

- **Etapas**: combina **segmentação** (detecta quando há fala e quando muda o falante) e **extração de embeddings** de voz (para agrupar os trechos de um mesmo falante).
- **Formato do áudio**: trabalha com **áudio monofônico** (um canal) **de 16 kHz**. Arquivos **estéreo ou multicanal** têm os canais **combinados em um só pela média**; arquivos com outra taxa de amostragem são **reamostrados para 16 kHz** ao serem carregados. Ele **não** exige estéreo nem um canal por orador: separa pela semelhança das vozes.
- **Número de falantes**:
- se for **conhecido**, informa-se pelo parâmetro **num_speakers**;
- se só se conhece **uma faixa**, usam-se **min_speakers** e **max_speakers**;
- **sem esses parâmetros**, o pipeline **estima sozinho** a quantidade de falantes. Informar é opcional.
- **Saída**: um objeto **Annotation**, que pode ser gravado no formato **RTTM** (um arquivo de texto padrão com linhas "falante X, começa em t, dura d"). Associa **trechos de tempo a rótulos de falante**. **Não contém o texto** das falas: o texto depende de um **sistema de ASR**, e depois é preciso **juntar** os dois resultados.
- **Acesso**: não basta instalar o pyannote.audio. É preciso **aceitar as condições de uso** dos modelos **pyannote/segmentation-3.0** e **pyannote/speaker-diarization-3.1** no Hugging Face e **criar um token de acesso**, que é informado ao carregar o pipeline.
- **Avaliação publicada**: os números de DER divulgados no cartão do modelo foram obtidos de forma **totalmente automática**: **sem** detecção de atividade de voz feita à mão, **sem** informar o número de falantes e **sem** ajuste fino do pipeline para cada base de dados.

pyannote/speaker-diarization-community-1

- Além da diarização usual, oferece a saída **exclusive_speaker_diarization**, que, segundo o cartão do modelo, **facilita a correspondência entre as marcas de tempo dos falantes e as da transcrição**. Ela **não escreve texto** nem atribui dois rótulos a cada palavra: só entrega a divisão por falante num formato mais fácil de casar com uma transcrição já existente (um falante por vez).

- Licença **CC-BY-4.0**: permite usar à vontade, mas **exige atribuir a autoria** aos criadores. Licença aberta não significa ausência de obrigações.

Google Cloud Speech-to-Text

- Na configuração da diarização, devem ser definidos **min_speaker_count** e **max_speaker_count de acordo com o número de falantes esperado**. O serviço não ignora esses campos.
- Os resultados são **cumulativos**: o **array words do último resultado** traz a **transcrição completa já diarizada**, com a **etiqueta de falante em cada palavra**. É dele que se deve ler quem falou. Os **resultados parciais não** trazem as etiquetas completas.

Amazon Transcribe

- Na diarização (particionamento de falantes), diferencia **no máximo 30 falantes**, rotulados de **spk_0 a spk_29**. (Não são 10 falantes nem rótulos "speaker_1".)
- Se o **número máximo de falantes** informado for **menor que o real**, o serviço **não recusa** a tarefa: ele **agrupa vozes diferentes sob o mesmo rótulo**, o que prejudica a atribuição das falas. O erro passa despercebido se ninguém revisar.
- Tem também a **identificação de canais**, recurso distinto da diarização (ver acima).

Azure AI Speech (Microsoft)

- No **reconhecimento em tempo real**, os falantes são identificados como **Guest-1, Guest-2** e assim por diante: **identificadores genéricos** atribuídos pelo serviço, **não o nome** das pessoas, e **sem consultar cadastro de voz**.
- Nos primeiros resultados intermediários, o falante pode aparecer como **desconhecido** até o sistema ouvir fala suficiente.
- Na **transcrição em lote** (*batch*), a diarização funciona em **gravações monocanal** com várias vozes. **Não** está disponível para gravações **estéreo**.
- Informar a **faixa esperada de falantes** (mínimo e máximo) **ajuda o agrupamento**, especialmente em **reuniões com vários participantes**. Dizer apenas que "há mais de uma voz" é pouco nesse caso.

> **Dica:** em todos os serviços vale a mesma lógica: dizer ao sistema quantas pessoas devem falar ajuda; dizer um máximo **menor** que o real faz vozes diferentes se fundirem num rótulo só.

Whisper não faz diarização

O **repositório oficial do Whisper** lista como tarefas: **reconhecimento de fala multilíngue**, **tradução de fala**, **identificação do idioma** e **detecção de atividade de voz**. **Diarização não está na lista**. Para separar quem fala, combina-se o Whisper com outra ferramenta (como o pyannote).

No Parlamento: a voz sozinha não diz quem é o parlamentar

Segundo descrição publicada pelo **Senado Federal em 2021**, no Plenário **um revisor munido de tablet monta o roteiro da sessão**, com as **fases** e **o parlamentar que tem a palavra**, e o sistema **Escriba combina essas informações com o áudio, o vídeo e o cadastro de parlamentares**. É a

ilustração prática da regra: a diarização separa vozes, mas o **nome** vem de informação externa (roteiro, lista de oradores, cadastro).

Quadros para memorizar

Diarização x tarefas parecidas

Tarefa	Pergunta que responde	Usa cadastro de voz?	Resultado
Diarização	Quem falou quando?	Não	Falante 1, Falante 2 (anônimos)
Identificação de falante	Quem é esta pessoa?	Sim	Nome da pessoa
Identificação de canais	O que foi dito em cada canal?	Não	Uma transcrição por canal, reunidas
ASR	O que foi dito?	Não	Texto

Pipeline por agrupamento

Ordem	Etapa	O que faz
1	Detecção de atividade de voz	Separa fala de silêncio e ruído
2	Segmentação	Corta a fala e acha os pontos de troca de falante
3	Embeddings de voz	Vetor que resume a voz de cada trecho
4	Agrupamento (clustering)	Junta vozes parecidas: um grupo por falante, rótulo anônimo

DER

Erro	O que é
Falso alarme	Detecta fala onde não há
Detecção perdida	Não detecta fala existente (inclui a segunda voz não percebida na fala simultânea)
Confusão de falantes	Detecta, mas atribui à pessoa errada
Denominador	Duração total da fala

Ferramentas

Ferramenta	Pontos cobrados
pyannote 3.1	Mono 16 kHz (estéreo vira média; outra taxa é reamostrada); num_speakers ou min/max_speakers, ou estima sozinho; saída Annotation/RTTM sem texto; aceitar condições de segmentation-3.0 e speaker-diarization-3.1 + token; avaliação totalmente automática
pyannote community-1	exclusive_speaker_diarization facilita casar com os tempos da transcrição; licença CC-BY-4.0 (exige crédito)

Ferramenta	Pontos cobrados
Google Speech-to-Text	min_speaker_count e max_speaker_count conforme o esperado; rótulos completos no array words do último resultado
Amazon Transcribe	Até 30 falantes, spk_0 a spk_29; máximo menor que o real funde vozes (não recusa); identificação de canais é outro recurso
Azure AI Speech	Tempo real: Guest-1, Guest-2, falante desconhecido no início; lote: diarização só em mono, não em estéreo; faixa de falantes ajuda
Whisper	Não faz diarização (faz ASR, tradução, identificação de idioma, detecção de voz)

Conceitos e autores que caem

- **Diarização de falantes** (*speaker diarization*): "quem falou quando", com rótulos anônimos.
- **Identificação de falante**: compara a voz com cadastro para dizer quem é.
- **Identificação de canais** (*channel identification*): transcreve cada canal separadamente.
- **VAD** (*voice activity detection*): separa fala de silêncio e ruído; primeira etapa.
- **Segmentação**: detecta fala e mudança de falante.
- **Embedding de voz**: vetor que resume as características da voz.
- **Clustering (agrupamento)**: junta embeddings parecidos, um grupo por falante.
- **Sobreposição de falas** (fala simultânea): ponto fraco dos sistemas clássicos.
- **DER** (*Diarization Error Rate*): (falso alarme + detecção perdida + confusão) / duração da fala.
- **RTTM**: formato de arquivo padrão de saída de diarização (tempos e rótulos).
- **Annotation**: objeto de saída do pyannote.
- **Hugging Face**: site que hospeda modelos; exige aceite de condições e token para os modelos do pyannote.
- **CC-BY-4.0**: licença aberta que exige atribuição de autoria.
- **Mono / estéreo / multicanal**: um canal / dois canais / vários canais de áudio.
- **16 kHz**: 16 mil amostras do som por segundo (taxa de amostragem).
- **Guest-1, Guest-2** (Azure), **spk_0 a spk_29** (Amazon), **Falante 1, Falante 2** (genérico).

Pegadinhas da banca

- **Diarização e identificação de falante trocadas.** Diarização é anônima; identificação usa cadastro de voz.
- **"A diarização revela a identidade real e dispensa cruzar com dados da sessão."** Errado: dá só rótulos; o nome vem de outra fonte.
- **"A VAD é a última etapa e dá o nome real."** Errado: é a primeira etapa, e nenhuma etapa dá nome.

- **Agrupar por conteúdo do texto ou por tema.** Errado: agrupa pelas características acústicas da voz.
- **"Nenhuma abordagem atribui dois falantes ao mesmo instante."** Errado: os neurais mais novos atribuem.
- **"A sobreposição não afeta o reconhecimento das palavras."** Errado: afeta.
- **"Com diarização, a revisão dos rótulos é desnecessária mesmo com muitos apartes."** Errado: a sobreposição confunde os sistemas.
- **"Ao vivo, o falante é identificado com certeza desde a primeira palavra."** Errado: pode aparecer como desconhecido no início.
- **DER definida como erro de palavras.** Errado: isso é a WER; a DER é erro de tempo de fala.
- **Confusão de falantes definida como fala não detectada.** Errado: isso é detecção perdida.
- **"pyannote só aceita estéreo, um canal por orador."** Errado: trabalha em mono 16 kHz e converte o estéreo pela média.
- **"No pyannote é obrigatório informar num_speakers."** Errado: é opcional; ele estima sozinho.
- **"O pyannote devolve o texto já separado por orador."** Errado: devolve só tempos e rótulos.
- **"Basta instalar o pyannote.audio."** Errado: precisa aceitar condições de uso e criar token.
- **"exclusive_speaker_diarization transcreve falas simultâneas com dois rótulos por palavra."** Errado: não gera texto; só facilita o casamento com a transcrição.
- **"Licença CC-BY dispensa qualquer obrigação."** Errado: exige atribuição.
- **"A DER do pyannote 3.1 foi obtida informando o número de falantes e ajustando a cada base."** Errado: avaliação totalmente automática.
- **"O Google ignora min_speaker_count e max_speaker_count."** Errado: devem ser definidos.
- **"Cada resultado parcial do Google já traz todas as etiquetas."** Errado: vêm no último resultado.
- **"Amazon: no máximo 10 falantes, speaker_1, speaker_2."** Errado: 30 falantes, spk_0 a spk_29.
- **"Máximo de falantes menor que o real leva à recusa da tarefa."** Errado: o serviço funde vozes no mesmo rótulo.
- **"Identificação de canais e diarização são o mesmo recurso."** Errado: são distintos.
- **"Azure dá o nome real a partir de cadastro de voz."** Errado: Guest-1, Guest-2.
- **"Azure lote: diarização só em estéreo."** Errado: é o contrário; só em mono.
- **"Informar faixa de falantes atrapalha em reunião cheia."** Errado: ajuda.
- **"O Whisper faz diarização."** Errado: não está entre as tarefas do repositório oficial.

Itens comentados

- **Item:** A diarização de falantes tem por finalidade confirmar, a partir de modelo de voz previamente cadastrado, a identidade de um parlamentar; a identificação de falante, por sua vez, apenas agrupa as falas em rótulos anônimos. **Errado.** Os conceitos estão trocados: a diarização dá rótulos anônimos; a identificação de falante compara com vozes cadastradas.

- **Item:** Situação hipotética: Um sistema de transcrição de reuniões de comissão passou a rotular os trechos do áudio como “Falante 1”, “Falante 2” e assim por diante, respondendo à pergunta “quem falou quando”, sem conhecer os nomes dos participantes. Nessa situação, trata-se de diarização de falantes, e a associação de cada rótulo ao nome do parlamentar depende de informação adicional, como a lista de oradores da reunião. **Certo.** É exatamente a diarização; o nome vem de fonte externa.
- **Item:** Na diarização por agrupamento, a detecção de atividade de voz é a última etapa, responsável por atribuir o nome real do orador a cada grupo de embeddings. **Errado.** A detecção de atividade de voz é a primeira etapa, e nenhuma etapa atribui nome real.
- **Item:** Na diarização por agrupamento, cada trecho de fala é primeiro convertido em texto pelo ASR, e os textos de conteúdo semelhante são reunidos, formando um grupo por falante. **Errado.** O agrupamento é feito pelos embeddings de voz, isto é, pelas características acústicas, não pelo conteúdo.
- **Item:** Nenhuma abordagem de diarização é capaz de atribuir mais de um falante ao mesmo instante; por isso, a sobreposição de falas sempre se resolve com a escolha de um único rótulo por trecho. **Errado.** Os sistemas clássicos dão um rótulo por trecho, mas os neurais mais novos tratam a sobreposição.
- **Item:** A taxa de erro de diarização (DER) é calculada somando-se as durações dos erros de falso alarme, de detecção perdida e de confusão de falantes e dividindo-se o resultado pela duração total da fala existente na gravação. **Certo.** É a definição da DER.
- **Item:** Na DER, a confusão de falantes é o erro em que o sistema deixa de detectar um trecho de fala, inclusive quando duas pessoas falam ao mesmo tempo e apenas uma delas é detectada. **Errado.** Isso é detecção perdida. Confusão é atribuir fala detectada à pessoa errada.
- **Item:** O pipeline pyannote/speaker-diarization-3.1 só aceita arquivos estéreo, porque a separação dos falantes depende de haver um canal de áudio para cada orador; gravações em áudio monofônico precisam ser descartadas. **Errado.** O pipeline trabalha em mono 16 kHz e converte o estéreo pela média; separa pelas vozes, não pelos canais.
- **Item:** No pipeline pyannote 3.1, o usuário é obrigado a informar o número exato de falantes por meio de num_speakers, porque o pipeline não possui mecanismo para estimar a quantidade de vozes presentes na gravação. **Errado.** Informar é opcional; sem o parâmetro, o pipeline estima o número de falantes.
- **Item:** O pipeline pyannote 3.1 devolve diretamente a transcrição textual de cada fala, já separada por orador, o que dispensa a utilização de qualquer sistema de reconhecimento automático de fala. **Errado.** A saída é um Annotation (gravável em RTTM) com tempos e rótulos; o texto depende de um ASR.
- **Item:** O Amazon Transcribe diferencia, na diarização, no máximo 10 falantes distintos e identifica cada um por rótulos do tipo speaker_1, speaker_2 e assim por diante. **Errado.** São até 30 falantes, rotulados de spk_0 a spk_29.
- **Item:** Se a gravação tiver mais falantes do que o máximo informado ao serviço de diarização, o resultado é a recusa da tarefa, razão pela qual não há risco de vozes diferentes receberem o

mesmo rótulo. **Errado.** O serviço processa e agrupa vozes diferentes sob o mesmo rótulo.

- **Item:** Na transcrição em lote do Azure AI Speech, a diarização foi concebida para gravações estéreo, com uma voz em cada canal, e não está disponível para gravações monocanal. **Errado.** É o contrário: no lote, a diarização funciona em gravações monocanal e não está disponível para estéreo.
- **Item:** O repositório oficial do Whisper lista a diarização de falantes entre as tarefas do modelo, ao lado do reconhecimento de fala multilíngue, da tradução de fala e da identificação do idioma. **Errado.** A diarização não está entre as tarefas do Whisper; faz-se com outra ferramenta.

Resumo para revisar

- Diarização = "quem falou quando", com rótulos anônimos (Falante 1, Falante 2); não diz o nome.
- Identificação de falante compara com vozes cadastradas e diz quem é; não confundir.
- O nome do parlamentar vem de informação externa: lista de oradores, roteiro da sessão, cadastro.
- Pipeline: VAD (primeira etapa) → segmentação → embeddings de voz → clustering (um grupo por falante).
- Embedding de voz = vetor que resume a voz; agrupa-se pela voz, nunca pelo conteúdo ou tema.
- Clássicos: um rótulo por trecho; na sobreposição, uma voz se perde. Neurais novos: dois falantes no mesmo instante.
- Sobreposição atrapalha também as palavras; reuniões com apartes exigem revisão humana dos rótulos.
- Tempo real: sem áudio futuro, menos preciso; falante pode aparecer como desconhecido no início.
- DER = (falso alarme + detecção perdida + confusão) / duração total da fala. DER mede tempo; WER mede palavras.
- Falso alarme: fala onde não há. Detecção perdida: fala não detectada (inclui a segunda voz na simultânea). Confusão: pessoa errada.
- Identificação de canais: transcreve cada canal separado e reúne; tempos podem se sobrepor. Diarização: separa vozes num mesmo canal.
- pyannote 3.1: mono 16 kHz (estéreo pela média, reamostra), num_speakers ou min/max_speakers ou estimativa automática, saída Annotation/RTTM sem texto.
- pyannote: aceitar condições de segmentation-3.0 e speaker-diarization-3.1 no Hugging Face + token; DER publicada sem ajudas.
- community-1: exclusive_speaker_diarization facilita casar com a transcrição; CC-BY-4.0 exige crédito.
- Google: min_speaker_count e max_speaker_count; etiquetas completas no words do último resultado.
- Amazon: até 30 falantes, spk_0 a spk_29; máximo menor que o real funde vozes, sem recusa.

- Azure: Guest-1, Guest-2 em tempo real; lote só em mono; faixa de falantes ajuda em reuniões cheias.
- Whisper não faz diarização.
- Senado (2021): revisor com tablet monta o roteiro; o Escriba combina com áudio, vídeo e cadastro de parlamentares.

TEMA 4 DE 20

Pontuação automática e capitalização

58 perguntas no app · Reconhecimento de fala

O que cai

O edital pede "Pontuação automática e capitalização em transcrições". As perguntas deste tema cobram:

- **A ideia de fundo**: a **fala não tem pontuação** nem maiúsculas; pausa e entonação **não correspondem de forma exata** a vírgulas e pontos. Por isso a pontuação e a capitalização vêm de **pós-processamento** ou de **modelos específicos**, e o resultado **sempre exige revisão**.
- **As duas tarefas de pesquisa**: **restauração de pontuação** (rotular cada palavra com o sinal que vem depois) e **truecasing** (restaurar maiúsculas, dependente do contexto). Pistas **lexicais** e **prosódicas**.
- **Cascata x modelo que já pontua**: o Whisper aprendeu com texto bruto e já escreve com pontuação; modelos treinados no LibriSpeech, não.
- **Os serviços**: Google (pontuação desligada por padrão; ao ligar, também capitaliza; suporte por idioma; pontuação falada à parte), Azure (punctuationMode, padrão DictatedAndAutomatic; normalização inversa não configurável; forma lexical x de exibição; ditado; filtro de palavrões mascarado por padrão; segmentação semântica), Amazon (pontua sempre; números por idioma; pontuação como item próprio; vocabulário em tabela com DisplayAs), OpenAI (prompt).
- **Fidelidade do registro**: vírgula muda sentido, filtro de palavrões altera o que foi dito, confiança alta não garante acerto.

Entenda o tema

Por que a pontuação é um problema

Quando falamos, **não dizemos** "vírgula" nem "ponto", e não há letra maiúscula no som. Pontuação e capitalização **só existem na escrita**. Um reconhecedor de fala, em princípio, devolve uma sequência de palavras.

Seria tentador usar a **pausa** como vírgula e a **entonação** como ponto. Mas isso **não funciona de forma exata**:

- a gente **para para respirar no meio da frase**, onde não cabe vírgula;
- às vezes **emenda duas frases sem pausa**;
- a mesma subida de voz pode ser pergunta, ênfase ou hesitação.

Por isso a pontuação e a capitalização automáticas costumam ser tratadas como **pós-processamento** (uma etapa depois do reconhecimento) ou feitas por **modelos específicos de restauração**. E o resultado **continua exigindo revisão humana**.

> **Pegadinha:** "Como pausas e entonação correspondem de forma exata a vírgulas e pontos, a pontuação automática dispensa revisão." Errado nas duas partes.

A vírgula muda o sentido

A pontuação **não é enfeite**. Ela muda o significado:

- "**Não, espere.**" (peça para a pessoa esperar) x "**Não espere.**" (peça para não esperar).
- "O deputado, disse o líder, mentiu." x "O deputado disse: o líder mentiu."

Num registro oficial, uma vírgula fora do lugar pode atribuir a alguém o contrário do que disse. Por isso a pontuação da máquina precisa ser conferida antes da publicação.

Por que pontuar e capitalizar importa

Um texto corrido, sem sinais e sem maiúsculas:

- é **ruim de ler** (prejudica a **legibilidade**);
- atrapalha **tarefas posteriores** que usam a transcrição como entrada, como a **tradução automática**, a sumarização e a busca.

A documentação do Azure resume: a pontuação automática **melhora a clareza** do texto e é especialmente útil para a **leitura posterior de transcrições de chamadas e conversas**.

Duas formas de obter pontuação

1. **Em cascata**: um **modelo posterior ao reconhecimento** lê o texto e insere os sinais.
2. **Diretamente pelo modelo de reconhecimento**, quando ele foi **treinado com transcrições já pontuadas**. É o caso do **Whisper**.

Whisper. No artigo que o apresenta, os autores treinaram o modelo para prever o **texto bruto das transcrições**, **sem padronização significativa**. Como esses textos tinham vírgulas, pontos e maiúsculas, a saída do Whisper **costuma incluir pontuação e capitalização**, sem etapa extra. (O resultado ainda deve ser revisado.) Dizer que o Whisper foi treinado com texto todo em minúsculas e sem pontuação e que sempre depende de modelo externo é errado.

LibriSpeech. É o contrário. As transcrições desse corpus estão em **letras maiúsculas e sem pontuação**. Muitos modelos treinados com ele **produzem texto sem pontuação nem capitalização adequada** e **exigem pós-processamento**. O modelo escreve como aprendeu.

Restauração de pontuação

Na pesquisa, a **restauração de pontuação** costuma ser tratada como uma **tarefa de rotulagem**: o modelo percorre o texto e, para **cada palavra**, decide **qual sinal vem logo depois dela**: vírgula, ponto, interrogação ou **nenhum sinal**.

> **Exemplo:** "senhor | presidente | peço | a | palavra | é | possível" Rótulos: senhor (nada), presidente (vírgula), peço (nada), a (nada), palavra (ponto), é (nada), possível (interrogação). Resultado: "senhor presidente, peço a palavra. é possível?" (as maiúsculas ficam para o truecasing).

O modelo pode usar duas fontes de pistas:

- **Pistas lexicais**: as **próprias palavras** e o **contexto das palavras vizinhas**. Só lendo o texto já dá para prever muita coisa (depois de "senhor presidente" costuma vir vírgula).
- **Pistas prosódicas**: **pausas e entonação** da fala (a voz que sobe no fim de uma pergunta).

Os modelos podem **combinar** as duas. Dizer que a restauração **só** pode usar pistas acústicas e que o contexto textual é inútil está errado. Nenhuma das fontes acerta sozinha o tempo todo.

Os erros se propagam. O modelo de pontuação em cascata lê **justamente o texto que o reconhecedor escreveu**. Se uma palavra veio errada, o contexto muda e o sinal pode ir para o lugar errado. Os erros de uma etapa **passam para a seguinte**; o modelo de pontuação **não** opera de forma independente do texto reconhecido.

Truecasing (restauração de maiúsculas)

Truecasing é a tarefa de **restaurar a capitalização correta** das palavras em um texto que **perdeu essa informação**, como a saída de um reconhecedor que emite tudo em minúsculas (ou tudo em maiúsculas).

Truecasing não é pontuação. Truecasing mexe em **maiúsculas e minúsculas**; inserir vírgulas e pontos é a **restauração de pontuação**. As duas costumam andar juntas, mas são tarefas diferentes.

Depende do contexto. A mesma palavra pode pedir maiúscula num caso e minúscula em outro:

- "a **Câmara** dos Deputados" (nome de instituição) x "a **câmara** frigorífica" (objeto comum);
- "**Brasília**" (cidade) sempre com maiúscula, mas o sistema precisa reconhecer que é nome próprio.

Por isso a decisão **não depende só da própria palavra**: o sistema olha as palavras vizinhas.

Capitalização também é pós-processamento

A **capitalização automática** resulta de **pós-processamento** ou de **modelo específico**. Ela **não** é "ouvida" no sinal acústico: ninguém fala uma letra maiúscula. E o resultado **continua exigindo revisão**.

Pontuação automática x pontuação falada (ditado)

- **Pontuação automática**: o **modelo decide** onde vão os sinais.
- **Pontuação falada** ou **ditada**: o **orador diz em voz alta** o nome do sinal ("vírgula", "ponto de interrogação") e o sistema escreve o símbolo.

O modo de ditado serve para **quem dita** (um médico ditando laudo, alguém escrevendo e-mail por voz). **Não** serve para **discurso espontâneo de plenário**: deputado discursando não fala "vírgula".

Para discurso, a pontuação é **automática e conferida pelo revisor**.

Normalização inversa de texto

O reconhecedor ouve palavras: "seis e meia", "novecentos dólares", "dois mil e vinte e seis". A **normalização inversa de texto** (ITN, *inverse text normalization*) converte essas **formas faladas em formas escritas convencionais**: "6:30", "$900", "2026". É o caminho **inverso** da leitura em voz alta (que transforma "$900" em "novecentos dólares").

> **Atenção:** o sentido é **falado → escrito** (por extenso → dígitos e símbolos). Dizer que a normalização inversa transforma "$900" em "novecentos dólares" é inverter o sentido.

Google Cloud Speech-to-Text

- **Por padrão, não inclui pontuação** nos resultados. Para obtê-la, o desenvolvedor deve **habilitar a pontuação automática** na configuração da requisição.
- Com a pontuação automática **ligada**, o serviço, além de inserir os sinais, **capitaliza a primeira letra após cada ponto final e cada ponto de interrogação**.
- A pontuação automática **não está disponível em todos os idiomas**: é preciso **verificar o suporte por idioma** antes de contar com ela.
- A **pontuação falada** e a **pontuação automática** são tratadas em **documentação distinta**, e o suporte à pontuação falada é **listado por idioma e localidade**.
- **Adaptação de modelo**: ajuda o serviço a **reconhecer mais vezes palavras raras na linguagem geral**, como **nomes próprios e termos de domínios específicos**, por meio de **conjuntos de frases fornecidos pelo usuário**. Isso importa porque **nomes de órgãos e siglas de comissões** são justamente palavras **raras** na linguagem do dia a dia e tendem a ser **erradas** pelos sistemas. Não constam de dicionário geral e não dispensam adaptação.

Azure AI Speech (Microsoft)

punctuationMode (transcrição em lote). A propriedade admite quatro valores:

- **None**: sem pontuação;
- **Dictated**: só os sinais **ditados de forma explícita** pelo orador;
- **Automatic**: só a pontuação decidida pelo sistema;
- **DictatedAndAutomatic**: as duas juntas. **É o valor padrão.**

Logo, sem configuração adicional, o texto **vem pontuado**. Só quem escolhe None fica sem sinais.

Modelos que pontuam sozinhos. Quando o **próprio modelo de reconhecimento** gera a pontuação e a capitalização, **como o Whisper**, as opções de pontuação do serviço **não controlam** o resultado. Não dá, por exemplo, para exigir só pontuação ditada.

Normalização inversa. O Azure faz a normalização inversa de texto (por extenso → dígitos e símbolos) **por conta própria, sem possibilidade de configuração**: não se liga nem se desliga.

Texto de exibição (*display form*). É a forma arrumada, pronta para ler. Nela o serviço:

- insere **pontuação**;

- **capitaliza** as palavras que **iniciam frases** e os **nomes próprios** (pessoas, cidades);
- aplica a **normalização inversa**;
- pode **remover hesitações e repetições** ("hum", "é...") — o serviço oferece essa limpeza, então é errado dizer que as preserva sempre.

As formas do resultado.

- **Forma lexical**: as **palavras puras**, do jeito que foram reconhecidas, **sem pontuação nem capitalização**.
- **Forma de exibição**: a **arrumada**, com pontuação e capitalização.
- (Há ainda a forma **normalizada**.)

> **Pegadinha:** "A forma lexical inclui pontuação e capitalização, e a de exibição traz só as palavras." Errado: está trocado.

- A **saída simples** traz o texto de exibição e os tempos. A **saída detalhada** acrescenta as **formas lexical e normalizada** e as **alternativas** consideradas pelo reconhecedor.
- A **API de transcrição rápida** (*fast transcription*) produz **apenas a forma de exibição** (com pontuação e capitalização). A **transcrição em lote** pode devolver **também a forma lexical**.

Modo de ditado. No SDK de fala, o **modo de ditado** é ativado por **EnableDictation**, usado com o **reconhecimento contínuo**, e faz o serviço interpretar palavras como "ponto de interrogação" ou "vírgula" como **sinais de pontuação**. ("você tem certeza ponto de interrogação" → "Você tem certeza?")

Filtro de palavrões. O SDK tem três opções:

- **Masked** (mascarado): troca o palavrão por **asteriscos**. **É o padrão.**
- **Removed**: **remove** o palavrão.
- **Raw**: mantém a palavra **como foi dita**.

No registro oficial de debates, o filtro deve ser usado **com cautela**: alterar automaticamente o que foi dito **compromete a fidelidade** do registro. Tirar ou manter palavras é decisão editorial da Casa, não do sistema.

Segmentação semântica. No **reconhecimento contínuo**, a **segmentação semântica** fecha o resultado final, em geral, quando **detecta pontuação de fim de frase**, e não só quando há **pausa de silêncio**. Ela é indicada para o **reconhecimento contínuo** e **não** para reconhecimento de enunciado único nem para cenários interativos.

Amazon Transcribe

- **Pontua sempre**: adiciona pontuação **automaticamente em todos os idiomas** aceitos, sem precisar de parâmetro. E **capitaliza** as palavras nos idiomas cuja escrita **distingue maiúsculas de minúsculas**. (Diferente do Google, em que é preciso ligar.)
- **Números**: para **a maioria dos idiomas**, transcreve os números **por extenso**. Só **nos idiomas com suporte** à transcrição de números ela trata os números **conforme o contexto**, produzindo

horários, valores monetários e decimais em algarismos. Não vale para todos os idiomas.

- **Itens do resultado**: **cada palavra e cada sinal de pontuação** vem como um **item próprio** do resultado (os sinais têm tipo "pontuação"), com **pontuação de confiança** e **carimbos de tempo**. Isso permite **localizar no áudio** cada trecho do texto. Os sinais **não** são grudados à palavra anterior.
- **Resultados parciais em fluxo**: na transcrição em tempo real, os resultados provisórios vão sendo **refeitos** até se estabilizarem. **A pontuação também pode mudar** entre um resultado parcial e o seguinte (um ponto pode virar vírgula quando o orador continua a frase). Não é só a palavra que muda.
- **Confiança alta não é garantia.** Uma pontuação de confiança elevada quer dizer que o erro é **menos provável**, não **impossível**. A conferência humana continua necessária.
- **Vocabulário personalizado**: há dois formatos, **lista** e **tabela**. A **tabela** tem colunas como **Phrase** (como o termo é dito/escrito na entrada) e **DisplayAs** (como deve **aparecer na saída**), o que ajuda a **padronizar a grafia de siglas e nomes próprios**. A documentação recomenda a **tabela** para novos vocabulários; o formato de **lista** está sendo descontinuado e oferece menos controle.

OpenAI (API de fala para texto)

Segundo o guia de conversão de fala em texto da OpenAI, um **prompt** enviado junto com o áudio pode **orientar o modelo**: dar pistas de **nomes, siglas e estilo**, e ajudar a **preservar a pontuação, a capitalização e as palavras de preenchimento** ("hum", "né"). Não é garantia. O **idioma** vai em **campo à parte**; o prompt **não serve exclusivamente** para informar o idioma.

Avaliação: pontuação e maiúsculas na WER

Ao calcular a **taxa de erro de palavras** (WER), a prática comum é **normalizar** antes: tirar a **pontuação** e as **diferenças de maiúsculas**. Assim o sistema não é punido por detalhes de formatação que não mudam as palavras reconhecidas. Contar toda diferença de maiúscula e pontuação como erro, sem normalização, **não** é a prática padrão.

Quadros para memorizar

Quem pontua por padrão

Serviço	Pontuação por padrão	Detalhe
Google Speech-to-Text	**Não**; habilitar na requisição	Ao ligar, capitaliza depois de ponto e interrogação; suporte por idioma; pontuação falada em documentação à parte
Azure (lote)	**Sim**: DictatedAndAutomatic	Valores: None, Dictated, Automatic, DictatedAndAutomatic; não controla modelos que já pontuam (Whisper)
Amazon Transcribe	**Sim**, em todos os idiomas	Capitaliza onde a escrita distingue maiúsculas
Whisper	**Sim**, pelo próprio modelo	Treinado com texto bruto, pontuado

Serviço	Pontuação por padrão	Detalhe
Modelos do LibriSpeech	**Não**	Transcrições em maiúsculas e sem pontuação

Tarefas de pesquisa

Tarefa	O que faz	Pistas
Restauração de pontuação	Rotula cada palavra com o sinal seguinte (vírgula, ponto, interrogação, nada)	Lexicais (palavras vizinhas) e prosódicas (pausa, entonação)
Truecasing	Restaura maiúsculas e minúsculas	Contexto (Câmara x câmara)
Normalização inversa	Falado → escrito ("seis e meia" → 6:30)	No Azure, automática e não configurável

Azure: formas e opções

Item	Regra
Forma lexical	Palavras puras, sem pontuação nem maiúsculas
Forma de exibição	Pontuação, maiúsculas (início de frase, nomes próprios), ITN, sem hesitações
Saída simples	Texto de exibição e tempos
Saída detalhada	+ lexical, normalizada e alternativas
Transcrição rápida	Só forma de exibição
Transcrição em lote	Pode devolver também a lexical
Ditado	EnableDictation, reconhecimento contínuo, "vírgula" vira ","
Filtro de palavrões	Masked (padrão, asteriscos), Removed, Raw
Segmentação semântica	Reconhecimento contínuo; fecha no fim de frase, não só no silêncio

Amazon Transcribe

Ponto	Regra
Pontuação	Automática em todos os idiomas
Capitalização	Onde a escrita distingue maiúsculas
Números	Por extenso na maioria; algarismos (horas, dinheiro, decimais) só nos idiomas com suporte
Itens	Palavra e pontuação como itens próprios, com tempo e confiança
Parciais	Palavras e pontuação podem mudar até estabilizar
Confiança alta	Não garante acerto
Vocabulário	Tabela (Phrase, DisplayAs) recomendada; lista em descontinuação

Conceitos e autores que caem

- **Pós-processamento**: etapa depois do reconhecimento que arruma o texto (pontuação, maiúsculas, números).
- **Restauração de pontuação**: rotular cada palavra com o sinal seguinte (Tilk e Alumäe, Interspeech 2016, rede recorrente bidirecional com atenção).
- **Truecasing**: restaurar a capitalização correta (Lita et al., "tRuEcasIng", ACL 2003).
- **Pistas lexicais x prosódicas**: palavras e contexto x pausas e entonação (Christensen, Gotoh e Renals, 2001, modelos prosódicos de pontuação).
- **Pontuação automática x pontuação falada (ditada)**.
- **Normalização inversa de texto (ITN)**: forma falada → forma escrita.
- **Forma lexical x forma de exibição** (Azure).
- **punctuationMode** (Azure): None, Dictated, Automatic, DictatedAndAutomatic (padrão).
- **EnableDictation** (Azure): modo de ditado no reconhecimento contínuo.
- **Filtro de palavrões** (*profanity filter*): Masked (padrão), Removed, Raw.
- **Segmentação semântica** (Azure): fecha o resultado no fim da frase.
- **Resultados parciais** e **estabilização**: textos provisórios do streaming.
- **Pontuação de confiança**: quanto o sistema confia na palavra; não é garantia.
- **Vocabulário personalizado** (Amazon): tabela com Phrase e DisplayAs.
- **Adaptação de modelo** (Google): conjuntos de frases para palavras raras.
- **Prompt** (OpenAI): orienta nomes, siglas, estilo, pontuação e preenchimentos.
- **LibriSpeech** (Panayotov et al., ICASSP 2015): transcrições em maiúsculas, sem pontuação.
- **Whisper** (Radford et al., 2022): treinado com texto bruto, já pontua.

Pegadinhas da banca

- **"Pausa e entonação determinam de forma unívoca as vírgulas e os pontos."** Errado: não correspondem de forma exata.
- **"Pontuação automática dispensa revisão."** Errado.
- **"Nenhuma API de ASR oferece pontuação automática."** Errado: várias oferecem, como opção ou por padrão.
- **"A capitalização vem diretamente do sinal acústico."** Errado: é pós-processamento.
- **"A vírgula tem só função estética."** Errado: muda o sentido.
- **"Google pontua por padrão."** Errado: é preciso habilitar.
- **"Pontuação automática do Google vale para todos os idiomas."** Errado: verificar suporte.
- **"Azure lote: punctuationMode padrão é None."** Errado: DictatedAndAutomatic.
- **"As opções de pontuação do serviço controlam o Whisper."** Errado: o modelo já pontua sozinho.

- **"A normalização inversa do Azure é configurável e transforma $900 em novecentos dólares."** Errado: não é configurável e vai do falado para o escrito.
- **"O texto de exibição do Azure preserva sempre as hesitações."** Errado: o serviço pode removê-las.
- **"Modo de ditado é o mais adequado para discurso de plenário."** Errado: deputado não dita a pontuação.
- **"Filtro de palavrões do Azure mantém a palavra por padrão."** Errado: o padrão é mascarar.
- **"A saída detalhada traz só o texto de exibição."** Errado: é a simples; a detalhada traz lexical, normalizada e alternativas.
- **"A forma lexical tem pontuação e a de exibição não."** Errado: trocado.
- **"Segmentação semântica é para enunciado único e cenários interativos."** Errado: é para reconhecimento contínuo.
- **"O modelo de pontuação em cascata não sofre com os erros do reconhecedor."** Errado: os erros se propagam.
- **"Na Amazon a pontuação é opcional."** Errado: vem sempre.
- **"Amazon converte números em algarismos em todos os idiomas."** Errado: só nos com suporte; na maioria, por extenso.
- **"Nos parciais, só as palavras mudam."** Errado: a pontuação também.
- **"Na Amazon, os sinais vão grudados à palavra anterior, sem tempo."** Errado: são itens próprios, com tempo.
- **"Formato de lista é o recomendado para vocabulário novo na Amazon."** Errado: tabela.
- **"Whisper foi treinado com texto em minúsculas e sem pontuação."** Errado: texto bruto, pontuado.
- **"O prompt da OpenAI serve só para o idioma."** Errado: orienta nomes, siglas, estilo e pontuação.
- **"Truecasing insere vírgulas e pontos."** Errado: truecasing é maiúscula/minúscula.
- **"Truecasing depende só da palavra."** Errado: depende do contexto.
- **"Restauração de pontuação só com pistas acústicas."** Errado: o contexto textual é muito útil.
- **"Na WER, toda diferença de maiúscula e pontuação conta, sem normalizar."** Errado: normaliza-se antes.
- **"Siglas de comissões raramente são erradas; dispensam adaptação."** Errado: são palavras raras e erradas com frequência.
- **"Confiança alta dispensa conferência."** Errado.

Itens comentados

- **Item:** Como as pausas e a entonação da fala correspondem de forma exata a vírgulas e pontos, a pontuação automática inserida pelo ASR dispensa revisão humana. **Errado.** Pausas e entonação não correspondem de forma exata aos sinais; a pontuação automática erra e precisa de revisão.

- **Item:** Por padrão, o Google Cloud Speech-to-Text não inclui sinais de pontuação nos resultados do reconhecimento; para obtê-los, o desenvolvedor deve habilitar o recurso de pontuação automática na configuração da requisição. **Certo.** No Google, a pontuação automática precisa ser ligada.
- **Item:** Na transcrição em lote do Azure AI Speech, o valor padrão da propriedade punctuationMode é None, de modo que, sem configuração adicional, o texto transcrito é entregue sem qualquer pontuação. **Errado.** O padrão é DictatedAndAutomatic; o texto vem pontuado.
- **Item:** A normalização inversa de texto do Azure AI Speech é uma etapa configurável, que o desenvolvedor pode ligar ou desligar para cada requisição, convertendo símbolos escritos, como $900, em palavras, como novecentos dólares. **Errado.** Não é configurável, e o sentido é o inverso: "novecentos dólares" vira "$900".
- **Item:** No modo de ditado de um serviço de reconhecimento de fala, o orador fala os sinais de pontuação em voz alta e o sistema os converte em símbolos, o que torna esse modo o mais adequado para registrar discursos espontâneos de plenário. **Errado.** O ditado serve a quem pronuncia os sinais; no discurso espontâneo a pontuação é automática e revisada.
- **Item:** No SDK de fala do Azure AI Speech, a opção padrão do filtro de palavrões é manter as palavras ofensivas exatamente como foram pronunciadas, sendo necessário configurar a máscara para que sejam substituídas por asteriscos. **Errado.** O padrão é Masked (asteriscos); para manter a palavra, escolhe-se Raw.
- **Item:** No Azure AI Speech, a forma lexical do resultado do reconhecimento inclui pontuação e capitalização, ao passo que a forma de exibição traz apenas as palavras reconhecidas, sem formatação. **Errado.** É o contrário: a exibição é a forma arrumada; a lexical traz as palavras puras.
- **Item:** Quando a pontuação é inserida por um modelo de pós-processamento, os erros de palavras cometidos pelo reconhecedor de fala não influenciam a qualidade dos sinais inseridos, pois o modelo de pontuação opera de forma independente do texto reconhecido. **Errado.** O modelo de pontuação lê o texto reconhecido; os erros se propagam.
- **Item:** Na Amazon Transcribe, a pontuação é um recurso opcional, inserido apenas quando o desenvolvedor o habilita por parâmetro específico na requisição de transcrição. **Errado.** A Amazon pontua automaticamente em todos os idiomas aceitos.
- **Item:** Na estabilização de resultados parciais da transcrição em fluxo, apenas as palavras podem mudar entre um resultado parcial e o seguinte, pois os sinais de pontuação são definidos uma única vez e nunca são revistos. **Errado.** A pontuação também pode mudar nos resultados provisórios.
- **Item:** O Whisper foi treinado com transcrições padronizadas, todas em minúsculas e sem sinais de pontuação, razão pela qual sempre depende de um modelo externo para inserir pontuação e capitalização. **Errado.** O Whisper foi treinado com texto bruto, com pontuação e maiúsculas, e costuma já sair pontuado.

- **Item:** Truecasing é a tarefa de inserir sinais de pontuação, como vírgulas e pontos finais, em um texto transcrito automaticamente, a partir do contexto das palavras. **Errado.** Truecasing restaura maiúsculas e minúsculas; inserir sinais é a restauração de pontuação.
- **Item:** Em português, uma mesma palavra, como câmara, pode exigir inicial maiúscula quando integra o nome de uma instituição e minúscula quando designa um objeto comum, o que torna a capitalização automática dependente do contexto. **Certo.** "Câmara dos Deputados" x "câmara frigorífica": só o contexto decide.
- **Item:** Uma pontuação de confiança elevada atribuída a uma palavra pela Amazon Transcribe garante que ela foi reconhecida corretamente e torna desnecessária a conferência humana desse trecho. **Errado.** Confiança alta só torna o erro menos provável; a conferência continua necessária.

Resumo para revisar

- A fala não tem pontuação nem maiúsculas; pausa e entonação não correspondem de forma exata aos sinais.
- Pontuação e capitalização vêm de pós-processamento ou de modelos específicos; sempre exigem revisão.
- Vírgula muda o sentido ("Não, espere" x "Não espere").
- Sem pontuação: pior legibilidade e pior desempenho de tradução e outras tarefas posteriores.
- Duas vias: modelo em cascata depois do ASR, ou o próprio ASR treinado com texto pontuado (Whisper).
- Whisper: treinado com texto bruto, sai com pontuação e maiúsculas. LibriSpeech: maiúsculas e sem pontuação, exige pós-processamento.
- Restauração de pontuação: rotular cada palavra com o sinal seguinte; pistas lexicais e prosódicas; erros do ASR se propagam.
- Truecasing: restaurar maiúsculas; depende do contexto (Câmara x câmara); não é pontuação.
- Ditado: o orador fala o sinal; não serve para discurso espontâneo.
- Normalização inversa: falado → escrito; no Azure, automática e não configurável.
- Google: pontuação desligada por padrão; ao ligar, capitaliza após ponto e interrogação; suporte por idioma; pontuação falada em documentação separada; adaptação de modelo com frases para palavras raras.
- Azure: punctuationMode None, Dictated, Automatic, DictatedAndAutomatic (padrão); não controla o Whisper.
- Azure: exibição = pontuação, maiúsculas, ITN, sem hesitações; lexical = palavras puras; detalhada traz lexical, normalizada e alternativas; rápida só exibição; lote também lexical.
- Azure: EnableDictation no reconhecimento contínuo; filtro de palavrões Masked por padrão (Removed, Raw); segmentação semântica para reconhecimento contínuo, fecha no fim da frase.
- Filtro de palavrões no registro oficial: com cautela, pela fidelidade.

- Amazon: pontua sempre, capitaliza onde há maiúsculas; números por extenso na maioria dos idiomas; pontuação como item próprio com tempo e confiança; parciais mudam palavras e pontuação; confiança alta não garante.
- Amazon: vocabulário em tabela (Phrase, DisplayAs) recomendado; lista em descontinuação.
- OpenAI: o prompt orienta nomes, siglas, estilo, pontuação e preenchimentos; o idioma vai em campo próprio.
- WER: normalizar pontuação e maiúsculas antes da conta.
- Siglas e nomes de comissões são palavras raras: precisam de adaptação de vocabulário.

TEMA 5 DE 20

Desafios do ASR em português: sotaques e vocabulário parlamentar

54 perguntas no app · Reconhecimento de fala

O que cai

O edital pede "Desafios do ASR em Português Brasileiro: sotaques, vocabulário técnico e parlamentar". As perguntas deste tema cobram:

- **Os desafios da sessão legislativa**: sotaques regionais, fala espontânea e acelerada, ruído, sobreposição de vozes, vocabulário parlamentar (siglas, nomes próprios, "questão de ordem").
- **O que torna o ASR mais difícil em geral**: tamanho do vocabulário, **fala lida x conversa**, canal e ruído, sotaque e classe do falante. A pegadinha campeã é inverter: dizer que fala lida é mais difícil, ou que microfone distante na rua é mais fácil.
- **Os corpora (bases de fala) em português**: Common Voice, Multilingual LibriSpeech e FLEURS (fala **lida**), Multilingual TEDx (fala **preparada**), CORAA, NURC-SP e MuPe (fala **espontânea**), Spotify Podcast (licença proprietária).
- **Resultados de pesquisa**: NURC-SP (Martinelli virou "martini", todos os modelos erram mais na fala espontânea), Whisper (dados por idioma predizem o desempenho; português bem representado; modelo maior erra menos), viés (PNAS 2020, modelo acústico; MuPe, escolaridade e idade).
- **A Câmara**: vozes femininas com WER maior, listas lexicais e roteiros contra erros em nomes, diarização e alucinações como problemas, precisão variável por tipo de reunião, revisão humana mantida; transcrição automática desde 2015 e IA desde 2022.
- **Ferramentas de vocabulário**: PhraseSet (Google), lista de frases (Azure: sem treino, não serve para lote, até 2.000 frases), vocabulário e modelo de linguagem personalizados (Amazon).

Entenda o tema

Por que transcrever a Câmara é difícil

A transcrição automática de **sessões legislativas em português brasileiro** enfrenta, ao mesmo tempo:

- **variação regional de sotaque**: deputados de todos os estados, cada um com sua pronúncia;
- **fala espontânea e acelerada**: discurso de improviso, rápido, com hesitações;
- **ruído de ambiente**: plenário cheio, conversas paralelas, microfones abertos;
- **sobreposição de vozes**: apartes e interrupções;

- **vocabulário parlamentar**: **siglas** (PEC, PLP, CCJC), **nomes próprios** de deputados e órgãos, **expressões regimentais** ("questão de ordem", "pela ordem", "requerimento de urgência").

Tudo isso faz um modelo genérico errar mais. O sotaque **é** um desafio relevante: o Brasil tem muita variação regional de pronúncia, e dizer que as dificuldades "se limitam ao ruído" é errado.

O que torna o reconhecimento de fala mais fácil ou mais difícil

Segundo o manual clássico da área (Jurafsky e Martin), a dificuldade do ASR varia conforme quatro fatores:

1. **Tamanho do vocabulário**: reconhecer "sim" e "não" é fácil; reconhecer qualquer palavra do português é difícil.
2. **Tipo de interlocução**: **fala lida** em voz alta é **mais fácil** do que **conversa espontânea** entre pessoas. Quem lê fala mais devagar e com mais clareza, e as palavras do áudio correspondem diretamente às do texto. A conversa tem pausas, interrupções, hesitações e frases cortadas.
3. **Canal e ruído**: gravação em **sala silenciosa com microfone de cabeça** (perto da boca) é muito mais fácil do que **microfone distante numa rua barulhenta**, em que a voz chega misturada a outros sons.
4. **Sotaque ou classe do falante**: falantes de **dialetos regionais ou étnicos**, e **crianças**, podem ser difíceis de reconhecer quando o sistema foi treinado **só com falantes de dialeto padrão ou com adultos**. O sistema reconhece melhor o jeito de falar que ouviu muito no treino.

Consequência prática. O erro é **bem menor em fala lida** (como a de audiolivros) do que em **conversas espontâneas** (como as telefônicas). Por isso a **taxa de erro medida em um tipo de fala não deve ser transposta sem ressalvas para outro**.

> **Exemplo:** o fornecedor anuncia WER de 5% em testes com áudios de **leitura em inglês**. O departamento de registro da Câmara não pode concluir que terá 5% nas **sessões em português**, com sotaques, apartes e siglas. O certo é **testar com gravações da própria Casa**.

Três tipos de fala

Tipo	Como é	Exemplo
Lida	A pessoa lê um texto palavra por palavra	Audiolivro, voluntário lendo frases
Preparada	A pessoa planejou o conteúdo, mas não lê palavra por palavra	Palestra (TEDx), aula
Espontânea	Improvisada, com hesitações, autocorreções, repetições	Conversa, entrevista, debate, aparte

A **fala preparada** fica **entre** a lida e a espontânea.

Por que a espontânea é mais difícil. Ela tem fenômenos que afastam o áudio do texto escrito:

- **redução segmental**: as pessoas "engolem" sons; no dialeto paulista, por exemplo, a **vogal final** de "merenda" em "merenda escolar" pode ser **elidida** (suprimida);
- **hesitações** ("é...", "hum");

- **autocorreções** ("o projeto de lei, aliás, a medida provisória");
- **repetições**.

Esses fenômenos **variam com a velocidade da fala**. Na fala espontânea, as palavras do áudio **não** correspondem diretamente às do texto, como acontece na leitura.

As bases de fala (corpora) que caem

Um **corpus** (plural **corpora**) é uma coleção de gravações com suas transcrições, usada para **treinar** e **avaliar** reconhecedores.

Fala lida

- **Common Voice** (Mozilla): corpus **colaborativo**. **Voluntários gravam frases de roteiros** e **outros contribuidores verificam** as gravações. O tamanho **cresce continuamente**. Tem muita **variedade de vozes e sotaques**, mas **não é fala espontânea**; por isso não é especialmente adequado para treinar sistemas destinados a sessões legislativas.
- **Multilingual LibriSpeech**: deriva de **audiolivros** (pessoas lendo livros em voz alta). **Não** vem de conversas informais e **não** serve para medir desempenho em debates.
- **FLEURS**: conjunto **paralelo** de fala lida: **as mesmas frases são lidas em muitos idiomas**. Permite **comparar** o desempenho dos reconhecedores **entre línguas**, mas **não representa a fala espontânea**.

Fala preparada

- **Multilingual TEDx**: palestras. O orador planeja, mas não lê palavra por palavra.

Fala espontânea (e mista)

- **CORAA**: criado para suprir a falta de fala espontânea em português. **Antes dele**, os recursos públicos de fala em português brasileiro **concentravam-se em fala lida e preparada**, o que dificultava treinar e avaliar sistemas para **conversas, entrevistas e debates**. O CORAA **mistura fala espontânea e preparada** (palestras), com validação manual. **Não** é só fala lida. No artigo, o modelo ajustado nele **errou mais no teste do próprio CORAA** (espontânea e preparada) **do que no Common Voice** (lida), o que confirma: **fala espontânea é mais difícil**.
- **NURC-SP Audio Corpus** (Lima et al., 2024): fala **espontânea** com o **sotaque de São Paulo**, para **avaliação** de ASR. Detalhes abaixo.
- **MuPe Life Stories** (COLING 2025): **entrevistas de histórias de vida**. Busca **ampliar a diversidade** de **faixa etária, escolaridade e sotaque regional** dos dados em português, o que ajuda a **reduzir diferenças de desempenho entre grupos** de falantes. Os autores **encontraram viés**: os modelos atuais erram mais para certos níveis de **escolaridade** e certas **faixas etárias**.
- **Spotify Podcast Dataset**: cerca de **7.600 horas** de fala espontânea em português, mas com **licença proprietária**, não aberta. Não pode ser usado livremente para treinar modelos.

> **Dica:** "lida" = Common Voice, Multilingual LibriSpeech, FLEURS. "Preparada" = TEDx. "Espontânea" = CORAA (com preparada), NURC-SP, MuPe, Spotify (proprietário).

NURC-SP Audio Corpus em detalhe

- Integra a **divisão de São Paulo do projeto NURC** (**Norma Urbana Linguística Culta**), criado para **documentar e estudar o português falado por pessoas com alto grau de escolaridade em capitais brasileiras**. Por isso não representa todos os tipos de falantes.
- Traz **conversas e entrevistas espontâneas**, cheias de hesitações e autocorreções. **Não** são leituras de locutores profissionais em estúdio.
- Os pares de áudio e texto foram **validados por pessoas**. Não são transcrições automáticas usadas sem revisão.
- É importante porque os **conjuntos públicos mais comuns** em português são formados **predominantemente por fala lida**.
- **Resultados**: **todos os seis modelos testados** tiveram **WER maior** no NURC-SP (fala espontânea paulistana) **do que no Common Voice** (fala lida).
- **Ajuste fino**: modelos ajustados ao próprio corpus **melhoraram**, mas **mantiveram taxa de erro relevante**. O ajuste fino **reduz, sem eliminar**, a dificuldade da fala espontânea.
- Entre os modelos treinados, uma **versão destilada do Whisper Large-v3**: um modelo menor treinado com **rótulos gerados pelo próprio Whisper Large-v3** (técnica de **pseudo-rotulagem**) e depois ajustado com transcrições conferidas por pessoas.
- **Análise de erros**: o modelo transcreveu o nome **"Martinelli" como "martini"**. Em geral, o modelo **preferiu palavras comuns mais frequentes a nomes próprios menos frequentes**. Nomes próprios estão entre os maiores problemas, não entre os acertos.

> **Atenção:** a regra do "Martinelli" vale para a Câmara: diante de um nome raro (de deputado, de município, de órgão), o reconhecedor tende a escrever uma palavra comum parecida.

Whisper e o português

- **Mesmo sem ajuste fino**, o Whisper tem **desempenho razoável em fala espontânea em português**, mas com **erro maior do que em fala lida**. Por isso deve ser **avaliado com dados semelhantes aos do uso real** antes de ser adotado.
- **Dados por idioma**: no artigo do Whisper, a **quantidade de horas de áudio de um idioma** vista no treino mostrou-se **muito preditiva do desempenho zero-shot** nesse idioma (no conjunto FLEURS). Mais horas, menos erros.
- **Distribuição desigual**: os dados **não** foram equilibrados entre os idiomas. A **maior parte foi em inglês**, e as demais línguas tiveram quantidades muito diferentes. Por isso o desempenho varia entre idiomas.
- **Português bem representado**: o português **não** foi tratado como idioma de poucos recursos; está **entre os idiomas mais representados depois do inglês**. O Whisper já transcreve português de modo utilizável **sem** ajuste fino.
- **Tamanho importa**: em português, **modelo maior erra bem menos**. Os modelos menores são mais baratos, mas a qualidade cai bastante.

Viés: o sistema não erra igual para todos

- **Estudo da PNAS (Koenecke et al., 2020)**: sistemas comerciais de reconhecimento de fala **erravam bem mais com falantes negros** do que com falantes brancos. Os autores atribuíram a diferença principalmente ao **modelo acústico** (a parte que "ouve" o som), **não ao modelo de linguagem**: o vocabulário dos dois grupos era quase o mesmo. Lição: a nota média pode esconder que o sistema funciona pior para certos grupos; a avaliação deve considerar **grupos distintos**.
- **MuPe Life Stories**: viés ligado a **escolaridade e faixa etária** nos modelos em português.
- **Câmara dos Deputados (ParlAmericas, 2026)**: os sistemas de transcrição têm **WER maior para vozes femininas**, o que decorre, entre outros fatores, da **sub-representação dessas vozes nas bases de treinamento**. A Câmara **não** afirma que o Whisper eliminou esse viés; mantém a **revisão humana em todo o texto**.

A experiência da Câmara

Apresentação à ParlAmericas (2026):

- Nos testes da ferramenta, a **precisão variou** conforme fatores como: **Plenário ou comissão**, o **número de membros** do órgão, a **fase da sessão**, as **audiências públicas** e o **início ou fim da sessão legislativa**. Não existe um único número de acerto.
- A **diarização** (saber quem fala em cada trecho) **foi apontada como problema** nos testes.
- A ferramenta trouxe **novos problemas de precisão**: **mudanças indesejadas no texto, repetições e alucinações**, além de erros de ortografia.
- Contra **erros sistemáticos em nomes próprios**, são usados **roteiros e retrancas** (as divisões do trabalho por trechos da sessão, com os nomes esperados) e **listas lexicais e vocabulários especializados do domínio legislativo** no **pós-processamento**. Não é preciso treinar um modelo do zero.
- **Vozes femininas** com WER maior (ver acima).

Reportagem da Gazeta do Povo:

- A Câmara usa **transcrição automática de fala desde 2015** e **ferramentas de inteligência artificial desde 2022**.
- O **trabalho humano continua**: identificar **oradores** e **organizar falas em debates complexos**. A revisão não foi dispensada.

> **Pegadinha:** a banca inverte os anos: "transcrição automática desde 2022 e IA desde 2015". Errado: **2015** é a transcrição automática; **2022** é a IA.

Como ensinar vocabulário ao reconhecedor

Siglas, nomes de comissões e de parlamentares são **palavras raras na linguagem geral**. Os serviços oferecem recursos para favorecê-las:

Google Cloud Speech-to-Text: adaptação de modelo. Com **conjuntos de frases** (**PhraseSet**), o serviço passa a **favorecer o reconhecimento de palavras raras** no uso geral da língua, como

nomes próprios e termos de domínio específico.

Azure AI Speech: lista de frases (*phrase list*).

- É aplicada **na hora** (em tempo de execução), **sem treinar modelo**.
- Funciona na transcrição em **tempo real** e na **transcrição rápida**; **não** está disponível na **transcrição em lote**.
- **Não é ilimitada**: a lista **não deve passar de 2.000 frases**; listas mais longas **pioram a qualidade e a latência**. Para listas grandes, o caminho é a **fala personalizada** (*custom speech*), que treina um modelo.

Amazon Transcribe:

- **Vocabulário personalizado**: melhora a transcrição de **palavras específicas** (marcas, siglas, nomes próprios). Pode ser usado com **todos os idiomas suportados**. Dá dicas sobre **palavras isoladas**.
- **Modelo de linguagem personalizado**: vai além; **aprende o contexto** em que os termos aparecem (com quais palavras costumam vir), a partir de textos do domínio. Como é **treinado com textos de um idioma específico**, exige **indicar o idioma** do áudio na requisição e **não pode ser combinado com a identificação automática de idioma**.

Vocabulário é dinâmico. Deputados mudam a cada legislatura, comissões e siglas novas surgem, temas novos entram em pauta. A lista de termos **precisa ser revista e atualizada** sempre. Dizer que é recurso estático, criado uma vez e nunca revisto, é errado.

Quadros para memorizar

Fatores de dificuldade do ASR

Fator	Mais fácil	Mais difícil
Vocabulário	Pequeno	Grande
Interlocução	Fala lida	Conversa espontânea
Canal e ruído	Sala silenciosa, microfone de cabeça	Rua barulhenta, microfone distante
Falante	Dialeto e perfil iguais aos do treino	Sotaque regional ou étnico, criança, perfil sub-representado

Corpora

Corpus	Tipo de fala	Ponto cobrado
Common Voice	Lida	Voluntários leem roteiros, outros verificam; cresce sempre; não é espontânea
Multilingual LibriSpeech	Lida	Audiolivros; não serve para debates
FLEURS	Lida, paralela	Mesmas frases em muitos idiomas; compara línguas

Corpus	Tipo de fala	Ponto cobrado
Multilingual TEDx	Preparada	Palestras; entre lida e espontânea
CORAA	Espontânea + preparada	Supriu falta de fala espontânea; erro maior nele que no Common Voice
NURC-SP	Espontânea, sotaque paulista	Projeto NURC (fala culta, capitais); validado por pessoas; 6 modelos erram mais nele
MuPe Life Stories	Espontânea (histórias de vida)	Diversidade de idade, escolaridade, sotaque; encontrou viés
Spotify Podcast	Espontânea, ~7.600 h	Licença proprietária

Câmara dos Deputados

Fonte	Fato
Gazeta do Povo	Transcrição automática desde 2015; IA desde 2022; humanos identificam oradores e organizam debates
ParlAmericas	WER maior para vozes femininas (sub-representação nos dados)
ParlAmericas	Nomes próprios: roteiros, retrancas, listas lexicais e vocabulários legislativos no pós-processamento
ParlAmericas	Precisão varia: Plenário x comissão, nº de membros, fase da sessão, audiências públicas, início/fim da sessão legislativa
ParlAmericas	Problemas: diarização, mudanças indesejadas, repetições, alucinações
ParlAmericas	Revisão humana em todo o texto

Recursos de vocabulário

Serviço	Recurso	Regra
Google	Adaptação de modelo (PhraseSet)	Favorece palavras raras, nomes próprios, termos de domínio
Azure	Lista de frases	Sem treino; tempo real e rápida, não lote; até 2.000 frases; mais longa piora qualidade e latência
Azure	Fala personalizada (custom speech)	Treina modelo; para listas grandes
Amazon	Vocabulário personalizado	Palavras isoladas (siglas, nomes, marcas); todos os idiomas
Amazon	Modelo de linguagem personalizado	Aprende contexto; exige idioma informado; sem identificação automática de idioma

Conceitos e autores que caem

- **Corpus / corpora**: coleção de gravações com transcrições.
- **Fala lida, preparada e espontânea**.
- **Redução segmental / elisão**: sons "engolidos" na fala rápida (vogal final de "merenda").

- **Hesitação, autocorreção, repetição**: marcas da fala espontânea.
- **Ajuste fino** (*fine-tuning*): treinar um pouco mais um modelo pronto com dados do domínio.
- **Destilação**: treinar um modelo menor para imitar um maior.
- **Pseudo-rotulagem**: usar transcrições geradas por um modelo como rótulos de treino.
- **Zero-shot**: desempenho sem ajuste fino.
- **Viés**: desempenho desigual entre grupos de falantes.
- **Modelo acústico x modelo de linguagem**: o primeiro "ouve"; o segundo avalia sequências de palavras.
- **NURC** (Norma Urbana Linguística Culta): projeto de documentação da fala culta em capitais.
- **Jurafsky e Martin**, *Speech and Language Processing*: fatores de dificuldade do ASR.
- **Lima et al. (2024)**: NURC-SP Audio Corpus.
- **Candido Junior et al.**: CORAA.
- **Koenecke et al., PNAS 2020**: disparidades raciais no ASR.
- **Radford et al. (2022)**: Whisper.
- **PhraseSet** (Google), **phrase list** (Azure), **custom vocabulary** e **custom language model** (Amazon).
- **Retranca**: divisão do trabalho de registro em trechos da sessão.

Pegadinhas da banca

- **"Não há variação regional relevante; o sotaque não é desafio."** Errado.
- **"Fala lida é mais difícil que conversa espontânea."** Errado: é o contrário.
- **"Microfone distante em rua barulhenta é mais fácil que sala silenciosa com microfone de cabeça."** Errado.
- **"Na fala espontânea, as palavras correspondem diretamente às do texto."** Errado: isso é a fala lida.
- **"O CORAA é só fala lida."** Errado: espontânea e preparada.
- **"No CORAA, o modelo errou menos na fala espontânea que no Common Voice."** Errado: errou mais.
- **"NURC-SP são leituras de locutores profissionais em estúdio."** Errado: conversas e entrevistas espontâneas.
- **"NURC-SP sem validação humana."** Errado: validado por pessoas.
- **"Nomes próprios foram mais acertados que palavras comuns."** Errado: o modelo prefere palavras comuns (Martinelli → martini).
- **"Common Voice é fala espontânea, ideal para sessões legislativas."** Errado: é fala lida.
- **"Multilingual LibriSpeech vem de conversas informais."** Errado: audiolivros.
- **"Spotify Podcast tem licença aberta."** Errado: proprietária.
- **"MuPe concluiu que não há viés de escolaridade e idade."** Errado: encontrou viés.

- **"Português foi idioma de poucos recursos no Whisper."** Errado: está entre os mais representados.
- **"Dados do Whisper equilibrados entre idiomas."** Errado: maioria em inglês.
- **"Tamanho do Whisper pouco influi no português."** Errado: maior erra bem menos.
- **"PNAS: a culpa era do modelo de linguagem."** Errado: modelo acústico.
- **"Whisper eliminou o viés de gênero; revisão dispensada para vozes femininas."** Errado.
- **"Nomes próprios não podem ser mitigados com listas lexicais; só treinando do zero."** Errado.
- **"A diarização não foi problema nos testes da Câmara."** Errado: foi.
- **"Só houve erros de ortografia."** Errado: mudanças indesejadas, repetições, alucinações.
- **"Transcrição automática desde 2022 e IA desde 2015, com revisão dispensada."** Errado: 2015 e 2022, revisão mantida.
- **"Lista de frases do Azure exige treino e serve para lote."** Errado: sem treino e não serve para lote.
- **"Lista de frases ilimitada; mais longa é melhor."** Errado: até 2.000; mais longa piora.
- **"Modelo de linguagem personalizado da Amazon só dá dicas de palavras isoladas."** Errado: aprende o contexto.
- **"Vocabulário personalizado é estático."** Errado: precisa ser atualizado.
- **"WER do fornecedor em leitura em inglês vale para as sessões em português."** Errado: testar com áudio da Casa.

Itens comentados

- **Item:** Por não haver variação regional relevante de pronúncia no português brasileiro, o sotaque não figura entre os desafios do ASR nas sessões legislativas, cujas dificuldades se limitam ao ruído de ambiente. **Errado.** O sotaque é desafio relevante, ao lado de ruído, fala acelerada, sobreposição e vocabulário parlamentar.

- **Item:** Para os sistemas de reconhecimento de fala, a fala lida em voz alta é mais difícil de transcrever do que a conversa espontânea entre duas pessoas, porque quem lê tende a falar mais rápido e de forma menos clara. **Errado.** Quem lê fala mais devagar e com mais clareza; a conversa espontânea é a mais difícil.

- **Item:** O erro dos reconhecedores de fala costuma ser bem menor em fala lida, como a de audiolivros, do que em conversas espontâneas, como as telefônicas, de modo que a taxa de erro medida em um tipo de fala não deve ser transposta sem ressalvas para outro. **Certo.** A WER depende do tipo de fala; não se transpõe automaticamente.

- **Item:** No artigo do CORAA, o modelo ajustado nesse corpus errou menos no teste do próprio CORAA, que reúne fala espontânea e preparada, do que no teste do Common Voice, de fala lida, o que confirma que a fala espontânea é mais fácil de reconhecer. **Errado.** O modelo errou mais no CORAA; a fala espontânea é mais difícil.

- **Item:** O NURC-SP Audio Corpus foi construído a partir de leituras de textos curtos feitas por locutores profissionais em estúdio, o que garante uniformidade da pronúncia e baixa incidência

de hesitações. **Errado.** São conversas e entrevistas espontâneas, com hesitações e autocorreções.

- **Item:** Os autores do NURC-SP relataram que os nomes próprios foram transcritos corretamente com mais frequência do que as palavras comuns, pois o modelo tende a preferir termos raros a termos frequentes. **Errado.** O modelo prefere palavras comuns e frequentes; "Martinelli" virou "martini".
- **Item:** O Spotify Podcast Dataset, com cerca de 7.600 horas de fala espontânea em português, é distribuído sob licença aberta e pode ser livremente usado para treinar modelos de reconhecimento de fala. **Errado.** A licença é proprietária.
- **Item:** No treinamento do Whisper, o português foi tratado como idioma de poucos recursos, com volume de áudio insignificante, razão pela qual o modelo só transcreve português de modo utilizável após ajuste fino. **Errado.** O português está entre os idiomas mais representados depois do inglês; o Whisper já o transcreve bem.
- **Item:** No estudo da PNAS sobre disparidades raciais em reconhecimento de fala, os autores atribuíram a diferença de desempenho principalmente ao modelo de linguagem dos sistemas, que preveria pior as sequências de palavras dos falantes negros. **Errado.** A diferença foi atribuída ao modelo acústico; o vocabulário dos grupos era quase o mesmo.
- **Item:** Segundo a apresentação da Câmara dos Deputados à ParlAmericas, para mitigar erros sistemáticos em nomes próprios são usados roteiros e retrancas, além de listas lexicais e vocabulários especializados do domínio legislativo na etapa de pós-processamento. **Certo.** É a estratégia relatada pela Câmara.
- **Item:** A apresentação da Câmara dos Deputados à ParlAmericas informa que a diarização dos discursos, isto é, a identificação de quem fala em cada trecho, não representou problema relevante nos testes da ferramenta. **Errado.** A diarização foi apontada como problema.
- **Item:** A lista de frases (phrase list) do Azure AI Speech exige o treinamento de um modelo personalizado antes do uso e é o recurso indicado para a transcrição em lote de grandes volumes de áudio. **Errado.** A lista é aplicada na hora, sem treino, e não está disponível na transcrição em lote.
- **Item:** Os modelos de linguagem personalizados do Amazon Transcribe, assim como os vocabulários personalizados, apenas fornecem dicas de pronúncia para palavras isoladas, sem aprender o contexto em que elas são usadas. **Errado.** O vocabulário trata palavras isoladas; o modelo de linguagem personalizado aprende o contexto.
- **Item:** Segundo reportagem da Gazeta do Povo, a Câmara dos Deputados usa transcrição automática desde 2022 e ferramentas de inteligência artificial desde 2015, ano em que os analistas passaram a ser dispensados da revisão dos textos. **Errado.** Transcrição automática desde 2015, IA desde 2022, e o trabalho humano continua.
- **Item:** Situação hipotética: Para escolher a ferramenta de transcrição de suas sessões em português, um departamento de registro adotou a taxa de erro de palavras divulgada pelo fornecedor em testes com áudios de leitura em inglês, por entender que esse índice vale automaticamente para o vocabulário parlamentar e os sotaques das sessões. Nessa situação, o

critério de escolha está correto. **Errado.** A WER muda com idioma, sotaque, tipo de fala e vocabulário; é preciso testar com gravações da própria Casa.

Resumo para revisar

- Sessões legislativas: sotaques, fala espontânea e rápida, ruído, sobreposição, siglas, nomes próprios, expressões regimentais.
- Dificuldade do ASR: vocabulário, tipo de interlocução, canal e ruído, sotaque ou classe do falante.
- Fala lida é mais fácil que conversa; microfone de cabeça em sala silenciosa é mais fácil que microfone distante na rua.
- Dialetos regionais ou étnicos e crianças erram mais se o treino foi só com padrão e adultos.
- WER de um tipo de fala não se transpõe para outro; testar com áudio da própria Casa.
- Fala preparada (TEDx) fica entre lida e espontânea.
- Espontânea: redução segmental (vogal de "merenda"), hesitações, autocorreções, repetições, variando com a velocidade.
- Lida: Common Voice (colaborativo, verificado, cresce sempre), Multilingual LibriSpeech (audiolivros), FLEURS (mesmas frases em muitas línguas).
- CORAA: espontânea + preparada; supriu a falta de fala espontânea; erro maior nele que no Common Voice.
- NURC-SP: projeto NURC (fala culta, capitais), sotaque paulista, espontânea, validado por pessoas; 6 modelos erram mais nele; ajuste fino reduz sem eliminar; Whisper destilado com pseudo-rotulagem; Martinelli → martini.
- MuPe: histórias de vida, diversidade de idade, escolaridade e sotaque; encontrou viés.
- Spotify Podcast: ~7.600 h, licença proprietária.
- Whisper: razoável em português espontâneo sem ajuste, pior que em fala lida; horas por idioma predizem o desempenho; dados desiguais, maioria inglês; português bem representado; maior erra menos.
- PNAS 2020: erra mais com falantes negros; culpa do modelo acústico.
- Câmara: WER maior para vozes femininas (sub-representação); revisão humana em tudo.
- Câmara: nomes próprios com roteiros, retrancas, listas lexicais e vocabulários legislativos; precisão varia por tipo de reunião; problemas de diarização, mudanças indesejadas, repetições e alucinações.
- Gazeta do Povo: transcrição automática desde 2015, IA desde 2022; humanos identificam oradores.
- Google: PhraseSet para palavras raras.
- Azure: lista de frases sem treino, não no lote, até 2.000 frases; mais longa piora qualidade e latência.
- Amazon: vocabulário personalizado (palavras isoladas, todos os idiomas); modelo de linguagem personalizado (contexto, idioma obrigatório, sem identificação automática).

- Vocabulário personalizado precisa ser atualizado sempre.

TEMA 6 DE 20

Transcrição em tempo real

59 perguntas no app · Reconhecimento de fala

O que cai

O edital pede "Transcrição em tempo real" (item 1.7), ao lado das ferramentas e APIs (Whisper, Google Speech-to-Text, Azure Speech, AWS Transcribe). As perguntas deste tema giram em torno de quatro blocos:

- **Tempo real x lote**: o que cada modo faz, por que o lote costuma ser mais preciso e por que o tempo real tem latência baixa. A banca adora **trocar os dois conceitos**.
- **Vocabulário do ao vivo**: modelo **causal**, **janela de contexto**, **latência**, **contexto futuro**, **resultado parcial x resultado final**, estabilização.
- **Modelos que servem (ou não) ao vivo**: o **RNN-Transducer** emite texto em fluxo; os modelos sequência a sequência com **atenção** sobre a frase inteira geram atraso; o **Whisper** usa janela de 30 segundos sobre o arquivo.
- **Como cada serviço de nuvem faz**: Google (síncrono, assíncrono e streaming por gRPC), Azure (tempo real, lote, transcrição rápida, reconhecimento contínuo x enunciado único), Amazon Transcribe (lote x streaming, IsPartial, estabilização, formatos de áudio, boas práticas) e OpenAI (Realtime API).

A ideia que se repete em quase todos os itens: **ao vivo, rapidez custa precisão**. Quem espera mais áudio acerta mais, mas atrasa o texto.

Entenda o tema

Reconhecimento de fala em duas velocidades

Reconhecimento automático de fala (ASR, do inglês *Automatic Speech Recognition*) é a tecnologia que transforma voz em texto. Ela pode trabalhar de dois jeitos.

Transcrição em lote (*batch*): o arquivo de áudio já está **completo e gravado**. Você entrega o arquivo ao sistema, ele processa **depois, de forma assíncrona** (sem você ficar esperando na linha), e devolve o texto quando terminar.

Transcrição em tempo real (*streaming* ou "em fluxo"): o áudio é processado **enquanto a pessoa fala**. O texto vai aparecendo na tela, com **resultados parciais** que podem ser corrigidos à medida que chega mais som. É o que se usa na legenda ao vivo de uma sessão.

> **Exemplo:** a sessão do Plenário está sendo transmitida pela TV Câmara com legenda automática. Isso é tempo real. No dia seguinte, a gravação inteira da sessão é enviada ao sistema para gerar o texto que os revisores vão trabalhar. Isso é lote.

Por que o lote costuma acertar mais? Porque, com a gravação pronta, o modelo pode usar o **contexto inteiro**, inclusive o que vem **depois** de cada palavra, e não tem pressa. No tempo real, o sistema **não sabe o que o orador vai dizer em seguida** e precisa responder rápido.

> **Dica:** pense em alguém traduzindo um discurso. O tradutor que recebe o texto pronto na véspera traduz melhor do que o intérprete simultâneo, que precisa falar junto com o orador. O primeiro é o lote; o segundo, o tempo real.
>
> **Pegadinha:** a banca troca os dois. "Na transcrição em lote, o áudio é processado enquanto a fala ocorre, com resultados parciais" está errado: isso é tempo real. "O tempo real dispõe de todo o contexto futuro, sem pressão de latência, e por isso é mais preciso" também está errado: quem tem o contexto inteiro é o lote.

Latência, contexto futuro e janela de contexto

Três termos aparecem o tempo todo e não podem ser confundidos.

Latência é o **atraso** entre a fala e o aparecimento do texto na tela. Na legenda ao vivo, latência alta incomoda: o texto chega depois que o orador já mudou de assunto.

Contexto futuro (*lookahead*) é quanto áudio **posterior** o modelo espera ouvir antes de escrever uma palavra. Ouvir um pouco do que vem depois ajuda a decidir: "a sessão" ou "à sessão"? "concerto" ou "conserto"? Mas cada pedacinho de espera **aumenta a latência**.

> **Atenção:** quanto **mais** contexto futuro o modelo espera, **maior** a latência e, em geral, maior a precisão. Esperar mais **nunca reduz** o atraso. Há um **compromisso** (uma troca) entre latência e precisão.

Janela de contexto é a **quantidade de áudio que o modelo enxerga de uma vez**. É como o campo de visão dele. Não confunda com latência: o intervalo entre o fim da fala e o texto na tela é latência, não janela de contexto.

Modelo causal

Um modelo de ASR **causal** usa **só o áudio passado e o presente**. Nunca olha o futuro, porque o futuro ainda não chegou. Por isso ele é **adequado ao tempo real**: pode escrever assim que ouve.

O preço é a precisão. Um modelo causal **tende a errar mais** do que um modelo que enxerga o áudio inteiro (chamado não causal ou bidirecional), que é o tipo natural do lote.

> **Pegadinha:** "Modelo causal é o que aguarda o fim da enunciação para usar todo o contexto futuro, o mais adequado ao lote." Errado. Causal é justamente o que **não espera** o futuro.

Que modelos servem para o ao vivo

CTC (*Connectionist Temporal Classification*) é uma técnica clássica dos modelos de fala ponta a ponta (*end-to-end*). Ele decide cada símbolo de saída de forma **independente** dos anteriores (supõe **independência condicional** entre as saídas). É rápido, mas não "lembra" o que já escreveu.

RNN-Transducer (RNN-T), proposto por Alex Graves em 2012, tem três peças:

1. **codificador acústico**: transforma o som em representações;
2. **rede de predição**: olha os **rótulos já emitidos** (o que já foi escrito), funcionando como um pequeno modelo de linguagem;
3. **rede conjunta**: junta as duas informações e escolhe o próximo símbolo.

Por causa da rede de predição, o RNN-T **não supõe independência entre as saídas**, ao contrário do CTC. E, como pode **emitir saídas à medida que o áudio chega**, permite **decodificação em fluxo**. Por isso é muito usado em transcrição em tempo real, como a legenda ao vivo de sessões.

> **Pegadinha:** "Assim como o CTC, o RNN-T supõe independência condicional entre as saídas." Errado. A diferença entre eles está exatamente na rede de predição, que consome o que já foi escrito.

Modelos sequência a sequência com atenção (como o *Listen, Attend and Spell*, de Chan e colegas): um codificador ouve o áudio e um decodificador escreve o texto **símbolo a símbolo**, usando a **atenção** para decidir em que parte do áudio prestar atenção a cada passo. Na forma padrão, a atenção olha a **enunciação inteira**. Isso **aumenta a latência** e dificulta o uso em fluxo contínuo; são precisos ajustes (atenção limitada, por blocos) para levá-los ao ao vivo.

> **Pegadinha:** "Nos modelos com atenção, o decodificador emite todo o texto de uma só vez, razão pela qual são os mais indicados ao tempo real." Errado duas vezes: eles geram **símbolo a símbolo** e, por quererem a frase toda, **não** são os mais indicados ao ao vivo.

Whisper (OpenAI): a função `transcribe()` do pacote Whisper **lê o arquivo de áudio inteiro** e o processa com uma **janela deslizante de 30 segundos**. Isso combina com **arquivos gravados**. Para usar o Whisper ao vivo é preciso adaptar (por exemplo, juntando o áudio em blocos).

Resultados parciais e resultados finais

No tempo real, o sistema mostra primeiro um **resultado parcial** (ou intermediário, ou provisório): o palpite do momento, que **pode ser revisto** quando chega mais áudio. Quando o sistema "fecha" aquele trecho, sai o **resultado final**: o texto consolidado, que não muda mais.

> **Exemplo:** o orador diz "o projeto foi aprovado por unanimidade". A legenda mostra primeiro "o projeto foi aprovado por uma", e um instante depois corrige para "por unanimidade". A palavra provisória mudou porque o sistema ouviu o resto. Isso é **comportamento esperado** no tempo real, e não defeito.
>
> **Atenção:** o parcial é o **provisório** (pode mudar); o final é o **definitivo**. A banca inverte os dois. E a aplicação deve **guardar o final**, não o parcial: guardar o parcial é guardar rascunho.

Na legenda ao vivo de uma sessão, essas oscilações são normais. A **versão oficial** do registro é produzida e **revisada depois**, por pessoas.

Como cada serviço de nuvem organiza os modos

Os grandes serviços de fala em nuvem costumam oferecer três modos, conforme o uso:

Situação	Modo
trecho **curto**, resposta na hora	requisição **síncrona**
gravação **longa** já concluída	processamento **assíncrono** (em lote)
áudio captado **ao vivo**	reconhecimento em **fluxo** (*streaming*)

Síncrono quer dizer que você manda o pedido e **fica esperando** a resposta na mesma chamada. **Assíncrono** quer dizer que você **inicia uma operação**, vai cuidar da vida e **consulta o resultado depois**. A diferença está no **jeito de pedir** e no tamanho do áudio, e não na qualidade do modelo.

Google Cloud Speech-to-Text

- **Reconhecimento síncrono**: para áudio **curto**; devolve o texto na mesma requisição. É o recomendado pela documentação para **transcrever arquivos de áudio locais** curtos. Não serve para uma sessão inteira gravada, porque o síncrono tem limite de duração.
- **Reconhecimento assíncrono**: o cliente inicia uma operação e consulta o resultado depois. Adequado a **gravações longas já concluídas**, como a reunião de uma comissão. **Não** serve para legenda ao vivo.
- **Reconhecimento em fluxo (streaming)**: para áudio **ao vivo**, como o captado por um **microfone**. Funciona **só por gRPC** (um protocolo de comunicação entre programas); o REST serve aos outros dois modos. Cada conexão de streaming tem **duração limitada**, curta; numa sessão plenária longa, o sistema precisa **reconectar** de tempos em tempos.

> **Pegadinha:** "No Google, o assíncrono usa modelo menos preciso em troca de aceitar áudios mais longos." Errado: síncrono e assíncrono não mudam a qualidade; mudam a forma de pedir e o tamanho aceito.

Microsoft Azure AI Speech

- **Transcrição em tempo real**: devolve **resultados intermediários** para **áudio ao vivo**.
- **Transcrição em lote** (*batch transcription*): processa de forma **assíncrona** grandes volumes de áudio **armazenados em arquivos**. O tempo de conclusão pode variar **de alguns minutos a**

horas, conforme o volume e a carga do serviço, e os resultados são recuperados depois em um **contêiner de armazenamento**.

- **Transcrição rápida** (*fast transcription*): processa **arquivos gravados** e devolve o resultado de forma **síncrona**, **mais depressa do que o tempo real** (o texto sai em menos tempo do que o áudio dura). Indicada para legendas, notas de reunião e correio de voz.

No **SDK** do Azure (o kit de programação), há dois jeitos de reconhecer fala:

- **Enunciado único** (*single-shot*): reconhece **um trecho curto** e **para sozinho** ao detectar o silêncio do fim da frase. Serve para comandos curtos, não para sessões longas.
- **Reconhecimento contínuo**: o programa precisa **se inscrever em eventos** para receber os resultados: **Recognizing** (texto provisório), **Recognized** (texto final) e **Canceled** (cancelamento). E o reconhecimento **só termina quando o programa chama o método de parada**; ele não para sozinho no primeiro silêncio. É o modo para sessões longas.

Dois ajustes de silêncio aparecem nas perguntas:

- **Tempo de silêncio de segmentação**: quanto silêncio **encerra um trecho** e gera o resultado final. Se for **curto demais**, qualquer pausa para respirar **corta a frase no meio**.
- **Tempo limite inicial de silêncio**: por quanto tempo o reconhecedor **espera a fala começar** antes de desistir sem resultado. Em sessões com longos intervalos sem fala, ele deve ser **maior**, e não o menor possível; senão o sistema desiste antes de o orador começar.

Amazon Transcribe (AWS)

A Amazon Transcribe faz **as duas coisas**: transcreve **arquivos de mídia** guardados no **Amazon S3** (o armazenamento da Amazon), em **lote**, e transcreve **áudio em fluxo**, em tempo real. Dizer que ela "permite apenas" arquivos do S3 é errado.

Lote e fluxo não têm o mesmo cardápio. Alguns **idiomas** e alguns **recursos** existem numa modalidade e não na outra. Exemplo cobrado: a **geração de arquivos de legendas** é recurso da transcrição **em lote**; no streaming, a Amazon devolve texto com marcação de tempo, e o programador monta a legenda.

Como enviar áudio em fluxo. As opções são: os **SDKs da AWS** (a **opção preferida**), o protocolo **HTTP/2**, **WebSockets** e o **console de gerenciamento**, onde se pode testar falando ao microfone do computador.

Formatos de áudio no streaming. São aceitos **FLAC**, **Opus em contêiner Ogg** e **PCM de 16 bits**. Os recomendados são os **sem perdas** (*lossless*), como **FLAC e PCM**. Compressão **com perdas** e baixa taxa de bits **joga fora informação acústica** e pode **piorar** o reconhecimento.

Taxa de amostragem. Mais alta **não** é sempre melhor. A voz cabe bem em taxas moderadas, como **16 kHz**, que é a taxa típica de treino dos modelos de fala. Subir muito a taxa só aumenta o arquivo.

Tamanho dos blocos. No fluxo, o áudio é enviado em **pequenos blocos**. Blocos **muito grandes aumentam a latência**, porque o serviço só começa a processar cada trecho depois de recebê-lo por inteiro.

Silêncio. Quando não há fala, o programa **não deve parar de enviar dados**. A boa prática é **continuar enviando silêncio**, no ritmo do tempo real, para o fluxo seguir sem buracos.

Segmentos. O áudio em streaming é dividido em **segmentos de fala naturais**, delimitados por uma **pausa** ou pela **troca de falante**. Dentro de cada segmento, o serviço devolve resultados **cada vez mais completos** até concluí-lo.

O campo IsPartial.

- **IsPartial = verdadeiro**: o segmento **ainda não está completo**; o texto pode mudar.
- **IsPartial = falso**: o segmento **foi concluído**; as palavras vêm com **pontuação de confiança** (uma nota de quanto o sistema confia nelas). Esse é o resultado a guardar.

Estabilização de resultados parciais. Quando ativada, **só as últimas palavras** do texto parcial podem mudar; o resto fica firme. O texto sai **mais rápido** (bom para legenda ao vivo), mas a **precisão pode cair**. Há três níveis:

Nível de estabilidade	Velocidade	Precisão
baixo	menor	**maior**
médio	intermediária	intermediária
alto	**maior**	menor

Com a estabilização ativada, cada palavra vem com o campo **Stable**. **Stable = falso** indica palavra **mais propensa a mudar** até o fim do segmento; as marcadas como estáveis **não serão alteradas**. Na tela, dá para mostrar as não estáveis em itálico, avisando o espectador.

Limites e erros. A duração de cada sessão de streaming é **limitada**; a aplicação que legenda reuniões longas deve **prever o encerramento e a abertura de novas sessões sem perder o áudio** entre elas. Se o serviço devolver **LimitExceededException** (excesso de fluxos simultâneos), a orientação é **tentar de novo com espera crescente** entre as tentativas e, se persistir, pedir aumento de cota. Repetir imediatamente e sem intervalo só piora o congestionamento.

OpenAI

O guia da OpenAI separa dois casos:

- **Áudio que ainda está chegando** (microfone, chamada, fluxo de mídia): usa-se a **transcrição em tempo real da Realtime API**, acessada por **WebSocket** no servidor ou por **WebRTC** em navegadores. O servidor envia **eventos**: primeiro **textos provisórios**, depois o **texto final** do trecho confirmado. A aplicação deve tratar o provisório como sujeito a mudança.
- **Arquivo pronto**: a transcrição de arquivos pode devolver o texto **aos poucos, em eventos** (*streaming* da saída). Isso **não é** tempo real: o áudio já foi gravado; só a **entrega** do texto é mais rápida.

> **Atenção:** "streaming da resposta" sobre um arquivo pronto não é o mesmo que transcrição em tempo real. Tempo real é quando **o áudio** ainda está sendo falado.

Quadros para memorizar

Tempo real x lote

Aspecto	Tempo real (streaming)	Lote (batch)
Quando processa	enquanto a pessoa fala	depois, com o arquivo completo
Forma	contínua, resultados parciais	assíncrona
Contexto futuro	pouco ou nenhum	todo o áudio
Latência	baixa (prioridade)	não importa
Precisão	tende a ser menor	tende a ser maior
Uso típico	legenda ao vivo	texto da sessão gravada, para revisão

Termos que a banca troca

Termo	O que é	Não é
Latência	atraso entre a fala e o texto na tela	tamanho do áudio visto
Janela de contexto	quantidade de áudio que o modelo enxerga de uma vez	atraso
Contexto futuro	áudio posterior que o modelo espera antes de escrever	— (mais contexto futuro = mais latência)
Modelo causal	usa só passado e presente; serve ao ao vivo	modelo que espera o fim da frase
Resultado parcial	provisório, pode mudar	definitivo
Resultado final	consolidado, não muda	rascunho

Modelos e o ao vivo

Modelo	Característica	Ao vivo?
CTC	saídas independentes entre si	possível, mas sem "memória" do que escreveu
RNN-T (Graves, 2012)	codificador + rede de predição + rede conjunta; não supõe independência	**sim**, decodifica em fluxo
Seq2seq com atenção (LAS)	atenção sobre a frase inteira; gera símbolo a símbolo	difícil na forma padrão (latência)
Whisper `transcribe()`	arquivo inteiro, janela deslizante de 30 s	feito para arquivos; ao vivo exige adaptação

Serviços de nuvem

Serviço	Ao vivo	Gravação
Google Speech-to-Text	streaming, **só gRPC**, conexão com duração limitada	síncrono (curto, arquivos locais); assíncrono (longo)

Serviço	Ao vivo	Gravação
Azure AI Speech	tempo real com resultados intermediários; SDK contínuo (Recognizing, Recognized, Canceled; parar manualmente)	lote assíncrono (minutos a horas, resultado em contêiner); transcrição rápida síncrona
Amazon Transcribe	streaming por SDK (preferido), HTTP/2, WebSockets ou console	lote com arquivos no S3; legendas só no lote
OpenAI	Realtime API: WebSocket (servidor) ou WebRTC (navegador)	transcrição de arquivos (pode devolver em eventos)

Amazon Transcribe em números e nomes

Ponto	Regra
Formatos no streaming	FLAC, Opus em Ogg, PCM 16 bits
Recomendados	sem perdas: FLAC e PCM
Taxa de amostragem	moderada (ex.: 16 kHz); mais alta não é melhor
Blocos de áudio	pequenos; grandes aumentam a latência
Sem fala	continuar enviando silêncio
IsPartial verdadeiro	segmento incompleto
IsPartial falso	segmento concluído, com confiança
Estabilidade baixa / alta	mais precisa / mais rápida
Stable falso	palavra ainda pode mudar
LimitExceededException	tentar de novo com espera crescente; pedir cota

Conceitos e autores que caem

Por que importa: a banca cobra a definição exata de cada termo e a autoria dos modelos.

- **ASR (Automatic Speech Recognition)**: reconhecimento automático de fala; converte voz em texto.
- **Transcrição em tempo real (streaming)**: processa o áudio enquanto a fala ocorre, com resultados parciais.
- **Transcrição em lote (batch)**: processa o arquivo completo depois, de forma assíncrona; usa o contexto inteiro.
- **Latência**: atraso entre a fala e o texto.
- **Janela de contexto**: quantidade de áudio que o modelo enxerga de uma vez.
- **Modelo causal**: usa só o áudio passado e o presente.
- **Compromisso latência x precisão**: mais contexto futuro, mais acerto e mais atraso.
- **RNN-Transducer**: Alex **Graves**, *Sequence Transduction with Recurrent Neural Networks* (**2012**); codificador acústico, rede de predição e rede conjunta; emite em fluxo.
- **CTC**: supõe independência condicional entre as saídas.

- **Listen, Attend and Spell**: **Chan** e colegas; modelo sequência a sequência com atenção; atenção sobre a enunciação inteira gera latência.
- **Whisper**: OpenAI; `transcribe()` com janela deslizante de **30 segundos** sobre o arquivo.
- **Síncrono / assíncrono / streaming**: modos de pedido; o primeiro para áudio curto, o segundo para gravação longa, o terceiro para ao vivo.
- **gRPC**: protocolo exigido pelo streaming do Google.
- **Recognizing, Recognized, Canceled**: eventos do reconhecimento contínuo no SDK do Azure.
- **IsPartial e Stable**: campos do resultado em fluxo da Amazon Transcribe.

Pegadinhas da banca

- **Lote e tempo real trocados.** O item diz que o lote processa enquanto a fala ocorre e que o tempo real processa o arquivo depois. É o contrário.
- **"O tempo real tem todo o contexto futuro e é mais preciso."** Errado: quem tem o contexto inteiro e sem pressa é o lote.
- **"Ampliar o contexto futuro reduz a latência."** Errado: esperar mais áudio **aumenta** o atraso.
- **Janela de contexto como atraso.** Errado: o atraso é a latência; a janela é a quantidade de áudio vista de uma vez.
- **"Modelo causal aguarda o fim da enunciação."** Errado: causal não olha o futuro; serve ao tempo real.
- **"O RNN-T, como o CTC, supõe independência entre as saídas."** Errado: a rede de predição do RNN-T consome o que já foi emitido.
- **"Modelos com atenção emitem tudo de uma vez e são os melhores para o ao vivo."** Errado: geram símbolo a símbolo e, olhando a frase toda, geram latência.
- **Parcial e final trocados.** O item diz que o parcial é definitivo e o final é revisável. É o contrário.
- **"No Google, assíncrono é menos preciso."** Errado: os modos não mudam a qualidade.
- **"Síncrono para sessão inteira gravada."** Errado: síncrono é para áudio curto; sessão longa vai para o assíncrono.
- **"Assíncrono para legenda ao vivo" ou "para áudio de microfone".** Errado: ao vivo é streaming.
- **"Streaming do Google por gRPC ou REST, à escolha."** Errado: **só gRPC**.
- **"Conexão de streaming aberta indefinidamente."** Errado: tem duração limitada; é preciso reconectar.
- **"Azure em tempo real processa só arquivos gravados e devolve só o final."** Errado: isso é lote.
- **"Reconhecimento contínuo do Azure para no primeiro silêncio."** Errado: isso é o enunciado único; o contínuo exige o método de parada.
- **"Enunciado único para sessões longas."** Errado: sessões longas pedem o contínuo.
- **"Tempo limite inicial de silêncio o menor possível em sessões com longas pausas."** Errado: deve ser maior.
- **"Amazon Transcribe só transcreve arquivos do S3."** Errado: também faz streaming.

- **"Amazon: mesmos recursos e idiomas no lote e no fluxo."** Errado: há diferenças (legendas, por exemplo, só no lote).
- **"Compressão com perdas melhora a precisão."** Errado: recomendam-se formatos sem perdas (FLAC, PCM).
- **"Taxa de amostragem mais alta sempre melhora."** Errado: taxa moderada, como 16 kHz, basta.
- **"IsPartial verdadeiro = segmento concluído, a guardar."** Errado: verdadeiro é incompleto.
- **Estabilidade alta = mais precisa.** Errado: alta é mais rápida; baixa é mais precisa.
- **"Sem fala, pare de enviar dados."** Errado: continue enviando silêncio.
- **"Diante de LimitExceededException, repita imediatamente."** Errado: tente de novo com espera crescente.
- **"Receber em eventos o texto de um arquivo equivale ao tempo real."** Errado: no tempo real, o áudio ainda está sendo falado.

Itens comentados

- **Item:** Na transcrição em lote (batch), o arquivo de áudio completo é processado depois, de forma assíncrona, o que permite ao modelo usar o contexto inteiro e tende a dar maior precisão que a transcrição em tempo real. **Certo.** Com a gravação pronta, o modelo ouve inclusive o que vem depois de cada palavra e não tem pressa.
- **Item:** Na transcrição em tempo real (streaming), o modelo dispõe de todo o contexto futuro da fala, sem pressão de latência, o que a torna, em regra, mais precisa que a transcrição em lote. **Errado.** Ao vivo, o sistema não conhece o futuro e precisa responder rápido. A vantagem do contexto inteiro é do lote.
- **Item:** Um modelo de ASR causal usa apenas o áudio passado e o presente, o que o torna adequado à transcrição em tempo real, mas tende a lhe custar precisão em relação a um modelo que enxerga o áudio inteiro. **Certo.** É a troca entre rapidez e precisão.
- **Item:** Em reconhecimento de fala, a janela de contexto corresponde ao intervalo entre o fim da fala do orador e a exibição do texto transcrito na tela. **Errado.** Esse intervalo é a latência. A janela de contexto é a quantidade de áudio que o modelo enxerga de uma vez.
- **Item:** Assim como o CTC, o RNN-Transducer (RNN-T) supõe independência condicional entre as saídas, pois não possui componente que consuma os rótulos já emitidos. **Errado.** O RNN-T tem a rede de predição, que consome o que já foi escrito; por isso não supõe independência.
- **Item:** Na transcrição em tempo real, os resultados parciais são definitivos e não podem ser alterados pelo sistema, ao passo que o resultado final é o que ainda pode ser revisto à medida que chega mais áudio. **Errado.** É o contrário: o parcial é provisório; o final é consolidado.
- **Item:** No Google Cloud Speech-to-Text, a diferença entre o reconhecimento síncrono e o assíncrono está na qualidade do resultado: o assíncrono usa modelo menos preciso, em troca de aceitar áudios mais longos. **Errado.** A diferença está no jeito de pedir (esperar na hora ou buscar depois) e no tamanho do áudio, não na qualidade.

- **Item:** O reconhecimento em fluxo do Google Cloud Speech-to-Text pode ser feito tanto por gRPC quanto por requisições REST, à escolha do desenvolvedor. **Errado.** O streaming do Google funciona só por gRPC.
- **Item:** No reconhecimento contínuo do SDK do Azure AI Speech, o serviço encerra o reconhecimento automaticamente ao detectar o primeiro silêncio, sem que o programa precise chamar nenhum método de parada. **Errado.** Parar no silêncio é próprio do enunciado único. No contínuo, o programa chama o método de parada.
- **Item:** Na estabilização de resultados parciais da Amazon Transcribe, o nível de estabilidade alto produz a transcrição mais precisa, ao passo que o nível baixo entrega o texto com maior velocidade, porém com menor precisão. **Errado.** Os níveis foram trocados: estabilidade baixa é mais precisa; alta é mais rápida.
- **Item:** Segundo as boas práticas da Amazon Transcribe para streaming, quando o fluxo de áudio não contém fala, o programa deve interromper o envio de dados até que a fala volte, para economizar banda. **Errado.** A orientação é continuar enviando silêncio, para manter o fluxo no ritmo do tempo real.
- **Item:** A função transcribe() do pacote Whisper lê o arquivo de áudio inteiro e o processa com uma janela deslizante de 30 segundos, o que a torna apropriada a arquivos gravados, e não a fluxo contínuo ao vivo. **Certo.** Para usar o Whisper ao vivo é preciso adaptá-lo, por exemplo, em blocos.
- **Item:** Situação hipotética: Em transmissão ao vivo de sessão com legendas geradas por reconhecimento de fala, o sistema exibe resultados parciais que, em alguns momentos, são alterados quando o sistema recebe mais áudio. Nessa situação, trata-se de comportamento esperado na transcrição em tempo real, e a versão oficial do registro deve ser produzida e revisada posteriormente. **Certo.** Correções do parcial são normais ao vivo; o texto oficial vem depois, com revisão humana.

Resumo para revisar

- Tempo real: processa enquanto a pessoa fala, com resultados parciais; latência baixa, precisão tende a ser menor.
- Lote: processa o arquivo completo depois, de forma assíncrona; usa todo o contexto; tende a ser mais preciso.
- Latência é o atraso entre fala e texto; janela de contexto é quanto áudio o modelo vê de uma vez.
- Mais contexto futuro = mais latência (e, em geral, mais precisão). Há um compromisso entre os dois.
- Modelo causal: só passado e presente; serve ao ao vivo; tende a errar mais.
- RNN-T (Graves, 2012): codificador, rede de predição e rede conjunta; não supõe independência (o CTC supõe); emite em fluxo.

- Seq2seq com atenção (LAS): gera símbolo a símbolo, mas a atenção sobre a frase inteira cria latência.
- Whisper `transcribe()`: arquivo inteiro, janela deslizante de 30 s; ao vivo exige adaptação.
- Parcial = provisório; final = consolidado. Guarde o final. Oscilações ao vivo são normais; o registro oficial é revisado depois.
- Nuvem: síncrono (curto), assíncrono (gravação longa), streaming (ao vivo). Os modos não mudam a qualidade.
- Google: streaming só por gRPC, conexão com duração limitada (reconectar); síncrono recomendado para arquivos locais curtos.
- Azure: tempo real com resultados intermediários; lote assíncrono (minutos a horas, resultado em contêiner); transcrição rápida síncrona, mais rápida que o tempo real.
- Azure SDK: enunciado único para no silêncio; contínuo usa Recognizing, Recognized e Canceled e só para com o método de parada.
- Silêncio de segmentação curto demais corta frases; tempo limite inicial deve ser maior quando há longas pausas.
- Amazon Transcribe: lote (arquivos no S3) e streaming; recursos e idiomas diferem; legendas só no lote.
- Amazon streaming: SDKs (preferidos), HTTP/2, WebSockets, console; FLAC, Opus em Ogg, PCM 16 bits; prefira sem perdas; 16 kHz basta.
- Blocos pequenos; continue enviando silêncio; segmentos por pausa ou troca de falante.
- IsPartial verdadeiro = incompleto; falso = concluído, com confiança. Stable falso = ainda pode mudar.
- Estabilização: só as últimas palavras mudam; baixa = mais precisa, alta = mais rápida.
- LimitExceededException: tentar de novo com espera crescente; sessões longas exigem reabrir conexões sem perder áudio.
- OpenAI: tempo real pela Realtime API (WebSocket no servidor, WebRTC no navegador); texto provisório e depois final. Entregar em eventos o texto de um arquivo pronto não é tempo real.

TEMA 7 DE 20

Ferramentas e APIs: Whisper, Google, Azure e AWS

58 perguntas no app · Reconhecimento de fala

O que cai

O edital pede, no item 1.8, "Ferramentas e APIs: Whisper (OpenAI), Google Speech-to-Text, Azure Speech, AWS Transcribe". As perguntas cobram detalhes da documentação oficial de cada ferramenta, e se concentram em:

- **Whisper**: código aberto (licença MIT), multilíngue e multitarefa (transcreve, traduz para o inglês, identifica o idioma), janelas de 30 segundos, **não faz diarização**, modelo **turbo**, modelos só de inglês, ffmpeg, tamanho do modelo x memória da placa de vídeo.
- **API de transcrição da OpenAI**: limite de **25 MB**, formatos aceitos, como dividir arquivos grandes, prompt e recursos que **variam conforme o modelo**.
- **Azure AI Speech**: Whisper no Azure, transcrição em lote (modelo personalizado, identificação de idioma, locale, retenção, contêiner, webhooks, diarização em mono), transcrição rápida e API REST de áudio curto.
- **Google Cloud Speech-to-Text**: adaptação de modelo (**boost**, **PhraseSet**, **CustomClass**, n-gramas), diarização e áudio longo no Cloud Storage.
- **Amazon Transcribe**: vocabulário personalizado (por região, sem dados pessoais), lote a partir do **S3**, diarização em lote e fluxo, Transcribe Medical e **Call Analytics**.

A banca cria o item errado com "apenas", "exclusivamente", "qualquer", "todos os modelos" e trocando um recurso de uma ferramenta pela de outra.

Entenda o tema

Para que servem essas ferramentas

Um órgão que precisa transcrever sessões tem dois caminhos:

- **Usar uma API em nuvem**: você envia o áudio para o serviço de uma empresa (Google, Microsoft, Amazon, OpenAI) e recebe o texto. **API** (interface de programação de aplicações) é a "porta" pela qual um programa conversa com outro.
- **Rodar um modelo localmente**: instalar o modelo nos computadores do próprio órgão. Assim o áudio **não sai de casa**, o que ajuda na proteção de dados.

O Whisper permite os dois caminhos. Google, Azure e Amazon são serviços em nuvem.

Whisper (OpenAI)

O que é. O Whisper é um modelo de reconhecimento de fala **de código aberto**, apresentado pela OpenAI em 2022 (Radford e colegas, *Robust Speech Recognition via Large-Scale Weak Supervision*). Foi treinado com um **grande volume de áudio da internet, em muitos idiomas e várias tarefas** (treino multilíngue e multitarefa).

Código aberto. O código e os **pesos** (os números aprendidos no treino, que são o modelo em si) estão sob a **licença MIT**, que é permissiva. Por isso:

- qualquer pessoa pode baixar e **executar localmente**, sem enviar o áudio a terceiros;
- a **API paga** da OpenAI é só **uma** das formas de usar o Whisper, não a única.

> **Pegadinha:** "O Whisper é proprietário, com pesos fechados, disponível exclusivamente por API paga, sem execução local." Errado. É aberto e roda no computador do órgão.

O que ele faz. Um só modelo executa várias tarefas:

1. **reconhecimento de fala multilíngue** (transcreve o português direto em português);
2. **tradução de fala para o inglês**;
3. **identificação do idioma** falado;
4. **detecção de atividade de voz** (perceber onde há fala e onde há só silêncio ou ruído).

Para saber qual tarefa executar, o decodificador recebe **tokens especiais** no início (códigos que dizem "transcreva", "traduza", "o idioma é português").

> **Pegadinha:** "O Whisper foi treinado só com inglês e transcreve outras línguas depois de traduzi-las internamente para o inglês." Errado. Ele foi treinado com muitas línguas e transcreve cada uma no próprio idioma. A tradução para o inglês é uma tarefa separada, usada quando se pede.

O que ele não faz: diarização. Diarização é separar as vozes e dizer **quem falou** cada trecho. O Whisper, sozinho, **não faz diarização**: entrega o texto sem indicar os falantes. Para isso, combina-se o Whisper com outra ferramenta.

Janelas de 30 segundos. O Whisper analisa o áudio em **janelas de 30 segundos**. A função `transcribe()` **lê o arquivo inteiro** e avança de 30 em 30 segundos (janela deslizante) até o fim. O usuário **não precisa recortar** a gravação.

> **Pegadinha:** "O `transcribe()` processa só os primeiros 30 segundos; é preciso recortar o resto manualmente." Errado. Ele percorre o arquivo todo.

Uso em nível mais baixo. Além do `transcribe()`, o repositório mostra o uso etapa por etapa: carregar e ajustar o áudio (cortar ou completar para 30 s), calcular o **espectrograma log-Mel** (uma "imagem" do som, que mostra a energia de cada faixa de frequência ao longo do tempo), chamar `detect_language()` para estimar o idioma e usar `decode()` para decodificar o texto.

ffmpeg. O pacote Whisper **exige** a ferramenta de linha de comando **ffmpeg** instalada no sistema. É ela que **abre e converte** os arquivos de áudio para o modelo ler.

Tamanhos do modelo. O Whisper vem em vários tamanhos (tiny, base, small, medium, large e turbo). Modelos **maiores** (mais parâmetros) costumam acertar mais, mas são mais lentos e **exigem mais memória da placa de vídeo** (GPU). Num servidor próprio, a memória disponível entra na escolha: o modelo grande pode **não caber** em hardware modesto.

Modelos só de inglês. Há variantes terminadas em `.en`, treinadas só com inglês. Elas tendem a ter **desempenho melhor em inglês** do que as multilíngues de mesmo tamanho, **sobretudo nos modelos menores**. Mas **não servem para português**.

Modelo turbo. É uma versão otimizada do **large-v3**. Ganha velocidade principalmente porque tem um **decodificador com muito menos camadas**. Faz sentido: o Whisper "escuta" o áudio de uma vez (codificador), mas **escreve o texto token a token** (decodificador), e essa geração é a etapa mais demorada. Encolher o decodificador acelera tudo, com pequena perda de precisão.

> **Atenção:** o turbo **não foi treinado para tradução**. Se você pedir tradução, ele devolve o texto no idioma original. Para traduzir para o inglês, o repositório indica o **medium** ou o **large**.

API de transcrição da OpenAI

Além do Whisper aberto, a OpenAI oferece uma **API de transcrição de arquivos** em nuvem.

- **Tamanho máximo do arquivo: 25 MB.**
- **Formatos aceitos**: mp3, mp4, mpeg, mpga, m4a, wav e webm.
- **Arquivo maior que 25 MB**: comprimir ou dividir em pedaços. Ao dividir, a documentação manda **evitar cortar no meio de frases**, porque isso tira o contexto do modelo; o ideal é cortar em **pausas naturais**.

Prompt. Dá para enviar um texto de apoio (*prompt*) junto com o áudio, por exemplo com a grafia correta de nomes e siglas. Mas o recurso **varia conforme o modelo**: em alguns ajuda mais, em outros menos, e há modelo que não o aceita. O grau de controle sobre estilo e grafia **depende do modelo escolhido**.

Recursos por modelo. Os modelos da API **não têm os mesmos recursos**. A **marcação de tempo por palavra**, por exemplo, não existe em todos. Quem troca de modelo precisa **conferir a documentação**.

Microsoft Azure AI Speech

Whisper dentro do Azure

O Whisper aparece em **dois** lugares do Azure:

- no **Azure AI Speech**, pela **API de transcrição em lote**, disponível num **subconjunto** das regiões que oferecem o lote (não em todas);
- no **Azure OpenAI**, por uma API síncrona.

> **Pegadinha:** "O Whisper só pode ser usado no Azure pelo AI Speech, pois o Azure OpenAI não o oferece." Errado: os dois oferecem.

Transcrição em lote: regras de configuração

A transcrição em lote do Azure recebe arquivos gravados e devolve os resultados depois. As perguntas cobram estes detalhes:

- **Modelo**: se a propriedade `model` **não for informada**, o serviço usa o **modelo de base padrão** do idioma. A requisição **não** é rejeitada. Só se informa o modelo para usar um específico.
- **Modelo personalizado (custom speech)**: no lote, basta indicar o modelo no pedido; **não é preciso publicar um endpoint de implantação hospedado** (um endereço ligado o tempo todo). Isso economiza recursos quando o modelo só é usado em lote.
- **Identificação de idioma + modelo personalizado**: se os dois forem pedidos na mesma requisição de lote, o **modelo personalizado é ignorado** e entram os **modelos de base** dos idiomas candidatos. Para combinar os dois, use o tempo real.
- **Idiomas candidatos (`candidateLocales`)**: na identificação de idioma, informam-se **no mínimo 2 e no máximo 10** localidades candidatas, **incluída a localidade principal**.
- **Locale**: o idioma (localidade) definido na **criação** do trabalho **não pode ser alterado** depois. Errou o idioma? Crie outra transcrição. Só o **nome de exibição** pode ser editado.
- **Retenção**: os resultados **não ficam guardados para sempre**. O serviço os apaga depois de um **prazo de retenção definido pelo cliente**. Quem precisa guardar o texto tem de **copiá-lo para armazenamento próprio**.
- **Contêiner de destino (`destinationContainerUrl`)**: se **não** for informado, os resultados ficam num **contêiner gerenciado pela Microsoft** e **são apagados quando o trabalho é excluído**. Para mantê-los, aponta-se um **contêiner próprio**.
- **Webhooks**: em vez de **consultar periodicamente** o estado da transcrição, o cliente pode registrar **webhooks** (endereços que o serviço chama para avisar) e ser avisado quando a transcrição em lote **terminar com sucesso ou falhar**. No cadastro, o serviço envia um **token de validação**, e o sistema do cliente deve devolvê-lo **como texto puro** no corpo da resposta. Devolvê-lo em JSON faz o registro falhar, sem mensagem clara.
- **Diarização no lote**: destina-se a gravações em **canal mono** (um canal só) com várias vozes misturadas. **Não** é para gravação **estéreo**, em que cada canal já pode separar os falantes. Para mais de dois falantes, informa-se quantos podem estar falando.

> **Exemplo:** a gravação de uma audiência pública captada por um único microfone de ambiente é mono, com todas as vozes juntas: aí a diarização ajuda. Uma ligação gravada com o atendente num canal e o cidadão no outro é estéreo: o próprio canal já diz quem fala.

Transcrição rápida (fast transcription)

- Aceita arquivos em **vários formatos**: WAV, MP3, OPUS/OGG, FLAC, AAC, WebM, entre outros.
- Devolve o resultado de forma **síncrona** e **apenas na forma de exibição** (texto pronto para leitura, com pontuação e maiúsculas).

- **Estéreo**: por padrão, os canais são **misturados em um só**. Para transcrever cada canal separadamente, é preciso **indicar os canais** na requisição.
- Admite uma `phraseList`: uma lista de frases (nomes de pessoas, termos específicos) que **melhora o reconhecimento** desses termos.

API REST para áudio curto

Como o nome diz, aceita áudio **curto**: **até 60 segundos**. **Não** serve para sessões longas, que pedem o **lote**, a **transcrição rápida** ou o **reconhecimento contínuo** do SDK.

Google Cloud Speech-to-Text

Adaptação de modelo

Adaptação de modelo é "ensinar" o reconhecedor a dar mais chance a certas palavras e frases (nomes de parlamentares, siglas, jargão). Os elementos são:

- **PhraseSet**: o conjunto de frases que se quer favorecer.
- **CustomClass** (classe personalizada): uma **lista de itens relacionados**, como nomes de restaurantes ou de deputados, que pode ser **referenciada dentro das frases** do PhraseSet. É a forma **recomendada** para **grandes grupos de nomes**, em vez de cadastrar cada nome como frase isolada.
- **Boost**: o "peso" dado a uma frase.

Como usar o boost.

- O valor certo **se encontra por experimentação**, comparando transcrições com valores diferentes, porque o efeito depende do áudio e das frases.
- Boost **mais alto não é sempre melhor**: aumenta os **falsos positivos** (o sistema "ouve" a frase onde ela não existe).
- O efeito padrão da adaptação é **pequeno**, sobretudo em **frases de uma palavra só**; em geral, é preciso **subir o boost** e testar.
- Se o boost numa frase de várias palavras não bastar, a documentação sugere **acrescentar os bigramas** (pares de palavras vizinhas) e outros **n-gramas** da frase como itens separados.

Limites. Há limites de **quantidade e de tamanho** de frases. Isso obriga a **selecionar e organizar** os termos, por exemplo agrupando itens da mesma categoria em classes personalizadas.

> **Dica:** CustomClass é a "gaveta" (lista de nomes); PhraseSet é a "frase com a gaveta dentro"; boost é o "volume" com que o sistema presta atenção nelas.

Diarização no Google

Na **versão 2** da API, a diarização é ativada pelo campo `diarization_config` de `RecognitionFeatures`, informando as contagens **mínima e máxima de falantes**. Cada palavra volta com uma **etiqueta de falante**. Funciona no reconhecimento **síncrono** e também no **em fluxo**; o que limita é o **idioma** (nem todos têm o recurso).

Áudio longo

O áudio enviado **diretamente no corpo da requisição** tem **limite de tamanho**. Áudios longos devem ser guardados no **Cloud Storage** e **referenciados por endereço** no pedido. Esse limite **não vale** para o arquivo no Cloud Storage; não é preciso picotar a gravação.

Amazon Transcribe (AWS)

Lote a partir do S3

Na transcrição **em lote**, o arquivo precisa estar guardado no **Amazon S3** (o armazenamento da AWS) antes do pedido. O lote **não** lê arquivos direto do computador do usuário. O áudio que chega ao vivo vai pela outra modalidade, o **streaming**.

Vocabulário personalizado

- É um **recurso criado previamente** e **referenciado pelo nome** em cada trabalho; a mesma lista serve a várias sessões.
- É **regional**: só funciona **na região da AWS em que foi criado**. Para usar em outra região, cria-se de novo lá.
- **Não** se deve colocar nele **informações confidenciais**, **dados pessoais (PII)** nem **informações de saúde protegidas (PHI)**. A lista é para siglas, marcas e termos técnicos.

Diarização (partição de falantes)

- Funciona **no lote e no fluxo**.
- Os rótulos (**spk_0**, **spk_1**...) são **genéricos**: distinguem as vozes, mas **não dizem quem é** cada orador. Associar "spk_0" ao nome do Deputado exige **outra fonte** (lista de oradores, ordem da sessão). Isso vale para os serviços de nuvem em geral.

Recursos por modalidade (tabela de recursos)

- **Identificação de idioma** e **identificação de vários idiomas no mesmo áudio**: disponíveis **em lote e em fluxo**.
- **Amazon Transcribe Medical** (versão para saúde): só **inglês dos Estados Unidos** e **sem** identificação de idioma. Não serve para português.
- **Call Analytics** (versão para ligações de atendimento): oferece **análise de sentimento** do falante (depois da chamada e em tempo real) e **redação do próprio áudio** (cobrir no arquivo de som os trechos com dados pessoais). A transcrição **padrão** não faz isso: ela pode ocultar dados pessoais **no texto**, não no áudio.

Quadros para memorizar

Whisper em uma tabela

Ponto	Regra
Licença	código aberto, **MIT** (código e pesos)
Onde roda	localmente ou pela API da OpenAI

Ponto	Regra
Tarefas	transcrição multilíngue, tradução **para o inglês**, identificação de idioma, detecção de atividade de voz
Diarização	**não** faz sozinho
Janela	30 s; `transcribe()` percorre o arquivo todo
Dependência	ffmpeg
Nível baixo	log-Mel, `detect_language()`, `decode()`
Modelos `.en`	melhores em inglês (sobretudo os pequenos); não servem para português
Turbo	large-v3 com decodificador muito menor; rápido; **não traduz** (use medium ou large)
Hardware	modelo maior exige mais memória de GPU
Autoria	Radford e colegas, OpenAI, 2022

API da OpenAI

Ponto	Regra
Tamanho máximo	25 MB
Formatos	mp3, mp4, mpeg, mpga, m4a, wav, webm
Arquivo grande	comprimir ou dividir, sem cortar no meio de frases
Prompt e recursos	variam conforme o modelo

Azure: lote, rápida e REST curta

Recurso	Regra
Whisper	no AI Speech (lote, parte das regiões) e no Azure OpenAI
`model` omitido	usa o modelo de base padrão
Custom speech no lote	dispensa endpoint hospedado
Idioma + modelo personalizado no lote	personalizado ignorado; usa base
`candidateLocales`	2 a 10, incluída a principal
Locale	não muda depois de criado (só o nome de exibição)
Retenção	prazo definido pelo cliente; copie para guardar
Sem `destinationContainerUrl`	contêiner da Microsoft; apagado com o trabalho
Webhook	avisa sucesso ou falha; token devolvido em texto puro
Diarização no lote	mono, não estéreo
Transcrição rápida	vários formatos; síncrona; só forma de exibição; canais misturados por padrão; `phraseList`

Recurso	Regra
REST de áudio curto	até 60 s

Google: adaptação e limites

Elemento	Função
PhraseSet	frases a favorecer
CustomClass	lista de itens relacionados, usada dentro das frases; ideal para muitos nomes
Boost	peso; achar por teste; alto demais gera falsos positivos
Frase de uma palavra	efeito padrão pequeno; subir o boost
Boost insuficiente	acrescentar bigramas e n-gramas
Diarização (v2)	`diarization_config` em `RecognitionFeatures`; mín. e máx. de falantes; síncrono e fluxo
Áudio longo	Cloud Storage, por endereço (limite vale só para o áudio no corpo)

Amazon Transcribe

Ponto	Regra
Lote	arquivos no S3
Vocabulário personalizado	criado antes, usado pelo nome; regional; sem PII, PHI ou dados confidenciais
Diarização	lote e fluxo; rótulos genéricos (spk_0, spk_1)
Identificação de idioma (inclusive vários idiomas)	lote e fluxo
Transcribe Medical	só inglês dos EUA; sem identificação de idioma
Call Analytics	sentimento; redação do áudio
Transcrição padrão	oculta dados pessoais no texto, não no áudio

Conceitos e autores que caem

Por que importa: a banca cobra o nome exato de cada recurso e de quem é cada ferramenta.

- **Whisper**: OpenAI; Radford e colegas, *Robust Speech Recognition via Large-Scale Weak Supervision* (2022); treino com supervisão fraca em larga escala, multilíngue e multitarefa.
- **Pesos**: os parâmetros aprendidos; no Whisper, abertos sob licença MIT.
- **Tokens especiais**: indicam ao decodificador a tarefa e o idioma.
- **Espectrograma log-Mel**: representação do som por faixa de frequência ao longo do tempo; é a entrada do Whisper.
- **Detecção de atividade de voz**: distinguir fala de silêncio ou ruído.

- **Diarização**: identificar quem falou cada trecho.
- **Adaptação de modelo**: favorecer palavras e frases esperadas (Google: PhraseSet, CustomClass, boost; Azure: phraseList; Amazon: vocabulário personalizado).
- **Webhook**: endereço que o serviço chama para avisar um evento.
- **Contêiner**: espaço de armazenamento de arquivos na nuvem.
- **Locale**: código de idioma e região (por exemplo, pt-BR).
- **PII / PHI**: informações pessoais identificáveis / informações de saúde protegidas.
- **Call Analytics**: versão da Amazon Transcribe para chamadas de atendimento.

Pegadinhas da banca

- **"Whisper proprietário, só por API paga, sem execução local."** Errado: código e pesos abertos (MIT); roda localmente.
- **"Whisper treinado só com inglês; traduz internamente antes de transcrever."** Errado: é multilíngue; transcreve cada idioma no próprio idioma.
- **"Whisper faz diarização nativa."** Errado: não identifica falantes por si só.
- **"`transcribe()` só processa os primeiros 30 s."** Errado: percorre o arquivo inteiro em janelas de 30 s.
- **"Turbo é o recomendado para tradução."** Errado: o turbo não foi treinado para traduzir; use medium ou large.
- **"Dividir o arquivo em pontos quaisquer."** Errado: evite cortar no meio de frases.
- **"Todos os modelos da API têm os mesmos recursos (tempo por palavra em qualquer um)."** Errado: varia por modelo.
- **"Whisper no Azure só pelo AI Speech."** Errado: também no Azure OpenAI.
- **"Idioma + modelo personalizado no lote: ambos aplicados."** Errado: o personalizado é ignorado.
- **"Locale pode ser alterado depois."** Errado: só o nome de exibição.
- **"Resultados do lote guardados indefinidamente."** Errado: há prazo de retenção; copie para armazenamento próprio.
- **"Sem `destinationContainerUrl`, os resultados vão para contêiner do cliente e ficam após a exclusão."** Errado: vão para contêiner da Microsoft e somem com o trabalho.
- **"Token do webhook devolvido em JSON."** Errado: texto puro.
- **"Diarização do lote funciona com estéreo, sem informar falantes."** Errado: é para mono; para mais falantes, informa-se o número.
- **"Sem `model`, a requisição é rejeitada."** Errado: usa o modelo de base padrão.
- **"Transcrição rápida transcreve cada canal estéreo separadamente por padrão."** Errado: mistura os canais, salvo indicação.
- **"REST de áudio curto aceita qualquer duração e serve a sessões longas."** Errado: até 60 s.
- **"Boost: quanto maior, melhor."** Errado: gera falsos positivos; ajuste por teste.

- **"Frases de uma palavra têm efeito forte por padrão."** Errado: efeito pequeno; é preciso subir o boost.
- **"Para centenas de nomes, evite classes personalizadas."** Errado: o Google recomenda justamente a CustomClass.
- **"Diarização do Google só no síncrono."** Errado: também em fluxo.
- **"Arquivo no Cloud Storage tem o mesmo limite do áudio no corpo; picote a gravação."** Errado: o limite é do envio direto.
- **"Vocabulário personalizado da AWS é global para a conta."** Errado: é regional.
- **"Lote da Amazon lê direto do computador."** Errado: exige o S3.
- **"Transcribe Medical em português do Brasil."** Errado: só inglês dos EUA.
- **"Diarização da Amazon só em lote."** Errado: lote e fluxo.
- **"Redação do áudio na transcrição padrão."** Errado: é do Call Analytics.

Itens comentados

- **Item:** O Whisper, da OpenAI, é um modelo de ASR de código aberto que faz transcrição em vários idiomas, tradução para o inglês e identificação do idioma, mas não realiza diarização de falantes por si só. **Certo.** Para saber quem falou, combina-se o Whisper com outra ferramenta.
- **Item:** O código e os pesos do Whisper, da OpenAI, são distribuídos sob a licença MIT, o que permite executar o modelo localmente, sem enviar o áudio a um serviço de terceiros. **Certo.** O órgão pode transcrever nos próprios servidores.
- **Item:** Para traduzir para o inglês a fala em português, o repositório oficial do Whisper recomenda o modelo turbo, que foi treinado especificamente para a tarefa de tradução. **Errado.** O turbo não foi treinado para traduzir e devolve o idioma original; para tradução, medium ou large.
- **Item:** O modelo turbo do Whisper ganha velocidade principalmente por ter um decodificador com muito menos camadas que o do large-v3, já que a geração do texto, feita token a token, é a etapa mais demorada da transcrição. **Certo.** Encolher a parte que escreve acelera a transcrição.
- **Item:** Para gravações maiores que o limite de tamanho da API de transcrição da OpenAI, a documentação recomenda dividir o arquivo em pontos quaisquer, sem se preocupar com o corte no meio de frases. **Errado.** Cortar no meio da frase tira contexto; corta-se nas pausas.
- **Item:** Na transcrição em lote do Azure AI Speech, quando a identificação de idioma e um modelo personalizado são especificados na mesma requisição, ambos são aplicados normalmente e o resultado usa o modelo personalizado para cada idioma candidato. **Errado.** O modelo personalizado é ignorado e entram os modelos de base.
- **Item:** Na identificação de idioma da transcrição em lote do Azure AI Speech, a propriedade candidateLocales admite no mínimo duas e no máximo dez localidades candidatas, incluída a localidade principal da transcrição. **Certo.** De 2 a 10, contando a principal.

- **Item:** No cadastro de um webhook para a transcrição em lote do Azure AI Speech, o serviço envia um token de validação, e o sistema do cliente deve devolvê-lo em formato JSON, no corpo da resposta, para concluir o registro. **Errado.** O token volta como texto puro.
- **Item:** A diarização da transcrição em lote do Azure AI Speech funciona com gravações estéreo, nas quais o serviço separa os falantes automaticamente usando os dois canais, sem necessidade de informar o número de falantes. **Errado.** A diarização do lote é para mono, e para mais falantes informa-se quantos podem estar falando.
- **Item:** Na adaptação de modelo do Google Cloud Speech-to-Text, quanto maior o valor de boost aplicado a uma frase, melhor o resultado, pois não há prejuízo em elevá-lo até o máximo prático. **Errado.** Boost alto gera falsos positivos; o valor se acha por teste.
- **Item:** No Google Cloud Speech-to-Text, quando um boost aplicado a uma frase de várias palavras não é suficiente, a documentação sugere acrescentar os bigramas e outros n-gramas dessa frase como itens separados. **Certo.** A frase ganha reforço por partes.
- **Item:** Um vocabulário personalizado criado em qualquer região da AWS pode ser usado em transcrições realizadas em outras regiões, pois o recurso é global para a conta. **Errado.** O vocabulário é regional; é preciso recriá-lo na outra região.
- **Item:** Na diarização dos serviços de transcrição em nuvem, os rótulos atribuídos aos falantes, como spk_0 e spk_1, são identificadores genéricos que distinguem as vozes, mas não revelam quem é cada orador, o que exige associar cada rótulo ao nome do parlamentar por outra fonte. **Certo.** O serviço separa as vozes; o nome vem de outra fonte.
- **Item:** A redação do próprio áudio, que oculta os trechos com informações pessoais, é recurso oferecido pela transcrição padrão da Amazon Transcribe, tanto em lote quanto em fluxo. **Errado.** A transcrição padrão oculta dados no texto; ocultar no áudio é do Call Analytics.

Resumo para revisar

- Whisper: OpenAI, código e pesos abertos (MIT); roda localmente ou pela API.
- Whisper é multilíngue e multitarefa: transcreve, traduz para o inglês, identifica idioma, detecta voz; tokens especiais indicam a tarefa.
- Whisper não faz diarização sozinho.
- Janela de 30 s; `transcribe()` percorre o arquivo inteiro; nível baixo: log-Mel, `detect_language()`, `decode()`; exige ffmpeg.
- Modelo maior = mais memória de GPU. Modelos `.en`: melhores em inglês, inúteis para português.
- Turbo: large-v3 com decodificador enxuto; rápido; não traduz (use medium ou large).
- API da OpenAI: até 25 MB; mp3, mp4, mpeg, mpga, m4a, wav, webm; dividir sem cortar frases; prompt e recursos variam por modelo.
- Azure: Whisper no AI Speech (lote, parte das regiões) e no Azure OpenAI.
- Lote do Azure: sem `model` usa o padrão; custom speech sem endpoint; idioma + personalizado = personalizado ignorado; `candidateLocales` de 2 a 10; locale imutável.

- Lote do Azure: retenção definida pelo cliente; sem contêiner próprio, resultados somem com o trabalho; webhooks com token em texto puro; diarização em mono.
- Transcrição rápida do Azure: vários formatos, síncrona, só forma de exibição, canais misturados por padrão, `phraseList`. REST de áudio curto: até 60 s.
- Google: PhraseSet, CustomClass (muitos nomes), boost por experimentação; boost alto gera falsos positivos; frases de uma palavra têm efeito pequeno; acrescentar n-gramas.
- Google: limites de frases obrigam a organizar termos; diarização v2 em `diarization_config` (mín./máx. de falantes), síncrona e em fluxo; áudio longo no Cloud Storage.
- Amazon: lote a partir do S3; vocabulário personalizado pelo nome, regional, sem PII/PHI.
- Amazon: diarização em lote e fluxo; rótulos genéricos spk_0, spk_1.
- Amazon: identificação de idioma em lote e fluxo; Medical só inglês dos EUA; sentimento e redação do áudio são do Call Analytics.

TEMA 8 DE 20

Transcrição automática, degravação e revisão humana

59 perguntas no app · Degravação e revisão

O que cai

O edital pede, no item 2.1, a "diferença entre transcrição automática, degravação e revisão humana". As perguntas deste tema se concentram em:

- **Os três conceitos**: transcrição automática (saída bruta da máquina), degravação (fala passada a texto segundo as convenções do órgão) e revisão humana (conferência com o áudio). A banca troca um pelo outro.
- **Como a Câmara e o Senado registram as sessões**: prazos do Detaq (texto sem revisão quase em tempo real, cerca de 2 horas, Prévia da Redação Final, 2 dias úteis), retirada do discurso pelo Deputado (RICD, art. 98, § 2º), Diário da Câmara x Diário do Congresso, os "quartos" do Senado.
- **A IA na taquigrafia da Câmara**: Azure em 2023, Whisper large-v3 desde 2026, contratação via SERPRO, WER média de 25%, ganho de cerca de 20% de produtividade, o sistema Escriba, revisão humana obrigatória.
- **Medir a qualidade**: a **WER** (taxa de erro de palavras), como se calcula, faixas da Microsoft, o que cada tipo de erro indica.
- **Limites do Whisper**: alucinação (model card e estudo *Careless Whisper*), desempenho desigual entre sotaques, transferência *zero-shot*, saída já formatada.

A mensagem que se repete: **a máquina faz o rascunho; o registro oficial depende de pessoas**.

Entenda o tema

Três etapas que não se confundem

Transcrição automática é a **saída bruta** do sistema de reconhecimento automático de fala (ASR). É o texto "cru" que a máquina entrega, sem tratamento editorial.

Degravação é a **passagem do registro oral para o texto escrito conforme as convenções do órgão**. Inclui identificar os oradores, seguir as regras de grafia da Casa, tratar as marcas da oralidade (repetições, hesitações), marcar as manifestações do Plenário. Ela pode partir da transcrição automática, mas não é a mesma coisa.

Revisão humana é a **conferência do texto com o áudio**. Uma pessoa escuta a gravação e corrige erros de **reconhecimento** (palavra trocada), de **fidelidade** (trecho que mudou de sentido) e de

forma, antes da **validação final**.

> **Dica:** pense numa reunião de condomínio gravada. O aplicativo do celular gera um texto corrido: é a transcrição automática. O síndico transforma esse texto em ata, com o nome de quem falou e no formato do condomínio: é a degravação. Outro morador ouve a gravação para conferir se a ata está fiel: é a revisão.

Consequências que a banca cobra:

- A transcrição automática, **por si só, não é degravação pronta**: falta a identificação dos oradores, as regras de grafia e o tratamento da oralidade exigidos pelo órgão.
- Mesmo com **diarização** (separação dos falantes) e **pontuação automática**, o texto da máquina continua bruto. Recursos automáticos bons **não dispensam** as convenções do órgão nem a revisão humana.
- A revisão **não se limita** a aplicar convenções editoriais: o coração dela é **ouvir o áudio**. Sem ouvir, o revisor não descobre o que a máquina entendeu errado.
- A degravação **não é** a etapa final de conferência com o áudio; isso é a revisão.

Manifestações do Plenário. Palmas, vaias, risos e tumulto **não se misturam à fala do orador**. São anotados **em separado**, de forma distinta, conforme a regra do órgão. Misturar faria parecer que o orador disse o que foi, na verdade, reação do público.

Como a Câmara publica os discursos

O **Detaq** (Departamento de Taquigrafia, Revisão e Redação da Câmara) descreve, no seu rol de produtos e serviços (2009), uma publicação **em etapas**:

1. **Texto sem revisão, quase em tempo real.** As notas taquigráficas dos discursos em Plenário são divulgadas no portal **quase em tempo real**, **antes de qualquer revisão**. Existe, portanto, publicação provisória.
2. **Troca automática pela versão revisada.** O discurso sem revisão permanece no portal, em média, **cerca de duas horas** e é **substituído automaticamente** pela forma revisada. Ele não fica para sempre ao lado da revisada.
3. **Prévia da Redação Final.** É a divulgação **na íntegra** das notas taquigráficas de uma sessão plenária **ainda sem redação final**, feita após o encerramento da sessão, em média **cerca de duas horas depois**.
4. **Redação final.** As notas taquigráficas da sessão **com redação final** são divulgadas na íntegra em **no máximo dois dias úteis após a divulgação da Prévia**.

> **Atenção:** a Prévia é o texto **sem** redação final. Os **dois dias úteis** são o prazo da versão **com** redação final, contados da Prévia.

Em página mais recente, a Câmara informa que o **apanhamento e a divulgação** dos discursos proferidos no Plenário ocorrem em **até 30 minutos** após o pronunciamento. Não é preciso esperar 48 horas para consultar um discurso; a espera é só para a versão final.

O Deputado pode revisar o próprio discurso. O Regimento Interno da Câmara garante ao Deputado retirar o discurso na Taquigrafia para revisão. A revisão, portanto, não é atribuição exclusiva dos revisores do Departamento.

> **Lei seca:** RICD, art. 98, § 2º: "Ao Deputado é licito **retirar na Taquigrafia, para revisão, o seu discurso**, não permitindo a publicação na ata respectiva. Caso o orador não devolva o discurso dentro de **cinco sessões**, a Taquigrafia dará à publicação o texto sem revisão do orador."

Onde se publica. O **Diário da Câmara dos Deputados** é o veículo oficial das **sessões da Câmara**. As **sessões conjuntas** e as **do Congresso Nacional** saem no **Diário do Congresso Nacional**. A banca troca os dois.

Como o Senado registra as sessões

No Senado, a gravação é dividida em **"quartos"**: blocos de **quatro minutos** de áudio, transcritos **um de cada vez** por servidores (vários trabalham ao mesmo tempo em quartos diferentes). Depois cada quarto é **revisado**, para corrigir incorreções textuais e imprecisões, e só então os blocos são reunidos (a "amarração"). A revisão **não é pulada**.

Segundo o Senado Notícias (2021), as notas taquigráficas são entregues no **intervalo tradicional de 30 a 90 minutos**, a cargo da **Secretaria de Registro e Redação Parlamentar**. Não são dias úteis: são minutos.

A IA na taquigrafia da Câmara

Linha do tempo. Segundo apresentação da Câmara à ParlAmericas (abril de 2026):

- a **primeira adesão** à transcrição automática foi em **2023**, com o **Azure, da Microsoft**;
- o **motor atual**, desde **2026**, é o **Whisper large-v3**;
- a **contratação atual** é feita **via SERPRO**.

> **Pegadinha:** a banca inverte: "Whisper em 2023 e Azure desde 2026". Errado. **Azure primeiro (2023), Whisper depois (2026).**

Números da apresentação.

- Tempo médio da transcrição automática: cerca de **2 minutos e 10 segundos para cada trecho de 4 minutos** de áudio.
- **WER média de 25%** nos testes (precisão média de cerca de **75%**), com forte variação conforme o contexto: **de 8% a 50%** de WER (Plenário, comissões e audiências públicas se comportam de forma diferente). Os 8% foram o **melhor caso**, não a média.
- A automação **reconfigurou o processo de trabalho** sem substituir a redação humana qualificada e elevou a **produtividade em cerca de 20%**, **mesmo com redução de pessoal**.
- O texto do ASR **volta ao sistema Escriba** e passa pela **redação final humana**; a revisão é **obrigatória** em todo texto transcrito. O texto da máquina **não** é publicado diretamente como registro oficial.

O sistema Escriba e os dois motores. Um artigo da série *Agenda Brasileira* (Edições Câmara, 2025) descreve como o sistema da Câmara usa os modelos:

- O **Whisper é o motor padrão**. Ele é **propenso à alucinação**: em áudios **ruidosos** ou com **silêncios extensos**, pode gerar **palavras repetidas** ou **inserir palavras não faladas**.
- Quando o **Escriba detecta repetição excessiva** na saída do Whisper, ele **pede automaticamente uma nova transcrição ao Azure Speech**, da Microsoft. O trecho não é deixado em branco.
- O **Azure Speech** costuma gerar transcrições **menos corretas** que o Whisper, mas **mais consistentes** ao longo do áudio (não "se perde"). Por isso é a segunda opção.

> **Dica:** Whisper = mais correto, mas às vezes "delira"; Azure = erra um pouco mais, mas é estável. Padrão: Whisper. Reserva: Azure.

Linha de frente e retaguarda. Segundo o mesmo artigo:

- os taquígrafos da **retaguarda**, que transcrevem a partir dos áudios, obtêm dos modelos **apenas um esboço inicial** do discurso, dada a quantidade de erros;
- os da **linha de frente** (no Plenário) **continuam necessários** para registrar **falas não captadas pelos microfones** (apartes fora do microfone, manifestações).

Os modelos **ainda não atingem** o padrão de qualidade da Câmara sem revisão.

Visão da direção. Em 2023, a diretora do departamento de taquigrafia declarou que a IA deve ser um **auxílio no registro inicial** dos discursos, com o trabalho passando **depois pelo taquígrafo**. Ela não previu o fim da revisão humana.

Medir a qualidade: a WER

A **WER** (*Word Error Rate*, taxa de erro de palavras) é a medida padrão de qualidade do reconhecimento de fala. Compara o texto da máquina com uma **transcrição de referência**, feita e conferida por **pessoas**.

Há três tipos de erro:

- **Inserção**: a máquina **acrescentou** uma palavra que não foi dita.
- **Deleção** (omissão): a máquina **deixou de fora** uma palavra dita.
- **Substituição**: a máquina **trocou** uma palavra por outra.

A fórmula, pela definição da Microsoft:

> **Atenção:** WER = (inserções + deleções + substituições) ÷ **número de palavras da transcrição de referência**. O denominador é o texto **correto**, rotulado por pessoas, e **não** o texto gerado pela máquina.
>
> **Exemplo:** a referência tem 100 palavras. A máquina acrescentou 3, omitiu 4 e trocou 8. WER = (3 + 4 + 8) ÷ 100 = 15%.

Quanto menor, melhor. WER é taxa de **erro**. As faixas indicadas pela Microsoft:

WER	Leitura
5% a 10%	boa qualidade, pronto para uso
cerca de 20%	aceitável, mas vale considerar mais treino
30% ou mais	qualidade ruim; exige personalização e treino

O que cada erro sugere (segundo a Microsoft):

- muitas **deleções**: **sinal de áudio fraco** (o microfone não pegou bem a voz);
- muitas **inserções**: ambiente **ruidoso**, com possível **crosstalk** (vozes sobrepostas, conversa ao fundo);
- muitas **substituições**: faltam na base de treino **amostras de termos do domínio** (vocabulário da área, como o jargão parlamentar).

> **Dica: D**eleção = **D**ébil (som fraco, a palavra some). **I**nserção = **I**ntrusos (barulho e vozes extras viram palavras). **S**ubstituição = **S**em vocabulário.

Uma **WER alta, por si só, não diz a causa**. Analisar os tipos de erro e as condições do áudio ajuda a decidir se é melhor **personalizar o modelo** (ensinar vocabulário) ou **melhorar a captação** (microfone, acústica).

Limites do Whisper que justificam a revisão

Alucinação. O próprio **model card** do Whisper (documento oficial que descreve o modelo, seus usos e limites) reconhece que as predições podem incluir **texto que não foi falado** no áudio. Isso se chama **alucinação**. O documento recomenda **avaliar o modelo** no contexto de uso antes de implantar; não há garantia de fidelidade.

Careless Whisper. O estudo *Careless Whisper: Speech-to-Text Hallucination Harms* (Koenecke e colegas, FAccT 2024) mostrou que as alucinações do Whisper, **embora pouco frequentes**, podem inserir **frases inteiras** não ditas, **inclusive com conteúdo danoso** (violência, informações falsas). Elas aparecem mais em **trechos de silêncio** e foram **mais frequentes em falantes com afasia** (distúrbio de linguagem que causa pausas longas) do que no grupo de controle: há relação com a **duração das pausas**. Conclusão: registro oficial precisa de **revisão humana**, sobretudo nos silêncios.

Sotaques e idiomas. O model card aponta **desempenho díspar entre sotaques e dialetos** de uma mesma língua e **acurácia menor em idiomas de baixos recursos** (com pouco material de treino). Por isso é preciso **testar com falantes reais** (por exemplo, brasileiros de várias regiões) antes de implantar.

Zero-shot. O artigo que apresentou o Whisper (Radford e colegas; publicado no ICML 2023) mostra que ele funciona em **transferência zero-shot**: transcreve conjuntos de teste que **não usou no treino**, **sem ajuste fino** específico. Ainda assim, o **ajuste a um domínio**, como o parlamentar, **pode melhorar** o resultado.

Forma lexical x forma de exibição. Alguns serviços devolvem duas versões do texto: a **lexical** (palavras cruas, sem pontuação nem formatação) e a **de exibição** (com pontuação, maiúsculas e

números em algarismos). Mas **nem todo modelo** faz isso. O **Whisper** entrega **diretamente a forma de exibição**, sem forma lexical separada. Por isso o revisor precisa conferir **as palavras e também a formatação** produzida pelo modelo.

Quadros para memorizar

Transcrição, degravação e revisão

Etapa	O que é	Quem faz
Transcrição automática	saída bruta do ASR	máquina
Degravação	fala passada a texto conforme as convenções do órgão (oradores, grafia, oralidade, manifestações)	pessoa, a partir ou não da máquina
Revisão humana	conferência com o áudio: reconhecimento, fidelidade e forma, antes da validação	pessoa

Prazos de publicação

Casa / fonte	Produto	Prazo
Câmara (Detaq, 2009)	discurso sem revisão no portal	quase em tempo real
Câmara (Detaq, 2009)	permanência do texto sem revisão	cerca de 2 h, depois trocado automaticamente
Câmara (Detaq, 2009)	Prévia da Redação Final (sessão inteira, sem redação final)	cerca de 2 h após o fim da sessão
Câmara (Detaq, 2009)	sessão com redação final	até 2 dias úteis após a Prévia
Câmara (página atual)	apanhamento e divulgação do discurso	até 30 min
Câmara (RICD, art. 98, § 2º)	devolução do discurso retirado pelo Deputado	5 sessões; depois, publica-se sem revisão do orador
Senado (2021)	notas taquigráficas	30 a 90 min
Senado	"quartos"	blocos de 4 min, transcritos e revisados

IA na Câmara (ParlAmericas, 2026, e Agenda Brasileira, 2025)

Ponto	Dado
Primeira adesão	2023, Azure (Microsoft)
Motor atual	Whisper large-v3, desde 2026
Contratação	via SERPRO
Tempo de máquina	cerca de 2 min 10 s por trecho de 4 min

Ponto	Dado
WER média	25% (precisão cerca de 75%); faixa de 8% a 50%
Produtividade	cerca de +20%, mesmo com menos pessoal
Revisão	redação final humana obrigatória (Escriba)
Repetição excessiva no Whisper	Escriba pede nova transcrição ao Azure
Azure x Whisper	Azure menos correto, mais consistente
Retaguarda / linha de frente	esboço inicial / falas fora do microfone

WER

Ponto	Regra
Fórmula	(I + D + S) ÷ palavras da **referência**
Melhor	menor
5% a 10%	bom, pronto para uso
30% ou mais	ruim, personalizar e treinar
Muitas deleções	áudio fraco
Muitas inserções	ruído, crosstalk
Muitas substituições	falta vocabulário do domínio

Conceitos e autores que caem

Por que importa: a banca cobra o nome do conceito, do estudo e de quem disse o quê.

- **Transcrição automática**: saída bruta do ASR.
- **Degravação**: registro oral passado a texto conforme as convenções do órgão.
- **Revisão humana**: conferência do texto com o áudio antes da validação.
- **Notas taquigráficas**: o texto produzido pela taquigrafia a partir das falas da sessão.
- **Prévia da Redação Final**: íntegra da sessão sem redação final (Detaq).
- **Quartos**: blocos de 4 minutos no registro do Senado.
- **WER (Word Error Rate)**: (inserções + deleções + substituições) ÷ palavras da referência.
- **Crosstalk**: vozes sobrepostas ou conversa paralela captada pelo microfone.
- **Model card**: documento oficial que descreve um modelo, seus usos e limites.
- **Alucinação**: texto que não foi falado no áudio.
- **Careless Whisper**: Koenecke e colegas, FAccT 2024; alucinações raras, mas às vezes danosas, ligadas a pausas longas (mais em falantes com afasia).
- **Zero-shot**: funcionar em dados novos sem ajuste fino (Radford e colegas, artigo do Whisper).
- **Forma lexical x forma de exibição**: texto cru x texto formatado; o Whisper só entrega a de exibição.

- **Escriba**: sistema da Câmara que recebe o texto do ASR para a redação final humana.
- **Figueiredo (2026)**: apresentação "Inteligência Artificial e Transcrições Inteligentes", da Câmara, à ParlAmericas.
- **Silva e colegas (2025)**: "Uso de inteligência artificial para agilizar o processo legislativo", série Agenda Brasileira, Edições Câmara.

Pegadinhas da banca

- **"Degravação é a saída bruta do ASR."** Errado: a saída bruta é a transcrição automática; degravação segue as convenções do órgão.
- **"Degravação é a conferência final com o áudio."** Errado: isso é revisão humana.
- **"Revisão humana só aplica convenções, sem ouvir o áudio."** Errado: ouvir o áudio é o essencial.
- **"Com diarização e pontuação automática, a transcrição já é degravação pronta."** Errado: faltam convenções e revisão.
- **"Palmas e vaias entram no texto do orador, sem indicação distinta."** Errado: anotam-se em separado.
- **"Notas taquigráficas só saem depois da redação final."** Errado: há publicação provisória quase em tempo real.
- **"O texto sem revisão fica no portal para sempre, ao lado do revisado."** Errado: é substituído automaticamente (cerca de 2 h).
- **"A Prévia da Redação Final é a versão revisada, em até 2 dias úteis."** Errado: a Prévia é sem redação final; os 2 dias úteis são da versão final, contados da Prévia.
- **"É vedado ao Deputado retirar o discurso para revisão."** Errado: RICD, art. 98, § 2º, permite.
- **Diários trocados.** Sessões da Câmara: Diário da Câmara; sessões conjuntas e do Congresso: Diário do Congresso Nacional.
- **"Discurso só disponível 48 horas depois."** Errado: até 30 minutos.
- **"Os quartos do Senado vão direto para a amarração, sem revisão."** Errado: são revisados.
- **"Senado entrega as notas em 5 a 10 dias úteis."** Errado: 30 a 90 minutos.
- **"Texto do ASR publicado direto como registro oficial."** Errado: passa pela redação final humana.
- **"WER dividida pelas palavras do texto da máquina."** Errado: pelas palavras da referência.
- **"WER de 30% é boa; 5% a 10% pede treino."** Errado: é o inverso.
- **Causas de erro trocadas.** Inserção = ruído e crosstalk; deleção = áudio fraco.
- **"WER média de 8%, sem variação."** Errado: média de 25%, de 8% a 50%.
- **"Model card diz que o Whisper reproduz fielmente só o que foi dito."** Errado: admite alucinação e pede avaliação prévia.
- **"Alucinações raras são sempre inofensivas; dispensa revisão nos silêncios."** Errado: podem ser danosas e surgem justamente nos silêncios.

- **"Careless Whisper: mesma proporção em afásicos e controle, sem relação com pausas."** Errado: mais alucinações com pausas longas.
- **"Escriba deixa o trecho em branco quando há repetição."** Errado: pede nova transcrição ao Azure.
- **"Azure é o padrão por ser mais correto."** Errado: o padrão é o Whisper; o Azure é menos correto e mais consistente.
- **"Modelos já atingem o padrão da Câmara; linha de frente desnecessária."** Errado: são esboço; a linha de frente continua.
- **"A diretora previu o fim da revisão humana."** Errado: IA como auxílio ao registro inicial.
- **"Produtividade +50%, com mais pessoal e sem redação humana."** Errado: cerca de +20%, com menos pessoal, mantida a redação humana.
- **"Whisper em 2023, Azure desde 2026."** Errado: Azure em 2023, Whisper large-v3 desde 2026.
- **"Todo modelo devolve forma lexical e de exibição."** Errado: o Whisper só a de exibição.
- **"Whisper só é competitivo depois de ajuste fino em cada conjunto."** Errado: funciona em zero-shot.
- **"Desempenho uniforme entre sotaques."** Errado: é díspar; teste com falantes reais.

Itens comentados

- **Item:** A transcrição automática é a saída bruta do sistema de ASR; a degravação é a passagem do registro oral para o texto escrito conforme as convenções do órgão; e a revisão humana confere o texto com o áudio. **Certo.** São as três definições que o tema cobra.
- **Item:** Quando produzida por sistema de ASR com diarização e pontuação automática, a transcrição automática já constitui degravação pronta, dispensando a aplicação das convenções do órgão e a revisão humana. **Errado.** O texto da máquina continua bruto; as convenções e a revisão continuam necessárias.
- **Item:** As manifestações do Plenário, como palmas e vaias, devem ser incorporadas ao texto da fala do orador, sem indicação distinta, para não interromper a fluidez da leitura. **Errado.** São anotadas em separado, para não atribuir ao orador a reação do público.
- **Item:** Segundo o Detaq, a Prévia da Redação Final é a versão já revisada e com redação final de uma sessão plenária, divulgada no portal da Câmara no prazo máximo de dois dias úteis após o término da sessão. **Errado.** A Prévia é a íntegra sem redação final; a versão final sai em até dois dias úteis após a Prévia.
- **Item:** Segundo o rol de serviços do Detaq (2009), o Deputado tem a prerrogativa de retirar o seu discurso em Plenário para revisá-lo, conforme o art. 98, § 2º, do Regimento Interno, mediante pedido feito ao Departamento de Taquigrafia. **Certo.** O RICD permite ao Deputado retirar o discurso na Taquigrafia para revisão.
- **Item:** Segundo o Detaq, o registro das sessões conjuntas do Congresso Nacional é publicado no Diário da Câmara dos Deputados, enquanto as sessões exclusivas da Câmara são publicadas

no Diário do Congresso Nacional. **Errado.** Os diários foram trocados.

- **Item:** No registro das sessões do Senado, os quartos são blocos de quatro minutos de gravação transcritos, um de cada vez, por servidores, e depois revisados para a correção de incorreções textuais e imprecisões. **Certo.** Os quartos são transcritos e revisados antes de reunidos.
- **Item:** A WER é calculada dividindo-se a soma das inserções, omissões e substituições pelo número total de palavras do texto gerado pelo sistema de reconhecimento, e não pelo da transcrição de referência. **Errado.** O denominador é a transcrição de referência, feita por pessoas.
- **Item:** Segundo a Microsoft, muitos erros de inserção costumam indicar sinal de áudio fraco, enquanto muitos erros de deleção sugerem gravação em ambiente ruidoso com crosstalk. **Errado.** As causas foram trocadas: deleção indica áudio fraco; inserção indica ruído e crosstalk.
- **Item:** Em testes da Câmara dos Deputados com a ferramenta de transcrição automática, a WER média foi de 25% (precisão média de cerca de 75%), com forte variação conforme o contexto, de 8% a 50% de WER. **Certo.** A média esconde grande variação entre tipos de reunião.
- **Item:** Segundo apresentação da Câmara à ParlAmericas (2026), a primeira adesão da Casa à transcrição automática ocorreu em 2023 com o Whisper, e o motor atual, desde 2026, é o Azure da Microsoft. **Errado.** Foi o contrário: Azure em 2023, Whisper large-v3 desde 2026.
- **Item:** Segundo o artigo da série Agenda Brasileira da Câmara (2025), quando o Escriba detecta repetição excessiva na saída do Whisper, o trecho é descartado e deixado em branco para preenchimento manual, sem nova tentativa de transcrição automática. **Errado.** O Escriba pede automaticamente nova transcrição ao Azure Speech.
- **Item:** O estudo Careless Whisper mostrou que as alucinações do Whisper, embora pouco frequentes, podem inserir na transcrição frases inteiras que não foram ditas, inclusive com conteúdo danoso, o que reforça a necessidade de revisão humana em registros oficiais. **Certo.** Raras, mas graves; por isso a revisão humana.
- **Item:** Alguns modelos de transcrição, como o Whisper, entregam diretamente o texto em forma de exibição, já com pontuação, maiúsculas e números, sem uma forma lexical separada, o que exige que a revisão confira tanto as palavras quanto a formatação produzida pelo modelo. **Certo.** Sem forma lexical, o revisor confere palavras e formatação.

Resumo para revisar

- Transcrição automática = saída bruta do ASR. Degravação = texto conforme as convenções do órgão. Revisão humana = conferência com o áudio.
- Diarização e pontuação automática não transformam a saída bruta em degravação pronta.
- Manifestações do Plenário (palmas, vaias) ficam anotadas em separado da fala do orador.
- Detaq (2009): discurso sem revisão quase em tempo real; substituído pelo revisado em cerca de 2 h; Prévia da Redação Final (íntegra sem redação final) cerca de 2 h após a sessão; versão final em até 2 dias úteis após a Prévia.
- Câmara hoje: apanhamento e divulgação do discurso em até 30 min.

- RICD, art. 98, § 2º: o Deputado pode retirar o discurso na Taquigrafia para revisão; se não devolver em 5 sessões, publica-se sem revisão do orador.
- Diário da Câmara: sessões da Câmara. Diário do Congresso Nacional: sessões conjuntas e do Congresso.
- Senado: quartos de 4 min, transcritos e revisados; notas em 30 a 90 min (Secretaria de Registro e Redação Parlamentar).
- Câmara: Azure em 2023; Whisper large-v3 desde 2026; contratação via SERPRO.
- Câmara: 2 min 10 s de máquina por 4 min de áudio; WER média 25% (8% a 50%); produtividade +20% com menos pessoal; redação final humana obrigatória.
- Escriba: repetição excessiva no Whisper leva a nova transcrição pelo Azure. Azure: menos correto, mais consistente.
- Retaguarda recebe só um esboço; linha de frente continua para falas fora do microfone. IA = auxílio ao registro inicial.
- WER = (inserções + deleções + substituições) ÷ palavras da referência humana. Menor é melhor.
- Microsoft: 5% a 10% bom; 30% ou mais ruim. Deleção = áudio fraco; inserção = ruído/crosstalk; substituição = falta vocabulário do domínio.
- WER alta não diz a causa; analisar erros e áudio para decidir entre personalizar o modelo e melhorar a captação.
- Whisper alucina (model card); Careless Whisper (Koenecke, FAccT 2024): raro, mas pode ser danoso, ligado a pausas longas.
- Whisper: desempenho desigual entre sotaques e pior em idiomas de baixos recursos; funciona em zero-shot, mas ajuste ao domínio ajuda.
- Whisper entrega só a forma de exibição; o revisor confere palavras e formatação.

TEMA 9 DE 20

Degravação assistida por IA (human in the loop)

55 perguntas no app · Degravação e revisão

O que cai

O edital pede, no item 2.2, o "fluxo de trabalho de degravação assistida por IA (Human in the loop)". As perguntas deste tema se concentram em:

- **O conceito**: humano no circuito (*human in the loop*) é o fluxo em que a máquina produz a saída e uma pessoa **revisa, corrige e valida** antes da publicação. A responsabilidade pelo texto final fica com **quem valida**.
- **As etapas, na ordem**: captura do áudio → transcrição automática → revisão → edição → validação. A banca embaralha a ordem.
- **Confiança do sistema não dispensa revisão**: pontuação de confiança alta não garante acerto (Google: de 0,0 a 1,0, inclusive por palavra).
- **O fluxo da Câmara** (apresentação à ParlAmericas, 2026, e artigo da série Agenda Brasileira, 2025): Whisper large-v3, Escriba, redação final humana, revisão obrigatória em **todo** texto, fé pública, nomes próprios, viés contra vozes femininas, fatores de variação, gestão da mudança, nuvem x modelo local, feedback dos usuários.
- **Apoios externos**: Senado (sempre um supervisor humano), model card do Whisper (não usar em alto risco), teste de acurácia com referência humana e áudio fora do treino, art. 20 da LGPD.

Entenda o tema

O que é "humano no circuito"

Humano no circuito é a tradução de *human in the loop*. Descreve um fluxo em que **o sistema de IA faz a primeira versão** e **uma pessoa fica dentro do processo**, conferindo, corrigindo e **aprovando** antes de o resultado ser publicado.

> **Dica:** pense num corretor ortográfico. Ele sublinha e sugere, mas quem decide aceitar a sugestão e quem assina o texto é você. A máquina acelera; a pessoa responde.

Por contraste, "humano **fora** do circuito" seria a máquina publicar sozinha. O desenho em que o profissional revisa e valida é o humano **no** circuito, e é **o recomendado** para o registro parlamentar, em que o texto precisa ser fiel.

Três ideias resumem o conceito:

1. A transcrição automática é **conferida e corrigida por pessoa** antes da validação do texto final.

2. A **validação final** cabe a uma **pessoa responsável**, nunca ao sistema.
3. A **responsabilidade** pelo texto final **não se transfere** à máquina. Quem valida responde pelo que foi publicado. O humano não fica "apenas com a captura do áudio".

As cinco etapas, na ordem

Ordem	Etapa	O que acontece
1	**Captura do áudio**	gravação da sessão; a qualidade aqui define o **piso** de qualidade do resultado
2	**Transcrição automática**	o ASR gera o rascunho (a diarização, separação dos falantes, acontece aqui, junto com a transcrição)
3	**Revisão**	uma pessoa **confere o texto com o áudio**
4	**Edição**	o texto é ajustado ao padrão do órgão
5	**Validação**	a pessoa responsável **aprova** o texto e **responde por ele**

> **Atenção:** a **captura** define o **piso**. Se o som foi mal gravado, nenhuma etapa seguinte faz milagre. Por isso microfone, acústica e gravação importam tanto quanto o modelo.

Erros de ordem que a banca inventa:

- "A transcrição **manual** vem antes da captura, e o ASR revisa o texto da pessoa." Errado: grava-se, a máquina transcreve, a pessoa revisa.
- "Depois da transcrição automática vem a **publicação**; a conferência com o áudio fica para reclamações." Errado: revisão, edição e validação vêm antes de publicar.
- "A última etapa é a **diarização**, em que o sistema aprova o texto." Errado: a última etapa é a **validação**, feita por pessoa; diarização é separar vozes, lá no começo.

> **Exemplo:** na Assembleia fictícia de Vale Verde, o sistema gera o rascunho da sessão com marcas de tempo; a taquígrafa Marta ouve o áudio, corrige o rascunho e valida a versão final. Isso é humano no circuito, e a responsabilidade pelo texto é de Marta, não do sistema.

Confiança do sistema não é garantia

Os sistemas de ASR informam uma **pontuação de confiança**: uma estimativa de quanto o próprio sistema acha que acertou.

- No **Google Cloud Speech-to-Text**, a confiança é um número **entre 0,0 e 1,0** (não de 0 a 100), para a transcrição e também **para cada palavra** reconhecida.
- A confiança é **opinião do próprio sistema**, não prova de acerto. Mesmo com nota alta pode haver nome trocado ou número errado.

> **Pegadinha:** "A revisão pode ser dispensada quando a confiança for elevada, pois a validação é feita pelo próprio sistema." Errado. A confiança serve, no máximo, para **priorizar** o que conferir primeiro. A validação continua humana.

Alucinação na revisão. Se o revisor encontra, num **silêncio prolongado**, uma frase que **ninguém pronunciou**, deve **apagá-la**. Ter sido escrita pelo sistema não significa que ela está no áudio. Os sistemas de ASR, como o Whisper, às vezes inventam texto, sobretudo em silêncios e ruídos.

O fluxo da Câmara dos Deputados

Arquitetura em quatro passos (apresentação da Câmara à ParlAmericas, abril de 2026):

1. **entrada do áudio** das sessões e reuniões;
2. **processamento por IA**, com ASR pelo **Whisper large-v3**;
3. **retorno do texto ao Escriba** (o sistema da Casa);
4. **redação final humana**.

A redação humana vem **depois** da IA, e não antes. A IA não "apenas formata" um texto já redigido.

Revisão obrigatória em todo texto. A revisão humana pelos **analistas de registro e redação** é **obrigatória em todo texto transcrito automaticamente**. Não é por amostragem, não se limita aos trechos de baixa confiança e não vale só para o Plenário: **comissões e audiências públicas** também são revisadas (e é nelas que a máquina tende a errar mais). A revisão figura entre as **medidas de mitigação** dos erros e dos vieses do reconhecimento de fala.

Fé pública. A Câmara apresentou a manutenção do **registro e da redação humana qualificada** como **salvaguarda da fé pública** (a confiança que todos devem poder ter no registro oficial). O motivo não é custo.

Nomes próprios. Para mitigar **erros sistemáticos em nomes próprios**, a Câmara usa **roteiros e retrancas** (documentos de apoio que indicam quem vai falar e sobre o quê) e, no **pós-processamento**, **listas lexicais** e **vocabulários especializados** do domínio legislativo. Não basta trocar o motor de ASR.

Novos problemas de precisão. Os testes da Câmara registraram, além dos erros de palavras, **mudanças indesejadas no texto**, **contrações**, **repetições** e **alucinações**.

Viés contra vozes femininas. A WER (taxa de erro de palavras) é **maior para vozes femininas**. É um padrão **já documentado na literatura internacional**. Causas típicas: **bases de treino com sub-representação de vozes femininas** e diferenças de **timbre** e de **prosódia** (entonação e ritmo da fala).

> **Pegadinha:** a banca inverte para "maior para vozes masculinas, por sub-representação masculina". Errado.

Fatores de variação da acurácia. A taxa de acerto varia conforme:

- ser reunião de **comissão** ou sessão do **Plenário**;
- o **número de membros** do órgão;
- a **fase da sessão**;
- as **audiências públicas**;
- o **início ou o fim da sessão legislativa** (período do ano).

O sotaque **não é o único** fator.

Gestão da mudança antes da capacitação. A Câmara colocou primeiro a **gestão da mudança**, com a **concepção do novo processo de trabalho**, e **depois a capacitação** dos servidores. Uma **equipe qualificada** realiza os **testes**, a **homologação** e a **análise** das soluções.

> **Dica:** primeiro se desenha o novo jeito de trabalhar; depois se treina as pessoas nele. Treinar antes de saber como será o processo é treinar no vazio.

Ações futuras. Aprimorar o **pós-processamento** com listas lexicais e vocabulários especializados, criar uma **ferramenta de pesquisa baseada em RAG** (busca que consulta o acervo antes de gerar a resposta) e a **geração automática de atas**.

O que diz o artigo da série Agenda Brasileira (Câmara, 2025)

- **Duas modalidades de transcrição automática**: uma versão **em nuvem, dedicada ao Detaq**, e uma versão com **modelo processado localmente por GPU** (placa de vídeo em computador da Casa), que **atende às demais áreas** e **substitui a nuvem** quando esta fica indisponível para o Detaq.
- A solução **não é exclusiva do Detaq**: outras áreas, como a **Direx** e a **Coped**, também a usam.
- **Quem desenvolveu**: a **Diretoria de Tecnologia** da Câmara, em alguns casos **com colaboração da academia**. Não foi empresa contratada sozinha.
- **Participação dos usuários**: a percepção de valor nas **reuniões periódicas de avaliação** levou os usuários a participar **mais ativamente** do desenvolvimento.
- **Monitoramento contínuo**: as soluções são **continuamente monitoradas**, também com **feedback dos usuários**, que se mostrou **fundamental** para a implantação. Os modelos não são "treinados uma vez e pronto".
- **Todo modelo tem falhas**, como o ser humano. Por isso o **envolvimento do usuário** é importante para entender **pontos fortes e fracos** e permitir **atualizações e correções**.
- **Mais volume com qualidade**: com os modelos, o volume de trabalho dos taquígrafos ficou **muito maior**, o que permite transcrever, com alto padrão de qualidade, a discussão em **diversas comissões e reuniões**, atendendo aos princípios da **transparência** e da **publicidade**.

O que dizem outras fontes

Senado (Senado Notícias, 2021). Mesmo com avanços como o **reconhecimento de voz dos parlamentares**, a **degravação automatizada** e a **correção por machine learning**, **sempre será preciso haver, no mínimo, um supervisor humano na etapa final**. A supervisão humana não tende a ser eliminada.

Model card do Whisper. O documento oficial do modelo **desaconselha o uso em domínios de alto risco**, como **contextos de decisão**, em que falhas de acurácia podem ter consequências graves, e recomenda **avaliações robustas** antes do uso em cada contexto.

Teste de acurácia (Microsoft).

- Para medir a acurácia, é preciso **áudio representativo** acompanhado de **transcrições de referência feitas por humanos**, que servem de padrão no cálculo da WER. O serviço **não** calcula a WER só a partir do áudio.
- Ao testar um modelo personalizado no **Speech Studio**, escolha um **conjunto de áudio diferente do usado no treino**. Testar com o mesmo áudio do treino faz o modelo parecer melhor do que é.

> **Exemplo:** é como um professor que aplica na prova exatamente os exercícios resolvidos em aula. A nota sobe, mas não mostra se o aluno aprendeu.

LGPD, art. 20. O titular dos dados pode pedir a **revisão de decisões tomadas unicamente com base em tratamento automatizado** de dados pessoais que afetem seus interesses. Atenção: o texto **vigente não exige** que essa revisão seja feita por **pessoa natural**. (Essa exigência chegou a constar de redação anterior, mas não está no texto atual.)

Quadros para memorizar

Fluxo humano no circuito

Etapa	Quem	Ponto-chave
Captura	equipamento e operador	define o piso de qualidade
Transcrição automática	ASR	rascunho (diarização junto)
Revisão	pessoa	confere com o áudio
Edição	pessoa	padrão do órgão
Validação	pessoa responsável	aprova e responde pelo texto

A Câmara em números e nomes

Ponto	O que a Câmara informou
Arquitetura	áudio → IA (Whisper large-v3) → Escriba → redação final humana
Revisão	obrigatória em todo texto, por analistas de registro e redação; Plenário, comissões e audiências
Justificativa	salvaguarda da fé pública
Nomes próprios	roteiros e retrancas; listas lexicais e vocabulários no pós-processamento
Problemas novos	mudanças indesejadas, contrações, repetições, alucinações
Viés	WER maior em vozes femininas (sub-representação, timbre, prosódia)
Fatores de variação	comissão x Plenário, número de membros, fase da sessão, audiências, início/fim da sessão legislativa
Implantação	gestão da mudança antes da capacitação; equipe qualificada testa e homologa
Futuro	pós-processamento, pesquisa com RAG, atas automáticas
Modalidades	nuvem para o Detaq; modelo local em GPU para outras áreas e como reserva

Ponto	O que a Câmara informou
Desenvolvimento	Diretoria de Tecnologia, às vezes com a academia; usuários nas avaliações
Operação	monitoramento contínuo e feedback dos usuários

Outras fontes

Fonte	Mensagem
Senado (2021)	sempre, no mínimo, um supervisor humano na etapa final
Model card do Whisper	não usar em alto risco; avaliar antes de cada uso
Microsoft (teste de acurácia)	referência humana; áudio de teste diferente do de treino
Google	confiança de 0,0 a 1,0, por transcrição e por palavra
LGPD, art. 20	revisão de decisão unicamente automatizada; o texto vigente não exige pessoa natural

Conceitos e autores que caem

Por que importa: a banca cobra o nome do conceito e quem disse o quê.

- **Humano no circuito (human in the loop)**: a máquina produz, a pessoa revisa, corrige e valida antes da publicação.
- **Validação**: aprovação final por pessoa responsável, que responde pelo texto.
- **Pontuação de confiança**: estimativa do próprio sistema sobre o acerto; não garante fidelidade.
- **Fé pública**: confiança que todos devem poder ter no registro oficial.
- **Roteiros e retrancas**: documentos de apoio sobre quem fala e o quê; ajudam a acertar nomes.
- **Listas lexicais e vocabulários especializados**: corrigem termos no pós-processamento.
- **Prosódia**: entonação, ritmo e acento da fala.
- **Gestão da mudança**: desenhar e preparar o novo processo de trabalho, antes da capacitação.
- **RAG**: geração aumentada por recuperação; busca no acervo antes de gerar a resposta.
- **Transcrição de referência**: texto feito por humanos, padrão para calcular a WER.
- **Figueiredo (2026)**: apresentação da Câmara à ParlAmericas sobre IA e transcrições.
- **Silva e colegas (2025)**: artigo da série Agenda Brasileira, Edições Câmara.

Pegadinhas da banca

- **"Confiança alta dispensa a revisão; o sistema valida."** Errado: a validação é humana; confiança não garante acerto.
- **"A responsabilidade passa ao ASR; o humano só capta o áudio."** Errado: responde quem valida.

- **Ordem trocada** (transcrição manual antes da captura; publicação logo após a máquina; diarização como última etapa). Errado: captura, transcrição automática, revisão, edição, validação.
- **"Humano fora do circuito"** para o fluxo em que o profissional revisa e valida. Errado: é humano **no** circuito, o desenho recomendado.
- **"Redação final humana antes da IA."** Errado: vem depois, quando o texto volta ao Escriba.
- **"Revisão só por amostragem" ou "só nos trechos de baixa confiança".** Errado: todo texto é revisado.
- **"Revisão obrigatória só no Plenário."** Errado: vale também para comissões e audiências.
- **"Nomes próprios resolvidos só trocando o motor."** Errado: roteiros, retrancas, listas lexicais e revisão.
- **"Redação humana mantida por custo menor."** Errado: salvaguarda da fé pública.
- **"Só erros de grafia, sem repetições nem alucinações."** Errado: houve mudanças, contrações, repetições e alucinações.
- **"WER maior para vozes masculinas."** Errado: maior para femininas.
- **"Sotaque é o único fator."** Errado: tipo de reunião, número de membros, fase da sessão, audiências, período do ano.
- **"Capacitação antes da gestão da mudança."** Errado: gestão da mudança primeiro.
- **"Soluções dispensam monitoramento após a implantação."** Errado: monitoramento contínuo e feedback.
- **"Modelos de IA não têm falhas relevantes."** Errado: todo modelo tem falhas.
- **"Nuvem para as demais áreas; Detaq só no modelo local."** Errado: nuvem para o Detaq; local para as demais e como reserva.
- **"Uso exclusivo do Detaq."** Errado: Direx e Coped também usam.
- **"Desenvolvido só por empresa contratada."** Errado: Diretoria de Tecnologia, às vezes com a academia, com participação dos usuários.
- **"Supervisão humana tende a ser eliminada" (Senado).** Errado: sempre ao menos um supervisor.
- **"Model card recomenda uso em alto risco."** Errado: desaconselha.
- **"WER sem referência humana."** Errado: exige transcrição de referência.
- **"Testar com o mesmo áudio do treino."** Errado: use áudio diferente.
- **"LGPD, art. 20, caput, exige revisão por pessoa natural."** Errado: o texto vigente não diz isso.
- **"Confiança do Google de 0 a 100, e o máximo garante fidelidade."** Errado: de 0,0 a 1,0, e não garante.
- **"Manter a frase inventada no silêncio, pois veio do sistema."** Errado: o revisor apaga o que não está no áudio.

Itens comentados

- **Item:** No fluxo de transcrição assistido por IA com humano no circuito, a qualidade da captura do áudio define o piso de qualidade do resultado, e a validação final cabe a pessoa responsável. **Certo.** Som ruim limita tudo o que vem depois; e quem aprova é uma pessoa.
- **Item:** No fluxo assistido por IA com humano no circuito, as etapas são: captura do áudio, transcrição automática, revisão, edição e validação. **Certo.** É a ordem do fluxo.
- **Item:** No fluxo assistido por IA com humano no circuito, a última etapa é a diarização, em que o sistema aprova automaticamente o texto já revisado e editado. **Errado.** A última etapa é a validação, por pessoa; diarização é separar vozes, no início.
- **Item:** O fluxo em que o sistema produz a saída e um profissional revisa, corrige e valida antes da publicação é chamado de humano fora do circuito, desenho desaconselhado para o registro parlamentar. **Errado.** É humano no circuito, e é justamente o desenho indicado.
- **Item:** Segundo a Câmara dos Deputados, a revisão humana dos textos transcritos automaticamente é feita apenas por amostragem, limitando-se aos trechos em que o sistema acusa baixa confiança. **Errado.** A revisão é obrigatória em todo texto transcrito.
- **Item:** Segundo a apresentação da Câmara, a WER maior para vozes femininas é um padrão já documentado na literatura internacional, e as causas típicas incluem bases de treinamento com sub-representação de vozes femininas e diferenças de timbre e de prosódia. **Certo.** É o viés de gênero do reconhecimento de fala.
- **Item:** Segundo a Câmara, a capacitação dos servidores ocorre antes da gestão da mudança, ficando a concepção do novo processo de trabalho para depois do treinamento no uso da ferramenta. **Errado.** Primeiro a gestão da mudança e o novo processo; depois a capacitação.
- **Item:** Segundo o artigo da série Agenda Brasileira da Câmara (2025), a versão em nuvem da transcrição atende às demais áreas da Casa, ao passo que o Detaq utiliza exclusivamente o modelo processado localmente por GPU. **Errado.** A nuvem é do Detaq; o modelo local atende às demais áreas e serve de reserva.
- **Item:** Segundo o Senado Notícias (2021), mesmo com avanços de inteligência artificial, como o reconhecimento de voz dos parlamentares, a degravação automatizada e a correção por machine learning, sempre será preciso haver, no mínimo, um supervisor humano na etapa final. **Certo.** A supervisão humana permanece.
- **Item:** Ao testar a acurácia de um modelo personalizado no Speech Studio, convém escolher o mesmo conjunto de áudio usado no treinamento, para garantir a comparabilidade e obter a medida mais realista do desempenho. **Errado.** O teste realista usa áudio diferente do treino.
- **Item:** De acordo com o art. 20 da LGPD, o titular dos dados tem direito a solicitar a revisão de decisões automatizadas, que deve ser obrigatoriamente realizada por pessoa natural, conforme prevê expressamente o caput do dispositivo. **Errado.** O caput garante o pedido de revisão, mas não exige que ela seja feita por pessoa natural.

- **Item:** Segundo a documentação do Google Cloud Speech-to-Text, o nível de confiança da transcrição é um número entre 0 e 100, e um valor máximo garante a fidelidade do texto, dispensando a conferência humana. **Errado.** A escala é de 0,0 a 1,0, e confiança alta não garante fidelidade.
- **Item:** Situação hipotética: Durante a revisão de uma transcrição automática, um revisor percebeu que, em um trecho de silêncio prolongado do áudio, o sistema havia inserido uma frase que ninguém pronunciou. Nessa situação, o revisor deve manter a frase, pois, por ter sido produzida pelo sistema de reconhecimento, ela reflete necessariamente o conteúdo do áudio. **Errado.** É alucinação; o revisor confere com o áudio e apaga.

Resumo para revisar

- Humano no circuito: a máquina produz; a pessoa revisa, corrige e valida antes de publicar. É o desenho recomendado ao registro parlamentar.
- A responsabilidade pelo texto final é de quem valida, não do sistema.
- Etapas: captura → transcrição automática → revisão → edição → validação.
- A captura define o piso de qualidade.
- Confiança do sistema (Google: 0,0 a 1,0, inclusive por palavra) não garante acerto e não dispensa revisão.
- Frase inventada em silêncio é alucinação: o revisor apaga.
- Câmara: áudio → Whisper large-v3 → Escriba → redação final humana.
- Revisão obrigatória em todo texto (Plenário, comissões, audiências), por analistas de registro e redação; salvaguarda da fé pública.
- Nomes próprios: roteiros, retrancas, listas lexicais e vocabulários especializados.
- Problemas: mudanças indesejadas, contrações, repetições, alucinações. WER maior em vozes femininas.
- Variação: comissão x Plenário, número de membros, fase da sessão, audiências, início/fim da sessão legislativa.
- Gestão da mudança antes da capacitação; equipe qualificada testa, homologa e analisa.
- Futuro: pós-processamento, pesquisa com RAG, atas automáticas.
- Nuvem para o Detaq; modelo local em GPU para outras áreas (como Direx e Coped) e como reserva.
- Desenvolvido pela Diretoria de Tecnologia, às vezes com a academia; monitoramento contínuo e feedback dos usuários; todo modelo tem falhas.
- Mais volume com qualidade: mais comissões registradas, em favor da transparência e da publicidade.
- Senado: sempre, no mínimo, um supervisor humano na etapa final.
- Model card do Whisper: não usar em alto risco; avaliar antes.
- Teste de acurácia: referência humana; áudio diferente do treino.

- LGPD, art. 20: revisão de decisão unicamente automatizada; o texto vigente não exige pessoa natural.

TEMA 10 DE 20

Revisão, fidelidade e controle de qualidade (revisão em dupla, auditorias, SLA)

58 perguntas no app · Degravação e revisão

O que cai

O edital pede, nos itens 2.3 e 2.7, "revisão e edição de transcrições: critérios de qualidade e fidelidade" e "controle de qualidade: revisão em dupla, auditorias de amostras, SLA". As perguntas deste tema se concentram em:

- **Fidelidade na revisão**: preservar o estilo e o registro do orador, corrigir só deslizes, manter repetições com efeito retórico, marcar o inaudível sem adivinhar.
- **Métricas**: **WER** (fórmula, os três erros, por que pode passar de 100%, por que trata todo erro igual), **CER** (por caractere; nomes, siglas e números) e **TER** (inclui pontuação, maiúsculas e formatação). Causas de cada tipo de erro, teste com áudio representativo, sclite.
- **Controle de qualidade**: **revisão em dupla** (segundo revisor, "quatro olhos"), **auditoria por amostragem** (parte dos textos) e **SLA** (metas de prazo e qualidade). A banca troca um pelo outro.
- **Regras da Câmara**: RICD, art. 98 (Errata; retirada do discurso e prazo de cinco sessões) e art. 176, § 5º (revisão dos apartes); Ato da Mesa nº 251/2026 (Departamento de Registro Oficial e Redação Parlamentar e Coordenação de Redação Final); capa da nota taquigráfica com redação final.

Entenda o tema

Fidelidade: o que o revisor pode e o que não pode mudar

A revisão de uma transcrição busca **fidelidade**: o texto deve dizer o que o orador disse, do jeito que ele disse, em português legível.

Estilo e registro do orador. O revisor **corrige deslizes gramaticais**, mas **preserva o estilo e o tom** do orador. **Registro** aqui é o nível de linguagem (mais formal, mais coloquial). Quem fala de modo simples continua soando simples; quem é formal continua formal. **Não** se reescreve o discurso na norma culta formal se isso muda o estilo: isso quebra a fidelidade e uniformiza a linguagem.

> **Exemplo:** o Deputado fictício Joaquim diz: "A gente não vai aceitar isso, não!". O revisor não transforma em "Nós não aceitaremos tal proposta". Pode, no máximo, ajustar um deslize de concordância, mantendo o jeito de falar dele.

Repetições. Repetição que é **tropeço** da fala (o orador repete uma palavra enquanto pensa) pode sair, como ruído da oralidade. Mas repetição **com efeito retórico ou de sentido fica**, porque faz parte do que o orador quis dizer.

> **Exemplo:** "Não, não e não!" é ênfase: fica. "O projeto, o projeto que nós, que nós apresentamos" é hesitação: pode ser limpo para "O projeto que nós apresentamos".

Trecho inaudível. Se uma parte da gravação é **ininteligível**, o texto registra a **indicação convencionada de inaudível** (a marca combinada pelo órgão). O revisor **não insere palavras que apenas presume** terem sido ditas: isso atribuiria ao orador algo que ninguém ouviu.

Medir a qualidade: WER

A **WER** (*Word Error Rate*, taxa de erro de palavras) compara o texto do sistema (a **hipótese**) com uma **transcrição de referência**, feita ou corrigida por pessoas e tida como correta.

São três tipos de erro:

- **Substituição**: o sistema **trocou** uma palavra por outra.
- **Supressão** (deleção, omissão): palavra da referência que o sistema **deixou de transcrever**. Palavra pulada **é erro**, sim.
- **Inserção**: palavra que o sistema **escreveu sem ter sido dita**.

> **Atenção:** WER = (substituições + supressões + inserções) ÷ **número de palavras da referência**. O denominador **não** é o número de palavras da hipótese, e a fórmula **não** usa palavras corretas.

Quanto menor, melhor. É taxa de erro. Comparando dois sistemas nos **mesmos áudios**, com a **mesma referência** revisada por taquígrafos, o de **menor WER** cometeu menos substituições, supressões e inserções.

Pode passar de 100%. Como as **inserções não têm limite** (o sistema pode inventar quantas palavras quiser) e o denominador é fixo (palavras da referência), a soma dos erros pode superar o total de palavras da referência. Logo, a WER **não está limitada a 100%** e **não é** uma porcentagem de acertos.

> **Exemplo:** a referência tem 10 palavras. O sistema acerta 6, troca 4 e ainda inventa 8 palavras num trecho de silêncio. WER = (4 + 0 + 8) ÷ 10 = 120%.

Todo erro pesa igual. A WER **não pondera a gravidade** do erro para o sentido. Trocar "aprovo" por "reprovo" (que inverte o voto) pesa o mesmo que trocar "o" por "a". Por isso um número baixo **não garante texto fiel**, e uma WER baixa **não pode ser o único critério** para dispensar a revisão humana.

> **Pegadinha:** "Dispensar a revisão quando a WER for menor que 5%, porque a métrica pondera os erros pela gravidade." Errado duas vezes: a WER não pondera gravidade, e um número baixo não substitui a revisão.

O que cada erro sugere (documentação do Azure AI Speech):

- muitas **supressões**: **sinal de áudio fraco** (corrige-se captando mais perto da fonte);
- muitas **inserções**: ambiente **ruidoso**, com possível **cruzamento de vozes** (*crosstalk*);
- muitas **substituições**: **faltam exemplos do vocabulário do domínio** no treino do modelo.

Faixas de referência são só uma régua. Fornecedores divulgam faixas de WER (por exemplo, a Microsoft considera de 5% a 10% boa qualidade e 30% ou mais ruim). São **referências gerais**. O órgão define a **própria meta** considerando o **tipo de áudio**, o **domínio** e o **esforço de revisão** que aceita assumir. A **mesma WER não indica sempre a mesma qualidade**: pode esconder erros bobos ou graves, e Plenário e audiência pública se comportam de modo diferente.

Como testar direito.

- Use **áudio de teste diferente do usado no treino**, com **transcrições humanas** como referência. Testar com o que o modelo já conhece dá nota inflada.
- A amostra de teste deve ser **representativa** do dia a dia (ruído, sotaques, vozes cruzadas). Testar **só com os melhores trechos** produz WER irreal.
- A ferramenta **sclite**, do **NIST Scoring Toolkit (SCTK)**, permite **replicar localmente** a medição de WER feita no Azure, conferindo o cálculo do fornecedor e comparando sistemas pelo mesmo método.

CER: erro por caractere

A **CER** (*Character Error Rate*, taxa de erro de caracteres) faz a mesma conta da WER, mas **letra por letra**, e não palavra por palavra. ("C" de **caractere**, não de frase.)

- Na **WER**, **uma letra errada** faz a **palavra inteira** contar como erro.
- Na **CER**, o peso do erro é **proporcional ao seu tamanho**: uma letra errada vale uma letra.

Por isso a CER é útil para evidenciar **erros pequenos de grafia** em **nomes próprios, siglas e números**, e também para **línguas sem separação clara entre palavras** (que não usam espaços). Ela funciona como **medida complementar** à WER.

> **Exemplo:** o sistema escreve "Deputada Lusia" em vez de "Deputada Luzia". Na WER, a palavra inteira conta como erro (1 de 2 palavras = 50%). Na CER, é 1 letra trocada em cerca de 14 caracteres (cerca de 7%). A CER mostra o erro no tamanho real.

TER: erro com formatação

A **TER** (*Token Error Rate*, taxa de erro de token), descrita pela Microsoft, **estende a lógica da WER ao formato final de exibição**: considera também **pontuação**, **capitalização** (maiúsculas) e **normalização inversa de texto** (escrever "dois mil e vinte e seis" como "2026", "por cento" como "%"). Por isso exige **transcrições de referência com essa formatação**.

A **WER** fica no nível das **palavras**, na forma falada; ela **não** conta como erro a falta de pontuação ou de maiúsculas. Quem mede o formato de exibição é a **TER**.

Controle de qualidade: três ferramentas complementares

Revisão em dupla. Depois que um revisor termina, **um segundo revisor, diferente**, confere o texto já revisado. É isso que garante a **independência** da verificação: quem fez o trabalho tende a não ver os próprios erros. O mesmo revisor conferir duas vezes (mesmo em dias diferentes) **não** é revisão em dupla. É o chamado **princípio dos quatro olhos**: **dois olhos do revisor + dois do segundo revisor** = **duas pessoas**, não quatro revisores.

Auditoria por amostragem. Avalia **uma amostra** dos textos entregues, com **critérios definidos**, para **estimar a qualidade do conjunto sem conferir todos**. Conferir tudo seria revisão total, não amostragem.

Acordo de nível de serviço (SLA). É o combinado, por escrito, com **metas mensuráveis** para a produção de transcrições: **prazo de entrega** e **nível mínimo de qualidade** (medido, por exemplo, pela taxa de erros). O SLA **não é** a conferência por um segundo revisor.

As três ferramentas são **complementares**: a auditoria não substitui o SLA nem a revisão em dupla.

> **Dica:** dupla = **quem** confere (outra pessoa); amostragem = **quanto** se confere (uma parte); SLA = **o que** se promete (prazo e qualidade).

Regras da Câmara sobre revisão e correção

Errata, não republicação. Erros e omissões de discurso já publicado no Diário da Câmara **não se corrigem reproduzindo o discurso**; as correções vão para a seção **"Errata"**. Assim o registro original continua rastreável.

> **Lei seca:** RICD, art. 98, § 1º: "Não são permitidas as **reproduções de discursos** no Diário da Câmara dos Deputados com o fundamento de corrigir erros e omissões; as correções constarão da seção **'Errata'**."

Discurso retirado para revisão. O Deputado pode retirar o discurso na Taquigrafia para revisá-lo, mas há **prazo**: se não devolver em **cinco sessões**, a Taquigrafia publica o texto **sem a revisão do orador**. O registro não fica parado esperando.

> **Lei seca:** RICD, art. 98, § 2º: "Ao Deputado é licito retirar na Taquigrafia, para revisão, o seu discurso, não permitindo a publicação na ata respectiva. Caso o orador não devolva o discurso dentro de **cinco sessões**, a Taquigrafia dará à publicação o texto **sem revisão do orador**."

Apartes. Aparte é a interrupção breve do orador por outro Deputado, para indagação ou esclarecimento. A revisão do aparte é do **autor do aparte**, e só **se o orador permitir**. O orador **não pode modificar** o aparte alheio.

> **Lei seca:** RICD, art. 176, § 5º: "Os apartes só serão sujeitos a **revisão do Autor** se **permitida pelo orador**, que **não poderá modificá-los**."

Departamento de Registro Oficial e Redação Parlamentar. O Ato da Mesa nº 251, de 16/03/2026, trata desse departamento da Câmara. Pontos cobrados:

- compete a ele **garantir a precisão** do texto do registro oficial e **responder por sua veracidade, integridade e autenticidade** (art. 2º, VI);
- ele **suprime expressões antirregimentais por determinação da Mesa**, e não por iniciativa própria (art. 2º, IV); o corte não pode depender do gosto do revisor;
- a **Coordenação de Redação Final avalia a qualidade do texto** dos discursos e debates registrados e **promove o aperfeiçoamento do registro** (art. 6º, V). É o setor do controle de qualidade do texto;
- a **Coordenação de Gestão Administrativa** cuida de planejamento, orçamento, pessoal e materiais (art. 4º), não da qualidade do texto.

Capa da nota taquigráfica com redação final. Nas notas taquigráficas de **comissões com redação final**, a capa informa que se trata de **versão para registro histórico, não passível de alteração**. As falhas do registro (como trechos **inaudíveis**) aparecem listadas em **observações**. Não é "versão provisória alterável a qualquer tempo".

Quadros para memorizar

WER, CER e TER

Métrica	Unidade	Fórmula / alcance	Útil para
WER	palavra	(S + D + I) ÷ palavras da referência; pode passar de 100%; menor é melhor	qualidade geral do reconhecimento
CER	caractere	mesma lógica, letra por letra; erro pesa pelo tamanho	nomes, siglas, números; línguas sem espaço entre palavras
TER	token	inclui pontuação, maiúsculas e normalização inversa; referência formatada	qualidade do texto de exibição

Os três erros e suas causas

Erro	O que é	Muitos deles sugerem
Substituição	palavra trocada	falta vocabulário do domínio no treino
Supressão (deleção)	palavra dita e omitida	áudio fraco (captar mais perto da fonte)
Inserção	palavra escrita sem ter sido dita	ruído, cruzamento de vozes

Controle de qualidade

Ferramenta	O que é	Não é
Revisão em dupla (quatro olhos)	segundo revisor, diferente, confere o texto revisado	o mesmo revisor conferindo duas vezes; quatro revisores
Auditoria por amostragem	parte dos textos, com critérios, para estimar o todo	conferência integral
SLA	metas mensuráveis: prazo e qualidade mínima	segundo revisor

Fidelidade

Situação	Conduta
Deslize gramatical	corrigir, preservando estilo e registro
Discurso coloquial	não reescrever na norma culta formal
Repetição por hesitação	pode sair
Repetição retórica	fica
Trecho ininteligível	marca convencionada de inaudível; nada de adivinhar

Câmara

Regra	Fonte
Correção de discurso publicado pela seção Errata	RICD, art. 98, § 1º
Discurso retirado: 5 sessões; depois, publica-se sem revisão do orador	RICD, art. 98, § 2º
Aparte: revisão do autor, se o orador permitir; orador não modifica	RICD, art. 176, § 5º
Precisão, veracidade, integridade e autenticidade do registro	Ato da Mesa 251/2026, art. 2º, VI
Supressão de expressões antirregimentais por determinação da Mesa	Ato da Mesa 251/2026, art. 2º, IV
Coordenação de Redação Final avalia a qualidade do texto	Ato da Mesa 251/2026, art. 6º, V
Capa da nota com redação final: registro histórico, não alterável	Detaq

Conceitos e autores que caem

Por que importa: a banca cobra as definições exatas e a diferença entre ferramentas parecidas.

- **Fidelidade**: o texto reproduz o que o orador disse, preservando estilo e registro.
- **Registro (linguístico)**: nível de linguagem do orador (formal, coloquial).
- **Hipótese**: o texto produzido pelo sistema de reconhecimento.
- **Transcrição de referência**: texto feito ou revisado por pessoas, usado como gabarito.
- **WER**: (substituições + supressões + inserções) ÷ palavras da referência.
- **CER**: taxa de erro por caractere.

- **TER**: taxa de erro de token, com pontuação, capitalização e normalização inversa.
- **Normalização inversa de texto**: converter a forma falada em forma escrita ("dez por cento" → "10%").
- **sclite / SCTK**: ferramenta do NIST para calcular a WER localmente.
- **Jurafsky e Martin**: *Speech and Language Processing*, manual de referência que define a WER.
- **Revisão em dupla / princípio dos quatro olhos**: duas pessoas, um segundo revisor independente.
- **Auditoria por amostragem**: conferência de parte dos textos para estimar o todo.
- **SLA (Service Level Agreement)**: acordo de nível de serviço, com metas mensuráveis.
- **Aparte**: interrupção breve do orador para indagação ou esclarecimento (RICD, art. 176).
- **Errata**: seção do Diário em que se publicam as correções.

Pegadinhas da banca

- **"Reescrever o discurso na norma culta formal, ainda que mude o estilo."** Errado: preserva-se estilo e registro.
- **"Eliminar todas as repetições, inclusive as retóricas."** Errado: as retóricas ficam.
- **"Completar o trecho inaudível com o que o revisor presume."** Errado: marca-se inaudível.
- **"WER dividida pelas palavras da hipótese."** Errado: pelas palavras da referência.
- **"WER = corretas ÷ hipótese; quanto maior, melhor."** Errado: soma erros; menor é melhor.
- **"Só substituições e inserções; omissões não contam."** Errado: supressões contam.
- **Supressão e inserção trocadas.** Supressão é palavra que faltou; inserção é palavra que sobrou.
- **"WER limitada a 100%."** Errado: as inserções podem levá-la acima de 100%.
- **"WER pondera a gravidade (aprovo x reprovo pesa mais)."** Errado: todo erro pesa igual.
- **"WER abaixo de 5% como único critério para dispensar revisão."** Errado.
- **"Na WER, uma letra errada pesa menos que na CER; use a WER para nomes."** Errado: é o contrário.
- **"Na CER, uma letra errada derruba a palavra inteira."** Errado: isso é a WER.
- **"CER é por frase, para pontuação e segmentação."** Errado: é por caractere.
- **"A WER mede pontuação e maiúsculas, ao contrário da TER."** Errado: quem mede o formato é a TER.
- **"Substituições indicam áudio fraco; capte mais perto."** Errado: áudio fraco gera supressões; substituições vêm de falta de vocabulário.
- **"Mesma WER = mesma qualidade, em qualquer áudio; faixas do fornecedor valem sem adaptação."** Errado.
- **"Testar só com os melhores trechos."** Errado: a amostra deve ser representativa.
- **"Mesmo revisor confere duas vezes" (revisão em dupla).** Errado: segundo revisor diferente.
- **"Quatro olhos = auditoria com quatro revisores."** Errado: duas pessoas, revisão em dupla.
- **"Auditoria por amostragem confere todos os textos."** Errado: só uma parte.

- **"SLA é o segundo revisor."** Errado: SLA são metas de prazo e qualidade.
- **"Corrige-se o erro republicando o discurso."** Errado: seção Errata.
- **"Retirado o discurso, a Taquigrafia espera sem prazo."** Errado: cinco sessões.
- **"O orador pode modificar os apartes."** Errado: não pode; só permite a revisão pelo autor.
- **"O departamento suprime expressões antirregimentais por iniciativa própria."** Errado: por determinação da Mesa.
- **"Qualidade do texto cabe à Coordenação de Gestão Administrativa."** Errado: Coordenação de Redação Final.
- **"Capa da nota com redação final: versão provisória, alterável a qualquer tempo."** Errado: registro histórico, não alterável.

Itens comentados

- **Item:** Em respeito à correção gramatical, o revisor deve reescrever o discurso na norma culta formal, ainda que isso modifique o estilo e o registro do orador. **Errado.** Corrigem-se deslizes, mas estilo e registro do orador se preservam.
- **Item:** Em trecho ininteligível da gravação, a transcrição deve registrar a indicação convencionada de inaudível, sem inserir palavras que o revisor apenas presume terem sido ditas. **Certo.** Adivinhar atribuiria ao orador algo que não se ouviu.
- **Item:** Como as inserções não têm limite superior e o denominador do WER é o número de palavras da referência, o WER pode ultrapassar 100%. **Certo.** Os erros podem superar o total de palavras da referência.
- **Item:** O WER pondera cada erro pela gravidade para o sentido da frase, de modo que a troca de "aprovo" por "reprovo" pesa mais que a troca de um artigo. **Errado.** Todo erro vale um; essa é uma limitação da WER.
- **Item:** No WER, uma única letra errada em uma palavra pesa menos que no CER, razão pela qual o WER é preferível para avaliar a grafia de nomes próprios e siglas. **Errado.** Na WER a palavra inteira conta como erro; a CER é que mede o erro miúdo.
- **Item:** Ao contrário do TER, o WER mede a qualidade do formato de exibição final, pois conta como erro a ausência de pontuação, de letras maiúsculas e de normalização inversa de texto. **Errado.** Quem mede pontuação, maiúsculas e normalização inversa é a TER.
- **Item:** Segundo a documentação do Azure AI Speech, muitos erros de substituição indicam sinal de áudio fraco, e a correção recomendada é captar o áudio mais perto da fonte. **Errado.** Áudio fraco gera supressões; substituições vêm de falta de vocabulário do domínio.
- **Item:** O princípio dos quatro olhos, no controle de qualidade de transcrições, corresponde à auditoria por amostragem, em que quatro revisores avaliam uma amostra dos textos entregues. **Errado.** Quatro olhos são duas pessoas: é a revisão em dupla.
- **Item:** Na produção de transcrições, a auditoria por amostragem avalia parte dos textos entregues e é complementar ao acordo de nível de serviço e à revisão em dupla. **Certo.** As três

ferramentas trabalham juntas.

- **Item:** O acordo de nível de serviço (SLA) é o mecanismo de controle de qualidade em que um segundo revisor confere o texto já revisado antes da entrega. **Errado.** Isso é revisão em dupla; SLA são metas de prazo e qualidade.
- **Item:** Retirado o discurso para revisão, o Regimento Interno da Câmara dos Deputados impede que a Taquigrafia o publique enquanto o orador não o devolver, sem fixar prazo para isso. **Errado.** O prazo é de cinco sessões; depois, publica-se sem revisão do orador.
- **Item:** Conforme o Regimento Interno da Câmara dos Deputados, o orador aparteado pode revisar e modificar o conteúdo dos apartes que recebeu, independentemente da concordância do aparteante. **Errado.** O orador não pode modificar os apartes; só permite que o autor os revise.
- **Item:** Segundo o Ato da Mesa da Câmara dos Deputados nº 251/2026, compete ao Departamento de Registro Oficial e Redação Parlamentar suprimir expressões antirregimentais por iniciativa própria, sem necessidade de determinação da Mesa. **Errado.** A supressão depende de determinação da Mesa.
- **Item:** Situação hipotética: Um departamento de registro de uma casa legislativa definiu, como único critério para dispensar a revisão humana das transcrições automáticas, a obtenção de WER inferior a 5% no conjunto de teste, por entender que a métrica pondera os erros conforme a gravidade para o sentido do texto. Nessa situação, o entendimento está correto. **Errado.** A WER não pondera gravidade; número baixo não garante fidelidade.

Resumo para revisar

- Revisão fiel: corrige deslizes, preserva estilo e registro; não reescreve na norma culta formal.
- Repetição por hesitação sai; repetição retórica fica.
- Inaudível: marca convencionada; nunca adivinhar.
- WER = (substituições + supressões + inserções) ÷ palavras da referência humana. Menor é melhor.
- Supressão = palavra dita e omitida; inserção = palavra escrita sem ter sido dita; substituição = palavra trocada.
- WER pode passar de 100% (inserções sem limite).
- WER trata todo erro igual ("aprovo" x "reprovo" = artigo trocado); WER baixa não dispensa revisão.
- Supressões: áudio fraco. Inserções: ruído e vozes cruzadas. Substituições: falta vocabulário do domínio.
- Faixas de fornecedores são referência geral; o órgão define a própria meta conforme áudio, domínio e esforço de revisão.
- Teste com áudio diferente do treino, representativo, e referência humana; sclite (NIST SCTK) replica a WER localmente.

- CER: por caractere; erro pesa pelo tamanho; útil para nomes, siglas, números e línguas sem espaço; complementa a WER.
- TER: inclui pontuação, maiúsculas e normalização inversa; exige referência formatada. A WER não mede formato.
- Revisão em dupla: segundo revisor diferente (quatro olhos = duas pessoas).
- Auditoria por amostragem: parte dos textos, com critérios, para estimar o todo.
- SLA: metas mensuráveis de prazo e qualidade. As três ferramentas se complementam.
- RICD, art. 98, § 1º: correção pela seção Errata, sem republicar o discurso.
- RICD, art. 98, § 2º: discurso retirado para revisão; 5 sessões; depois, publicação sem revisão do orador.
- RICD, art. 176, § 5º: aparte revisado pelo autor, se o orador permitir; o orador não o modifica.
- Ato da Mesa 251/2026: departamento garante precisão, veracidade, integridade e autenticidade; suprime expressões antirregimentais por determinação da Mesa; Coordenação de Redação Final avalia a qualidade do texto.
- Nota taquigráfica com redação final: registro histórico, não alterável; falhas listadas em observações.

TEMA 11 DE 20

Formatação de transcrições parlamentares

52 perguntas no app · Degravação e revisão

O que cai

O edital pede "Formatação de transcrições parlamentares: identificação de oradores, marcação de pausa, ruído etc." (item 2.4 da matéria). As perguntas deste tema giram em torno de cinco blocos:

- **Conceitos básicos**: transcrição automática (saída bruta do ASR) x degravação (texto feito segundo as convenções do órgão) x revisão (que preserva o sentido e pode limpar vícios de linguagem).
- **O que se marca no texto**: quem fala (orador, presidente, aparteante, "Não identificado"), apartes, manifestações do Plenário (palmas, vaias, risos, tumulto), trechos inaudíveis, ruído, pausa, campainha. Tudo entre parênteses e em linha própria, nunca misturado à fala.
- **O Regimento Interno da Câmara (RICD)**: quando a taquigrafia começa e para de registrar, quem manda não registrar (o Presidente), apartes antirregimentais não publicados, falas contra o decoro não publicadas (com recurso ao Plenário), atas de sessão e de comissão.
- **O modelo real das notas taquigráficas** da Câmara e do Senado: "O SR. PRESIDENTE (Nome)", "(Pausa.)", "(Intervenção fora do microfone. Inaudível.)", capa com bloco de observações, senador com partido e UF.
- **A estrutura do Departamento** que cuida do registro: qual coordenação faz atas, roteiros e retrancas, e qual indexa os discursos; onde se publica o registro (Diário da Câmara x Diário do Congresso Nacional).

A pegadinha clássica é sempre a mesma: o item diz que algo "pode ser incorporado à fala", "dispensa marcação" ou "é descartado". Na transcrição parlamentar, quase tudo é **marcado**, e nada é **inventado** nem **apagado** por conta própria.

Entenda o tema

Transcrição automática, degravação e revisão

Pense em três etapas de uma cozinha. A **transcrição automática** é o ingrediente cru: o texto que sai do sistema de reconhecimento de fala (ASR, sigla em inglês para *Automatic Speech Recognition*), sem tratamento nenhum. Tem erros, não diz quem falou direito e reproduz a fala do jeito que veio.

A **degravação** é o prato preparado: é a passagem do registro oral para o texto escrito **segundo as convenções do órgão**. Aqui entram a identificação de quem fala, a marcação de apartes e ocorrências, o tratamento da linguagem falada. A degravação precisa de **revisão humana**.

> **Pegadinha:** a banca inverte os conceitos. Item errado: "a degravação é a saída bruta do ASR, e a transcrição automática é a versão revisada". É o contrário: a **transcrição automática é a bruta**; a **degravação segue as regras do órgão**.

A **revisão** é o controle final de qualidade. A regra de ouro da revisão é **preservar o sentido** do que o orador disse. Dentro desse limite, o revisor pode tratar:

- **vícios de linguagem** ("né", "tipo assim", "é... é...");
- **repetições sem função**, que são só ruído da fala.

Já a repetição que tem função, como a que dá **ênfase** ("isso é grave, muito grave, gravíssimo"), deve ficar, porque faz parte do que o orador quis dizer.

A qualidade do áudio decide o tamanho da revisão

O sistema automático só transcreve bem o que ouve bem. **Microfone inadequado, ruído do ambiente e vozes sobrepostas** fazem o ASR errar mais. Cada erro vira trabalho de revisão. Por isso a qualidade da **captação** do áudio influencia **diretamente** a precisão da transcrição automática e, por consequência, o esforço de revisão.

> **Dica:** "lixo entra, lixo sai". Áudio ruim gera transcrição ruim, e transcrição ruim gera mais horas de revisão.

Pedal e atalhos de teclado

Quem transcreve ou revisa usa um **editor de transcrição**, que toca o áudio junto com o texto. Para controlar a reprodução (tocar, pausar, voltar alguns segundos), há dois caminhos:

- **atalhos de teclado**, que tocam, pausam e retrocedem o áudio;
- o **pedal**, que deixa as mãos livres para digitar enquanto os pés controlam a gravação.

O pedal é um **complemento**, não o único meio. Item que diga "o pedal é o único meio, porque os atalhos não pausam nem retrocedem" está errado.

Identificar quem fala

Num debate parlamentar, saber **quem** disse cada frase é tão importante quanto saber **o que** foi dito. Por isso a transcrição sempre identifica o orador.

O presidente dos trabalhos. Nas notas taquigráficas de comissões da Câmara, a fala de quem preside aparece como **O SR. PRESIDENTE** seguido, **entre parênteses**, do **nome do parlamentar** que ocupa a Presidência naquele momento. Exemplo de forma: "O SR. PRESIDENTE (Deputado Fulano de Tal) – Está aberta a reunião." Isso importa porque a presidência pode mudar de mãos durante a reunião, e a fala é de quem ocupa o cargo naquele instante. Os demais oradores vêm com o tratamento e o nome.

> **Pegadinha:** item errado diz que a fala do presidente é registrada "apenas com o nome do parlamentar, sem a indicação do cargo". O padrão traz o **cargo** (O SR. PRESIDENTE) **e** o nome entre parênteses.

Orador não identificado. Às vezes alguém faz uma breve intervenção e não dá para saber quem foi. A fala **não é descartada**. Ela fica no texto precedida de **"(Não identificado)"** no lugar do nome, e o fato é anotado nas **observações da capa**. Atribuir a fala a alguém "por palpite" seria inventar; apagá-la deixaria o registro incompleto.

No Senado. Nas notas taquigráficas do Senado Federal (por exemplo, as da Comissão Especial do Impeachment, em 2016, publicadas pela Secretaria de Registro e Redação Parlamentar), antes de cada fala vem o nome do senador e, **entre parênteses, o partido (ou bloco) e a unidade da Federação**. Assim o leitor sabe quem fala e por qual legenda sem depender do áudio. Item que diga que a identificação "limita-se ao nome" está errado.

Apartes

Aparte é a interrupção breve do orador por outro parlamentar, para perguntar ou esclarecer algo sobre a matéria em debate (RICD, art. 176). Na transcrição, o aparte **é marcado e o aparteante é identificado**.

Por quê? Se o aparte fosse "incorporado" ao discurso sem identificação, pareceria que o orador disse algo que, na verdade, foi dito por outra pessoa. Isso destrói a **fidelidade** do registro. Item que diga que a marcação de apartes é "dispensável" ou que os apartes são incorporados "para preservar a continuidade do discurso" está errado.

> **Exemplo:** a Deputada Ana discursa; o Deputado Bruno pede um aparte e pergunta sobre o orçamento. No texto, a pergunta aparece com a identificação "O SR. BRUNO..." e não como se fosse frase da Deputada Ana.

Manifestações do Plenário e ocorrências sonoras

Tudo o que acontece na sala e **não é fala** do orador ganha **marcação própria**, separada do discurso. Na prática das notas da Câmara e do Senado, essas ocorrências entram **entre parênteses, em linha própria**:

- **palmas, vaias, risos, tumulto** no plenário;
- **"(Soa a campainha.)"**, no Senado, quando a campainha avisa, por exemplo, o fim do tempo;
- **"(Pausa.)"**, quando se aguarda uma manifestação e ninguém fala.

Misturar palmas ou tumulto dentro da fala daria a impressão de que o parlamentar disse aquilo. E o fato de não ser fala **não tira** a ocorrência do registro: só obriga a marcá-la de forma separada.

O que significa "(Pausa.)". Indica um **momento de silêncio** em que se espera manifestação. Exemplo típico: o presidente pergunta "Algum Deputado deseja discutir a ata?" e ninguém responde. Aparece "(Pausa.)" e, em seguida, o presidente continua. A pausa **não** significa que o revisor cortou um trecho irrelevante. Cortar trechos por conta própria feriria a fidelidade.

Trecho inaudível, ruído e pausa

Quando um pedaço da gravação **não pode ser compreendido**, a transcrição registra o trecho **inaudível** com a **marcação convencionada pelo órgão**. Ninguém pode "chutar" o que o orador teria dito, nem "reconstituir o conteúdo provável pelo contexto". Deduzir é inventar.

Nas notas da Câmara, quando um parlamentar fala longe do microfone e não dá para entender, o texto registra a ocorrência entre parênteses: **"(Intervenção fora do microfone. Inaudível.)"**.

O **ruído** e a **pausa** também são indicados por marcação que segue a convenção do órgão, **sem alterar o que foi dito**. Não é só o inaudível que ganha marca.

> **Atenção:** a marcação no corpo do texto e a nota na capa se **somam**. A capa avisa que houve trechos inaudíveis, mas isso **não dispensa** a marca no lugar exato em que ocorreram.

A capa das notas taquigráficas

As notas taquigráficas de comissões da Câmara têm uma **capa** com dados da reunião e, quando é o caso, um **bloco de observações**. Esse bloco avisa o leitor sobre os **problemas do registro**:

- intervenções **inaudíveis** ou **ininteligíveis**;
- oradores **não identificados**;
- **falha na gravação**.

É uma forma de transparência. O bloco de observações **não** serve para listar as emendas ou mudanças que o revisor fez no texto de cada orador.

O que diz o Regimento Interno da Câmara sobre o registro

O RICD (Resolução 17/1989) tem várias regras que tocam diretamente o trabalho da taquigrafia.

Quando começa o registro. Nenhum deputado fala sem pedir a palavra e sem que o Presidente a conceda. **Somente depois dessa concessão** a taquigrafia inicia o **apanhamento** (o registro) do discurso (art. 73, VI). Subir à tribuna não basta.

Quando termina. Se o deputado insiste em falar de forma antirregimental, mesmo advertido, o Presidente dá o discurso por terminado (art. 73, VII). **Sempre que o Presidente der por findo o discurso, os taquígrafos deixam de registrá-lo** (art. 73, VIII). O que o deputado falar depois não entra no registro e não é publicado como "complemento".

Quem manda não registrar. É atribuição do **Presidente**, quanto às sessões, **determinar o não apanhamento de discurso, ou aparte, pela taquigrafia** (art. 17, I, h). Não é o Secretário-Geral da Mesa.

Apartes fora das regras. O RICD não admite aparte, entre outros casos, **à palavra do Presidente**, paralelo a discurso, a parecer oral, no **encaminhamento de votação**, quando o orador declara que **não permite** apartes e quando o orador está suscitando questão de ordem ou falando para reclamação (art. 176, § 2º). E **não são publicados** os apartes proferidos em desacordo com o Regimento (art. 176, § 4º).

Decoro. O Regimento **não autoriza a publicação** de pronunciamentos ou expressões **atentatórias do decoro parlamentar**, mas **cabe recurso do orador ao Plenário** (art. 98, § 6º). Também é atribuição do Presidente não permitir essa publicação (art. 17, V, b). A decisão, portanto, **não é definitiva**.

Revisão pelo orador. O deputado pode retirar na Taquigrafia o seu discurso para revisão; se não o devolver em **cinco sessões**, a Taquigrafia publica o texto sem revisão do orador (art. 98, § 2º). Os apartes só são revistos pelo autor se o orador permitir, e o aparteante não pode modificá-los (art. 176, § 5º).

Ata não é transcrição

Aqui mora uma confusão frequente. **Ata** e **notas taquigráficas** são documentos diferentes.

- A **ata da sessão** é um **resumo**: o RICD manda lavrar ata com a **sinopse dos trabalhos** de cada sessão, cuja redação obedece a **padrão uniforme adotado pela Mesa** (art. 97). Dela consta a lista nominal de presença e de ausência (art. 97, § 2º).
- As **notas taquigráficas** registram as falas **palavra por palavra**. Os discursos são publicados **por extenso** (art. 98, § 1º).

Item que diga que a ata é "transcrição literal de tudo o que foi dito, sem sinopse e sem padrão fixado pela Mesa" está errado.

Ata de comissão. Lida e aprovada, a ata de cada reunião de comissão é assinada pelo Presidente e publicada no Diário da Câmara. Ela segue **padrão uniforme** com (art. 63, parágrafo único):

1. data, hora e local da reunião;
2. nomes dos membros **presentes e dos ausentes**, com expressa referência às **faltas justificadas**;
3. resumo do expediente;
4. relação das matérias distribuídas, por proposições, relatores e relatores substitutos;
5. registro das proposições apreciadas e das respectivas conclusões.

> **Pegadinha:** "a ata de comissão dispensa o registro dos ausentes, bastando relacionar os presentes". Errado: presentes **e** ausentes.

Quem faz o quê no Departamento de Registro

O registro das sessões fica com o **Departamento de Registro Oficial e Redação Parlamentar** (estrutura tratada no Ato da Mesa nº 251, de 16/03/2026). Dentro dele, três coordenações aparecem nas perguntas:

- **Coordenação de Registro Oficial**: elabora as **retrancas e os roteiros** de sessões plenárias, reuniões de comissões e outros eventos legislativos (os roteiros guiam a equipe sobre quem fala e em que ordem) e elabora as **atas das sessões plenárias**.
- **Coordenação de Gestão do Discurso**: trata, **resume e indexa** os discursos; pode **sugerir termos** para inclusão no vocabulário controlado e **vincular os pronunciamentos às proposições** legislativas de que tratam.

- **Coordenação de Gestão Administrativa**: cuida de planejamento, compras, pessoal e outros assuntos internos. **Não** faz roteiros, retrancas nem atas.

> **Dica:** "Registro Oficial registra a sessão" (roteiro antes, ata depois). "Gestão do Discurso cuida do discurso depois de pronto" (resumo, índice, ligação com projetos).

Indexação com vocabulário controlado

Os discursos da Câmara são **indexados com vocabulário controlado**, isto é, uma lista padronizada de termos. Pense numa biblioteca: se cada bibliotecário inventasse uma etiqueta ("aposentadoria", "previdência", "INSS", "benefício do idoso"), a busca nunca acharia tudo do mesmo assunto. Com vocabulário controlado, todos usam o mesmo termo, e a busca funciona. Por isso a indexação **não** é feita em texto livre, "à escolha de cada servidor".

Divulgação e publicação

Primeiro rápido, depois revisado. Segundo o antigo Departamento de Taquigrafia, Revisão e Redação (DETAQ), os pronunciamentos do Plenário eram divulgados no portal **quase em tempo real**, **antes da revisão**. Depois de revisados e com redação final, a nova versão **substituía automaticamente** a primeira. Havia, portanto, divulgação prévia.

Onde se publica. Sessão **da Câmara** sai no **Diário da Câmara dos Deputados**. Sessão **conjunta ou do Congresso Nacional** sai no **Diário do Congresso Nacional**. A banca gosta de inverter.

Quadros para memorizar

Marcações das notas taquigráficas

Situação	Como aparece	O que não se faz
Fala de quem preside	O SR. PRESIDENTE (nome do parlamentar)	registrar só o nome, sem o cargo
Orador desconhecido	(Não identificado) antes da fala + aviso na capa	descartar a fala ou atribuí-la por palpite
Fala longe do microfone, ininteligível	(Intervenção fora do microfone. Inaudível.)	reconstituir pelo contexto
Silêncio aguardando manifestação	(Pausa.)	usar para indicar trecho cortado
Palmas, vaias, risos, tumulto	entre parênteses, em linha própria	incorporar à fala do orador
Campainha (Senado)	(Soa a campainha.)	excluir do registro
Aparte	marcado, com aparteante identificado	incorporar ao discurso
Senador falando (Senado)	nome + (partido ou bloco/UF)	só o nome

Transcrição automática x degravação x ata x notas

Documento	O que é
Transcrição automática	saída bruta do ASR, sem tratamento
Degravação	fala passada a texto segundo as convenções do órgão; exige revisão humana
Notas taquigráficas	registro das falas por extenso, palavra por palavra, com marcações
Ata da sessão	sinopse (resumo) dos trabalhos, em padrão uniforme da Mesa
Ata de comissão	padrão uniforme: data/hora/local, presentes e ausentes (faltas justificadas), expediente, matérias distribuídas, proposições apreciadas

Regimento Interno: quem decide e quando

Regra	Dispositivo
Taquigrafia só começa após o Presidente conceder a palavra	art. 73, VI
Presidente dá o discurso por terminado; taquígrafos param	art. 73, VII e VIII
Presidente determina o não apanhamento de discurso ou aparte	art. 17, I, h
Não se admite aparte à palavra do Presidente, no encaminhamento de votação etc.	art. 176, § 2º
Aparte antirregimental não é publicado	art. 176, § 4º
Fala contra o decoro não é publicada; cabe recurso ao Plenário	art. 98, § 6º
Orador que retira o discurso para revisão tem 5 sessões para devolver	art. 98, § 2º
Ata = sinopse em padrão uniforme da Mesa	art. 97
Ata de comissão em padrão uniforme	art. 63, parágrafo único

Departamento de Registro Oficial e Redação Parlamentar

Coordenação	Faz	Não faz
Registro Oficial	retrancas e roteiros; atas das sessões plenárias	indexação de discursos
Gestão do Discurso	trata, resume e indexa discursos; sugere termos ao vocabulário controlado; vincula discursos a proposições	atas das sessões
Gestão Administrativa	planejamento, compras, pessoal	roteiros, retrancas, atas

Publicação

Sessão	Onde sai
Da Câmara	Diário da Câmara dos Deputados
Conjunta ou do Congresso Nacional	Diário do Congresso Nacional

Conceitos e autores que caem

Primeiro, os conceitos. A transcrição automática é a saída bruta do sistema; a degravação, o texto conforme as convenções do órgão.

> **Atenção:** a transcrição automática é a saída bruta de um sistema de ASR; a degravação é a passagem do registro oral para o texto escrito **segundo as convenções do órgão**.

A revisão tem um limite claro: o sentido.

> **Atenção:** a revisão deve **preservar o sentido** do que foi dito, podendo tratar **vícios de linguagem e repetições sem função** que não alterem o conteúdo.

O RICD é a base legal das regras de registro. Os dispositivos mais cobrados:

> **Lei seca:** Art. 73, VI – a nenhum Deputado será permitido falar sem pedir a palavra e sem que o Presidente a conceda, e **somente após essa concessão** a taquigrafia iniciará o apanhamento do discurso;
>
> **Lei seca:** Art. 73, VIII – **sempre que o Presidente der por findo o discurso**, os taquígrafos deixarão de registrá-lo;
>
> **Lei seca:** Art. 17, I, h – [compete ao Presidente, quanto às sessões] determinar o **não-apanhamento** de discurso, ou aparte, pela taquigrafia;
>
> **Lei seca:** Art. 176, § 4º – **Não serão publicados** os apartes proferidos em desacordo com os dispositivos regimentais.
>
> **Lei seca:** Art. 98, § 6º – Não será autorizada a publicação de pronunciamentos ou expressões atentatórias do decoro parlamentar, **cabendo recurso do orador ao Plenário**.
>
> **Lei seca:** Art. 97 – Lavrar-se-á ata com a **sinopse** dos trabalhos de cada sessão, cuja redação obedecerá a **padrão uniforme adotado pela Mesa**.
>
> **Lei seca:** Art. 63, parágrafo único, II – nomes dos membros **presentes e dos ausentes**, com expressa referência às **faltas justificadas**;

Termos que aparecem nas perguntas:

- **Apanhamento**: o ato de a taquigrafia registrar a fala.
- **Aparte**: interrupção breve e oportuna do orador, para indagação ou esclarecimento sobre a matéria em debate.
- **Aparteante**: quem faz o aparte.
- **Retranca e roteiro**: documentos que organizam o registro da sessão (quem fala, em que ordem, como dividir o trabalho).
- **Vocabulário controlado**: lista padronizada de termos usada para indexar documentos.
- **Redação final**: a versão revisada do texto, que substitui a versão prévia divulgada.

Pegadinhas da banca

- **Conceitos invertidos.** "A degravação é a saída bruta do ASR." Errado: a saída bruta é a **transcrição automática**; a degravação segue as convenções do órgão.
- **Apartes incorporados.** "A fala do aparteante pode ser incorporada ao discurso sem identificação, para preservar a continuidade." Errado: o aparte é **marcado** e o aparteante **identificado**.
- **Inaudível reconstituído.** "O revisor deve reconstituir o conteúdo provável pelo contexto, dispensando marcação." Errado: marca-se o trecho como **inaudível**; nada se inventa.
- **Só o inaudível tem marca.** "Ruído e pausa nunca são indicados." Errado: **ruído e pausa** também têm marcação convencionada.
- **Pedal exclusivo.** "O pedal é o único meio; atalhos não pausam nem retrocedem." Errado: **atalhos de teclado** também controlam o áudio; o pedal é complemento.
- **Taquigrafia começa na tribuna.** "Começa assim que o deputado se dirige à tribuna." Errado: só **depois de o Presidente conceder a palavra**.
- **Registro continua após o fim.** "Os taquígrafos continuam registrando e publicam como complemento." Errado: findo o discurso pelo Presidente, **param de registrar**.
- **Competência trocada.** "Quem determina o não apanhamento é o Secretário-Geral da Mesa." Errado: é o **Presidente**.
- **Aparte ao Presidente.** "É admitido aparte à palavra do Presidente, registrado como intervenção." Errado: **não se admite**, e aparte antirregimental **não é publicado**.
- **Decoro sem recurso.** "A proibição é definitiva e não admite recurso." Errado: **cabe recurso do orador ao Plenário**.
- **Presidente só com o nome.** Errado: **O SR. PRESIDENTE** + nome entre parênteses.
- **Inaudível só na capa.** "Basta constar nas observações da capa." Errado: marca-se **no texto e** na capa.
- **Pausa como corte.** "(Pausa.) assinala trecho cortado pelo revisor." Errado: indica **silêncio** à espera de manifestação.
- **Observações da capa como lista de emendas.** Errado: avisam sobre **problemas do registro** (inaudíveis, não identificados, falha de gravação).
- **Não identificado descartado.** Errado: a fala fica com **"(Não identificado)"** e aviso na capa.
- **Senador só com o nome.** Errado: nome + **partido ou bloco e UF** entre parênteses.
- **Campainha excluída.** Errado: entra como **(Soa a campainha.)**.
- **Palmas e tumulto dentro da fala.** Errado: **entre parênteses, em linha própria**.
- **Coordenação trocada.** Roteiros e retrancas na Gestão Administrativa, ou atas na Gestão do Discurso: errado. As duas tarefas são da **Coordenação de Registro Oficial**.
- **Ata de comissão só com presentes.** Errado: **presentes e ausentes**, com faltas justificadas.
- **Ata como transcrição literal.** Errado: ata é **sinopse** em padrão da Mesa.
- **Sem divulgação prévia.** Errado: havia divulgação **quase em tempo real**, depois **substituída automaticamente** pela revisada.

- **Indexação livre.** Errado: usa **vocabulário controlado**.
- **Diários invertidos.** Errado: Câmara no **Diário da Câmara**; sessões conjuntas no **Diário do Congresso Nacional**.

Itens comentados

- **Item:** A degravação é a saída bruta do sistema de ASR, enquanto a transcrição automática é a versão revisada e formatada segundo as convenções do órgão. **Errado.** Os conceitos estão invertidos. A transcrição automática é o texto bruto; a degravação segue as convenções do órgão e passa por revisão humana.
- **Item:** A revisão de uma transcrição deve preservar o sentido do que foi dito pelo orador, podendo tratar vícios de linguagem e repetições sem função que não alterem o conteúdo. **Certo.** O limite da revisão é o sentido. Vícios e repetições sem função podem sair; repetições com função de ênfase ficam.
- **Item:** Quando um trecho da gravação não pode ser compreendido, o revisor deve reconstituir o conteúdo provável a partir do contexto do discurso, dispensando qualquer marcação no texto. **Errado.** Reconstituir pelo contexto é inventar. O trecho recebe a marcação de inaudível convencionada pelo órgão.
- **Item:** De acordo com o Regimento Interno da Câmara dos Deputados, a taquigrafia inicia o apanhamento do discurso assim que o Deputado se dirige à tribuna, antes mesmo de o Presidente conceder a palavra. **Errado.** Pelo art. 73, VI, somente após a concessão da palavra pelo Presidente a taquigrafia inicia o apanhamento.
- **Item:** Compete ao Presidente da Câmara dos Deputados, quanto às sessões, determinar o não apanhamento de discurso ou de aparte pela taquigrafia. **Certo.** É a alínea h do inciso I do art. 17 do RICD.
- **Item:** Segundo o Regimento Interno da Câmara dos Deputados, a proibição de publicar pronunciamentos atentatórios ao decoro parlamentar é definitiva e não admite recurso do orador. **Errado.** O art. 98, § 6º, proíbe a publicação, mas garante recurso do orador ao Plenário.
- **Item:** Quando uma intervenção é inaudível, a nota taquigráfica da Câmara dispensa a indicação no corpo do texto, bastando constar o fato no bloco de observações da capa. **Errado.** A marca vai no ponto exato do texto, entre parênteses, e a capa também avisa. Uma não dispensa a outra.
- **Item:** A indicação Pausa, entre parênteses, nas notas taquigráficas da Câmara, assinala trecho que foi cortado pelo revisor por ser considerado irrelevante. **Errado.** (Pausa.) registra um momento de silêncio em que se aguarda manifestação, como quando o presidente pergunta se alguém quer discutir a ata.
- **Item:** Segundo as práticas das notas taquigráficas da Câmara, as falas de oradores não identificados em breve intervenção devem ser descartadas do registro, pois o texto só mantém falas atribuíveis a parlamentar identificado. **Errado.** A fala fica, precedida de "(Não identificado)", e o fato é anotado nas observações da capa.

- **Item:** Nas notas taquigráficas da Comissão Especial do Impeachment, publicadas pelo Senado Federal em 2016, a identificação do orador traz, entre parênteses, o partido e a unidade da Federação do senador. **Certo.** É o padrão do Senado: nome do senador e, entre parênteses, partido ou bloco e UF.
- **Item:** No Departamento de Registro Oficial e Redação Parlamentar da Câmara, a elaboração das retrancas e dos roteiros de sessões e reuniões compete à Coordenação de Gestão Administrativa. **Errado.** Retrancas e roteiros são da Coordenação de Registro Oficial. A Gestão Administrativa cuida de planejamento, compras e pessoal.
- **Item:** O Regimento Interno da Câmara dos Deputados determina que a ata de cada sessão seja lavrada como transcrição literal de tudo o que foi dito, sem sinopse e sem padrão fixado pela Mesa. **Errado.** O art. 97 manda lavrar ata com a sinopse dos trabalhos, em padrão uniforme adotado pela Mesa. A fala literal fica nas notas taquigráficas.
- **Item:** Na Câmara dos Deputados, a indexação dos discursos é feita em texto livre, sem vocabulário controlado, para que cada servidor escolha livremente os termos que melhor descrevem o assunto. **Errado.** A indexação usa vocabulário controlado; com termos livres, as buscas deixariam de reunir discursos do mesmo assunto.
- **Item:** Segundo o Departamento de Taquigrafia, Revisão e Redação da Câmara, o registro das sessões da Câmara dos Deputados é publicado no Diário do Congresso Nacional, e o das sessões conjuntas, no Diário da Câmara. **Errado.** Inverteu tudo: sessão da Câmara no Diário da Câmara; sessão conjunta ou do Congresso no Diário do Congresso Nacional.

Resumo para revisar

- Transcrição automática = saída **bruta** do ASR. Degravação = texto **segundo as convenções do órgão**, com revisão humana.
- Revisão **preserva o sentido**; pode limpar vícios de linguagem e repetições **sem função**.
- Captação ruim (microfone, ruído) = mais erro do ASR = mais revisão.
- Pedal é **complemento**; atalhos de teclado também tocam, pausam e retrocedem.
- Aparte: **marcado**, com aparteante **identificado**.
- Palmas, vaias, risos, tumulto, campainha: **entre parênteses, em linha própria**, fora da fala.
- Inaudível, ruído e pausa: **marcação convencionada**; nada se inventa.
- "(Intervenção fora do microfone. Inaudível.)" no ponto exato + aviso na capa.
- "(Pausa.)" = silêncio aguardando manifestação, não corte do revisor.
- Presidente: **O SR. PRESIDENTE (nome)**.
- Orador desconhecido: **(Não identificado)** + aviso na capa; a fala não é descartada.
- Capa: bloco de observações sobre inaudíveis, não identificados e falha de gravação.
- Senado: nome do senador + **(partido ou bloco/UF)**.
- RICD: taquigrafia só começa **após o Presidente conceder a palavra**; para quando o Presidente **dá o discurso por findo**.

- **Presidente** determina o não apanhamento de discurso ou aparte.
- Aparte à palavra do Presidente não é admitido; aparte antirregimental **não é publicado**.
- Fala contra o decoro não é publicada, **com recurso ao Plenário**.
- Ata da sessão = **sinopse** em padrão uniforme da **Mesa**; notas = fala por extenso.
- Ata de comissão: data/hora/local, **presentes e ausentes** (faltas justificadas), expediente, matérias distribuídas, proposições apreciadas.
- Coordenação de **Registro Oficial**: roteiros, retrancas e atas do Plenário.
- Coordenação de **Gestão do Discurso**: resume e indexa discursos, sugere termos ao vocabulário controlado, liga discursos a proposições.
- Indexação com **vocabulário controlado**, não texto livre.
- Divulgação **quase em tempo real** sem revisão, depois **substituída automaticamente** pela revisada.
- Câmara → **Diário da Câmara**; sessões conjuntas → **Diário do Congresso Nacional**.

TEMA 12 DE 20

Normalização de números, siglas, abreviações e termos técnicos

59 perguntas no app · Degravação e revisão

O que cai

O edital pede "Normalização de texto: números, siglas, abreviações e termos técnicos" (item 2.5 da matéria). As perguntas se dividem em três blocos:

- **A técnica**: a **normalização inversa de texto (ITN)**, que transforma a forma falada ("vinte por cento") na forma escrita padronizada ("20%"). A banca troca a ITN por diarização ou inventa outro significado para a sigla. E insiste num ponto: mesmo com ITN automática, a **revisão confere tudo pelo manual do órgão**.
- **O Manual de redação da Câmara dos Deputados** (Edições Câmara, 2017): quando escrever números por extenso ou em algarismos, votos, porcentagem, dinheiro, milhão no singular ou no plural, datas, horas, séculos, faixas numéricas e siglas (maiúsculas, inicial maiúscula, plural, partido e estado).
- **Microsoft Azure Speech**: os quatro formatos do resultado (Lexical, ITN, MaskedITN, Display) e o que o Custom Speech permite personalizar.

Aparecem ainda alguns pontos do **Manual de Redação da Presidência da República** (sigla x acrônimo, siglas em atos normativos, data dos documentos) e da **LC 95/1998** (Art. 9º, Art. 10). Quase todo item errado troca um detalhe de grafia: espaço antes do %, símbolo da moeda depois do valor, zero à esquerda na data, "16h32min", "1,1 milhões", "PT/BA".

Entenda o tema

O problema: a fala não tem grafia

Quando alguém fala "dois mil e vinte e seis", não diz se é para escrever "2026" ou "dois mil e vinte e seis". Quando fala "doze por cento", não diz se é "12%", "12 %" ou "doze por cento". A fala deixa **em aberto** a grafia de números, siglas, abreviações, datas, valores e termos técnicos.

Normalização de texto, na revisão de transcrições, é justamente a **padronização dessa grafia conforme o manual do órgão**. É como um uniforme: cada órgão decide como os números devem "se vestir", e todo texto que sai dali precisa seguir o mesmo padrão.

A normalização inversa de texto (ITN)

Nos sistemas de reconhecimento de fala (ASR), o passo que converte a **forma falada** na **forma escrita padronizada** se chama **normalização inversa de texto**, em inglês *Inverse Text*

Normalization, sigla **ITN**.

> **Exemplo:** o orador diz "vinte por cento" e "três de maio". A ITN escreve "20%" e "3 de maio".

Por que "inversa"? Porque a normalização "direta" é a que os sistemas de síntese de voz fazem: pegam "20%" escrito e o transformam em "vinte por cento" para falar. O reconhecimento de fala faz o caminho de volta: da fala para o símbolo.

> **Pegadinha:** a banca troca o nome. Converter "vinte por cento" em "20%" **não** é **diarização**. Diarização é separar o áudio por pessoa, dizendo **quem** falou em cada momento. E ITN **não** quer dizer "identificação de termos novos" (aprender palavras fora do vocabulário).

A ITN automática não dispensa a revisão

Os sistemas de ASR já fazem ITN sozinhos. Mas seguem **regras gerais**, que podem ser diferentes das regras do órgão. O sistema pode escrever "03/05/2016" quando o manual da Câmara manda "3/5/2016", ou "12 %" quando o manual manda "12%".

Por isso a padronização de números, siglas e datas **não dispensa a conferência final segundo o manual do órgão**. A ITN é um primeiro passo; a revisão humana ajusta o resultado ao padrão da Casa.

> **Atenção:** qualquer item que conclua "como o ASR já normaliza, a revisão pode dispensar a padronização pelo manual" está **errado**.

Números: por extenso ou em algarismos

O Manual de redação da Câmara dos Deputados (Edições Câmara, 2017, adotado pela Portaria DG nº 77/2017) tem uma regra simples de base:

- **Numeral de uma só palavra** (cardinal ou ordinal) vai **por extenso**: quinze, mil, primeiro, cem.
- **Numeral de mais de uma palavra** vai em **algarismos arábicos**: 23 projetos de lei (vinte e três tem três palavras).

> **Dica:** conte as palavras. "Quinze" é uma palavra: extenso. "Vinte e três" são três: algarismo.

Mistura na mesma frase. Se a mesma frase tem um número de uma palavra e outro de várias, usam-se **algarismos para os dois**, para a frase ficar uniforme. Exemplo: "Foram aprovados 15 requerimentos e 23 projetos" (e não "quinze requerimentos e 23 projetos").

Exceções que sempre vão em algarismos, mesmo que o número seja de uma palavra só:

- **Escores e contagem de votos**: "aprovado por 300 votos a favor, 125 contra e 13 abstenções". Placar não vai por extenso.
- **Porcentagens**: algarismo e símbolo **%**, **sem espaço**: 12%. Nunca "12 %".
- **Unidades monetárias**: **símbolo da moeda antes** do valor, **com espaço**: R$ 92,35. Nunca "92,35R$".

Números grandes, aproximações e milhão

Forma mista. De **mil em diante**, o Manual admite misturar algarismo e palavra: 2 mil, 14,25 milhões.

Aproximações pedem número redondo. Com "cerca de", "aproximadamente" e similares, usa-se **número redondo**: "cerca de 2 mil sem-terra". Escrever "cerca de 1.980 sem-terra" é o exemplo do que **não** se faz.

Milhão, bilhão, trilhão: singular abaixo de dois. Se o número é **menor que dois** (1; 1,1; 1,9), a palavra fica no **singular**: 1,1 milhão de pessoas. De dois em diante, plural: 2,5 milhões.

Faixas numéricas repetem a ordem de grandeza. "Compareceram à convenção entre **4 mil e 5 mil** pessoas", e não "entre 4 e 5 mil" (o leitor ficaria em dúvida se o primeiro número é 4 ou 4 mil).

Textos para leitura em voz alta. Em discursos e textos feitos para serem lidos em voz alta, os números seguem o critério da **melhor visualização para o leitor ou orador**. Daí formas como "10 mil e 300 pessoas", mais fáceis de ler em voz alta do que "10.300".

Valores por extenso em textos que exigem segurança

Em **textos legais e administrativos que demandem segurança especial** (um crédito, um contrato), o valor vai **em algarismos e, entre parênteses, por extenso**: R$ 1.000.000,00 (um milhão de reais). Um confere o outro; é uma trava contra erro de digitação. Item que diga que é "vedado repeti-los por extenso" está errado.

Como escrever por extenso. Usa-se a conjunção **"e" entre centenas, dezenas e unidades**: 128 = cento **e** vinte **e** oito. Entre o **milhar e a centena**, em geral, **não** se usa "e": 2.101 = dois mil cento e um. O "e" só entra ali quando a centena é redonda (termina em 00): 2.100 = dois mil **e** cem.

Datas

- **Data abreviada**: dia, mês e ano separados por **barra**, **sem zero à esquerda**: 3/5/2016 (e não 03/05/2016).
- **Ano com quatro dígitos**, sempre: Lei n. 8.112/**1990** (e não 8.112/90). Com dois dígitos, o leitor poderia ter dúvida sobre o século.
- **Ordinal só no primeiro dia do mês**: 1º de abril de 2016. Os demais dias vão em cardinal: 7 de setembro, 15 de novembro.

> **Atenção:** o Manual da Câmara rejeita o **zero à esquerda** em geral, inclusive nas datas.

Horas e duração

- **Só horas cheias**: escreve-se a **palavra** "horas": "A reunião será realizada às **14 horas**."
- **Horas e minutos**: usa-se **só o símbolo h**, sem "min": "A Ordem do Dia iniciou-se às **16h32**." Nunca "16h32min".
- **Horas, minutos e segundos**: aí entra o "min": **7h23min40**.
- **Duração** (um período, e não um horário do relógio): vai por **palavras**, sem símbolos: "a reunião se estendeu por quatro horas e vinte minutos" (e não "por 4h20min").

> **Dica:** os símbolos h e min marcam **o ponteiro do relógio** (um instante). Para dizer **quanto tempo** algo durou, use palavras.

Séculos

Séculos vão em **algarismos romanos**: século XX. Não "século 20".

> **Exemplo:** revisando um discurso de sessão solene, Fábio encontra "século 20" na transcrição automática. Ele corrige para "século XX", como manda o Manual.

Siglas

O Manual da Câmara classifica as siglas pela **forma como são lidas**:

Tipo de sigla	Grafia	Exemplos
Até **três letras**	todas **maiúsculas**	ONU, PIS, OMC
Quatro ou mais letras, **lida como palavra**	só a **inicial maiúscula** (como nome próprio)	Otan, Unesco, Petrobras
Quatro ou mais letras, **lida letra por letra**	todas **maiúsculas**	INSS, FGTS
Leitura mista (parte soletrada, parte como palavra)	todas **maiúsculas**	DNIT, HRAN
Exceções consagradas	grafia própria	CNPq, UnB

Outras regras de siglas:

- **Sem pontos** entre as letras: ONU, e não O.N.U.
- **Primeira menção**: nome completo **por extenso**, seguido da sigla **entre parênteses**; nas menções seguintes, só a sigla. Para entidades conhecidas pela sigla, como a Petrobras, o extenso pode ser dispensado.
- **Plural**: **s minúsculo, sem apóstrofo**: TREs (e não TRE's). Se a sigla **já termina em s**, o plural é marcado pelo **artigo**: os DVS (e não DVS's).
- **Partido e estado**: separados por **hífen**: PT-BA, PSDB-MG (e não PT/BA). Já o estado depois do nome de uma **cidade** vai **entre parênteses**: Feira de Santana (BA).

O que diz o Manual de Redação da Presidência da República

Alguns itens usam o manual do Executivo federal (3ª edição, 2018):

- **Sigla x acrônimo. Sigla** é a soma das **iniciais** de um título: CEF (Caixa Econômica Federal). **Acrônimo** é a soma de **partes (sílabas) dos vocábulos**: Anvisa (Agência Nacional de Vigilância Sanitária). A banca inverte.
- **Siglas em atos normativos.** Nos textos de **atos normativos** (lei, decreto), **não se usam siglas** para designar **órgãos da administração pública direta** (ministérios, por exemplo). Para entidades da administração indireta, só se a lei previr a sigla.

- **Local e data dos documentos oficiais.** Cidade **sem** a sigla da UF e mês com **inicial minúscula**: "Brasília, 2 de fevereiro de 2018."

Numeração de artigos (LC 95/1998)

A Lei Complementar 95/1998, que trata da redação das leis, manda indicar o artigo pela abreviatura "Art." seguida de numeração **ordinal até o nono** e **cardinal a partir do décimo** (art. 10, I): Art. 1º ... Art. 9º, Art. 10, Art. 11. Os parágrafos seguem a mesma regra (§ 9º, § 10). Quem normaliza uma citação de artigo na transcrição segue essa grafia.

ITN no Azure Speech

O serviço de fala da Microsoft (Azure AI Speech) aparece em várias perguntas.

O que a ITN do Azure faz. Converte a **forma verbalizada** na **forma escrita simbólica**: a palavra *four* vira 4; *nine hundred dollars* vira $900. Cobre **datas, horários, decimais, moedas, endereços, e-mails e telefones**.

Não é configurável caso a caso. Na saída padrão do serviço, a ITN é feita pelo próprio sistema e **não é configurável pelo usuário** conversão por conversão. Para ter regras próprias, é preciso **personalizar o modelo** (Custom Speech) ou ajustar o texto depois, na revisão.

Os quatro formatos do resultado detalhado. Na API REST para áudios curtos, no formato *detailed*, cada alternativa de reconhecimento (lista **NBest**) traz quatro representações do mesmo texto:

Campo	O que traz
Lexical	as palavras reconhecidas, como foram ditas, **sem formatação**
ITN	o texto com a normalização inversa aplicada (números, datas etc. em forma escrita)
MaskedITN	a forma ITN com **palavrões mascarados** (filtro de profanidade)
Display	a versão **pronta para exibição**, com **pontuação e capitalização**

> **Pegadinha:** o item troca Lexical e Display. Lexical é o **cru**; Display é o **pronto**, com pontuação e maiúsculas.

Custom Speech. O recurso de personalização do Azure vai **além do vocabulário**. Permite:

- adaptar o **vocabulário** e o modelo de linguagem ao domínio;
- definir **pronúncias** personalizadas;
- ajustar o **formato de exibição**: **ITN personalizada**, **regras de reescrita** (regravação de termos) e **filtro de palavrões** personalizado.

Item que diga que o Custom Speech "permite personalizar apenas o vocabulário" está errado.

Quadros para memorizar

Grafia de números (Manual da Câmara)

Caso	Regra	Certo	Errado
Uma palavra	por extenso	quinze, mil, primeiro	15 proposições
Mais de uma palavra	algarismo	23 projetos	vinte e três projetos
Mistura na frase	algarismo para todos	15 requerimentos e 23 projetos	quinze ... e 23
Votos e escores	algarismo	300 a favor, 125 contra, 13 abstenções	trezentos votos
Porcentagem	algarismo + % sem espaço	12%	12 %
Dinheiro	símbolo antes, com espaço	R$ 92,35	92,35R$
Mil em diante	forma mista	2 mil; 14,25 milhões	
Aproximação	número redondo	cerca de 2 mil	cerca de 1.980
Abaixo de dois	milhão no singular	1,1 milhão	1,1 milhões
Faixa	repete a grandeza	entre 4 mil e 5 mil	entre 4 e 5 mil
Segurança especial	algarismo + extenso entre parênteses	R$ 1.000.000,00 (um milhão de reais)	só algarismo
Extenso	"e" entre centena, dezena e unidade	cento e vinte e oito	
Milhar + centena	sem "e" (salvo centena redonda)	dois mil cento e um; dois mil e cem	dois mil e cento e um
Século	romano	século XX	século 20
Texto para leitura em voz alta	melhor visualização	10 mil e 300 pessoas	

Datas e horas

Caso	Certo	Errado
Data abreviada	3/5/2016	03/05/2016
Ano	8.112/1990	8.112/90
Primeiro dia do mês	1º de abril	1 de abril
Outros dias	7 de setembro	7º de setembro
Hora cheia	às 14 horas	às 14h
Hora e minuto	16h32	16h32min
Com segundos	7h23min40	
Duração	quatro horas e vinte minutos	4h20min

Caso	Certo	Errado
Data de documento oficial (MRPR)	Brasília, 2 de fevereiro de 2018.	Brasília-DF, 2 de Fevereiro

Siglas

Regra	Certo	Errado
Até 3 letras	ONU, PIS, OMC	Onu, O.N.U.
4+ letras lida como palavra	Otan, Unesco, Petrobras	OTAN
4+ letras soletrada	INSS, FGTS	Inss
Leitura mista	DNIT, HRAN	Dnit
Plural	TREs; os DVS	TRE's; DVS's
Partido e estado	PT-BA	PT/BA
Cidade e estado	Feira de Santana (BA)	
Primeira menção	nome por extenso (SIGLA)	só a sigla
Sigla (MRPR)	iniciais: CEF	
Acrônimo (MRPR)	partes das palavras: Anvisa	

Azure Speech

Ponto	O que cai
ITN	forma falada → forma escrita (four → 4); datas, horas, decimais, moedas, endereços, e-mails, telefones
ITN na saída padrão	feita pelo sistema; não configurável caso a caso pelo usuário
Lexical	palavras cruas
ITN	texto normalizado
MaskedITN	normalizado com palavrões mascarados
Display	com pontuação e capitalização
Custom Speech	vocabulário, pronúncia, ITN própria, regras de reescrita, filtro de palavrões

Conceitos e autores que caem

Normalização de texto (na revisão). Padronização, conforme o manual do órgão, da grafia de números, siglas, abreviações, datas, valores e termos técnicos que a fala deixa em aberto.

Normalização inversa de texto (ITN, *Inverse Text Normalization*). Etapa do ASR que converte a forma falada em forma escrita padronizada ("vinte por cento" → "20%"). Feita depois do reconhecimento das palavras; o resultado final é conferido na revisão.

Diarização. Não confundir: é separar o áudio por falante ("quem falou quando").

Sigla e acrônimo (Manual da Presidência). Sigla = iniciais (CEF). Acrônimo = partes das palavras (Anvisa).

O texto oficial da LC 95/1998 sobre numeração de artigos:

> **Lei seca:** Art. 10, I – a unidade básica de articulação será o artigo, indicado pela abreviatura "Art.", seguida de numeração **ordinal até o nono e cardinal a partir deste**;

Pegadinhas da banca

- **ITN = diarização.** Errado: "vinte por cento" → "20%" é **normalização inversa de texto**; diarização separa falantes.
- **ITN = identificação de termos novos.** Errado: ITN é **Inverse Text Normalization**.
- **ASR normaliza, revisão dispensa o manual.** Errado: o sistema segue regras gerais; a revisão **confere pelo manual do órgão**.
- **Algarismo para qualquer quantidade.** Errado: número de **uma palavra** vai **por extenso**.
- **Mistura: um por extenso, outro em algarismo.** Errado: na mistura, **algarismos para ambos**.
- **Votos por extenso.** Errado: votos e escores vão em **algarismos**.
- **12 % com espaço.** Errado: **12%**, sem espaço.
- **92,35R$.** Errado: **R$ 92,35**, símbolo antes e com espaço.
- **"Cerca de 1.980".** Errado: aproximação pede **número redondo** (cerca de 2 mil).
- **"1,1 milhões".** Errado: abaixo de dois, **singular** (1,1 milhão).
- **Valor só em algarismos em texto de segurança especial.** Errado: algarismos **e** extenso entre parênteses.
- **"Dois mil e cento e um".** Errado: **dois mil cento e um**.
- **Data com zero à esquerda.** Errado: **3/5/2016**.
- **Ano com dois dígitos.** Errado: **quatro dígitos** sempre.
- **16h32min.** Errado: **16h32**; o min só aparece com segundos.
- **Duração com símbolos (4h20min).** Errado: duração vai **por palavras**.
- **Século 20.** Errado: **século XX**.
- **"Entre 4 e 5 mil".** Errado: **entre 4 mil e 5 mil**.
- **Onu, Pis, Omc.** Errado: até três letras, **tudo maiúsculo**.
- **Inss, Fgts.** Errado: lida letra por letra, **tudo maiúsculo**.
- **Dnit, Hran.** Errado: leitura mista, **tudo maiúsculo**.
- **TRE's, DVS's.** Errado: **TREs**; **os DVS**.
- **PT/BA.** Errado: **PT-BA** (hífen).
- **Sigla e acrônimo invertidos** (MRPR). Errado: sigla = **iniciais** (CEF); acrônimo = **partes** (Anvisa).
- **Data de documento oficial com UF e mês maiúsculo** (MRPR). Errado: "Brasília, 2 de fevereiro de 2018."

- **ITN do Azure configurável caso a caso.** Errado: na saída padrão, **não é configurável** pelo usuário; para regras próprias, Custom Speech ou revisão.
- **Lexical com pontuação, Display cru.** Errado: **invertidos**.
- **Custom Speech só vocabulário.** Errado: também pronúncia, **ITN**, **reescrita** e **filtro de palavrões**.

Itens comentados

- **Item:** Em ASR, a conversão da forma falada para a forma escrita padronizada, como de "vinte por cento" para "20%", é chamada de diarização. **Errado.** Esse passo é a normalização inversa de texto (ITN). Diarização é separar o áudio por falante.
- **Item:** Como os sistemas de ASR já realizam a normalização inversa de texto de forma automática, a padronização de números, siglas e datas dispensa a conferência final segundo o manual do órgão. **Errado.** A ITN segue regras gerais, que podem divergir das do órgão. A revisão confere tudo pelo manual.
- **Item:** Se, na mesma frase, houver numeral representado por uma palavra e outro representado por mais de uma palavra, o Manual de redação da Câmara manda escrever o primeiro por extenso e o segundo em algarismos. **Errado.** Na mistura, os dois vão em algarismos, para a frase ficar uniforme.
- **Item:** Segundo o Manual de redação da Câmara dos Deputados, escores e contagem de votos são grafados em algarismos, como em aprovado por 300 votos a favor, 125 contra e 13 abstenções. **Certo.** Placar e votos vão sempre em algarismos.
- **Item:** Segundo o Manual de redação da Câmara dos Deputados, números decimais abaixo de dois levam as palavras milhão, bilhão e trilhão no plural, como em 1,1 milhões de pessoas. **Errado.** Abaixo de dois, singular: 1,1 milhão.
- **Item:** O Manual de redação da Câmara dos Deputados indica que o número 2.101 seja escrito por extenso como dois mil e cento e um, usando sempre a conjunção e entre o milhar e a centena. **Errado.** O certo é "dois mil cento e um". O "e" entre milhar e centena só aparece quando a centena é redonda, como em "dois mil e cem".
- **Item:** O Manual de redação da Câmara dos Deputados manda grafar a data abreviada com zero à esquerda no dia e no mês, como em 03/05/2016, para uniformizar o número de dígitos. **Errado.** A forma é 3/5/2016, sem zero à esquerda; só o ano tem sempre quatro dígitos.
- **Item:** Segundo o Manual de redação da Câmara dos Deputados, o horário com horas e minutos deve trazer sempre os dois símbolos, h e min, como em 16h32min. **Errado.** Com horas e minutos, só o h: 16h32. O min aparece com segundos: 7h23min40.
- **Item:** O Manual de redação da Câmara dos Deputados manda indicar a duração de uma reunião com símbolos de tempo, como em a reunião se estendeu por 4h20min. **Errado.** Duração vai por palavras: quatro horas e vinte minutos. Os símbolos marcam horário.
- **Item:** Segundo o Manual de redação da Câmara dos Deputados, siglas de quatro ou mais letras que formem palavra pronunciável são grafadas como nome próprio, com apenas a inicial

maiúscula, como Otan, Unesco e Petrobras. **Certo.** Lida como palavra, só a inicial maiúscula. Se fosse lida letra por letra (INSS), seria toda em maiúsculas.

- **Item:** De acordo com o Manual de redação da Câmara dos Deputados, o plural das siglas é formado com apóstrofo antes do s, como em TRE's, e também em siglas terminadas em s, como DVS's. **Errado.** Plural sem apóstrofo (TREs); sigla terminada em s marca o plural pelo artigo (os DVS).
- **Item:** Segundo o Manual de redação da Câmara dos Deputados, as siglas partidárias são separadas das siglas dos estados por barra, como em PT/BA e PSDB/MG. **Errado.** Usa-se hífen: PT-BA, PSDB-MG.
- **Item:** Segundo o Manual de Redação da Presidência da República, acrônimo é o resultado da soma das iniciais de um título, como CEF, e sigla é o resultado da soma de partes dos vocábulos, como Anvisa. **Errado.** Conceitos invertidos: sigla junta iniciais (CEF); acrônimo junta partes das palavras (Anvisa).
- **Item:** No formato detalhado de resposta da API REST do Azure para áudios curtos, o campo Lexical traz o texto já com pontuação e capitalização adicionadas, enquanto o campo Display traz as palavras reconhecidas sem formatação. **Errado.** É o contrário: Lexical é o texto cru; Display é a versão para exibição, com pontuação e maiúsculas.
- **Item:** O Custom Speech do Azure AI Speech permite personalizar apenas o vocabulário do modelo, sem possibilidade de personalizar a normalização inversa de texto, a regravação de termos ou o filtro de palavrões. **Errado.** O Custom Speech também personaliza pronúncia e o formato de exibição: ITN própria, regras de reescrita e filtro de palavrões.

Resumo para revisar

- **ITN** (normalização inversa de texto): fala → escrita padronizada ("vinte por cento" → 20%). Não é diarização.
- A ITN automática **não dispensa** a revisão pelo **manual do órgão**.
- Número de **uma palavra**: por extenso. De **várias**: algarismo. **Mistura**: algarismo para todos.
- Votos e escores: **algarismo** (300 a favor, 125 contra, 13 abstenções).
- **12%** sem espaço; **R$ 92,35** com símbolo antes e espaço.
- Mil em diante: forma mista (2 mil; 14,25 milhões). Aproximação: **número redondo**.
- Abaixo de dois: **1,1 milhão** (singular).
- Faixa: **entre 4 mil e 5 mil**.
- Segurança especial: **R$ 1.000.000,00 (um milhão de reais)**.
- Extenso: cento **e** vinte **e** oito; dois mil cento e um; dois mil **e** cem.
- Texto para leitura em voz alta: **melhor visualização** (10 mil e 300).
- Data: **3/5/2016**, ano com **4 dígitos**, ordinal só no **1º** do mês.
- Hora cheia: **14 horas**. Com minutos: **16h32**. Com segundos: **7h23min40**. Duração: **por palavras**.
- Século: **romano** (XX).

- Siglas: até 3 letras **maiúsculas**; 4+ lida como palavra **só inicial** (Unesco); soletrada ou mista **maiúsculas** (INSS, DNIT); exceções CNPq, UnB.
- Plural de sigla: **TREs**, **os DVS**. Partido-estado: **PT-BA**. Primeira menção: extenso + (SIGLA).
- MRPR: sigla = iniciais (CEF); acrônimo = partes (Anvisa); atos normativos não usam sigla para órgão da administração direta; "Brasília, 2 de fevereiro de 2018."
- LC 95: **Art. 9º**, **Art. 10** (ordinal até o nono).
- Azure: ITN converte four → 4 (datas, horas, moedas, endereços, e-mails, telefones); na saída padrão **não é configurável** pelo usuário.
- Azure detailed: **Lexical** (cru), **ITN**, **MaskedITN** (palavrões mascarados), **Display** (pontuação e maiúsculas).
- **Custom Speech**: vocabulário, pronúncia, ITN própria, reescrita, filtro de palavrões.

TEMA 13 DE 20

Ferramentas CAT e vocabulário parlamentar adaptado

55 perguntas no app · Degravação e revisão

O que cai

O edital pede "Ferramentas de CAT (*Computer Assisted Transcription*) e editores de transcrição" (item 2.6) e "Vocabulário técnico parlamentar e vocabulário adaptado (*language model adaptation*)" (item 2.8). As perguntas deste tema se concentram em:

- **Como ensinar ao reconhecedor o jargão do Parlamento**: vocabulário personalizado (uma lista de termos) x modelo de linguagem adaptado ou personalizado (treinado com textos). O vocabulário **ajuda**, mas **não garante** acerto e **não dispensa** revisão.
- **Os recursos de cada fornecedor**: OpenAI (parâmetro *prompt* do Whisper), Amazon Transcribe (vocabulário personalizado, tabela com coluna Phrase, modelo de linguagem personalizado, filtro de vocabulário), Azure (lista de frases, peso, Custom Speech, WER), Google (PhraseSet, boost, CustomClass, tokens de classe).
- **O editor de transcrição**: áudio sincronizado ao texto, velocidade, palavras de baixa confiança, pedal e atalhos.
- **A sigla CAT** no edital: *Computer Assisted Transcription*, não *Translation*.

A pegadinha que mais se repete: dizer que o recurso **garante** acerto, que exige **retreinar** o modelo com horas de áudio, que é **ilimitado** ou que o **peso máximo** é sempre melhor.

Entenda o tema

O problema: palavras raras

Um sistema de reconhecimento de fala (ASR) "aposta" em cada palavra com base em probabilidades. Ele aprendeu com uma montanha de textos e áudios genéricos. Palavras comuns, como "casa" e "hoje", ele acerta fácil. Mas **siglas** (CCJC, PLP, DVS), **nomes de parlamentares** e **expressões regimentais** ("destaque para votação em separado", "requerimento de urgência") quase não aparecem nos dados genéricos. O sistema aposta pouco nelas e erra.

A solução é **adaptar** o sistema ao domínio. Há dois caminhos principais, e a banca adora confundi-los.

Caminho 1: vocabulário personalizado (a "colinha")

O **vocabulário personalizado** é uma **lista de termos, nomes e frases do domínio** entregue ao serviço para **aumentar a chance** de serem reconhecidos. Funciona como uma colinha: "nesta

gravação vão aparecer estas palavras". Em geral, **não exige retreinar o modelo**.

Três limites importantes:

- **Não garante acerto.** Cadastrar a palavra só aumenta a probabilidade. Se o áudio estiver ruim ou o orador pronunciar de outro jeito, o sistema ainda pode errar. **A revisão humana continua necessária.**
- **Tem tamanho limitado.** As listas dos serviços em nuvem têm limite, o que obriga a **priorizar os termos de maior impacto**: nomes próprios e siglas frequentes que o modelo genérico costuma errar. Não faz sentido carregar "a língua portuguesa inteira": o modelo já conhece as palavras comuns.
- **Não elimina, por si só, os erros** em nomes próprios e siglas.

> **Exemplo:** o departamento de registro percebe que o sistema erra o nome da Deputada (fictícia) Helena Albuquerque e a sigla CFT. Fornece uma lista com esses termos. O reconhecimento desses termos tende a melhorar, mas o revisor continua conferindo.

Caminho 2: modelo de linguagem adaptado (o "estágio")

A **adaptação do modelo de linguagem** (*language model adaptation*) usa **textos do domínio** (transcrições de sessões, nomes de parlamentares, siglas, termos regimentais) para que o sistema **atribua maior probabilidade** a esses termos. É como mandar o sistema fazer um estágio no Parlamento: ele lê muito texto da Casa e aprende que "destaque" e "requerimento" aparecem o tempo todo ali.

O efeito é **reduzir** a taxa de erro de palavras (**WER**, *Word Error Rate*) **no domínio**. Item que diga que a adaptação "tende a elevar o WER no domínio, pois o modelo perde generalidade" está errado.

A diferença essencial:

- **Vocabulário personalizado** = lista de palavras soltas; dá **dicas** sobre palavras específicas.
- **Modelo de linguagem personalizado** = treinado com **textos inteiros**; aprende o **contexto**: como e quando a palavra é usada e com que outras palavras costuma aparecer.

> **Pegadinha:** o item troca os dois: "o vocabulário personalizado consiste em retreinar o modelo acústico com horas de áudio, e o modelo adaptado é apenas uma lista". É o contrário.

Também funciona em sistemas end-to-end

Sistemas **end-to-end** são os feitos "de uma peça só": uma única rede neural vai do áudio ao texto, sem módulos separados. Mesmo neles a adaptação é possível, de duas formas:

- **acoplar um modelo de linguagem externo** treinado com textos do Parlamento;
- **fornecer listas de termos** ao reconhecedor.

Item que diga que a adaptação é "inviável" em sistemas end-to-end está errado.

OpenAI e Whisper: o parâmetro *prompt*

Na API de transcrição da OpenAI, o parâmetro **prompt** é um **campo de texto livre** enviado junto com o áudio. Serve para **ajudar no reconhecimento de nomes, siglas e vocabulário específico** da gravação.

Como ele funciona:

- O prompt atua como **contexto anterior ao trecho**, como se fosse o texto que veio antes. Isso favorece a grafia correta de nomes e siglas e influencia o **estilo** (pontuação, por exemplo).
- O **Whisper não segue instruções** como um modelo de texto de uso geral (como um chatbot). O prompt é **contexto de vocabulário e estilo**, não ordem. Não dá para pedir "resuma" ou "traduza" pelo prompt.
- Um uso típico: passar o final da transcrição do trecho anterior para dar **continuidade entre trechos** de uma gravação longa.
- O prompt tem **tamanho limitado**: o modelo só aproveita um pedaço curto (no Whisper, os últimos 224 tokens). Não dá para mandar "a lista completa de nomes da Casa".
- **Não equivale a retreinar** o modelo e **não garante** a grafia correta.

O parâmetro **language** é outra coisa: só diz **em que idioma** está o áudio. Não serve para ensinar nomes e siglas.

Nem todo modelo aceita prompt. O **gpt-4o-transcribe-diarize**, modelo que **identifica os falantes**, **não aceita** o parâmetro prompt. É preciso conferir o que cada modelo suporta.

Amazon Transcribe

O serviço de transcrição da AWS tem três recursos que a banca diferencia.

1. Vocabulário personalizado (*custom vocabulary*). Melhora a acurácia em **palavras específicas**: termos de domínio, nomes de marca, siglas e nomes próprios que o serviço não grafa corretamente. Regras:

- **Não incluir dados pessoais nem informações confidenciais** no vocabulário. A documentação traz esse aviso expresso. A lista é para termos do domínio.
- O vocabulário precisa ter sido criado na **mesma Região da AWS** em que a transcrição será executada.
- Tem **tamanho limitado**.
- **Formato de tabela**: a coluna **Phrase** é a **obrigatória**. As colunas **SoundsLike** e **IPA** (de pronúncia) **não são mais suportadas**: devem ficar vazias, e qualquer valor nelas é ignorado. Há também a coluna **DisplayAs**, que separa **a forma como o termo é reconhecido** da **forma como deve ser exibido**. Assim, uma sigla falada letra por letra pode sair grafada do jeito certo no texto.

2. Modelo de linguagem personalizado (*custom language model*). Treinado com **textos do domínio**, aprende o **contexto** das palavras. Não é "um vocabulário maior". Regras:

- Os melhores dados de treinamento são **transcrições precisas do próprio domínio**. No Parlamento, isso significa **notas taquigráficas revisadas** de sessões anteriores.

- Os **dados de treinamento** e os **dados de ajuste** (*tuning*) **não devem se sobrepor**. Repetir os mesmos textos nas duas etapas enviesa o modelo e piora a acurácia.
- Com modelo de linguagem personalizado, **não se pode usar a identificação automática de idioma**: é preciso informar o idioma, porque o modelo foi treinado para uma língua específica.

3. Filtro de vocabulário (*vocabulary filter*). Age sobre a **saída**, não sobre o reconhecimento. Para uma lista de palavras escolhida pelo usuário, pode:

- **mascarar** com asteriscos (***);
- **remover**;
- apenas **sinalizar** (marcar), sem alterar a palavra.

O filtro **não aumenta** a chance de reconhecer palavras. Para siglas e nomes difíceis, o recurso certo é o **vocabulário personalizado**.

> **Dica:** vocabulário personalizado **acha** a palavra; filtro de vocabulário **esconde** a palavra.

Azure AI Speech

Lista de frases (*phrase list*). É um recurso aplicado **no momento do reconhecimento**, que **não exige treinar modelo**. Funciona na **transcrição em tempo real** e na **transcrição rápida**, mas **não na transcrição em lote** (*batch*).

- A lista tem **limite prático** (a orientação é ficar em cerca de 2.000 itens). Listas maiores pioram a **qualidade** e a **latência**. Para vocabulários muito extensos, o caminho é o **Custom Speech**.
- **Peso da lista**: aumentar o peso torna mais provável o reconhecimento das frases da lista, mas também **eleva o risco** de o sistema "ouvir" esses termos onde eles **não foram ditos**. Por isso não se usa sempre o peso máximo: é preciso testar.

Custom Speech. É o modelo personalizado do Azure:

- Com **dados de texto**, melhora a acurácia para o **vocabulário do domínio**.
- Com **dados de áudio e transcrições de referência** (conferidas por humanos), melhora também para as **condições acústicas** da aplicação (ruído, microfone, sala).
- Não é "só áudio".

Quando personalizar. A Microsoft recomenda medir: compara-se a transcrição do **modelo base** com uma **transcrição humana** do mesmo áudio e calcula-se o **WER**. Se o WER for alto, vale treinar um modelo personalizado.

Estabilidade. O modelo personalizado implantado em um *endpoint* **fica fixo** até o usuário decidir mudar. Ele **não** é atualizado automaticamente quando sai um novo modelo base. Isso garante resultados estáveis; a troca é decisão do cliente.

Google Cloud Speech-to-Text: adaptação de modelo

No Google, a adaptação de modelo (*model adaptation*) **não retreina nada com áudio**. Você envia **frases com pesos**, e elas valem para aquela transcrição.

- **PhraseSet**: conjunto de frases. Fornecer uma **frase com várias palavras** aumenta a probabilidade de essas palavras serem reconhecidas **em sequência** (por exemplo, o nome completo de uma comissão).
- **Boost**: o reforço é atribuído **frase a frase**. Dá para dar mais peso a nomes críticos para o registro e menos a termos de menor importância.
- **Boost alto: troca-troca.** Pode **reduzir falsos negativos** (deixar de reconhecer a frase dita), mas pode **aumentar falsos positivos** (reconhecer a frase onde ela não foi dita). O valor deve ser testado, não fixado no máximo.
- O boost de uma frase com várias palavras vale para **a frase inteira**. Para favorecer **correspondências parciais**, é preciso adicionar **bigramas ou n-gramas maiores** como frases separadas.
- **CustomClass**: uma **lista de itens** definida pelo usuário (por exemplo, centenas de nomes de restaurantes ou de deputados), que funciona como as **classes pré-definidas** do Google (números, datas, moedas) e **pode ser combinada** com elas em uma frase. Não é um modelo acústico treinado.
- **Token de classe inválido** ou mal formado é **ignorado sem gerar erro**. E a **disponibilidade das classes varia** conforme o modelo de transcrição e o idioma.

Ferramentas CAT e editores de transcrição

No edital, **CAT** significa ***Computer Assisted Transcription***, **transcrição assistida por computador**. Na área de tradução existe outra sigla CAT (*Computer Assisted Translation*), mas o edital trata de **transcrição**.

Os **editores de transcrição com áudio sincronizado** ligam cada palavra do texto ao trecho de áudio correspondente. Eles permitem:

- **clicar numa palavra e ouvir** aquele trecho;
- **ajustar a velocidade** de reprodução (tocar mais devagar um trecho difícil);
- em alguns casos, **destacar palavras de baixa confiança** do ASR, isto é, aquelas de que a máquina não teve certeza, para o revisor olhar primeiro.

O **pedal** e os **atalhos de teclado** servem para **controlar o áudio**: tocar, pausar, voltar alguns segundos. O pedal deixa as mãos livres para digitar. **Não** servem para inserir pontuação nem para trocar o orador.

Quadros para memorizar

Vocabulário personalizado x modelo de linguagem personalizado

	Vocabulário personalizado	Modelo de linguagem personalizado
O que é	lista de termos, nomes e frases	modelo treinado com textos do domínio
O que aprende	dicas sobre palavras isoladas	contexto: como, quando e com que palavras o termo aparece

	Vocabulário personalizado	Modelo de linguagem personalizado
Exige treinar?	em geral, não	sim, com textos (notas taquigráficas revisadas)
Limite	tamanho limitado	dados de treino e de ajuste sem sobreposição
Garante acerto?	não	não

Recursos por fornecedor

Fornecedor	Recurso	O que cai
OpenAI	prompt	contexto de vocabulário e estilo; tamanho limitado; não é instrução; não retreina; continuidade entre trechos
OpenAI	language	só o idioma
OpenAI	gpt-4o-transcribe-diarize	identifica falantes; não aceita prompt
Amazon	custom vocabulary	palavras específicas; sem dados pessoais; mesma Região; tamanho limitado
Amazon	tabela	Phrase obrigatória; SoundsLike e IPA não suportadas (vazias); DisplayAs separa reconhecido de exibido
Amazon	custom language model	aprende contexto; treino ≠ ajuste; sem identificação automática de idioma
Amazon	vocabulary filter	mascara, remove ou sinaliza; não melhora reconhecimento
Azure	phrase list	sem treino; tempo real e rápida, não lote; cerca de 2.000 itens; peso alto = mais falsos positivos
Azure	Custom Speech	texto → vocabulário; áudio + transcrição → acústica; decide-se pelo WER; modelo implantado fica fixo
Google	PhraseSet e boost	frase inteira em sequência; boost por frase; boost alto = menos falsos negativos e mais falsos positivos; n-gramas para parciais
Google	CustomClass	lista de itens; combina com classes pré-definidas
Google	token de classe	inválido é ignorado sem erro; disponibilidade varia por modelo e idioma

Peso e boost

Mais peso ou boost	Efeito
Falsos negativos (não reconhecer o termo dito)	diminuem
Falsos positivos (inserir o termo onde não foi dito)	aumentam
Conclusão	testar; não usar sempre o máximo

Conceitos e autores que caem

- **CAT (*Computer Assisted Transcription*)**: transcrição assistida por computador. Não confundir com *Computer Assisted Translation*.
- **Vocabulário personalizado**: lista de termos do domínio fornecida ao serviço para aumentar a chance de reconhecimento, em geral sem retreinar.
- **Adaptação do modelo de linguagem (*language model adaptation*)**: uso de textos do domínio para o sistema dar mais probabilidade aos termos daquele domínio. Reduz o WER no domínio.
- **WER (*Word Error Rate*)**: taxa de erro de palavras; mede a distância entre a transcrição da máquina e uma transcrição humana de referência. Quanto menor, melhor.
- **Modelo end-to-end**: sistema de uma peça só, do áudio ao texto; aceita modelo de linguagem externo e listas de termos.
- **Falso negativo x falso positivo**: deixar de reconhecer o que foi dito x "reconhecer" o que não foi dito.
- **Palavra de baixa confiança**: palavra que o ASR transcreveu com pouca certeza; os editores podem destacá-la.
- **Bigrama, n-grama**: sequência de 2 ou n palavras.

Pegadinhas da banca

- **"Vocabulário personalizado exige sempre retreinar o modelo e elimina, por si só, os erros."** Errado: em geral **não retreina** e **não garante** acerto.
- **Vocabulário e modelo adaptado trocados.** Errado: vocabulário = **lista**; modelo adaptado = **treinado com textos** (e às vezes áudio).
- **"Adaptação eleva o WER no domínio."** Errado: **reduz**.
- **"Vocabulário vai no parâmetro language."** Errado: vai no **prompt**; language só indica o idioma.
- **"Prompt ilimitado, com garantia de grafia."** Errado: **tamanho limitado** e **sem garantia**.
- **"O Whisper cumpre o prompt como instrução, podendo resumir e traduzir."** Errado: o prompt é **contexto**, não ordem.
- **"Todos os modelos aceitam prompt, inclusive o gpt-4o-transcribe-diarize."** Errado: o diarize **não aceita**.
- **"Pedal insere pontuação; atalhos trocam o orador."** Errado: ambos **controlam o áudio**.
- **"End-to-end não admite modelo externo nem listas."** Errado: admite os dois.
- **"Amazon recomenda pôr dados pessoais no vocabulário."** Errado: recomenda **não** pôr.
- **"SoundsLike e IPA obrigatórias; Phrase opcional."** Errado: **Phrase** é obrigatória; SoundsLike e IPA não são mais suportadas.
- **"Termo cadastrado é reconhecido com certeza."** Errado: só **aumenta a chance**.
- **"Vocabulário sem limite; carregue a língua inteira."** Errado: **tamanho limitado**; priorize os termos de maior impacto.

- **"Modelo de linguagem personalizado = vocabulário maior, sem contexto."** Errado: aprende o **contexto**.
- **"Treino e ajuste devem se sobrepor."** Errado: **não devem**.
- **"Modelo personalizado com identificação automática de idioma."** Errado: é preciso **informar o idioma**.
- **"Filtro de vocabulário melhora o reconhecimento."** Errado: ele **mascara, remove ou sinaliza** na saída.
- **"CAT = Computer Assisted Translation."** Errado: **Transcription**.
- **"Lista de frases do Azure exige treino e vale em lote."** Errado: **sem treino**; **não vale em lote**.
- **"Peso máximo reduz o risco de inserção indevida."** Errado: **aumenta** o risco.
- **"Lista de frases sem limite, dispensa Custom Speech."** Errado: cerca de **2.000** itens; listas maiores pioram qualidade e latência.
- **"Custom Speech só aceita áudio."** Errado: aceita **texto** (vocabulário) e **áudio com transcrição** (acústica).
- **"Modelo implantado atualiza sozinho com cada novo modelo base."** Errado: **fica fixo** até o cliente mudar.
- **"Adaptação do Google retreina o modelo acústico com horas de áudio."** Errado: só **frases com boost**.
- **"Boost alto reduz falsos negativos e falsos positivos."** Errado: aumenta os **falsos positivos**.
- **"CustomClass é modelo acústico e não combina com classes pré-definidas."** Errado: é **lista** e **combina**.
- **"Token de classe inválido gera erro; classes em todos os modelos e idiomas."** Errado: é **ignorado sem erro**; disponibilidade **varia**.

Itens comentados

- **Item:** O vocabulário personalizado exige sempre o retreinamento completo do modelo de reconhecimento e elimina, por si só, os erros de transcrição de nomes próprios e siglas. **Errado.** É uma lista de termos que, em geral, dispensa retreino, e só aumenta a chance de acerto. A revisão continua necessária.
- **Item:** A adaptação do modelo de linguagem ao vocabulário parlamentar, com transcrições de sessões, nomes de parlamentares e siglas, tende a elevar o WER no domínio, pois o modelo perde generalidade. **Errado.** A adaptação faz o sistema errar menos no domínio: o WER cai.
- **Item:** O prompt enviado junto com o áudio a um modelo como o Whisper funciona como contexto anterior ao trecho e pode favorecer a grafia correta de nomes próprios e siglas, mas tem tamanho limitado e não equivale a retreinar o modelo. **Certo.** Resume bem o prompt: contexto, ajuda com nomes e siglas, curto e sem efeito permanente.
- **Item:** Na API de transcrição de áudio da OpenAI, o prompt do Whisper funciona como instrução que o modelo cumpre como um modelo de texto de uso geral, o que permite pedir que ele

resuma e traduza o conteúdo da fala. **Errado.** O Whisper não segue instruções; o prompt só dá contexto de vocabulário e estilo.

- **Item:** Em sistemas de ASR end-to-end, a adaptação ao vocabulário parlamentar é inviável, pois esses modelos não admitem o acoplamento de modelo de linguagem externo nem o uso de listas de termos. **Errado.** Admitem as duas coisas: modelo de linguagem externo acoplado e listas de termos.
- **Item:** Na tabela de vocabulário personalizado do Amazon Transcribe, SoundsLike e IPA são as colunas obrigatórias, pois definem a pronúncia dos termos, e a coluna Phrase é opcional. **Errado.** A obrigatória é Phrase. SoundsLike e IPA não são mais suportadas e devem ficar vazias.
- **Item:** Os modelos de linguagem personalizados do Amazon Transcribe aprendem o contexto associado a uma palavra, isto é, como e quando ela é usada e sua relação com outras palavras, ao passo que os vocabulários personalizados apenas fornecem dicas sobre palavras específicas. **Certo.** Essa é a diferença central entre os dois recursos.
- **Item:** Segundo a documentação do Amazon Transcribe, ao criar um modelo de linguagem personalizado é recomendável que os dados de treinamento e os de ajuste se sobreponham, para reforçar o aprendizado dos mesmos termos. **Errado.** A sobreposição enviesa o modelo e piora a acurácia; os conjuntos devem ser distintos.
- **Item:** No Amazon Transcribe, o filtro de vocabulário aumenta a probabilidade de o serviço reconhecer corretamente as palavras da lista, razão pela qual é indicado para siglas e nomes próprios difíceis. **Errado.** O filtro mascara, remove ou sinaliza palavras na saída. Para reconhecer melhor, usa-se o vocabulário personalizado.
- **Item:** No edital do concurso de Analista Legislativo – Registro e Redação da Câmara dos Deputados, a sigla CAT, nas ferramentas de apoio à transcrição, é desdobrada em Computer Assisted Translation. **Errado.** No edital, CAT é Computer Assisted Transcription.
- **Item:** No Azure AI Speech, a lista de frases é um recurso aplicado no momento do reconhecimento, que não exige treinar um modelo e funciona na transcrição em tempo real e na transcrição rápida, mas não na transcrição em lote. **Certo.** É exatamente o alcance da lista de frases.
- **Item:** O modelo personalizado do Azure AI Speech implantado em um endpoint é atualizado automaticamente a cada novo modelo base lançado, para manter a acurácia sempre no nível mais recente. **Errado.** O modelo implantado fica fixo até o usuário decidir trocá-lo, para garantir resultados estáveis.
- **Item:** No Cloud Speech-to-Text do Google, um boost mais alto reduz simultaneamente os falsos negativos e os falsos positivos, motivo pelo qual o valor deve ser sempre o maior possível. **Errado.** Boost alto reduz falsos negativos, mas pode aumentar falsos positivos; o valor deve ser testado.
- **Item:** No Cloud Speech-to-Text do Google, uma CustomClass é um modelo acústico novo, treinado pelo usuário com horas de áudio da lista de itens, e não pode ser combinado com as classes pré-definidas. **Errado.** CustomClass é uma lista de itens que funciona como as classes pré-definidas e pode ser combinada com elas.

Resumo para revisar

- Termos raros (siglas, nomes, expressões regimentais) são o ponto fraco do ASR genérico.
- **Vocabulário personalizado**: lista de termos; em geral **sem retreino**; **aumenta a chance**, não garante; **tamanho limitado**; não dispensa revisão.
- **Modelo de linguagem adaptado**: treinado com **textos do domínio**; aprende **contexto**; **reduz o WER** no domínio.
- End-to-end também se adapta: **modelo de linguagem externo** ou **listas de termos**.
- OpenAI **prompt**: contexto de vocabulário e estilo, **curto**, **não é instrução**, não retreina; serve para continuidade entre trechos. **language** = só idioma.
- **gpt-4o-transcribe-diarize** identifica falantes e **não aceita prompt**.
- Amazon vocabulário: **sem dados pessoais**; **mesma Região**; **Phrase** obrigatória; SoundsLike e IPA não suportadas; **DisplayAs** separa reconhecido de exibido.
- Amazon modelo personalizado: melhores dados = **notas taquigráficas revisadas**; treino e ajuste **sem sobreposição**; **sem identificação automática de idioma**.
- Amazon **filtro de vocabulário**: **mascara, remove ou sinaliza**; não melhora o reconhecimento.
- Azure **lista de frases**: sem treino; **tempo real e rápida**, **não lote**; cerca de **2.000** itens; peso alto = mais inserções indevidas.
- Azure **Custom Speech**: texto → vocabulário; áudio + transcrição → acústica; decidir pelo **WER**; modelo implantado **fica fixo**.
- Google: **sem retreino com áudio**; PhraseSet favorece palavras **em sequência**; **boost por frase**; boost alto = menos falsos negativos, **mais falsos positivos**; **n-gramas** para correspondência parcial.
- Google **CustomClass**: lista de itens; **combina** com classes pré-definidas. Token inválido **ignorado sem erro**; classes variam por modelo e idioma.
- **CAT = Computer Assisted Transcription**.
- Editor com áudio sincronizado: clicar e ouvir, **velocidade**, **palavras de baixa confiança**.
- Pedal e atalhos **controlam o áudio**, não pontuam nem trocam orador.

TEMA 14 DE 20

IA em parlamentos: transcrição, sumarização, indexação e busca

53 perguntas no app · IA no Parlamento

O que cai

O edital pede "Aplicações de IA em parlamentos: transcrição de sessões, sumarização, indexação e busca" (item 3.1 da matéria). As perguntas deste tema são muito factuais e giram em torno de:

- **O princípio que atravessa tudo**: a IA é **apoio**. A responsabilidade pela fidelidade do registro oficial **continua com as pessoas e a instituição**, por melhor que seja a máquina.
- **O Ulysses**, programa de IA da Câmara: lançamento em 2018, nome (Ulysses Guimarães), o que fazia e o que era só plano, a nova fase de dezembro de 2025 e os usos descritos no estudo de caso da Apolitical (Ulysses Chat, busca por similaridade, análise de emendas e de comentários, encaminhamento de pedidos à consultoria).
- **A Portaria nº 227/2025 da Câmara** (Política de Governança de IA): definições, primazia da decisão humana, aviso de interação com IA, responsabilidade de quem usa IA generativa, vedação de nuvem pública para dados restritos, citação de fontes, CETIA.
- **Experiências de outros parlamentos e da União Interparlamentar (UIP)**: Chéquia (transcrição por IA desde 2024), Senado Federal (caso de uso com o sistema Escriba), LabHacker, World e-Parliament Report 2024, Diretrizes de IA da UIP (2024) e marco de maturidade (2025).

A banca troca números (200 milhões por 20 milhões, 68% por 20%, seis áreas por três), datas (LabHacker de 2014, não 2018), nomes (Ulysses Guimarães, não Tancredo) e transforma "apoio com revisão humana" em "totalmente automático".

Entenda o tema

A regra de ouro: IA é ajudante, não responsável

Pense na IA como um estagiário muito rápido. Ele faz o rascunho, separa os papéis, sugere caminhos. Mas quem assina o documento é o servidor e a instituição.

Em parlamentos, a IA é usada como **apoio** em várias frentes:

- **transcrição automática** de sessões;
- **sumarização** (resumo) de discursos;
- **indexação e busca** em acervos;
- **classificação temática** de proposições.

Em todas, **a responsabilidade pela fidelidade do registro oficial não passa ao sistema**. Nem mesmo "sempre que sua taxa de acerto supera a de revisores humanos". Quem revisa, valida e responde são as **pessoas e a instituição**.

> **Atenção:** item que diga que o uso de IA "transfere ao sistema a responsabilidade" pelo registro, ou que a responsabilidade passa ao sistema quando ele acerta mais que humanos, está **errado**.

O Ulysses: lançamento em 2018

O **Ulysses** é o programa de inteligência artificial da Câmara dos Deputados, lançado em **novembro de 2018**. O nome homenageia **Ulysses Guimarães**, presidente da Assembleia Nacional Constituinte (não Tancredo Neves).

O que ele fazia no lançamento:

- **combinava vários algoritmos** para **articular automaticamente dados legislativos** do portal da Câmara e de outros sistemas internos;
- **extraía palavras-chave** de documentos legislativos para **melhorar a relevância dos resultados** tanto na **busca da própria Casa** quanto em **buscadores externos, como o Google**.

O motivo: o portal recebia, à época, **quase 200 milhões de acessos por ano**. Com tanto acesso, a busca precisava funcionar bem.

O Ulysses **nunca foi só de transcrição**. E, em 2018, vários usos foram apresentados como **planos para breve**, não como funções já operacionais:

- traduzir conteúdos para outros idiomas;
- reconhecer a voz dos deputados;
- responder às dúvidas dos cidadãos;
- classificar discursos de deputados e estudos técnicos;
- resumir proposições;
- identificar a opinião pública sobre temas.

> **Pegadinha:** "em 2018 o Ulysses já traduzia, reconhecia voz e respondia cidadãos, usos plenamente operacionais desde o lançamento". Errado: eram **planos**.

O Ulysses hoje: o estudo de caso da Apolitical

A Apolitical (plataforma internacional sobre governo) publicou um estudo de caso sobre como a Câmara usa IA em tarefas de grande volume. Os pontos cobrados:

Transcrição de debates. A IA produz a primeira versão, que **passa por edição humana** antes de virar registro oficial. A **Secretaria-Geral da Mesa** ressalta a necessidade de **manter a revisão humana em todas as etapas**.

Encaminhamento de pedidos à consultoria. A consultoria legislativa recebe **mais de 20 mil pedidos por ano** (por exemplo, pedidos de elaboração de proposições). A IA **sugere** para qual

grupo de especialistas cada pedido deve ir, e os **especialistas conferem** a sugestão antes do envio. **Não é totalmente automático.**

Ulysses Chat. Assistente **interno**, integrado ao ecossistema de IA da Câmara, que **responde a perguntas dos servidores sobre normas e procedimentos da Casa**. Não é um serviço aberto ao público.

Busca por similaridade. Localiza estudos ou proposições já existentes **com sentido semelhante**, mesmo escritos com outras palavras. Ajuda a **evitar duplicidade de trabalho**. Não exige título idêntico ao termo digitado; isso seria uma busca comum.

Análise de emendas. O sistema **agrupa as emendas sobrepostas** e indica onde cada uma se encaixa. **Não as exclui sozinho**: o mérito continua avaliado pela equipe da Casa.

Análise de comentários públicos. Agrupa os comentários escritos de cidadãos sobre proposições **de acordo com os argumentos** que apresentam (não pela UF de origem). Assim a equipe vê quais ideias aparecem mais, sem ler milhares de mensagens uma a uma.

Organização do portal. O módulo agrupa os conteúdos legislativos públicos **por tema** (o que exige entender o assunto de cada texto), e não por data.

Reconhecimento facial. Usado para **autenticar parlamentares em votações remotas**; o estudo descreve essa aplicação como **em revisão**, por envolver dados sensíveis.

> **Dica:** em todos os usos do ecossistema Ulysses, o padrão é o mesmo: a máquina **sugere, agrupa, organiza**; a pessoa **confere e decide**.

A nova fase (dezembro de 2025)

Em **dezembro de 2025**, o programa de IA da Câmara entrou em **nova fase**, com **chat para os servidores** e **maior facilidade de acesso a plataformas de IA**, como **Claude, Gemini e ChatGPT**. Não houve proibição de modelos de empresas externas; o que a política de IA faz é impor **limites**, como a vedação de enviar dados restritos a nuvens públicas.

Segundo a matéria sobre essa fase, o Ulysses auxilia a **organizar proposições**, a **distribuir matérias entre as comissões** e a **identificar possíveis conflitos constitucionais**, integrando-se à agenda da Casa.

A Portaria nº 227/2025: a política de governança de IA da Câmara

A **Portaria nº 227, de 23/12/2025**, estabelece a **Política de Governança de Inteligência Artificial** da Câmara dos Deputados. Dois detalhes formais:

- É uma **portaria** assinada pelo **Diretor-Geral** da Câmara, não um ato da Mesa.
- Ela **regulamenta** o **Ato da Mesa nº 225, de 15/12/2025**. **Não o revoga.**

Definições (art. 2º).

- **Inteligência artificial**: tecnologias ou algoritmos capazes de realizar tarefas que normalmente requerem inteligência humana.

- **IA generativa**: modalidade de IA capaz de criar **novos conteúdos em diversos formatos** (textos, imagens, vídeos, músicas) a partir de padrões aprendidos nos dados de treinamento.

Princípios (art. 4º). Boa-fé e finalidade legítima; privacidade e proteção de dados pessoais; transparência; responsabilização e prestação de contas; resultados justos e sem vieses discriminatórios; integridade e segurança; respeito à propriedade intelectual e aos direitos autorais; e a **primazia da decisão humana**, com **autonomia no uso** dos sistemas e **supervisão contínua** sobre o seu comportamento (inciso VII).

Aviso de interação com IA (art. 12). Os usuários **devem ser informados** quando estiverem interagindo com um agente de IA. A regra é **geral**, não só quando há dados pessoais.

Papéis e responsabilidades (art. 13). As unidades que decidirem usar IA em seus processos devem **definir papéis e responsabilidades em cada ação em que a IA esteja envolvida**. Vale para **toda** ação com IA, inclusive quando ela só auxilia, e não apenas quando decide sozinha.

Quem usa IA generativa responde (art. 14). Os usuários **respondem pelos documentos** que criarem a partir dos resultados da IA generativa e devem **revisá-los** antes de publicá-los ou de usá-los em decisões. A responsabilidade **não passa ao fornecedor** da ferramenta. Decisões automatizadas sem revisão humana devem ser evitadas.

Dados restritos (arts. 18 e 19).

- **Nuvem pública**: é **vedado** o tratamento de dados com restrição de acesso, sob responsabilidade da Câmara **ou de outra organização**, para uso por sistemas de IA em nuvem pública (art. 19). Nem com autorização.
- **Nuvem privada ou infraestrutura própria**: o tratamento depende de **autorização prévia e expressa do Gestor de Dados** responsável (art. 18).

> **Pegadinha:** "dados restritos podem ir para IA em nuvem pública com aprovação do Gestor de Dados". Errado: a aprovação do Gestor vale para **nuvem privada ou estrutura interna**. Nuvem pública é **vedada**.

Fontes e autoria (art. 21). Quem produz documento com IA generativa deve **verificar as fontes** dos dados, **indicá-las** e **reconhecer os autores**. O conteúdo gerado **não é presumido original**.

CETIA (art. 23). A portaria criou, em **caráter permanente** e de **natureza técnica**, o **Comitê de Ética no Uso da Inteligência Artificial (CETIA)**. É **multidisciplinar**. Compõem-no o **Encarregado de Proteção de Dados Pessoais** e representantes de:

- **Assessoria de Projetos e Gestão**, que **preside** o comitê;
- Secretaria-Geral da Mesa;
- Advocacia da Câmara;
- Diretoria de Inovação e Tecnologia da Informação (Ditec);
- Diretoria de Gestão de Pessoas;
- Centro de Documentação e Informação.

Avaliação de riscos (art. 24). Antes de iniciar um projeto de IA, a **Ditec avalia os riscos** de violação dos princípios éticos e **submete a análise ao CETIA**. Se o parecer indicar alto risco, a demanda é rejeitada. A Ditec, portanto, **não preside** o CETIA nem concentra todas as decisões.

LabHacker

O **Laboratório Hacker** da Câmara foi inaugurado em **fevereiro de 2014**, depois da **Maratona Hacker de outubro de 2013**, como **espaço permanente** para **programadores** (e cidadãos) desenvolverem aplicativos que facilitem o compartilhamento de dados legislativos. É bem **anterior** ao Ulysses e **não** é de uso exclusivo de servidores de TI.

Outros parlamentos

Chéquia. A Câmara dos Deputados da República Tcheca passou a usar **plenamente**, desde **setembro de 2024**, a transcrição automática por IA (depois de meses de teste). O modelo partiu de um **grande modelo de reconhecimento de fala**, **enriquecido com gravações e textos da própria Casa** para lidar com termos do Parlamento. Ele **identifica os oradores** e cobre **Plenário e comissões**. Os **estenógrafos não foram dispensados**: passaram a **ouvir e editar** o texto produzido pela máquina, em vez de digitar tudo.

Senado Federal. Num caso de uso registrado pela União Interparlamentar, o Senado prevê a **produção automática de transcrições** do áudio de **Plenário e comissões**, com **separação e identificação opcional dos falantes** (diarização), e **entrega do texto ao sistema Escriba** em **arquivo JSON**. O sucesso é medido por indicadores de **qualidade da transcrição**, como a taxa de erro de palavras e o tempo de processamento, e **não** pelo número de acessos ao portal ou de discursos publicados (isso mede audiência, não qualidade).

União Interparlamentar (UIP)

A **União Interparlamentar** (*Inter-Parliamentary Union*, IPU) é a organização mundial dos parlamentos.

World e-Parliament Report 2024. Feito com respostas de **115 câmaras parlamentares de 86 países** e organismos supranacionais. Mostrou que **68% dos parlamentos** adotaram **estratégias digitais plurianuais**. Traz um **índice de maturidade digital** que avalia os parlamentos em **seis áreas**, para **comparar e orientar** a evolução digital, e não para punir. O relatório aponta uma divisão digital entre as casas, mas não descreve a transformação como "incipiente".

Diretrizes para IA em Parlamentos (*Guidelines for AI in parliaments*). Publicadas em **dezembro de 2024**. Organizam a governança de IA em torno de **política e estrutura**, **estratégia e inovação** e **engajamento de partes interessadas**. São um **guia prático**, escrito com a experiência dos próprios parlamentos; **não são normas vinculantes** e não há sanção para quem não as seguir.

Marco de maturidade em IA. Divulgado em **novembro de 2025**, para o parlamento ver em que estágio está; foi concebido para ser usado **em conjunto com as diretrizes de 2024**.

Quadros para memorizar

Linha do tempo

Data	Fato
Out. 2013	Maratona Hacker da Câmara
Fev. 2014	Inauguração do LabHacker
Nov. 2018	Lançamento do Ulysses
Set. 2024	Chéquia passa a usar plenamente a transcrição por IA
Dez. 2024	Diretrizes da UIP para IA em parlamentos
Nov. 2025	Marco de maturidade em IA da UIP
15/12/2025	Ato da Mesa nº 225
Dez. 2025	Nova fase do Ulysses (chat e acesso a Claude, Gemini, ChatGPT)
23/12/2025	Portaria nº 227 (regulamenta o Ato da Mesa 225)

Números

Número	O que é
quase 200 milhões	acessos por ano ao portal da Câmara (2018)
mais de 20 mil	pedidos por ano à consultoria legislativa
115 câmaras / 86 países	respondentes do World e-Parliament Report 2024
68%	parlamentos com estratégia digital plurianual
6 áreas	índice de maturidade digital do relatório

Ecossistema Ulysses: o que a IA faz e o que não faz

Uso	A IA faz	A IA não faz
Transcrição de debates	primeira versão	dispensar edição humana
Pedidos à consultoria	sugere o grupo de especialistas	enviar sem conferência
Ulysses Chat	responde servidores sobre normas e procedimentos	atender o público
Busca por similaridade	acha textos de sentido semelhante	exigir título idêntico
Emendas	agrupa sobrepostas, indica onde se encaixam	excluir e julgar mérito
Comentários públicos	agrupa por argumento	agrupar por UF
Portal	organiza por tema	organizar por data
Reconhecimento facial	autentica parlamentar em votação remota	(aplicação em revisão)

Portaria nº 227/2025

Dispositivo	Regra
Art. 1º	institui a política; regulamenta (não revoga) o Ato da Mesa 225/2025
Art. 2º, I	IA = tecnologias ou algoritmos que fazem tarefas que normalmente requerem inteligência humana
Art. 2º, II	IA generativa = cria conteúdos novos em vários formatos a partir de padrões aprendidos
Art. 4º, VII	primazia da decisão humana, autonomia e supervisão contínua
Art. 12	usuário sempre informado de que interage com IA
Art. 13	papéis e responsabilidades em cada ação com IA
Art. 14	usuário de IA generativa responde pelo documento e revisa antes
Art. 18	nuvem privada ou interna: autorização prévia do Gestor de Dados
Art. 19	nuvem pública: vedado tratar dados restritos
Art. 21	verificar e citar fontes; reconhecer autores
Art. 23	CETIA permanente, técnico, multidisciplinar; presidido pela Assessoria de Projetos e Gestão
Art. 24	Ditec avalia riscos e submete ao CETIA

Conceitos e autores que caem

Primazia da decisão humana. Princípio segundo o qual a decisão final é das pessoas, que mantêm autonomia no uso da IA e supervisão contínua sobre seu comportamento.

> **Atenção:** Portaria 227/2025, art. 4º, VII – garantir a **primazia da decisão humana**, com autonomia no uso e **supervisão contínua** dos sistemas.

Transparência com o usuário. Quem conversa com um assistente de IA deve saber que não fala com uma pessoa.

> **Atenção:** Portaria 227/2025, art. 12 – os usuários **deverão ser informados** quando estiverem interagindo com um agente de IA.

Vedação da nuvem pública.

> **Atenção:** Portaria 227/2025, art. 19 – **é vedado** o tratamento de dados com restrição de acesso, sob responsabilidade da Câmara ou de outra organização, para uso por sistemas de IA **em nuvem pública**.

Ulysses Guimarães. Presidente da Assembleia Nacional Constituinte de 1987-1988; dá nome ao programa de IA da Câmara.

Busca por similaridade. Busca pelo **sentido** do texto, e não pelas palavras exatas.

Diarização. Separar e identificar quem fala em cada trecho do áudio (no caso do Senado, opcional).

JSON. Formato de arquivo de dados estruturados usado para entregar a transcrição ao sistema Escriba.

Pegadinhas da banca

- **"IA transfere ao sistema a responsabilidade pelo registro."** Errado: a responsabilidade é das **pessoas e da instituição**.
- **"A responsabilidade passa ao sistema quando ele acerta mais que humanos."** Errado: a taxa de acerto não muda isso.
- **"Ulysses homenageia Tancredo Neves e só transcreve."** Errado: **Ulysses Guimarães**; também **extrai palavras-chave** para a busca.
- **"20 milhões de acessos por ano."** Errado: quase **200 milhões**.
- **"Em 2018 o Ulysses já traduzia, reconhecia voz e respondia cidadãos."** Errado: eram **planos**.
- **"Encaminhamento à consultoria totalmente automático."** Errado: a IA **sugere**, especialistas **conferem**.
- **"Usuário de IA generativa não responde; a culpa é do fornecedor."** Errado: o **usuário responde** e revisa (art. 14).
- **"Dados restritos em nuvem pública com aprovação do Gestor de Dados."** Errado: nuvem pública é **vedada**; o Gestor autoriza **nuvem privada ou interna**.
- **"Documento com IA dispensa citar fontes."** Errado: deve **verificar e citar fontes** e **reconhecer autores**.
- **"CETIA presidido pela Ditec, que concentra as decisões."** Errado: presidido pela **Assessoria de Projetos e Gestão**.
- **"CETIA só com servidores de TI."** Errado: **multidisciplinar** (Advocacia, SGM, encarregado de dados etc.).
- **"LabHacker criado em 2018, só para servidores de TI."** Errado: **fevereiro de 2014**, aberto a programadores e cidadãos.
- **"Só 20% com estratégia digital plurianual."** Errado: **68%**.
- **"Índice com três áreas, para punir."** Errado: **seis áreas**, para comparar e orientar.
- **"Diretrizes da UIP vinculantes, com sanção."** Errado: **guia prático**, sem sanção.
- **"Ulysses Chat é aberto ao público."** Errado: é **interno**, para servidores.
- **"Busca por similaridade exige título idêntico."** Errado: acha textos de **mesmo sentido** com outras palavras.
- **"Sistema exclui emendas sobrepostas sozinho."** Errado: **agrupa**; o mérito é da equipe.
- **"Comentários agrupados por UF."** Errado: **por argumento**.
- **"Portal organizado por data."** Errado: **por tema**.
- **"Nova fase proibiu modelos externos."** Errado: **facilitou** o acesso a Claude, Gemini e ChatGPT.

- **"Portaria 227 é ato da Mesa e revogou o Ato da Mesa 225."** Errado: **regulamenta** o Ato da Mesa 225.
- **"Chéquia usa modelo genérico, sem identificar oradores nem cobrir comissões."** Errado: modelo **adaptado** com material da Casa, **identifica oradores**, cobre **Plenário e comissões**.
- **"Chéquia dispensou os estenógrafos."** Errado: eles **ouvem e editam** o texto da máquina.
- **"Sucesso do caso do Senado medido por acessos e discursos publicados."** Errado: mede-se a **qualidade** (erros de palavras) e o **tempo**.
- **"Papéis e responsabilidades só quando a IA decide sozinha."** Errado: em **toda ação** com IA.
- **"Aviso de IA só quando há dados pessoais."** Errado: aviso **sempre**.

Itens comentados

- **Item:** Nas aplicações de inteligência artificial em parlamentos, como a transcrição e a sumarização de sessões, a responsabilidade pelo registro oficial passa ao sistema sempre que sua taxa de acerto supera a de revisores humanos. **Errado.** A IA é apoio. A responsabilidade pelo registro oficial continua com as pessoas e a instituição, qualquer que seja a taxa de acerto.
- **Item:** O Ulysses, lançado em 2018, recebeu esse nome em homenagem a Tancredo Neves e foi concebido exclusivamente para transcrever discursos, sem qualquer função de indexação ou de melhoria da busca no portal. **Errado.** A homenagem é a Ulysses Guimarães, e o sistema extraía palavras-chave para melhorar a busca no portal e em buscadores externos.
- **Item:** Segundo a matéria do lançamento do Ulysses, o portal da Câmara recebia, à época, cerca de 20 milhões de acessos por ano, volume que justificava a adoção de algoritmos de inteligência artificial. **Errado.** Eram quase 200 milhões de acessos por ano.
- **Item:** Na Câmara dos Deputados, a transcrição de debates feita por inteligência artificial passa por edição humana antes de se tornar registro oficial, e a Secretaria-Geral ressalta a necessidade de manter a revisão humana em todas as etapas. **Certo.** A máquina faz a primeira versão; a pessoa revisa antes de o texto virar registro oficial.
- **Item:** A Portaria nº 227/2025 da Câmara permite que dados com restrição de acesso sejam tratados por sistemas de inteligência artificial em nuvem pública, desde que haja aprovação prévia do Gestor de Dados. **Errado.** Em nuvem pública é vedado (art. 19). A autorização do Gestor de Dados vale para nuvem privada ou infraestrutura própria (art. 18).
- **Item:** De acordo com a Portaria nº 227/2025 da Câmara, os usuários de sistemas de inteligência artificial generativa não respondem pelos documentos criados a partir dos resultados obtidos, porque a responsabilidade é do fornecedor da ferramenta. **Errado.** Pelo art. 14, o usuário responde pelo documento e deve revisá-lo antes de publicar ou usar.
- **Item:** Segundo a Portaria nº 227/2025 da Câmara, o CETIA é presidido pela Diretoria de Inovação e Tecnologia da Informação, unidade que concentra todas as decisões sobre projetos de inteligência artificial. **Errado.** Preside a Assessoria de Projetos e Gestão. A Ditec avalia riscos e submete a análise ao comitê.

- **Item:** A Portaria nº 227/2025 da Câmara dos Deputados é um ato da Mesa Diretora que revogou o Ato da Mesa nº 225, de 15 de dezembro de 2025, ao instituir a Política de Governança de Inteligência Artificial. **Errado.** A portaria regulamenta o Ato da Mesa nº 225/2025; não o revoga.
- **Item:** O Laboratório Hacker da Câmara foi criado em 2018, ao mesmo tempo que o Ulysses, como unidade interna de uso exclusivo dos servidores de tecnologia da informação, vedada a participação de cidadãos. **Errado.** O LabHacker é de fevereiro de 2014 e foi pensado também para programadores e cidadãos.
- **Item:** O World e-Parliament Report 2024, da União Interparlamentar, foi elaborado com respostas de 115 câmaras parlamentares de 86 países e organismos supranacionais e apontou que 68% dos Parlamentos adotaram estratégias digitais plurianuais. **Certo.** São exatamente os números do relatório.
- **Item:** As Diretrizes para IA em Parlamentos, da União Interparlamentar, são normas vinculantes aprovadas por Assembleia da organização, que os Parlamentos-membros devem aplicar sob pena de sanção. **Errado.** São um guia prático, sem caráter obrigatório nem sanção.
- **Item:** Na análise de emendas feita pelo ecossistema de inteligência artificial da Câmara, o sistema exclui automaticamente as emendas sobrepostas, dispensando a avaliação dos consultores quanto ao seu mérito. **Errado.** O sistema agrupa as emendas sobrepostas e indica onde se encaixam; o mérito continua com a equipe.
- **Item:** Segundo a notícia sobre a adoção da transcrição automática na Câmara dos Deputados tcheca, o uso de inteligência artificial dispensou os estenógrafos, que deixaram de participar do registro das sessões. **Errado.** Os estenógrafos passaram a ouvir e editar o texto feito pela máquina.

Resumo para revisar

- IA em parlamentos: transcrição, sumarização, indexação e busca, classificação temática. Sempre **apoio**; a responsabilidade é **humana e institucional**.
- **Ulysses**: novembro de **2018**, homenagem a **Ulysses Guimarães**, vários algoritmos, articula dados do portal e de sistemas internos, **extrai palavras-chave** (busca interna e Google). Portal com quase **200 milhões** de acessos/ano.
- Planos de 2018 (não operacionais): tradução, reconhecimento de voz, responder cidadãos, classificar discursos e estudos, resumir proposições, identificar opinião pública.
- Apolitical: transcrição com **edição humana**; SGM exige revisão humana em todas as etapas; consultoria com **mais de 20 mil** pedidos/ano, IA **sugere** e especialistas conferem.
- **Ulysses Chat**: interno, para servidores, sobre normas e procedimentos.
- Busca por **similaridade** (sentido); emendas **agrupadas**, não excluídas; comentários agrupados **por argumento**; portal organizado **por tema**; reconhecimento facial em votação remota **em revisão**.
- Dez. 2025: nova fase com chat e acesso a **Claude, Gemini, ChatGPT**; ajuda a organizar proposições, distribuir às comissões e apontar conflitos constitucionais.

- **Portaria 227/2025** (Diretor-Geral) **regulamenta** o Ato da Mesa 225/2025.
- Princípio: **primazia da decisão humana** (autonomia e supervisão contínua).
- Art. 12: aviso **sempre** de interação com IA. Art. 13: papéis em **cada ação** com IA. Art. 14: usuário **responde** e revisa.
- Art. 19: dados restritos em **nuvem pública: vedado**. Art. 18: nuvem privada ou interna com autorização do **Gestor de Dados**.
- Art. 21: **citar fontes** e reconhecer autores.
- **CETIA**: permanente, técnico, multidisciplinar; preside a **Assessoria de Projetos e Gestão**; inclui o Encarregado de Dados, SGM, Advocacia, Ditec, Gestão de Pessoas, Cedi. Ditec avalia riscos e submete ao CETIA.
- **LabHacker**: **fevereiro de 2014**, após Maratona Hacker de **outubro de 2013**.
- **Chéquia**: transcrição por IA desde **setembro de 2024**, modelo adaptado à Casa, identifica oradores, Plenário e comissões; estenógrafos **editam**.
- **Senado**: caso de uso na UIP; transcrição de Plenário e comissões, diarização opcional, entrega ao **Escriba** em **JSON**; sucesso medido pela qualidade, não por acessos.
- **World e-Parliament Report 2024**: **115** câmaras, **86** países, **68%** com estratégia plurianual, índice de maturidade com **seis áreas**.
- **Diretrizes da UIP**: **dez. 2024**, guia não vinculante; política e estrutura, estratégia e inovação, engajamento de partes interessadas. **Marco de maturidade**: **nov. 2025**.

TEMA 15 DE 20

Busca semântica em acervos parlamentares

59 perguntas no app · IA no Parlamento

O que cai

O edital pede "Sistemas de busca semântica em acervos parlamentares" (item 3.2 da matéria). As perguntas deste tema cobram:

- **A diferença central**: busca **léxica** (por palavras iguais) x busca **semântica** (por sentido, com **embeddings** e vetores). A banca troca uma pela outra e diz que a semântica exige as mesmas palavras ou que o cosseno conta palavras em comum.
- **RAG (geração aumentada por recuperação)**: primeiro recupera trechos de uma base confiável, depois o modelo responde com base neles. **Não retreina** o modelo. Reduz alucinação e permite citar a fonte.
- **Os artigos de referência**: Lewis et al. (RAG), Reimers e Gurevych (Sentence-BERT), Karpukhin et al. (DPR), Malkov e Yashunin (HNSW), Liu et al. (*Lost in the Middle*), Muennighoff et al. (MTEB).
- **A documentação das plataformas**: OpenAI (vetores normalizados, encurtamento), Azure AI Search (busca vetorial, multilíngue e multimodal, busca híbrida, RRF, ranqueador semântico, filtros, chunking), Amazon Bedrock (fluxo da base de conhecimento, vetores binários) e Sentence Transformers (busca simétrica x assimétrica).

As pegadinhas típicas: inverter conceitos (léxica x semântica, simétrica x assimétrica, Lexical x vetorial), dizer que algo é "universal", "exato" ou "sempre melhor", e afirmar que a RAG retreina o modelo.

Entenda o tema

Busca léxica: procurar palavras iguais

A **busca léxica** (ou por palavras-chave) procura documentos que contenham **as mesmas palavras** da consulta. É a busca "tradicional", feita com um **índice invertido** (uma lista que diz em quais documentos cada palavra aparece), operadores booleanos (E, OU, NÃO) e fórmulas de pontuação como **TF-IDF** e **BM25**. Esses métodos são chamados de **esparsos**, porque representam o texto por palavras (a maioria das palavras do vocabulário não aparece em cada documento).

O ponto fraco: **sinônimos e formulações diferentes**. Se o cidadão procura "aposentadoria de servidores" e o discurso fala em "previdência do funcionalismo", a busca léxica não acha. Se pergunta sobre "trabalho remoto" e os documentos dizem "teletrabalho", também falha. A busca léxica **não** lida bem com sinônimos, abreviações e erros de grafia.

O ponto forte: **correspondência exata**. Para **códigos de produto, jargões especializados, datas e nomes de pessoas**, a busca por palavras-chave tende a funcionar **melhor** que a vetorial.

Busca semântica: procurar pelo sentido

A **busca semântica** procura pelo **significado**. Imagine um mapa em que cada texto é um ponto, e textos de sentido parecido ficam perto uns dos outros. "Reforma tributária" e "mudança nos impostos" ficam vizinhos, embora não tenham nenhuma palavra em comum.

Como funciona:

1. **Todo o acervo** é convertido em **vetores** (listas de números) num **mesmo espaço**.
2. Na consulta, a **pergunta também vira vetor** nesse espaço.
3. O sistema devolve os itens cujos vetores estão **mais próximos** da pergunta.

Por isso ela encontra documentos relevantes **mesmo quando o usuário usa outra formulação**, e lida bem com **sinônimos, abreviações e pequenos erros de grafia**.

Embedding: o sentido virando números

Embedding é a **representação numérica que traduz o significado de um texto em um vetor**, permitindo comparar documentos por proximidade de sentido. Textos parecidos viram vetores parecidos.

> **Pegadinha:** embedding não é **diarização**. Diarização é tarefa de áudio: descobrir quem falou em cada momento.

Similaridade de cosseno é a medida mais usada para comparar dois vetores: olha o **ângulo** entre eles. Ângulo pequeno = sentido parecido. O cosseno compara **vetores de significado**, e **não** conta palavras em comum.

Exemplos da documentação do Azure:

- *dog* e *canine* são palavras diferentes, mas **conceitualmente próximas**: seus vetores ficam perto.
- **Multilíngue**: com um modelo de embeddings multilíngue, *dog* (inglês) e *hund* (alemão) podem ser aproximados. A busca vetorial **não** exige o mesmo idioma.
- **Multimodal**: com embeddings apropriados, uma descrição em texto pode recuperar **imagens** e outros tipos de conteúdo. A busca vetorial **não** se limita a texto.

RAG: geração aumentada por recuperação

Um modelo de linguagem sozinho responde com base no que "decorou" no treino. Às vezes **inventa** (a chamada **alucinação**). A **RAG** (*Retrieval-Augmented Generation*, geração aumentada por recuperação) resolve isso como um aluno que faz **prova com consulta**:

1. **Recupera** primeiro os trechos pertinentes de uma **base confiável** (o acervo da Casa, por exemplo).
2. **Entrega** esses trechos ao modelo, junto com a pergunta.

3. O modelo **responde fundamentado neles**.

Resultado: **reduz a alucinação** e **permite citar a origem** da resposta.

> **Atenção:** a RAG **não retreina** o modelo a cada consulta. A **busca prévia** é o coração da técnica. Item que diga que a RAG "retreina o modelo gerador a cada consulta com todo o acervo, dispensando a busca" ou que "exige treinamento contínuo" está errado.

Boas práticas de RAG (documentação do Azure AI Search):

- Como os modelos aceitam um **número limitado de tokens**, o sistema deve recuperar **resultados altamente relevantes e concisos**, e não despejar documentos inteiros no prompt.
- A recuperação deve **respeitar o controle de acesso**: entregar só o conteúdo que o usuário está **autorizado** a ver.

O fluxo de uma base de conhecimento (Amazon Bedrock)

O guia do Amazon Bedrock descreve o passo a passo de uma base de conhecimento para RAG:

1. **Preparação**: os dados são **convertidos em texto**, **divididos em trechos** (*chunks*), **transformados em embeddings** e **gravados em um índice vetorial**, com **mapeamento para o documento original**.
2. **Consulta**: a pergunta é **vetorizada**, os **trechos semelhantes** são buscados no índice e **adicionados ao prompt** enviado ao modelo.

Não há retreino na consulta.

Tipos de vetor. Os embeddings podem ser:

- **ponto flutuante (float32)**: 32 bits por dimensão, mais **precisos**, ocupam mais espaço;
- **binários**: **1 bit por dimensão**, ocupam **menos armazenamento**, mas representam o texto com **menos precisão**.

Chunking: cortar documentos em trechos

Chunking é dividir os documentos em trechos antes de vetorizar. Serve para duas coisas:

- **Respeitar o limite de tokens** dos modelos de embeddings e de chat. Se uma ata extensa passar do limite, o **texto excedente é truncado** e fica **sem representação** na busca.
- **Melhorar a qualidade**, **mesmo quando o documento cabe no limite**: um documento que trata de **assuntos variados**, representado por um único vetor, fica mal representado (o vetor vira uma "média" sem foco).

Sobreposição (*overlap*). No chunking de tamanho fixo, repetir um pedacinho do fim de um trecho no começo do seguinte **preserva o contexto** de ideias que cruzam a fronteira. Mas **sobreposição excessiva** duplica texto e **aumenta o custo** de armazenamento e processamento.

Não há receita universal. Não existe tamanho de trecho nem sobreposição que sirvam para tudo. **Atas, discursos e tabelas** pedem ajustes diferentes: é preciso **testar**.

Embeddings da OpenAI

O guia de embeddings da OpenAI traz quatro pontos cobrados:

- Os vetores vêm **normalizados para comprimento 1**. Por isso a similaridade de cosseno pode ser calculada **só com o produto escalar**, e produz o **mesmo ranking** que a **distância euclidiana**. A escolha da métrica pesa pouco.
- Os modelos de **terceira geração** permitem **encurtar os vetores** (reduzir o número de dimensões), o que **diminui o custo** de armazenamento e de busca com **perda limitada** de qualidade.
- Se o desenvolvedor **encurtar manualmente** um embedding, deve **normalizá-lo de novo** para comprimento 1 antes de comparar.
- Embeddings servem para **busca**, mas também para **agrupamento** (*clustering*), **classificação**, **recomendação** e **detecção de anomalias**, entre outras tarefas.

> **Pegadinha:** "o número de dimensões é sempre fixo; para reduzir armazenamento, só descartando documentos". Errado: dá para **encurtar** vetores ou usar vetores **binários**.

Busca híbrida e RRF (Azure AI Search)

A **busca híbrida** junta o melhor dos dois mundos. Numa **única requisição**, ela executa **em paralelo** a **consulta de texto completo** (léxica, BM25) e a **consulta vetorial**. Depois, **combina** as duas listas de resultados com o algoritmo **RRF** (*Reciprocal Rank Fusion*, fusão por posição recíproca).

Por que híbrida? Porque códigos, jargões, datas e nomes de pessoas funcionam melhor com palavras-chave; consultas por assunto e sentido funcionam melhor com vetores. Juntas, cobrem os dois casos.

Como o RRF funciona. As pontuações brutas do BM25 e do cosseno estão em **escalas diferentes**, então não dá para somá-las. O RRF usa a **posição** de cada documento em cada lista:

- em cada lista, o documento recebe a pontuação **1 / (posição + k)**, em que **k** é uma **constante** (o Azure usa 60);
- as pontuações das várias listas são **somadas**;
- quem aparece **nas primeiras posições de mais de um método** fica no **topo** da lista combinada.

> **Exemplo:** um discurso está em 1º lugar na busca por palavras e em 2º na vetorial. Outro está em 1º na vetorial, mas nem aparece na de palavras. O primeiro tende a ganhar na fusão, porque foi bem nas duas.

Ranqueador semântico. No Azure AI Search, o **ranqueador semântico** atua **depois** da fusão por RRF, como uma **segunda leitura** dos melhores resultados. Ele tem **pontuação própria, de 0 a 4**, informada à parte. **Não** substitui o BM25 e **não** se confunde com o escore do RRF.

Filtros. Uma requisição de busca vetorial pode incluir uma **expressão de filtro** sobre **campos de texto ou numéricos** (metadados como data, comissão, tipo de documento). O filtro pode ser

processado **antes ou depois** da consulta vetorial. O **campo de vetores não é filtrável**: para filtrar, é preciso ter **campos de metadados** comuns.

HNSW: achar vizinhos rápido

Comparar a consulta com **todos** os vetores de um acervo enorme é lento. Essa busca exaustiva, que **garante** o resultado exato, é o **KNN exaustivo** (eKNN).

O **HNSW** (*Hierarchical Navigable Small World*, de Malkov e Yashunin) é um método de **busca aproximada de vizinhos mais próximos** (ANN). Organiza os vetores em **vários níveis de grafos de proximidade** e busca de cima para baixo, como procurar um endereço indo do mapa do país para o do estado, depois da cidade, depois do bairro. Escala com **complexidade logarítmica**: muito mais rápido, ao custo de **não garantir** o resultado exato (pode deixar escapar algum vizinho).

Os artigos de referência

Lewis et al. (2020), *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. O artigo que propôs a RAG. Parte do problema de guardar todo o conhecimento **só nos parâmetros** do modelo (difícil de atualizar e de verificar). Propõe combinar:

- uma **memória paramétrica**: um modelo **seq2seq pré-treinado** (que gera o texto);
- uma **memória não paramétrica**: um **índice vetorial denso da Wikipédia**, acessado por um **recuperador neural**.

Não é um índice invertido de palavras-chave com operadores booleanos. O artigo traz **duas formulações**: uma que condiciona **toda a sequência** gerada aos **mesmos trechos** recuperados (RAG-Sequence) e outra que pode usar **trechos diferentes a cada token** produzido (RAG-Token).

Reimers e Gurevych (2019), *Sentence-BERT*. O BERT original, para comparar duas frases, precisa processá-las **em conjunto**, par a par. Num conjunto grande, o número de comparações cresce com o **quadrado** do número de frases (10 mil frases dão cerca de 50 milhões de pares), o que torna a busca inviável. O **Sentence-BERT (SBERT)** usa **redes siamesas e triplas** para gerar **embeddings de sentenças** semanticamente significativos, **calculados de forma independente** para cada frase. Depois, basta comparar os vetores pela **similaridade de cosseno**: muito mais rápido, sem perder qualidade. Não é "uma rede menor e menos precisa" que continua comparando pares.

Karpukhin et al. (2020), *Dense Passage Retrieval* (DPR). Mostrou que um modelo com **dois codificadores** (um para a **pergunta**, outro para as **passagens**) pode **superar métodos esparsos como o BM25** na recuperação de passagens para perguntas de domínio aberto. A recuperação **densa** venceu; não é "só complemento".

Liu et al. (2023), *Lost in the Middle*. Os modelos de linguagem usam melhor a informação relevante quando ela está no **início ou no fim** do contexto de entrada; o desempenho **cai significativamente** quando ela está **no meio** de um contexto longo (curva em U). Lição para a RAG: não enterrar o trecho mais importante no meio de um prompt enorme.

Muennighoff et al. (2022), MTEB (*Massive Text Embedding Benchmark*). Comparou modelos de embeddings em muitas tarefas e concluiu que **nenhum método domina todas as tarefas**. Por isso, convém **testar** o modelo no próprio acervo e idioma.

Busca simétrica x assimétrica (Sentence Transformers)

A documentação da biblioteca Sentence Transformers distingue:

- **Busca simétrica**: compara itens de **tamanho e conteúdo semelhantes** (uma pergunta com outras perguntas, para achar duplicadas).
- **Busca assimétrica**: uma **consulta curta** (uma pergunta ou algumas palavras-chave) é comparada com **passagens mais longas**. Nesse caso, a biblioteca recomenda **métodos distintos** para codificar **consultas** e **documentos**, com modelos próprios para a tarefa.

> **Dica:** "assimétrica" = tamanhos **diferentes** (pergunta curta x trecho longo).

Aplicações em parlamentos

A busca semântica é uma das aplicações de IA em parlamentos, ao lado da **transcrição de sessões**, da **sumarização** de documentos, da **indexação automática** e da **classificação temática de proposições** (organizar grandes volumes de projetos por assunto), além de legendas e acessibilidade.

Quadros para memorizar

Léxica x semântica

	Busca léxica (esparsa)	Busca semântica (densa, vetorial)
Procura	palavras iguais	proximidade de sentido
Técnica	índice invertido, booleanos, TF-IDF, BM25	embeddings, cosseno
Sinônimos, abreviações, erros de grafia	falha	lida bem
Códigos, datas, nomes, jargão exato	funciona melhor	funciona pior
Exemplo de falha	"trabalho remoto" não acha "teletrabalho"	

Artigos e autores

Autor(es)	Ano	Contribuição
Lewis et al.	2020	RAG: memória paramétrica (seq2seq) + não paramétrica (índice vetorial denso da Wikipédia, recuperador neural); RAG-Sequence e RAG-Token
Reimers e Gurevych	2019	Sentence-BERT: redes siamesas e triplas; embeddings independentes; cosseno; resolve o custo quadrático do BERT
Karpukhin et al.	2020	DPR: dois codificadores; supera BM25
Malkov e Yashunin		HNSW: busca aproximada em grafos de vários níveis; complexidade logarítmica

Autor(es)	Ano	Contribuição
Liu et al.	2023	Lost in the Middle: melhor no início e no fim; pior no meio
Muennighoff et al.	2022	MTEB: nenhum embedding domina todas as tarefas

Azure AI Search

Recurso	O que cai
Busca vetorial	dog ~ canine; multilíngue (dog ~ hund); multimodal (texto ~ imagem)
Filtros	em campos de texto ou numéricos; antes ou depois da consulta vetorial; campo de vetor não é filtrável
Busca híbrida	texto + vetor numa requisição, em paralelo, fundidos por RRF
RRF	1/(posição + k) por lista, somado; usa posição, não pontuação bruta
Ranqueador semântico	depois do RRF; nota própria de 0 a 4
Chunking	limite de tokens e qualidade; sobreposição moderada; sem receita universal
RAG	resultados relevantes e concisos; respeitar controle de acesso

Vetores

Ponto	Regra
OpenAI	normalizados para comprimento 1; cosseno = produto escalar; mesmo ranking que euclidiana
Encurtar	possível nos de 3ª geração; menos custo, perda limitada; encurtou à mão, normaliza de novo
Usos	busca, agrupamento, classificação, recomendação, anomalias
float32	32 bits por dimensão; mais preciso; mais espaço
Binário	1 bit por dimensão; menos espaço; menos preciso
HNSW	aproximado, rápido
KNN exaustivo	exato, lento

Simétrica x assimétrica

Tipo	Compara
Simétrica	itens de tamanho e conteúdo parecidos (pergunta x pergunta)
Assimétrica	consulta curta x passagem longa; codificar consulta e documento de modos distintos

Conceitos e autores que caem

- **Embedding**: vetor que representa o significado de um texto.
- **Similaridade de cosseno**: mede o ângulo entre dois vetores; compara significado, não palavras.

- **Alucinação**: resposta inventada pelo modelo, sem base nos dados.
- **RAG**: recuperar trechos de base confiável e gerar a resposta com base neles; reduz alucinação e permite citar fonte; não retreina.
- **Memória paramétrica x não paramétrica** (Lewis): o que está nos pesos do modelo x o acervo externo consultável.
- **Esparso x denso**: representação por palavras (TF-IDF, BM25) x por vetores contínuos (embeddings, DPR).
- **BM25**: fórmula clássica de pontuação da busca por palavras-chave.
- **RRF (*Reciprocal Rank Fusion*)**: fusão de listas pela posição recíproca.
- **HNSW**: grafos hierárquicos para busca aproximada de vizinhos.
- **Chunk e overlap**: trecho e sobreposição entre trechos.
- **Token**: pedaço de texto (parte de palavra) que o modelo processa; os modelos têm limite de tokens.
- **MTEB**: benchmark de embeddings.

Pegadinhas da banca

- **"A busca semântica exige as mesmas palavras do documento."** Errado: isso é a **léxica**; a semântica acha "previdência do funcionalismo" para "aposentadoria de servidores".
- **"A busca léxica recupera por sentido e não falha com sinônimos."** Errado: a léxica busca **palavras exatas**.
- **"RAG retreina o modelo a cada consulta e dispensa a busca."** Errado: **busca primeiro**, sem retreino.
- **"Embedding é diarização."** Errado.
- **"Memória não paramétrica de Lewis = índice invertido com booleanos."** Errado: **índice vetorial denso** com **recuperador neural**.
- **"RAG dispensa memória externa."** Errado: a RAG **usa** memória externa.
- **"SBERT compara pares dentro da rede, com rede menor e menos precisa."** Errado: gera **vetores independentes** e compara por cosseno.
- **"No SBERT as frases entram juntas e dispensa cosseno."** Errado: isso é o BERT comum.
- **"BM25 e TF-IDF superam a recuperação densa (DPR)."** Errado: o **DPR superou** o BM25.
- **"Vetores da OpenAI não são normalizados; ranking muda com a métrica."** Errado: **normalizados**; **mesmo ranking**.
- **"Dimensões sempre fixas; só descartando documentos."** Errado: dá para **encurtar** ou usar **binários**.
- **"Embeddings só para busca."** Errado: também agrupamento, classificação, recomendação, anomalias.
- **"Busca vetorial só no mesmo idioma (dog x hund jamais)."** Errado: com modelo **multilíngue**, aproxima.
- **"Busca vetorial só para texto."** Errado: pode ser **multimodal**.

- **"Na híbrida, vetorial primeiro e textual depois, nunca em paralelo."** Errado: **em paralelo**, fundidas por RRF.
- **"Códigos, datas e nomes vão melhor com busca vetorial pura."** Errado: vão melhor com **palavras-chave**.
- **"RRF soma pontuações brutas, ignorando posição."** Errado: usa a **posição**: 1/(posição + k).
- **"Ranqueador semântico antes do RRF, substitui o BM25, nota confundida com RRF."** Errado: **depois**, nota própria **0 a 4**.
- **"HNSW é exaustivo e exato."** Errado: é **aproximado**; exaustivo é o **eKNN**.
- **"Tamanho de trecho e sobreposição universais."** Errado: é preciso **testar**.
- **"Chunking só ajuda acima do limite de tokens."** Errado: também ajuda documentos com **assuntos variados**.
- **"Bedrock retreina o modelo na consulta."** Errado: só **busca e adiciona trechos** ao prompt.
- **"Lost in the Middle: o meio é o melhor lugar."** Errado: o meio é o **pior**.
- **"MTEB: um embedding domina tudo."** Errado: **nenhum** domina.
- **"Lexical lida bem com sinônimos e erros de grafia."** Errado: é a **semântica** que lida.
- **Simétrica e assimétrica invertidas.** Errado: assimétrica = **curta x longa**.
- **"O campo de vetores serve como filtro."** Errado: filtra-se por **campos de metadados**.
- **"Binários ocupam mais e são mais precisos."** Errado: ocupam **menos** e são **menos precisos**.
- **"Cosseno conta palavras em comum."** Errado: compara **vetores de significado**.

Itens comentados

- **Item:** Em sistemas de pesquisa de acervos parlamentares, a busca semântica depende de que o usuário empregue exatamente as mesmas palavras presentes no documento procurado, de modo que uma consulta por aposentadoria de servidores não recuperaria discurso que tratasse de previdência do funcionalismo. **Errado.** Essa é a limitação da busca léxica. A semântica procura sentido parecido e acharia o discurso.

- **Item:** A geração aumentada por recuperação (RAG) reduz a alucinação porque retreina o modelo gerador a cada consulta com todo o acervo legislativo, dispensando a busca prévia de trechos. **Errado.** A RAG não retreina o modelo; ela busca primeiro os trechos e o modelo responde com base neles.

- **Item:** No artigo de Lewis e colaboradores sobre geração aumentada por recuperação (RAG), o modelo combina uma memória paramétrica, representada por um modelo seq2seq pré-treinado, com uma memória não paramétrica, formada por um índice vetorial denso da Wikipédia acessado por um recuperador neural. **Certo.** É a arquitetura descrita no artigo original.

- **Item:** O Sentence-BERT acelera a busca de sentenças semelhantes porque continua comparando as sentenças aos pares dentro da rede, como o BERT, mas usa uma rede menor e, por isso, menos precisa. **Errado.** O SBERT gera um vetor para cada frase, de forma independente, e compara os vetores por cosseno.

- **Item:** Segundo o artigo sobre recuperação densa de passagens (DPR), os métodos esparsos, como TF-IDF e BM25, superam as representações vetoriais densas em perguntas e respostas de domínio aberto, razão pela qual a recuperação densa só serve como complemento. **Errado.** O DPR mostrou que a recuperação densa supera o BM25.
- **Item:** De acordo com o guia de embeddings da OpenAI, os vetores dos modelos de embeddings são normalizados para comprimento 1, razão pela qual a similaridade de cosseno pode ser calculada apenas com o produto escalar e produz o mesmo ranking que a distância euclidiana. **Certo.** Com vetores de comprimento 1, cosseno, produto escalar e distância euclidiana dão a mesma ordem.
- **Item:** Na busca vetorial do Azure AI Search, a correspondência entre conteúdos só funciona quando consulta e documento estão no mesmo idioma, de modo que palavras como dog, em inglês, e hund, em alemão, jamais podem ser aproximadas. **Errado.** Com modelo de embeddings multilíngue, dog e hund podem ser aproximados.
- **Item:** Na busca híbrida do Azure AI Search, a consulta vetorial é executada primeiro, e a consulta textual só é aplicada depois, sobre o subconjunto retornado, de modo que as duas buscas nunca ocorrem em paralelo. **Errado.** As duas rodam em paralelo numa só requisição e são combinadas pelo RRF.
- **Item:** O RRF usado em busca híbrida soma diretamente as pontuações brutas de cada algoritmo, como a do BM25 e a de similaridade de cosseno, sem levar em conta a posição dos documentos nas listas originais. **Errado.** O RRF usa a posição: 1/(posição + k) em cada lista, somando os resultados.
- **Item:** O HNSW é uma técnica de busca exaustiva, que compara a consulta com todos os vetores do índice e, por isso, garante sempre o resultado exato, ao custo de tempo de resposta proporcional ao tamanho do acervo. **Errado.** O HNSW é busca aproximada em grafos de vários níveis; a exaustiva e exata é o eKNN.
- **Item:** Segundo a documentação do Azure AI Search, a divisão de documentos em trechos só traz benefícios quando o texto ultrapassa o limite de tokens do modelo, não havendo ganho de qualidade em dividir documentos que caibam no limite. **Errado.** Dividir também melhora a busca em documentos com assuntos variados, que um único vetor representaria mal.
- **Item:** Segundo Liu e colaboradores, os modelos de linguagem aproveitam melhor a informação relevante quando ela está posicionada no meio de um contexto longo, de modo que os trechos mais importantes devem ser colocados ao centro. **Errado.** É o contrário: o modelo usa melhor o início e o fim; o meio é o pior lugar.
- **Item:** A documentação do Sentence Transformers define a busca semântica simétrica como aquela em que uma consulta curta, como uma pergunta, é comparada com passagens longas, e a assimétrica como a que compara itens de tamanho e conteúdo semelhantes. **Errado.** Conceitos invertidos: simétrica compara itens parecidos; assimétrica, consulta curta com passagem longa.
- **Item:** Segundo o guia do Amazon Bedrock, os vetores binários, de 1 bit por dimensão, são mais custosos em armazenamento e mais precisos que os vetores de ponto flutuante (float32), por

isso são a escolha recomendada para acervos pequenos. **Errado.** Binários ocupam menos espaço e são menos precisos que os float32.

Resumo para revisar

- **Léxica**: palavras iguais (índice invertido, TF-IDF, BM25); falha com sinônimos; ótima para códigos, datas e nomes.
- **Semântica**: sentido; acervo e pergunta viram **vetores no mesmo espaço**; devolve os mais próximos; lida com sinônimos, abreviações e erros.
- **Embedding** = vetor de significado. **Cosseno** compara vetores, não conta palavras.
- Busca vetorial: *dog* ~ *canine*; **multilíngue** (*dog* ~ *hund*); **multimodal** (texto ~ imagem).
- **RAG**: recupera, entrega, responde; **reduz alucinação**, **cita fonte**, **não retreina**.
- RAG: trechos **relevantes e concisos**; respeitar **controle de acesso**.
- **Bedrock**: texto → trechos → embeddings → índice com mapeamento; consulta vetorizada e trechos no prompt. **Binário** (1 bit) menor e menos preciso; **float32** maior e mais preciso.
- **Chunking**: limite de tokens (senão trunca) **e** qualidade em documentos de vários assuntos; sobreposição **moderada**; **sem receita universal**.
- **OpenAI**: vetores com **comprimento 1** (cosseno = produto escalar = mesmo ranking da euclidiana); **3ª geração encurta**; encurtou à mão, **normaliza**; usos: busca, agrupamento, classificação, recomendação, anomalias.
- **Híbrida (Azure)**: texto + vetor **em paralelo**, numa requisição, fundidos por **RRF**.
- **RRF**: **1/(posição + k)**, somado; topo em vários métodos = topo final.
- **Ranqueador semântico**: **depois** do RRF; nota **0 a 4**.
- Filtros em campos de **metadados** (texto ou número), antes ou depois; **campo de vetor não filtra**.
- **HNSW**: aproximado, grafos em níveis, logarítmico. **eKNN**: exaustivo e exato.
- **Lewis (RAG)**: seq2seq + índice vetorial denso da Wikipédia; RAG-Sequence e RAG-Token.
- **SBERT**: redes siamesas e triplas; vetores independentes; cosseno; resolve o custo quadrático do BERT.
- **DPR**: dois codificadores; **supera BM25**.
- **Lost in the Middle**: início e fim bons; **meio ruim**.
- **MTEB**: **nenhum** embedding vence tudo; teste no seu acervo.
- **Simétrica**: itens parecidos. **Assimétrica**: consulta curta x passagem longa, codificadas de modos distintos.

TEMA 16 DE 20

Geração automática de atas e resumos

55 perguntas no app · IA no Parlamento

O que cai

O edital pede "Geração automática de atas e resumos de sessões" (item 3.3 de Reconhecimento de Fala, Transcrição e IA). As perguntas deste tema giram em torno de quatro blocos:

- **Resumo extrativo x abstrativo**: quem recorta e quem reescreve, qual é mais fiel e qual alucina mais. É a troca campeã da banca.
- **Como os serviços de nuvem resumem**: o Azure AI Language (pontuação de frases, ordem das frases, resumo de conversas com recap, título de capítulo e narrativa, limitações) e a verificação de fundamentação do Amazon Bedrock (fundamentação x relevância, limiar).
- **Pesquisa sobre alucinação**: Maynez e colegas (ROUGE x implicação textual), See, Liu e Manning (rede ponteiro-gerador) e o levantamento de Ji e colegas.
- **A ata no Regimento Interno da Câmara**: sinopse em padrão uniforme, lista de presença, Anais em ordem cronológica, aprovação sem votação, publicação no Diário da Câmara, revisão do discurso em cinco sessões, ata das comissões. E a regra da Câmara (Portaria 227/2025) de que quem usa IA generativa revisa e responde pelo resultado.

O fio que une tudo: **a máquina faz o rascunho, a pessoa confere e responde pelo texto**.

Entenda o tema

O que é resumir com IA

Sumarização é a tarefa de pegar um texto longo e produzir um texto curto com o que importa. No parlamento, a matéria-prima costuma ser a transcrição de uma sessão ou de uma reunião, e o produto é um resumo, uma pauta comentada ou uma minuta de ata.

Existem dois jeitos de resumir, e quase toda pergunta do tema depende de saber a diferença.

Sumarização extrativa. O sistema lê o texto, dá uma nota a cada frase e devolve as frases mais importantes **exatamente como estão** no original. É como um estudante que resume um capítulo passando marca-texto nas frases-chave e copiando só essas frases. Vantagem: preserva a literalidade, quase não inventa nada. Desvantagem: o resultado pode ficar "picotado", pouco fluido, porque as frases foram tiradas de lugares diferentes.

Sumarização abstrativa. O sistema entende o conteúdo e **escreve um texto novo**, com palavras próprias, parafraseando o original. É como o estudante que fecha o livro e conta, com suas

palavras, o que leu. Vantagem: texto fluente e conciso. Desvantagem: como reescreve, pode perder informação, distorcer o sentido ou **alucinar**, isto é, afirmar algo que não estava no original.

> **Pegadinha:** a banca troca os dois. Quem **recorta trechos literais** é a **extrativa**, e é ela a de **menor** risco de distorção. Quem **redige texto novo** é a **abstrativa**, de **maior** risco de alucinação. Reescrever "com palavras próprias" não deixa o texto mais seguro; deixa mais arriscado.

A documentação da Hugging Face (biblioteca Transformers) descreve a mesma divisão: o resumo pode ser **extrativo**, quando extrai as informações mais relevantes de um documento, ou **abstrativo**, quando gera um texto novo que capta essas informações. O guia de sumarização da Hugging Face trabalha com a forma abstrativa.

Como medir se um resumo é bom: a ROUGE

A **ROUGE** é a métrica clássica para avaliar resumos automáticos. Ela **compara o resumo gerado com um resumo de referência** escrito por pessoas e mede quantas palavras e sequências de palavras os dois têm em comum. Sem resumo de referência, não há como calcular a ROUGE. Por isso ela depende do conjunto de dados usado na avaliação.

> **Atenção:** a ROUGE mede sobreposição de palavras, não verdade. Um resumo pode ter ROUGE alta e mesmo assim trazer um fato errado. É o que mostrou o estudo de Maynez, logo abaixo.

O problema da alucinação nos resumos

Maynez e colaboradores (artigo "On Faithfulness and Factuality in Abstractive Summarization", ACL 2020) estudaram resumos abstrativos feitos por redes neurais e concluíram:

- os sumarizadores abstrativos neurais são **muito propensos** a produzir conteúdo **infiel** ao documento de origem;
- os avaliadores humanos encontraram conteúdo alucinado em **todos** os resumos gerados pelos modelos analisados;
- as medidas baseadas em **implicação textual** (verificar se o resumo "decorre logicamente" do texto-fonte) se correlacionam **melhor** com a fidelidade do que a **ROUGE**. Logo, a ROUGE sozinha **não basta** para detectar alucinações.

See, Liu e Manning (artigo "Get To The Point: Summarization with Pointer-Generator Networks", 2017) apontaram dois defeitos dos modelos neurais sequência a sequência usados em resumo abstrativo: eles **reproduzem mal os detalhes factuais** (nomes, números) e **se repetem**. A solução proposta foi a **rede ponteiro-gerador**, uma arquitetura **híbrida**:

- o **ponteiro** permite **copiar palavras do texto de origem**, o que ajuda a reproduzir detalhes com exatidão;
- o **gerador** permite **criar palavras novas** quando convém;
- um **mecanismo de cobertura** acompanha o que já foi dito e evita repetições.

> **Dica:** o nome entrega a resposta. "Ponteiro" aponta e copia; "gerador" cria. Se o item disser que a rede é **puramente extrativa** ou que **não gera palavras novas**, está errado.

O levantamento **"Survey of Hallucination in Natural Language Generation"** (Ji e colaboradores, publicado na **ACM Computing Surveys**) mostra que a alucinação não é exclusividade dos resumos. Ele trata de várias tarefas de geração: **sumarização abstrativa**, **geração de diálogo**, **perguntas e respostas generativas**, **tradução automática** e **geração visual-linguística** (texto a partir de imagens). Não se restringe à tradução.

Resumo no Azure AI Language (Microsoft)

O **Azure AI Language** é o serviço de linguagem da Microsoft. Ele oferece os dois tipos de resumo.

Resumo extrativo no Azure. O serviço escolhe frases relevantes do próprio texto e devolve cada uma com:

- a **posição** dela no documento de origem;
- uma **pontuação** (nota) que indica a **relevância** da frase para o tema principal.

A pontuação mede **importância**, e não lugar. Uma frase do fim do texto pode ser a mais bem pontuada; não é verdade que as frases do início sempre recebem as maiores notas.

Quando você pede um resumo de **três frases**, o serviço devolve as **três de maior pontuação**. **Por padrão**, elas aparecem **na ordem em que estão no texto**; se você pedir, elas podem ser ordenadas **por ranking** (da maior para a menor nota). Se você pedir **cinco frases** do mesmo documento, recebe as três anteriores **mais duas**: os conjuntos não são totalmente diferentes, porque as melhores frases continuam as melhores.

> **Exemplo:** uma transcrição de reunião tem 40 frases. Pedido de 3 frases: o serviço devolve as frases 4, 18 e 33 (as de maior nota), nessa ordem. Pedido de 5 frases: devolve 4, 11, 18, 27 e 33. As três primeiras continuam lá.

Resumo abstrativo no Azure. O serviço gera **frases concisas e coerentes que não são extratos literais** do original. Ele não devolve frases copiadas ordenadas por nota; isso é o extrativo.

Resumo de conversas no Azure. Para conversas (chamadas, reuniões, chats), há três formatos:

Recurso	O que faz
Recap	resume a conversa inteira em **um parágrafo breve**
Título de capítulo (chapter title)	**divide** a conversa por tópicos e **sugere um título** para cada parte
Narrativa	gera **notas detalhadas** da chamada, da reunião ou do chat

Limitações que a própria Microsoft declara:

- o recurso de sumarização usa **método abstrativo**, que tenta compreender o texto e parafraseá-lo; por isso **pode haver perda de informação ou de acurácia**;

- o serviço **não verifica fatos** nem confirma o conteúdo enviado pelo cliente. Resultado: a **revisão humana continua necessária**;
- a maior parte dos dados de treinamento está em **inglês** e em línguas muito usadas, como **alemão** e **espanhol**; o desempenho pode ser **pior em idiomas menos representados**. Para o português, convém testar com textos reais;
- a **qualidade do resumo depende da qualidade da entrada**. O modelo resume o que recebe; uma transcrição com erros tende a gerar um resumo com erros. Ele não corrige automaticamente as falhas da transcrição.

Verificação de fundamentação no Amazon Bedrock

O **Amazon Bedrock Guardrails** (AWS) tem um filtro contra alucinação chamado **verificação de fundamentação contextual** (contextual grounding check). Ele olha a **resposta do modelo** e a compara com a **fonte** fornecida e com a **pergunta** do usuário. Dá duas notas:

- **Fundamentação (grounding):** a resposta é factualmente correta **com base na fonte**? Qualquer **informação nova**, que não está na fonte, torna a resposta **não fundamentada**.
- **Relevância (relevance):** a resposta **responde à pergunta** do usuário?

As duas notas são independentes. Veja os casos:

Situação	Fundamentação	Relevância
Resposta tirada da fonte, mas que não responde à pergunta	**fundamentada**	**irrelevante** (nota baixa)
Fonte diz "Tóquio é a capital do Japão"; resposta diz "a capital do Japão é Londres"	**não fundamentada**	**relevante** (fala do que foi perguntado)
Resposta acrescenta dado que não está na fonte	**não fundamentada**	depende da pergunta

A verificação se aplica **só à resposta do modelo**. O que o usuário escreve no prompt **não** é checado contra a fonte por esse filtro.

O limiar. Você escolhe um limiar (nota mínima) para cada verificação. **Limiar mais alto** = filtro mais rigoroso: **bloqueia mais** respostas sem amparo na fonte, mas também **aumenta o risco de barrar respostas úteis**. Nenhum ajuste **elimina completamente** as alucinações sem prejudicar a disponibilidade das respostas; o filtro reduz o risco, não zera.

Numa verificação **estrita**, qualquer informação que não esteja na fonte reduz a nota, **inclusive inferências razoáveis** (deduções óbvias). Isso deixa o filtro **mais seguro** contra alucinações, porém **mais propenso a bloquear respostas legítimas**.

A ata gerada por IA é minuta

A ata é **documento oficial**, com efeitos jurídicos: registra o que foi dito e decidido. Por isso, a ata produzida automaticamente é tratada como **minuta** (rascunho). Ela precisa:

- ser **conferida contra o áudio**;
- não suprimir **manifestações, apartes e deliberações**;

- marcar como **ininteligível** o trecho que o sistema não entendeu, em vez de deixá-lo **"completar pelo contexto"**.

> **Atenção:** lacuna marcada é honesta; texto inventado pode virar prova falsa num documento oficial. O item que manda o modelo preencher os trechos não compreendidos "para que a ata não tenha lacunas" está errado.

Portaria nº 227/2025 da Câmara dos Deputados (uso de IA generativa na Casa, art. 14): o servidor que usa IA generativa para elaborar, por exemplo, um resumo de reunião **é responsável pelo documento** que criar e publicar e **deve revisar o resultado antes** de:

- **torná-lo público**; e também
- **utilizá-lo em seus processos de trabalho e decisões**.

A revisão não é dispensada no uso interno.

Exemplo real de uso em parlamento. Entre os casos de uso de IA reunidos pela **União Interparlamentar (UIP)**, está o do **Senado italiano**, que prevê um **sumarizador baseado em modelo de linguagem de grande porte** para oferecer resumos concisos e precisos de **projetos de lei** e de outros documentos parlamentares, tornando-os mais acessíveis.

A ata no Regimento Interno da Câmara

As regras da ata estão nos arts. 97 e 98 (sessões do Plenário), no art. 80 (leitura da ata) e nos arts. 62 e 63 (comissões) do Regimento Interno (Resolução nº 17/1989).

O que a ata é. A ata é a **sinopse** dos trabalhos de cada sessão, ou seja, um **resumo organizado**, e não a reprodução palavra por palavra de tudo o que se falou. A redação segue **padrão uniforme adotado pela Mesa**, e não o estilo livre de cada secretário.

O que consta. Da ata das sessões **ordinárias e extraordinárias** consta a **lista nominal de presença e de ausência** dos Deputados.

Onde fica. As atas impressas ou datilografadas são organizadas em **Anais**, por **ordem cronológica**, **encadernadas por sessão legislativa** e recolhidas ao **Arquivo da Câmara**. Não é por ordem alfabética de oradores nem por legislatura.

Última sessão do ano. A ata da última sessão, ao se encerrar a sessão legislativa, é redigida **em resumo** e submetida a discussão e aprovação **antes de se levantar a sessão**, **presente qualquer número** de Deputados. Não fica para o ano seguinte.

Leitura e aprovação. Abertos os trabalhos, o **Segundo-Secretário** lê a ata da sessão anterior, e o **Presidente a considera aprovada, independentemente de votação**. O Deputado que quiser **retificar** a ata envia **declaração escrita à Mesa**; a declaração entra na ata, e o Presidente decide, cabendo recurso ao Plenário.

Publicação. O **Diário da Câmara dos Deputados** publica a ata da **sessão do dia anterior**, com **toda a sequência dos trabalhos**. Os **discursos** são publicados **por extenso** na ata impressa, salvo restrições expressas do Regimento.

Correção de discurso. Não se republica discurso inteiro no Diário para corrigir erros e omissões: as correções vão para a seção **"Errata"**.

Revisão pelo orador. O Deputado pode **retirar na Taquigrafia**, para revisão, o seu discurso. Se não o devolver em **cinco sessões**, a Taquigrafia publica o **texto sem revisão** do orador. A publicação não fica adiada indefinidamente.

Atas das comissões. Cada comissão tem uma **secretaria**, e a **redação da ata das reuniões** é serviço dessa secretaria (art. 62, parágrafo único, I), e não do relator. Lida e aprovada, a ata é **assinada pelo Presidente** da comissão e **rubricada em todas as folhas**. É publicada no **Diário da Câmara**, **de preferência no dia seguinte**, em **padrão uniforme**, com: data, hora e local; nomes dos membros presentes e ausentes (com referência às faltas justificadas); **resumo do expediente**; matérias distribuídas, com relatores; proposições apreciadas e suas conclusões. O Regimento **não** exige transcrição integral dos debates na ata de comissão.

Quadros para memorizar

Extrativo x abstrativo

	Extrativo	Abstrativo
Como faz	recorta frases do original	redige texto novo, parafraseando
Literalidade	preservada	não
Fluência	menor (texto "picotado")	maior
Risco de alucinação	menor	maior
No Azure	frases com posição e pontuação de relevância	frases concisas e coerentes, não literais

Autores e estudos

Estudo	Ideia central
Maynez et al. (ACL 2020)	sumarizadores abstrativos neurais alucinam muito; humanos acharam alucinação em todos os resumos; implicação textual acompanha a fidelidade melhor que a ROUGE
See, Liu e Manning (2017)	modelos seq2seq erram detalhes e se repetem; rede ponteiro-gerador copia (ponteiro), gera (gerador) e evita repetição (cobertura)
Ji et al. (ACM Computing Surveys)	alucinação em sumarização, diálogo, perguntas e respostas, tradução e geração visual-linguística
Hugging Face (Transformers)	resumo extrativo ou abstrativo; ROUGE compara com resumo de referência

Bedrock: fundamentação x relevância

Nota	Pergunta que responde	Derruba a nota
Fundamentação	a resposta se apoia na fonte?	informação nova ou contrária à fonte

Nota	Pergunta que responde	Derruba a nota
Relevância	a resposta responde à pergunta?	resposta fora do assunto perguntado
Limiar alto		bloqueia mais alucinação e mais respostas úteis

A ata no Regimento Interno da Câmara

Ponto	Regra	Artigo
Natureza	sinopse dos trabalhos, padrão uniforme da Mesa	art. 97
Arquivo	Anais, ordem cronológica, encadernados por sessão legislativa	art. 97, § 1º
Presença	lista nominal de presença e ausência (sessões ordinárias e extraordinárias)	art. 97, § 2º
Última sessão do ano	ata em resumo, aprovada antes de levantar a sessão, qualquer número	art. 97, § 3º
Leitura	Segundo-Secretário lê; Presidente considera aprovada sem votação	art. 80
Retificação	declaração escrita à Mesa	art. 80, § 1º
Publicação	Diário da Câmara publica a ata do dia anterior	art. 98
Discursos	por extenso; correção vai para a "Errata"	art. 98, § 1º
Revisão do discurso	devolver em 5 sessões; senão, publica sem revisão	art. 98, § 2º
Ata de comissão	secretaria redige; Presidente assina; rubrica em todas as folhas; Diário de preferência no dia seguinte	arts. 62 e 63

Conceitos e autores que caem

> **Lei seca:** Art. 97. Lavrar-se-á ata com a **sinopse** dos trabalhos de cada sessão, cuja redação obedecerá a **padrão uniforme adotado pela Mesa**. (RICD)
>
> **Lei seca:** Art. 98, § 2º. (...) Caso o orador não devolva o discurso dentro de **cinco sessões**, a Taquigrafia dará à publicação o texto **sem revisão do orador**. (RICD)
>
> **Lei seca:** Art. 80. Abertos os trabalhos, o Segundo-Secretário fará a leitura da ata da sessão anterior, que o Presidente considerará aprovada, **independentemente de votação**. (RICD)

- **Sumarização extrativa**: seleciona e recorta trechos do original, preservando a literalidade.
- **Sumarização abstrativa**: gera texto novo, mais fluente, com maior risco de imprecisão e alucinação.
- **Alucinação**: conteúdo gerado que não está na fonte ou a contradiz.
- **ROUGE**: métrica que compara o resumo gerado com resumos de referência humanos.

- **Implicação textual**: verificar se o resumo decorre logicamente da fonte; acompanha melhor a fidelidade do que a ROUGE.
- **Fundamentação (grounding)**: a resposta se apoia na fonte; informação nova = não fundamentada.
- **Minuta**: rascunho que ainda precisa ser conferido e aprovado.

Pegadinhas da banca

- **"A abstrativa tem menor risco de distorção porque reescreve com palavras próprias."** Errado: reescrever aumenta o risco. A extrativa, que recorta, é a mais fiel.
- **"A abstrativa recorta trechos literais; a extrativa parafraseia."** Errado: os tipos foram trocados.
- **"O extrativo do Azure redige frases novas e não informa a posição."** Errado: ele copia frases do texto e informa posição e pontuação.
- **"O abstrativo do Azure devolve obrigatoriamente frases copiadas, ordenadas por ranking."** Errado: isso descreve o extrativo.
- **"A pontuação da frase indica sua posição; as do início sempre ganham mais."** Errado: a pontuação mede relevância.
- **"As frases vêm sempre em ordem decrescente de pontuação."** Errado: por padrão vêm na ordem do texto; o ranking é opcional.
- **"O resumo de cinco frases traz cinco frases totalmente diferentes do de três."** Errado: mantém as três e soma duas.
- **"Recap divide em capítulos; título de capítulo resume em um parágrafo."** Errado: é o inverso.
- **"O Azure verifica os fatos antes de resumir, então dispensa revisão humana."** Errado: não verifica fatos; a revisão continua necessária.
- **"A qualidade do resumo independe da entrada, pois o modelo corrige a transcrição."** Errado: entrada ruim gera resumo ruim.
- **"A ROUGE é calculada só sobre o resumo gerado, sem referência."** Errado: ela compara com resumos de referência.
- **"Segundo Maynez, a ROUGE é melhor que a implicação textual e basta para pegar alucinações."** Errado: é o contrário.
- **"Para See, Liu e Manning, os modelos seq2seq acertam os detalhes e não se repetem."** Errado: erram e se repetem; daí a cópia e a cobertura.
- **"A rede ponteiro-gerador é puramente extrativa."** Errado: copia e também gera palavras novas.
- **"O levantamento de Ji et al. trata só de tradução e diz que resumos não alucinam."** Errado: cobre várias tarefas, inclusive sumarização abstrativa.
- **"Resposta tirada da fonte que não responde à pergunta é não fundamentada."** Errado: é fundamentada e irrelevante.
- **"A verificação de fundamentação também checa o prompt do usuário."** Errado: checa só a resposta do modelo.

- **"Dá para ajustar o limiar e eliminar todas as alucinações sem perder respostas."** Errado: limiar alto barra também respostas úteis.
- **"O modelo deve completar os trechos não compreendidos para a ata não ter lacunas."** Errado: o trecho é marcado como ininteligível e conferido no áudio.
- **"Pela Portaria 227/2025, a revisão só é exigida se o documento for público."** Errado: também antes do uso interno em trabalho e decisões.
- **"A ata reproduz palavra por palavra os pronunciamentos, com redação livre."** Errado: é sinopse, em padrão uniforme da Mesa.
- **"A ata da última sessão é redigida na íntegra e aprovada no ano seguinte."** Errado: em resumo, aprovada antes de levantar a sessão, com qualquer número.
- **"O Deputado pode republicar o discurso inteiro para corrigir erros."** Errado: a correção vai para a Errata.
- **"Discurso não devolvido em dez sessões tem a publicação adiada."** Errado: são cinco sessões, e o texto sai sem revisão.
- **"A ata da sessão anterior só se aprova por votação nominal."** Errado: considera-se aprovada sem votação.
- **"A ata de comissão exige transcrição integral dos debates e dispensa o resumo do expediente."** Errado: exige o resumo do expediente, não a íntegra dos debates.
- **"A ata de comissão é redigida pelo relator da matéria."** Errado: é serviço da secretaria da comissão.
- **"As atas vão para os Anais por ordem alfabética dos oradores, a cada legislatura."** Errado: ordem cronológica, encadernadas por sessão legislativa.

Itens comentados

- **Item:** A sumarização extrativa seleciona e recorta trechos do próprio original, preservando a literalidade, enquanto a abstrativa redige texto novo, mais fluente, porém com maior risco de imprecisão e de alucinação. **Certo.** É a definição correta dos dois tipos: recortar preserva, reescrever arrisca.
- **Item:** A sumarização abstrativa, por recortar trechos literais do original, apresenta menor risco de alucinação do que a extrativa, que redige texto novo parafraseando o conteúdo. **Errado.** Os tipos foram trocados. Quem recorta é a extrativa, a mais segura.
- **Item:** No resumo extrativo do Azure AI Language, ao ser pedido um resumo de três frases, o serviço devolve as três frases de maior pontuação, que por padrão aparecem na ordem em que figuram no texto, podendo ser ordenadas por ranking. **Certo.** Três melhores notas, na ordem do texto por padrão, com ranking opcional.
- **Item:** Segundo Maynez e colaboradores, a métrica ROUGE se correlaciona com a fidelidade factual dos resumos melhor do que as medidas baseadas em implicação textual, sendo por isso suficiente para detectar alucinações. **Errado.** A implicação textual acompanha melhor a fidelidade; a ROUGE sozinha não basta.

- **Item:** A rede ponteiro-gerador proposta por See, Liu e Manning é um sistema puramente extrativo, que só consegue copiar palavras do texto de origem e é incapaz de gerar palavras novas. **Errado.** É híbrida: copia pelo ponteiro e gera pelo gerador.
- **Item:** No Amazon Bedrock Guardrails, uma resposta que utiliza informações presentes na fonte, mas não responde à pergunta do usuário, recebe baixa pontuação de fundamentação por ser considerada não fundamentada. **Errado.** Ela é fundamentada; a nota baixa é a de relevância.
- **Item:** Na verificação de fundamentação contextual do Amazon Bedrock, se a fonte afirma que Tóquio é a capital do Japão e a resposta diz que a capital do Japão é Londres, a resposta é relevante para a pergunta, mas é considerada não fundamentada. **Certo.** Fala do que foi perguntado (relevante), mas contradiz a fonte (não fundamentada).
- **Item:** Na geração automática de atas parlamentares, os trechos não compreendidos pelo sistema devem ser completados pelo próprio modelo com base no contexto, para que a ata não apresente lacunas. **Errado.** Em documento oficial, o trecho incompreendido é sinalizado e conferido no áudio, nunca adivinhado.
- **Item:** Segundo a Microsoft, o serviço de sumarização do Azure AI Language verifica os fatos do conteúdo enviado pelo cliente antes de resumi-lo, motivo pelo qual não é necessária revisão humana dos resumos abstrativos. **Errado.** O serviço não verifica fatos, e o abstrativo pode perder ou distorcer informação.
- **Item:** Pela Portaria nº 227/2025 da Câmara dos Deputados, a revisão do resultado de sistema de IA generativa só é exigida quando o documento é divulgado ao público, sendo dispensada quando o resumo gerado for utilizado apenas internamente em processos de trabalho e decisões. **Errado.** A revisão vale antes de divulgar e antes de usar em trabalho e decisões.
- **Item:** Segundo o Regimento Interno da Câmara dos Deputados, a ata da última sessão da sessão legislativa é redigida na íntegra e somente é aprovada na primeira sessão do ano seguinte. **Errado.** É redigida em resumo e aprovada antes de se levantar a própria sessão, com qualquer número de Deputados.
- **Item:** De acordo com o Regimento Interno da Câmara dos Deputados, o Deputado que retira seu discurso na Taquigrafia para revisão e não o devolve em dez sessões tem a publicação adiada até que o devolva. **Errado.** O prazo é de cinco sessões; depois dele, o texto sai sem revisão do orador.
- **Item:** Segundo o Regimento Interno da Câmara dos Deputados, aberta a sessão, o Segundo-Secretário lê a ata da sessão anterior, que o Presidente considera aprovada independentemente de votação, e o Deputado que pretenda retificá-la deve enviar declaração escrita à Mesa. **Certo.** É o texto do art. 80 e do seu § 1º.
- **Item:** De acordo com o Regimento Interno da Câmara dos Deputados, as atas impressas ou datilografadas são organizadas em Anais por ordem alfabética dos oradores e recolhidas ao Arquivo da Câmara a cada legislatura. **Errado.** Ordem cronológica, encadernadas por sessão legislativa.

Resumo para revisar

- Extrativo recorta frases do original: fiel, menos fluente, quase não alucina.
- Abstrativo reescreve: fluente, mas pode perder, distorcer e inventar.
- Hugging Face: resumo extrativo (extrai) ou abstrativo (gera texto novo).
- ROUGE compara o resumo com resumos de referência; não mede verdade.
- Maynez (2020): abstrativos neurais alucinam muito; alucinação em todos os resumos avaliados; implicação textual > ROUGE para medir fidelidade.
- See, Liu e Manning (2017): seq2seq erra detalhes e se repete; ponteiro copia, gerador cria, cobertura evita repetição.
- Ji et al.: alucinação em resumo, diálogo, perguntas e respostas, tradução e geração visual-linguística.
- Azure extrativo: frases do texto com posição e nota de relevância; ordem do texto por padrão, ranking opcional; 5 frases = as 3 melhores + 2.
- Azure abstrativo: frases concisas e coerentes, não literais.
- Azure conversas: recap (um parágrafo), título de capítulo (divide e nomeia), narrativa (notas detalhadas).
- Azure não verifica fatos; treinado sobretudo em inglês, alemão, espanhol; resumo depende da qualidade da transcrição.
- Bedrock: fundamentação (apoio na fonte) e relevância (responde à pergunta) são notas separadas; checa só a resposta do modelo.
- Limiar alto: barra mais alucinação e mais respostas úteis; nada zera a alucinação. Modo estrito pune até inferências razoáveis.
- Ata gerada por IA é minuta: conferir com o áudio, não suprimir apartes e deliberações, marcar o ininteligível.
- Portaria 227/2025 da Câmara: quem usa IA generativa responde pelo documento e revisa antes de publicar e antes de usar internamente.
- Senado italiano (caso na UIP): sumarizador com LLM para projetos de lei.
- RICD: ata é sinopse em padrão uniforme da Mesa, com lista nominal de presença e ausência.
- Anais em ordem cronológica, por sessão legislativa, no Arquivo da Câmara.
- Última sessão do ano: ata em resumo, aprovada antes de levantar a sessão, com qualquer número.
- Ata lida pelo Segundo-Secretário e considerada aprovada sem votação; retificação por declaração escrita à Mesa.
- Diário da Câmara publica a ata do dia anterior; discursos por extenso; correções na Errata.
- Discurso retirado para revisão: 5 sessões; depois, sai sem revisão.
- Comissões: secretaria redige a ata; Presidente assina; rubrica em todas as folhas; Diário de preferência no dia seguinte, com resumo do expediente.

TEMA 17 DE 20

Modelos multilíngues e especializados em português

54 perguntas no app · IA no Parlamento

O que cai

O edital pede "Modelos de IA multilíngues e especializados em português" (item 3.4). As perguntas deste tema se concentram em:

- **Multilíngue x especializado**: o que significa cada um e por que o modelo ajustado em português costuma se sair melhor no português do Brasil.
- **Whisper (OpenAI)**: 680 mil horas de supervisão fraca (só 117 mil em outros 96 idiomas), arquitetura codificador-decodificador, 16 kHz, janelas de 30 segundos, espectrograma log-Mel, tamanhos (tiny a large), versões .en, turbo, large-v3 com pseudorrótulos, alucinações e repetições, ajuste fino.
- **wav2vec 2.0, XLSR-53 e XLS-R (Meta)**: aprendizado autossupervisionado com áudio sem transcrição, seguido de ajuste fino com pouca fala transcrita.
- **Corpora de fala em português**: CORAA (fala espontânea validada, licença que proíbe uso comercial), Common Voice (voluntários leem e validam), Multilingual LibriSpeech (audiolivros, pouco português).
- **Métricas**: WER e CER, como se calculam e por que podem passar de 100%.
- **Modelos de texto em português**: Sabiá (continuação do pré-treino) e BERTimbau (lê texto, não áudio).

Entenda o tema

Multilíngue x especializado em português

Um **modelo multilíngue** foi treinado com dados de **muitos idiomas**. Um **modelo monolíngue** ou **especializado** foi treinado, ou ajustado, **predominantemente em um idioma**, como o português.

Pense em dois tradutores. Um fala vinte línguas razoavelmente; o outro nasceu no Brasil e só trabalha com português. Para entender "tô de boa", "pra mim" ou "vossa excelência", o segundo costuma acertar mais. É isso: modelos treinados ou ajustados em português **tendem a ter melhor desempenho em vocabulário e construções próprias do português brasileiro**. A especialização vale **para a língua que o modelo mais estudou**: um modelo de português não fica melhor em inglês técnico por ter visto menos idiomas.

Escolher entre os dois é **pesar abrangência e especialização**. O multilíngue é versátil; o especializado é mais afiado no seu idioma. Nenhum dos dois "supera necessariamente" o outro em tudo.

> **Pegadinha:** "modelos treinados em muitos idiomas, ditos **monolíngues**". Errado: quem é treinado em muitos idiomas é **multilíngue**.

Whisper: como foi treinado

O **Whisper** é o modelo de reconhecimento de fala da OpenAI, apresentado no artigo "Robust Speech Recognition via Large-Scale Weak Supervision" (Radford e colaboradores).

Supervisão fraca. O Whisper foi treinado com cerca de **680 mil horas de áudio** que já vinham com transcrições **coletadas da internet**. Ninguém revisou essas transcrições uma a uma; elas têm falhas, mas o volume enorme compensa. É isso que se chama **supervisão fraca** (weak supervision).

Quanto é multilíngue. Das 680 mil horas, só cerca de **117 mil** cobrem **96 outros idiomas** além do inglês. O grosso do treino é **inglês**. Por isso o Whisper é multilíngue, mas rende melhor nos idiomas com mais dados.

> **Atenção:** o item que diz que "a maior parte" das 680 mil horas está nos 96 outros idiomas está errado. Os outros idiomas são a minoria.

Arquitetura. O Whisper é um **Transformer codificador-decodificador**. O áudio é:

1. **reamostrado a 16 kHz** (16 mil amostras por segundo, o padrão que o modelo espera);
2. cortado em **segmentos de 30 segundos**;
3. convertido em **espectrograma log-Mel**.

O **codificador** lê essa representação, e o **decodificador** escreve o texto.

Espectrograma log-Mel. É uma espécie de "imagem do som": mostra, ao longo do tempo, **quanta energia há em cada faixa de frequência**, do grave ao agudo. As faixas são espaçadas pela **escala Mel**, que imita a percepção do ouvido humano (percebemos melhor diferenças nos graves do que nos agudos). O artigo original usa 80 canais Mel; o **large-v3** passou a usar **128 bandas Mel**.

Multitarefa. O mesmo modelo faz várias coisas: **reconhecimento de fala multilíngue**, **tradução de fala** (para o inglês), **identificação do idioma falado** e **detecção de atividade de voz** (perceber se há fala ou silêncio). A tarefa é escolhida por **tokens especiais** no início da saída do decodificador. Há tokens de idioma no vocabulário, e por isso o Whisper **identifica o idioma sozinho**. Informar o idioma quando você sabe qual é ajuda, mas **não é obrigatório**.

Whisper: tamanhos e versões

Tamanho	Parâmetros (aprox.)	Versão só inglês (.en)?
tiny	39 milhões	sim
base	74 milhões	sim

Tamanho	Parâmetros (aprox.)	Versão só inglês (.en)?
small	244 milhões	sim
medium	769 milhões	sim
large	1.550 milhões	**não**
turbo	809 milhões	não

Quanto maior o modelo, em geral **mais preciso**, mas também **mais memória de vídeo** e **mais tempo de inferência** (tempo para transcrever).

Versões .en. Existem **só nos tamanhos menores** (tiny a medium) e **só servem para inglês**. O large não tem versão .en. Para transcrever português, usa-se o modelo **multilíngue**.

Turbo. É uma versão **otimizada do large-v3**: teve o **decodificador encolhido** (menos camadas), por isso tem **menos parâmetros** e é **bem mais rápido**. O preço: **não foi treinado para tradução de fala**. Serve para transcrever português, não para traduzir.

large-v2 x large-v3. Não é só o nome que muda. O large-v3 mudou o **pré-processamento** (128 bandas Mel em vez de 80) e o **treinamento**. Trocar uma versão pela outra exige ajustar o extrator de características e testar de novo.

Pseudorrótulos no large-v3. O large-v3 foi treinado com cerca de **1 milhão de horas** de áudio com rótulos fracos e cerca de **4 milhões de horas** de áudio **pseudorrotulado**, isto é, transcrito automaticamente por uma versão anterior do próprio modelo (o **large-v2**). Isso amplia o volume de dados **sem exigir transcrição humana**. Não é verdade que o large-v3 foi treinado só com áudio revisado por pessoas.

Whisper: limitações e ajustes

O próprio **cartão do modelo** (model card) do large-v3 avisa:

- as previsões podem conter **texto que não foi falado** no áudio: são as **alucinações**;
- por ser **sequência a sequência**, o modelo é **propenso a repetições**;
- técnicas como **busca em feixe** (beam search) e **escalonamento de temperatura reduzem** esses problemas, mas **não os eliminam**. A revisão humana continua necessária em transcrição oficial.

Taxa de compressão como alarme. Em áudios longos, o Whisper às vezes entra em laço e repete a mesma frase. Texto muito repetitivo é **facilmente comprimível** (um compactador o reduz muito). Por isso, uma **taxa de compressão elevada** serve de **sinal de falha**: o sistema **decodifica o trecho de novo com temperatura maior**, ou seja, com mais variação na escolha das palavras, para sair da repetição.

Ajuste fino (fine-tuning). É treinar um pouco mais um modelo já pronto com dados de um idioma ou de um domínio específico. Como o Whisper **já chega pré-treinado**, o ajuste pode melhorar o desempenho naquele contexto **mesmo com pouco áudio transcrito**. O tutorial da Hugging Face mostra que ajustar um Whisper pequeno com **poucas horas** de fala de um idioma **pouco representado** no pré-treino **reduz de forma expressiva** a taxa de erro.

No tutorial:

- o **tokenizador não precisa ser refeito**: ele já foi construído com textos de dezenas de idiomas; basta informar o **idioma** e a **tarefa** (transcrever);
- o áudio **precisa ser reamostrado para 16 kHz**; o extrator de características **não se adapta sozinho** a outras taxas.

Normalização antes da WER. Para comparar transcrições, o artigo do Whisper normaliza o texto antes de contar erros. As arrumações mais elaboradas (números por extenso viram algarismos, contrações são expandidas, grafias britânicas e americanas são unificadas) valem **para o inglês**. Para os **outros idiomas**, como o português, o normalizador básico só **troca pontuação por espaço**, **passa para minúsculas** e **ajeita os espaços**.

wav2vec 2.0: aprender ouvindo, sem legenda

O **wav2vec 2.0** (Baevski e colaboradores, Meta) inverteu a lógica tradicional. Em vez de precisar de muito áudio transcrito, ele aprende primeiro com **áudio sem transcrição**:

1. **Pré-treino autossupervisionado.** O modelo ouve muito áudio sem texto. Parte da entrada é **mascarada** (tapada) no espaço latente, e o modelo resolve uma **tarefa contrastiva**: descobrir, entre várias opções, qual era a representação **quantizada** correta do trecho tapado. É como ouvir uma frase com um "piiii" no meio e adivinhar o som escondido.
2. **Ajuste fino.** Depois, o modelo é ajustado com um **volume pequeno de áudio transcrito** para aprender a escrever o que ouve. No artigo, até **dez minutos** de fala transcrita já deram resultado razoável.

> **Atenção:** o pré-treino sozinho **não** produz transcrições. O ajuste fino com fala transcrita continua necessário. A vantagem é precisar de **pouca** transcrição, e não de nenhuma. E o ponto forte é **usar** áudio sem rótulo, não dispensá-lo.

XLSR-53 e XLS-R: wav2vec em muitos idiomas

XLSR-53 (Conneau e colaboradores) é um wav2vec 2.0 pré-treinado com áudio de **53 idiomas**. É um **modelo-base**: precisa de **ajuste fino com fala transcrita** para fazer reconhecimento de voz e exige áudio a **16 kHz**. O estudo mostrou que pré-treinar um único modelo com muitos idiomas **ajuda**, principalmente os idiomas **com poucos dados**: uma língua aproveita o que o modelo aprendeu com as outras.

XLS-R (Babu e colaboradores) é a família seguinte, também baseada no wav2vec 2.0, pré-treinada de forma autossupervisionada com áudio de **mais de uma centena de idiomas** e oferecida em **vários tamanhos**. Os checkpoints publicados na Hugging Face são **apenas a base**: **não transcrevem** sem ajuste fino. São ponto de partida para ajustar a idiomas como o português.

Como se ajusta o XLS-R (tutorial da Hugging Face):

- adiciona-se uma **camada linear** sobre o modelo pré-treinado;
- o treino usa a **perda CTC** (Connectionist Temporal Classification), que dispensa marcar o tempo exato de cada letra ou palavra;

- o **codificador de características** (a parte que lê o som bruto) é **congelado**;
- o áudio é **reamostrado para 16 kHz**;
- o modelo escreve **letra por letra**: o vocabulário de saída tem **pouco mais de trinta símbolos** (letras e marcas especiais), e não uma entrada para cada palavra do idioma.

Modelo de linguagem na decodificação CTC. O CTC decide cada pedaço do som quase isoladamente, sem pensar no contexto. Um **modelo de linguagem** na decodificação ajuda a escolher palavras que fazem sentido juntas e **pode reduzir a WER**. Um modelo XLSR-53 ajustado ao português, por exemplo, erra menos quando decodificado com modelo de linguagem.

Corpora de fala em português

Corpus é uma coleção organizada de dados (aqui, áudios com transcrições) usada para treinar e testar modelos.

CORAA ASR (Candido Junior e colaboradores). Criado em parte para suprir a **escassez de conjuntos públicos de português brasileiro com fala espontânea**. Tem fala **espontânea e preparada** (não só leitura), e os pares de áudio e transcrição passaram por **validação manual**. O modelo de referência divulgado com ele, um **wav2vec 2.0 XLSR-53 ajustado ao corpus**, obteve **WER de 24,18%** no teste do CORAA e **20,08%** no teste do Common Voice em português. A licença é **CC BY-NC-ND 4.0**: **proíbe uso comercial** (NC) e **obras derivadas** (ND). Antes de usar um conjunto de dados num sistema real, leia a licença.

Common Voice (Mozilla; Ardila e colaboradores). Corpus **multilíngue** construído por **colaboração coletiva**: **voluntários gravam sentenças** prontas, lendo em voz alta, e **outros voluntários validam** as gravações. Cresce com a participação de milhares de pessoas. É **fala lida**, não espontânea, e não vem de sessões de órgãos públicos; o vocabulário parlamentar fica quase todo de fora. **Só parte das horas gravadas chega a ser validada**; para treino e avaliação, usa-se de preferência o que foi validado.

Multilingual LibriSpeech (MLS) (Pratap e colaboradores). Reúne **fala lida de audiolivros** em vários idiomas, **inclusive o português**. A quantidade de horas em português é **muito menor que a do inglês**, um desequilíbrio comum em corpora multilíngues. Não tem entrevistas nem debates, interrupções ou vozes sobrepostas; não é o melhor teste para transcrição de debates.

Domínio de treino x domínio real. Um modelo ajustado com fala lida pode ter **erro baixo** no teste do **mesmo corpus** e **bem mais alto** em áudio de **outro domínio** (por exemplo, uma sessão parlamentar). O desempenho medido dentro do domínio de treino **não se transfere automaticamente**. Teste sempre com o áudio real.

WER e CER: como medir o erro

WER (Word Error Rate, taxa de erro de palavras). Conta-se:

- **S** = substituições (palavra trocada);
- **D** = remoções (palavra esquecida);
- **I** = inserções (palavra inventada).

Depois divide-se pelo **N = número de palavras da transcrição de referência** (o texto correto):

WER = (S + D + I) / N

Como as inserções também contam e o divisor é a referência, **a WER pode passar de 100%** quando o sistema inventa muito texto.

> **Exemplo:** referência: "a sessão foi aberta" (4 palavras). O sistema escreve "a sessão foi foi aberta agora hoje". São 3 inserções e nenhuma outra falha: WER = 3/4 = 75%. Se tivesse inventado 5 palavras, seria 125%.

CER (Character Error Rate, taxa de erro de caracteres). Mesma conta, **letra por letra**. É útil em **avaliações multilíngues**, porque a separação em palavras não funciona igual em todos os idiomas. Também **pode superar 1** (100%) com muitas inserções.

> **Atenção:** WER e CER dizem **quanto** o sistema erra, mas **não discriminam os tipos de erro nem as causas**. Para saber se os erros estão em nomes, números ou siglas, é preciso **examinar exemplos** manualmente.

Modelos de texto em português: Sabiá e BERTimbau

Sabiá (Pires e colaboradores, 2023). Os autores **não treinaram do zero**: pegaram modelos de linguagem **já existentes** e **continuaram o pré-treinamento com textos em português**, gastando **fração pequena do custo** do treino original. Conclusões:

- o pré-treino no idioma-alvo **melhora o desempenho** em tarefas em português, **mesmo em modelos que já tinham sido amplamente treinados** em dados diversos;
- boa parte do ganho vem do **conhecimento específico do domínio** (assuntos, cultura e contexto do país), e **não apenas de sutilezas linguísticas**.

BERTimbau (Souza, Nogueira e Lotufo, BRACIS 2020). É um modelo **BERT para o português brasileiro**: **lê texto, não áudio**. Serve para tarefas como **reconhecer nomes em frases** (entidades nomeadas) e **comparar sentidos** entre frases. **Não é modelo de reconhecimento de fala**, não foi treinado com o CORAA nem transcreve sessões. Pode ajudar **depois** da transcrição, trabalhando o texto.

Quadros para memorizar

Whisper em números

Ponto	Valor
Dados de treino (artigo)	~680 mil horas, supervisão fraca
Parte em outros idiomas	~117 mil horas, 96 idiomas
Taxa de amostragem	16 kHz
Janela	30 segundos
Entrada	espectrograma log-Mel (80 canais; 128 no large-v3)

Ponto	Valor
Arquitetura	Transformer codificador-decodificador
Tamanhos	tiny 39 M, base, small, medium, large 1.550 M
Versões .en	só tiny a medium; large não tem
Turbo	large-v3 com decodificador encolhido; mais rápido; não traduz
large-v3	~1 milhão de horas fracas + ~4 milhões pseudorrotuladas pelo large-v2

Modelos e o que precisam

Modelo	Tipo	Precisa de ajuste fino para transcrever?
Whisper	fala para texto, multilíngue, multitarefa	não (ajuste melhora domínios específicos)
wav2vec 2.0	fala, autossupervisionado	sim, com pouca fala transcrita
XLSR-53	wav2vec 2.0 em 53 idiomas	sim
XLS-R	wav2vec 2.0 em mais de 100 idiomas, vários tamanhos	sim
Sabiá	texto, LLM com pré-treino continuado em português	(não é de fala)
BERTimbau	texto, BERT em português	(não é de fala)

Corpora de fala

Corpus	Tipo de fala	Detalhe que cai
CORAA ASR	espontânea e preparada, PT-BR	validação manual; CC BY-NC-ND 4.0; baseline 24,18% (CORAA) e 20,08% (Common Voice)
Common Voice	lida, voluntários	colaboração coletiva; validação por outros voluntários; só parte validada
Multilingual LibriSpeech	lida, audiolivros	muito mais inglês que português

Métricas

Métrica	Fórmula	Pode passar de 100%?
WER	(S + D + I) / palavras da referência	sim
CER	mesma conta, por caractere	sim

Conceitos e autores que caem

- **Supervisão fraca** (Radford et al., Whisper): treino com transcrições da internet, não revisadas uma a uma.

- **Pseudorrotulagem**: usar um modelo para transcrever áudio sem legenda e treinar outro modelo com esse texto.
- **Espectrograma log-Mel**: energia do som por faixa de frequência ao longo do tempo, na escala Mel, próxima da audição humana.
- **Aprendizado autossupervisionado** (Baevski et al., wav2vec 2.0): o próprio dado gera a tarefa (mascarar e adivinhar), sem rótulo humano.
- **Tarefa contrastiva sobre representações quantizadas**: escolher, entre candidatos, a representação certa do trecho mascarado.
- **Perda CTC**: forma de treinar reconhecimento de fala sem alinhar cada letra a um instante do áudio.
- **Ajuste fino**: treino extra, com poucos dados, de um modelo já pré-treinado.
- **Pré-treinamento continuado** (Pires et al., Sabiá): seguir treinando um modelo pronto com textos do idioma-alvo.
- **Conneau et al.**: XLSR; aprender com muitas línguas ajuda as de poucos dados.
- **Babu et al.**: XLS-R; mais de cem idiomas, vários tamanhos.
- **Candido Junior et al.**: CORAA. **Ardila et al.**: Common Voice. **Pratap et al.**: MLS.
- **Souza, Nogueira e Lotufo**: BERTimbau.

Pegadinhas da banca

- **"Modelos de muitos idiomas, ditos monolíngues, superam necessariamente os ajustados em português."** Errado: são multilíngues, e o ajustado em português costuma ganhar no português brasileiro.
- **"Modelo ajustado em português fica melhor em inglês técnico."** Errado: a especialização vale para o português.
- **"A maior parte das 680 mil horas do Whisper está nos 96 outros idiomas."** Errado: são só cerca de 117 mil horas.
- **"large-v2 e large-v3 diferem só no nome."** Errado: mudaram treino e pré-processamento.
- **"Todos os tamanhos têm versão .en, inclusive o large, e ela é a escolha para português."** Errado: .en só nos menores e só para inglês.
- **"O turbo tem os mesmos parâmetros e velocidade do large, só com mais dados."** Errado: é menor (decodificador encolhido) e mais rápido; e não traduz.
- **"O Whisper precisa de módulo externo para identificar o idioma e o usuário sempre deve informá-lo."** Errado: identifica sozinho, por tokens especiais.
- **"O large-v3 foi treinado só com áudio transcrito por humanos."** Errado: usou pseudorrótulos do large-v2.
- **"Busca em feixe e temperatura eliminam alucinações e dispensam revisão."** Errado: só reduzem.
- **"O tokenizador do Whisper tem de ser refeito para cada idioma."** Errado: já é multilíngue.

- **"No ajuste fino, mantenha a taxa original do áudio; o extrator se adapta."** Errado: é preciso reamostrar para 16 kHz.
- **"O wav2vec 2.0 dispensa ajuste fino."** Errado: precisa de ajuste com pouca fala transcrita.
- **"O wav2vec 2.0 dispensa áudio sem rótulos."** Errado: é justamente dele que aprende.
- **"No XLSR, muitos idiomas prejudicam as línguas com poucos dados."** Errado: ajudam.
- **"Os checkpoints do XLS-R já transcrevem sem ajuste."** Errado: são só a base.
- **"No tutorial do XLS-R, cada palavra do idioma tem um índice."** Errado: o vocabulário é de caracteres, pouco mais de trinta símbolos.
- **"O CORAA é só fala lida, para complementar corpora espontâneos já abundantes."** Errado: nasceu porque faltava fala espontânea.
- **"O CORAA é CC BY e permite venda de modelos."** Errado: é CC BY-NC-ND 4.0.
- **"O Common Voice é fala espontânea de sessões de órgãos públicos."** Errado: é fala lida por voluntários.
- **"O MLS tem entrevistas espontâneas em oito idiomas e é o melhor teste para debates."** Errado: são audiolivros lidos.
- **"Modelo de linguagem não reduz a WER de um reconhecedor CTC."** Errado: pode reduzir.
- **"A WER divide pelo número de palavras da hipótese e nunca passa de 100%."** Errado: divide pela referência e pode passar.
- **"WER e CER mostram os tipos e causas de erro; dispensa-se o exame manual."** Errado: é preciso olhar exemplos.
- **"O Sabiá foi treinado do zero só com português."** Errado: partiu de modelos existentes.
- **"O BERTimbau é modelo de ASR treinado no CORAA para sessões parlamentares."** Errado: é modelo de texto.
- **"Para outros idiomas, o normalizador do Whisper converte números por extenso e expande contrações."** Errado: isso é do inglês; nos demais, só pontuação, minúsculas e espaços.

Itens comentados

- **Item:** Modelos treinados ou ajustados predominantemente em português tendem a ter melhor desempenho em vocabulário e construções próprias do português brasileiro do que modelos multilíngues. **Certo.** A especialização dá vantagem no idioma que o modelo mais estudou.
- **Item:** Das 680 mil horas de áudio usadas no treinamento do Whisper, a maior parte corresponde a fala em 96 outros idiomas além do inglês, o que explica o fato de o modelo ser descrito como essencialmente multilíngue. **Errado.** Só cerca de 117 mil horas são de outros idiomas; o grosso é inglês.
- **Item:** O Whisper é um modelo Transformer do tipo codificador-decodificador que processa o áudio reamostrado a 16 kHz em segmentos de 30 segundos, convertidos em espectrogramas log-Mel antes de entrarem no codificador. **Certo.** Descreve exatamente a entrada e a arquitetura do Whisper.

- **Item:** O modelo turbo do Whisper é uma versão otimizada do large-v3 que acelera a transcrição, mas não foi treinado para a tarefa de tradução de fala. **Certo.** Mais rápido, só transcreve.
- **Item:** Todos os tamanhos do Whisper têm uma versão exclusiva para inglês, com sufixo .en, inclusive o large, o que torna essas versões a escolha padrão para transcrever sessões em português. **Errado.** O large não tem .en, e as versões .en não servem para português.
- **Item:** Na transcrição de áudios longos pelo Whisper, um texto muito repetitivo é facilmente comprimível, razão pela qual uma taxa de compressão elevada serve de sinal de falha, levando o sistema a decodificar de novo o trecho com temperatura maior. **Certo.** Compressão alta denuncia repetição; refaz-se com mais temperatura.
- **Item:** A principal ideia do wav2vec 2.0 é dispensar qualquer etapa de ajuste fino: depois de pré-treinado apenas com áudio sem rótulos, o modelo já produz transcrições utilizáveis, sem precisar de um único exemplo de fala transcrita. **Errado.** O ajuste fino com pouca fala transcrita continua necessário.
- **Item:** O CORAA ASR é distribuído sob licença Creative Commons CC BY, que autoriza uso comercial e a criação de obras derivadas, razão pela qual os modelos treinados com ele podem ser livremente vendidos. **Errado.** A licença é CC BY-NC-ND 4.0, que proíbe uso comercial e derivadas.
- **Item:** O Common Voice é composto majoritariamente por fala espontânea registrada em sessões de órgãos públicos, o que o torna representativo do vocabulário parlamentar brasileiro. **Errado.** É fala lida por voluntários.
- **Item:** Na taxa de erro de palavras (WER), o total de substituições, remoções e inserções é dividido pelo número de palavras da hipótese gerada pelo sistema, e não pelo da transcrição de referência, razão pela qual a métrica nunca ultrapassa 100%. **Errado.** Divide-se pela referência, e a WER pode passar de 100%.
- **Item:** Os modelos Sabiá descritos no artigo de 2023 foram treinados do zero, exclusivamente com textos em português, sem partir de modelos pré-existentes, o que explicaria o desempenho superior aos modelos multilíngues. **Errado.** Partiram de modelos prontos e receberam pré-treino continuado em português.
- **Item:** O BERTimbau é um modelo de reconhecimento automático de fala para o português brasileiro, treinado com áudio do corpus CORAA e destinado a transcrever sessões parlamentares. **Errado.** O BERTimbau é modelo de texto (BERT), não de fala.

Resumo para revisar

- Multilíngue = muitos idiomas; especializado = foco em um. Escolha pondera abrangência e especialização.
- Ajustado em português tende a ganhar no português brasileiro (não no inglês).
- Whisper: 680 mil horas, supervisão fraca (transcrições da internet); só ~117 mil horas em 96 outros idiomas.

- Whisper: Transformer codificador-decodificador; 16 kHz; 30 s; log-Mel (escala próxima do ouvido).
- Multitarefa por tokens especiais: transcreve, traduz, identifica idioma, detecta voz. Idioma informado é opcional.
- Tamanhos: tiny (39 M) a large (1.550 M); maior = mais memória e mais lento.
- .en só nos menores e só para inglês. Turbo = large-v3 enxuto, rápido, sem tradução.
- large-v3: 128 bandas Mel, pseudorrótulos do large-v2; trocar versão exige ajustes.
- Alucinações e repetições: beam search e temperatura reduzem, não eliminam. Compressão alta = refazer com temperatura maior.
- Ajuste fino funciona com pouco áudio; tokenizador não muda; reamostrar para 16 kHz.
- Normalizador do Whisper para não inglês: pontuação vira espaço, minúsculas, espaços ajustados.
- wav2vec 2.0: mascaramento + tarefa contrastiva sobre representações quantizadas; depois ajuste com pouca fala transcrita.
- XLSR-53: 53 idiomas, base, precisa de ajuste, 16 kHz; muitos idiomas ajudam os de poucos dados.
- XLS-R: mais de 100 idiomas, vários tamanhos; checkpoints não transcrevem sem ajuste. Tutorial: camada linear, CTC, codificador congelado, 16 kHz, vocabulário de caracteres.
- Modelo de linguagem na decodificação CTC pode reduzir a WER.
- CORAA: fala espontânea e preparada, validação manual, CC BY-NC-ND 4.0, WER 24,18% (CORAA) e 20,08% (Common Voice).
- Common Voice: voluntários leem e validam; só parte validada; fala lida.
- MLS: audiolivros; pouco português perto do inglês.
- Resultado no domínio de treino não se transfere automaticamente; teste com áudio real.
- WER = (S + D + I) / palavras da referência; pode passar de 100%. CER = mesma conta por caractere.
- WER e CER não explicam a causa dos erros; examine exemplos.
- Sabiá: pré-treino continuado em português, custo pequeno; ganho vem muito do conhecimento do domínio.
- BERTimbau: BERT de texto em português; não transcreve áudio.

TEMA 18 DE 20

LGPD em sistemas de transcrição e IA

57 perguntas no app · Proteção e ética

O que cai

O edital pede "LGPD e proteção de dados em sistemas de transcrição e IA" (item 4.1). Aqui a Lei Geral de Proteção de Dados (Lei nº 13.709/2018) é aplicada a um cenário concreto: a Câmara grava sessões e audiências, transcreve com IA, guarda o texto e, às vezes, contrata empresas e serviços em nuvem. As perguntas se concentram em:

- **Conceitos**: dado pessoal, dado sensível (a voz como biometria), tratamento, anonimização x pseudonimização, controlador x operador x encarregado.
- **Bases legais**: consentimento é só uma delas; políticas públicas e obrigação legal dispensam consentimento; legítimo interesse **não** serve para dado sensível; dado de acesso público continua protegido.
- **Princípios**: finalidade, necessidade, livre acesso x transparência, não discriminação.
- **Poder Público**: art. 23 (publicidade das hipóteses, encarregado), compartilhamento e repasse a entidades privadas (arts. 26 e 27), papel da ANPD (arts. 29 a 32).
- **Decisões automatizadas** (art. 20), **término e eliminação** (arts. 15, 16 e 18), **segurança e incidentes** (arts. 46 a 48 e regulamento da ANPD), **transferência internacional** (art. 33), **sanções** e **responsabilidade do operador**.

Números que a banca troca: multa de **2%** limitada a **R$ 50 milhões**; incidente comunicado em **3 dias úteis**; registro guardado por **5 anos**.

Entenda o tema

A voz e a transcrição são dados pessoais

Dado pessoal é a informação relacionada a **pessoa natural identificada ou identificável**. A gravação da voz de um Deputado e o texto transcrito com o nome de quem falou levam a uma pessoa real. Logo, são dados pessoais, e quem grava, transcreve e guarda precisa cumprir a LGPD, **inclusive no Poder Público**.

Tratamento é **toda operação** realizada com dados pessoais: coletar, receber, transmitir, processar, armazenar, eliminar e assim por diante. No caminho do áudio até o texto, **cada etapa é um tratamento**: a coleta do áudio, o envio a um serviço de transcrição, o armazenamento do texto e até a eliminação posterior dos arquivos.

Dado público continua sendo dado pessoal. As sessões do Plenário são públicas, mas isso **não tira** os dados dos oradores do alcance da LGPD. O que a lei diz é que o tratamento de dados de

acesso público deve considerar a **finalidade**, a **boa-fé** e o **interesse público** que justificaram a divulgação (art. 7º, § 3º). Se o dado for usado para nova finalidade, é preciso propósito legítimo e específico e respeito aos direitos do titular (§ 7º). E a dispensa de consentimento **não dispensa** os demais deveres da lei (§ 6º).

> **Exemplo:** a Câmara publica a transcrição de uma audiência pública. Uma empresa baixa esse material e monta um cadastro de "cidadãos críticos ao governo" para vender. O dado era público, mas o novo uso não combina com a finalidade da divulgação, não é de boa-fé e fere o interesse público.

Dado sensível: a voz como biometria

Dado pessoal sensível é o dado sobre: origem racial ou étnica, **convicção religiosa**, **opinião política**, filiação a sindicato ou a organização religiosa, filosófica ou política, dado referente à **saúde** ou à **vida sexual**, dado **genético** ou **biométrico**, quando vinculado a uma pessoa natural (art. 5º, II).

O que torna um dado sensível é o **assunto** dele, pelo risco de discriminação. **Não** é o fato de ser tratado por IA. Nome e CPF continuam dados pessoais **comuns**, mesmo dentro de um sistema de inteligência artificial.

Dois pontos ligam isso à transcrição:

- **Manifestações em audiências.** Um cidadão que, numa audiência pública, fala da sua religião ou da sua posição política revela dado sensível. A transcrição exige cuidado especial.
- **Biometria de voz.** A ANPD, no estudo sobre biometria (Radar Tecnológico nº 2), menciona a **voz** entre as características fisiológicas ou comportamentais que podem reconhecer um indivíduo. Um sistema que **identifica automaticamente os parlamentares pelas características da voz** trata **dado biométrico**, ou seja, **sensível**.

Bases legais: quando se pode tratar dados

A lei lista as **hipóteses** (bases legais) que autorizam o tratamento. O **consentimento** é só **uma** delas.

Dados comuns (art. 7º). Entre as hipóteses: consentimento; cumprimento de obrigação legal ou regulatória; **pela administração pública, para execução de políticas públicas previstas em leis e regulamentos**; estudos por órgão de pesquisa; execução de contrato; exercício regular de direitos; proteção da vida; tutela da saúde; **legítimo interesse** do controlador ou de terceiro; proteção do crédito. Por isso, o tratamento pelo poder público para executar políticas públicas previstas em lei **dispensa o consentimento**.

Dados sensíveis (art. 11). A lista é **outra, mais restrita**:

- **com consentimento** dado de forma **específica e destacada**, para **finalidades específicas**;
- **sem consentimento**, só quando **indispensável** para: obrigação legal ou regulatória; tratamento compartilhado para políticas públicas previstas em leis ou regulamentos; estudos por órgão de pesquisa; exercício regular de direitos; proteção da vida; tutela da saúde; prevenção à fraude e segurança do titular em identificação e autenticação de cadastro.

> **Atenção:** o **legítimo interesse não está** na lista do art. 11. Um sistema de biometria de voz não pode se apoiar nele para dispensar consentimento. Também não basta a sessão ser pública: o tratamento de biometria vocal precisa de base legal do art. 11 e deve respeitar finalidade e necessidade.

Quando órgão público trata dado sensível **sem consentimento** com base em **obrigação legal** ou **políticas públicas**, ele **deve dar publicidade** a essa dispensa de consentimento (art. 11, § 2º, c/c art. 23, I). A transparência é a contrapartida; o interesse público não dispensa a publicidade.

O consentimento

Quando a base legal for o consentimento (art. 8º):

- deve ser dado **por escrito** ou por outro meio que demonstre a vontade do titular; se por escrito, em **cláusula destacada**;
- deve se referir a **finalidades determinadas**: **autorizações genéricas são nulas**, mesmo em cláusula destacada e mesmo que possam ser revogadas depois;
- cabe ao **controlador** o **ônus da prova** de que obteve o consentimento corretamente;
- é **vedado** tratar dados mediante **vício de consentimento** (pressão, engano);
- pode ser **revogado a qualquer momento**, por manifestação expressa, em **procedimento gratuito e facilitado**, sem ir à Justiça. O que foi feito antes da revogação **continua válido** (é ratificado), enquanto não houver pedido de eliminação.

Princípios que mais caem

O art. 6º manda observar a **boa-fé** e dez princípios. Os cobrados no tema:

- **Finalidade**: propósitos **legítimos, específicos, explícitos e informados** ao titular, sem tratamento posterior **incompatível** com essas finalidades.
- **Necessidade**: limitar o tratamento ao **mínimo necessário**. Coletar "o máximo possível" porque um dia pode servir para treinar IA viola a lei.
- **Livre acesso**: consulta **facilitada e gratuita** sobre a forma e a duração do tratamento e sobre a **integralidade** dos dados.
- **Transparência**: informações **claras, precisas e facilmente acessíveis** sobre a realização do tratamento e sobre **os agentes de tratamento**.
- **Não discriminação**: **impossibilidade** de tratamento para fins **discriminatórios ilícitos ou abusivos**. Alcança sistemas automatizados que classifiquem pessoas de forma enviesada.

> **Pegadinha:** a banca põe a definição do **livre acesso** (consulta gratuita da forma, duração e integralidade dos dados) com o nome de **transparência**. Integralidade dos dados = livre acesso.

Anonimização x pseudonimização

Dado anonimizado é o que não permite identificar o titular, considerando meios técnicos **razoáveis** disponíveis na ocasião. Ele **não é dado pessoal** para a LGPD, **salvo** se a anonimização for **revertida**

usando exclusivamente meios próprios, ou se puder ser revertida **com esforços razoáveis** (art. 12). O que é "razoável" considera custo e tempo, conforme a tecnologia disponível.

Pseudonimização é o tratamento pelo qual o dado perde a possibilidade de associação a um indivíduo, **senão pelo uso de informação adicional mantida separadamente** pelo controlador em ambiente controlado e seguro (art. 13, § 4º). Como a "chave" existe, dá para voltar à pessoa. Por isso o dado pseudonimizado **continua sendo dado pessoal**.

> **Exemplo:** a Câmara troca os nomes dos cidadãos ouvidos em audiências por códigos (Cidadão 017, Cidadão 018) e guarda, em arquivo separado e seguro, a tabela que liga cada código a um nome. Isso é pseudonimização. Os dados **continuam** sob a LGPD.

	Anonimização	Pseudonimização
Dá para voltar à pessoa?	não, com meios razoáveis	sim, com a informação guardada à parte
É dado pessoal?	não (salvo reversão)	sim
Está na LGPD?	em regra, fora	dentro

Controlador, operador e encarregado

- **Controlador**: a quem **competem as decisões** referentes ao tratamento (define finalidades e meios).
- **Operador**: quem **realiza o tratamento em nome do controlador**, seguindo suas instruções.
- **Encarregado**: pessoa indicada para ser o **canal de comunicação** entre controlador, titulares e ANPD. **Não decide** sobre o tratamento.

> **Exemplo:** a Câmara contrata uma empresa para operar, em seu nome, a transcrição automática das sessões, e a empresa segue exatamente as instruções recebidas. A **Câmara é controladora**; a **empresa é operadora**. Cabe à Câmara **verificar** se a empresa cumpre as instruções e as normas (art. 39).

Responsabilidade do operador. O operador **não está imune**. Ele **responde solidariamente** pelos danos quando **descumprir a legislação** ou **não seguir as instruções lícitas** do controlador; nesse caso, **equipara-se ao controlador** (art. 42, § 1º, I).

Atividades do encarregado (art. 41, § 2º): aceitar reclamações e comunicações dos titulares, prestar esclarecimentos e adotar providências; receber comunicações da ANPD; **orientar funcionários e contratados** sobre práticas de proteção de dados; executar outras atribuições do controlador. A **identidade e o contato** do encarregado devem ser **divulgados publicamente**, de forma clara e objetiva, **preferencialmente no sítio eletrônico** do controlador.

Decisões automatizadas (art. 20)

O titular pode **solicitar a revisão** de decisões tomadas **unicamente com base em tratamento automatizado** que afetem seus interesses, inclusive as que definem seu **perfil pessoal, profissional, de consumo e de crédito** ou aspectos da personalidade.

O texto em vigor **não exige** que a revisão seja feita por **pessoa natural**. A redação original falava em revisão por pessoa natural, mas a Lei nº 13.853/2019 mudou o texto, e o dispositivo que trazia a exigência foi **vetado**, com o veto mantido pelo Congresso.

O controlador deve fornecer, **sempre que solicitadas**, informações claras e adequadas sobre os **critérios e procedimentos** da decisão automatizada, observados os **segredos comercial e industrial**. Se negar a informação com base nesses segredos, a **ANPD pode fazer auditoria** para verificar aspectos discriminatórios.

Tratamento pelo Poder Público

Art. 23. O tratamento pelas pessoas jurídicas de direito público deve atender à sua **finalidade pública**, na persecução do **interesse público**, para executar **competências legais** ou cumprir **atribuições legais** do serviço público, desde que:

- sejam **informadas as hipóteses** de tratamento, com informações claras e atualizadas sobre a previsão legal, a finalidade, os procedimentos e as práticas, **em veículos de fácil acesso, preferencialmente nos sítios eletrônicos**. É **divulgação ativa**: o órgão não espera alguém pedir;
- seja **indicado um encarregado**.

Outros pontos do art. 23:

- a LGPD **não dispensa** os órgãos de instituir as **autoridades da Lei de Acesso à Informação**; o encarregado **não as substitui** (§ 2º);
- os **prazos e procedimentos** para o titular exercer seus direitos perante o Poder Público seguem a legislação específica, em especial a **Lei do Habeas Data**, a **Lei Geral do Processo Administrativo** (Lei 9.784/1999) e a **Lei de Acesso à Informação** (§ 3º).

Uso compartilhado (art. 26). O uso compartilhado de dados pelo Poder Público deve atender a **finalidades específicas** de execução de **políticas públicas** e **atribuição legal**, respeitados os **princípios** do art. 6º.

Repasse a entidades privadas. Em regra, é **vedado** ao Poder Público transferir a entidades privadas os dados de suas bases (art. 26, § 1º). As exceções: execução descentralizada de atividade pública; dados acessíveis publicamente; **previsão legal ou contratos, convênios ou instrumentos congêneres**; prevenção de fraudes ou proteção da segurança do titular. Os **contratos e convênios** que respaldam a transferência devem ser **comunicados à ANPD** (§ 2º). Não basta comunicar ao titular.

Art. 27. A comunicação ou o uso compartilhado de dados do Poder Público com pessoa de direito privado será **informado à ANPD** e dependerá de **consentimento**, **exceto**: nas hipóteses de dispensa de consentimento; nos casos de uso compartilhado com publicidade (art. 23, I); e nas exceções do art. 26, § 1º. Portanto, **não** depende "sempre" do consentimento.

Poderes da ANPD sobre o Poder Público:

- pedir, **a qualquer momento**, informações específicas sobre o âmbito e a natureza dos dados e outros detalhes, e emitir **parecer técnico complementar** (art. 29);
- em caso de infração por órgão público, **enviar informe** com medidas para fazer cessar a violação (art. 31);

- **solicitar a publicação de relatórios de impacto** e **sugerir padrões e boas práticas** (art. 32).

Relatório de impacto à proteção de dados (RIPD) é o documento do controlador que descreve os tratamentos que podem gerar riscos às liberdades civis e aos direitos fundamentais e as medidas para reduzir esses riscos. A ANPD pode determinar sua elaboração "**inclusive de dados sensíveis**" (art. 38). A palavra "inclusive" mostra que **não é só** para dados sensíveis.

Término do tratamento e eliminação

O tratamento **termina** quando (art. 15):

1. a **finalidade foi alcançada** ou os dados deixaram de ser necessários;
2. acaba o **período de tratamento**;
3. o **titular comunica**, inclusive revogando o consentimento, **resguardado o interesse público**;
4. a **ANPD determina**, por violação à lei.

Depois do término, os dados **são eliminados**, mas a lei **autoriza a conservação** para (art. 16):

- **cumprimento de obrigação legal ou regulatória**;
- estudo por órgão de pesquisa (anonimizando sempre que possível);
- transferência a terceiro, respeitada a lei;
- uso exclusivo do controlador, sem acesso de terceiro, com dados **anonimizados**.

O direito do titular de pedir a **eliminação** (art. 18, VI) vale para os dados tratados **com seu consentimento** e tem as **exceções do art. 16**. Dados que o órgão é obrigado por lei a guardar não são apagados só porque o titular pediu.

Segurança e incidentes

Os agentes de tratamento devem adotar **medidas de segurança, técnicas e administrativas**, contra acessos não autorizados e situações acidentais ou ilícitas de destruição, perda, alteração ou comunicação (art. 46). Essas medidas valem **desde a fase de concepção** do produto ou serviço **até a sua execução** (§ 2º). Os sistemas devem ser **estruturados** para atender à segurança e às boas práticas (art. 49). É a ideia de **privacidade desde a concepção**: segurança não se acrescenta depois.

O dever de segurança alcança **qualquer pessoa que intervenha** em uma das fases do tratamento e continua **mesmo após o seu término** (art. 47).

Incidente de segurança (por exemplo, um vazamento de áudios). Se puder acarretar **risco ou dano relevante**, o controlador **comunica à ANPD e ao titular** (art. 48). A comunicação menciona, no mínimo: a natureza dos dados afetados; os titulares envolvidos; as medidas técnicas e de segurança usadas; os riscos; os motivos da demora, se não foi imediata; e as medidas para reverter ou mitigar os efeitos.

No **juízo de gravidade**, a ANPD avalia se foram adotadas medidas que tornem os dados **ininteligíveis** para terceiros não autorizados, como a **criptografia** (§ 3º). Isso **conta** e pode reduzir a gravidade.

Regulamento de Comunicação de Incidente (Resolução CD/ANPD nº 15/2024):

- a comunicação deve ser feita em **3 dias úteis**, contados do **conhecimento**, pelo controlador, de que o incidente afetou dados pessoais. Não são 72 horas corridas desde a ocorrência;
- o controlador deve **registrar todo incidente**, inclusive os **não comunicados**, e guardar o registro por **no mínimo 5 anos**, contados da data do registro.

Transferência internacional

Transferência internacional é o envio de dados pessoais a país estrangeiro ou organismo internacional (art. 5º, XV). A LGPD **não proíbe**: ela **só permite nos casos listados** no art. 33, entre eles:

- país ou organismo com **grau de proteção adequado**;
- **garantias** oferecidas pelo controlador: cláusulas contratuais específicas, **cláusulas-padrão contratuais**, normas corporativas globais, selos e certificados;
- **autorização da ANPD**;
- execução de **política pública** ou atribuição legal, com publicidade;
- **consentimento específico e em destaque** do titular, com informação prévia do caráter internacional.

> **Atenção:** um órgão público **pode** usar serviço de transcrição em nuvem com servidores no exterior, **desde que** a transferência se encaixe numa das hipóteses do art. 33. O fato de a empresa ser **operadora contratada não libera** a transferência; continua sendo preciso uma hipótese legal.

Sanções

As sanções do art. 52 incluem: advertência; **multa simples de até 2% do faturamento** da pessoa jurídica **de direito privado**, grupo ou conglomerado no Brasil no último exercício, **limitada a R$ 50 milhões por infração**; multa diária (com o mesmo limite total); publicização da infração; bloqueio e eliminação dos dados; suspensões e proibições.

Para **órgãos públicos**, a lei permite aplicar **advertência, publicização, bloqueio, eliminação, suspensões e proibição** (art. 52, § 3º), **mas não as multas**.

As sanções só são aplicadas **após procedimento administrativo** que garanta a **ampla defesa** (art. 52, § 1º). Compete à ANPD fiscalizar e aplicar sanções **mediante processo administrativo que assegure o contraditório, a ampla defesa e o direito de recurso** (art. 55-J, IV). O poder de polícia não dispensa nada disso.

Quadros para memorizar

Quem é quem

Figura	Papel	Exemplo no cenário da Câmara
Titular	pessoa a quem os dados se referem	Deputado, cidadão ouvido em audiência

Figura	Papel	Exemplo no cenário da Câmara
Controlador	toma as decisões sobre o tratamento	a Câmara
Operador	trata em nome do controlador	empresa contratada de transcrição
Encarregado	canal com titulares e ANPD	servidor designado, com contato no site
ANPD	fiscaliza, regulamenta, sanciona	

Bases legais

	Dados comuns (art. 7º)	Dados sensíveis (art. 11)
Consentimento	sim	sim, específico e destacado, para finalidades específicas
Obrigação legal	sim	sim (indispensável)
Políticas públicas	sim	sim (tratamento compartilhado, indispensável)
Legítimo interesse	**sim**	**não**
Proteção da vida, saúde, exercício de direitos	sim	sim
Prevenção à fraude em autenticação	(não listada)	sim

Números

Ponto	Regra	Fonte
Multa simples	até 2% do faturamento, limite R$ 50 milhões por infração	art. 52, II
Multa a órgão público	não cabe	art. 52, § 3º
Comunicação de incidente	3 dias úteis do conhecimento	Res. CD/ANPD 15/2024
Registro de incidentes	todos, guardados por no mínimo 5 anos	Res. CD/ANPD 15/2024
Suspensões	até 6 meses, prorrogáveis por igual período	art. 52, X e XI

Princípios que a banca troca

Princípio	Palavra-chave
Finalidade	propósitos legítimos, específicos, explícitos e informados
Necessidade	mínimo necessário
Livre acesso	consulta facilitada e gratuita; integralidade dos dados
Transparência	informações claras sobre o tratamento e os agentes
Não discriminação	proibido fim discriminatório ilícito ou abusivo

Lei seca que cai

Base de tudo: a definição de dado pessoal e de dado sensível, com a biometria.

> **Lei seca:** Art. 5º, I - dado pessoal: informação relacionada a pessoa natural **identificada ou identificável**; II - dado pessoal sensível: dado pessoal sobre origem racial ou étnica, **convicção religiosa, opinião política**, filiação a sindicato ou a organização de caráter religioso, filosófico ou político, dado referente à saúde ou à vida sexual, dado genético ou **biométrico**, quando vinculado a uma pessoa natural;

Cada etapa do pipeline de áudio é tratamento.

> **Lei seca:** Art. 5º, X - tratamento: **toda operação** realizada com dados pessoais, como as que se referem a coleta, (...) transmissão, (...) processamento, arquivamento, armazenamento, **eliminação** (...);

Dado público continua protegido.

> **Lei seca:** Art. 7º, § 3º O tratamento de dados pessoais cujo acesso é público deve considerar a **finalidade**, a **boa-fé** e o **interesse público** que justificaram sua disponibilização.

Base do poder público sem consentimento.

> **Lei seca:** Art. 7º, III - pela administração pública, para o tratamento e uso compartilhado de dados necessários à **execução de políticas públicas previstas em leis e regulamentos** (...);

Consentimento genérico é nulo; revogação gratuita.

> **Lei seca:** Art. 8º, § 4º O consentimento deverá referir-se a finalidades determinadas, e as **autorizações genéricas** para o tratamento de dados pessoais serão **nulas**. § 5º O consentimento pode ser revogado **a qualquer momento** mediante manifestação expressa do titular, por procedimento **gratuito e facilitado**, ratificados os tratamentos realizados sob amparo do consentimento anteriormente manifestado (...).

Dado sensível com consentimento qualificado.

> **Lei seca:** Art. 11. O tratamento de dados pessoais sensíveis somente poderá ocorrer nas seguintes hipóteses: I - quando o titular ou seu responsável legal consentir, de forma **específica e destacada**, para **finalidades específicas**;

Publicidade da dispensa pelo órgão público.

> **Lei seca:** Art. 11, § 2º Nos casos de aplicação do disposto nas alíneas "a" e "b" do inciso II do caput deste artigo pelos órgãos e pelas entidades públicas, **será dada publicidade** à referida dispensa de consentimento (...).

Anonimização e sua reversão.

> **Lei seca:** Art. 12. Os dados anonimizados **não serão considerados dados pessoais** para os fins desta Lei, **salvo** quando o processo de anonimização ao qual foram submetidos for revertido, utilizando exclusivamente meios próprios, ou quando, **com esforços razoáveis**, puder ser revertido.

Pseudonimização.

> **Lei seca:** Art. 13, § 4º (...) a pseudonimização é o tratamento por meio do qual um dado perde a possibilidade de associação, direta ou indireta, a um indivíduo, **senão pelo uso de informação adicional mantida separadamente** pelo controlador em ambiente controlado e seguro.

Revisão de decisão automatizada.

> **Lei seca:** Art. 20. O titular dos dados tem direito a **solicitar a revisão** de decisões tomadas **unicamente com base em tratamento automatizado** de dados pessoais que afetem seus interesses, incluídas as decisões destinadas a definir o seu perfil pessoal, profissional, de consumo e de crédito ou os aspectos de sua personalidade.

Divulgação ativa pelo órgão público.

> **Lei seca:** Art. 23, I - sejam informadas as hipóteses em que (...) realizam o tratamento de dados pessoais, fornecendo informações claras e atualizadas sobre a previsão legal, a finalidade, os procedimentos e as práticas (...), em **veículos de fácil acesso, preferencialmente em seus sítios eletrônicos**;

Repasse ao setor privado.

> **Lei seca:** Art. 26, § 1º **É vedado** ao Poder Público transferir a entidades privadas dados pessoais constantes de bases de dados a que tenha acesso, exceto: (...) § 2º Os contratos e convênios de que trata o § 1º deste artigo deverão ser **comunicados à autoridade nacional**.

Transferência internacional só nos casos da lei.

> **Lei seca:** Art. 33. A transferência internacional de dados pessoais **somente é permitida** nos seguintes casos: I - para países ou organismos internacionais que proporcionem grau de proteção de dados pessoais adequado (...);

Operador responde.

> **Lei seca:** Art. 42, § 1º, I - o operador **responde solidariamente** pelos danos causados pelo tratamento quando descumprir as obrigações da legislação de proteção de dados ou quando não tiver seguido as instruções lícitas do controlador, hipótese em que o operador **equipara-se ao controlador** (...);

Segurança desde o projeto.

> **Lei seca:** Art. 46, § 2º As medidas de que trata o caput deste artigo deverão ser observadas **desde a fase de concepção** do produto ou do serviço **até a sua execução**.

Criptografia pesa na gravidade.

> **Lei seca:** Art. 48, § 3º No juízo de gravidade do incidente, será avaliada eventual comprovação de que foram adotadas medidas técnicas adequadas que tornem os dados pessoais afetados **ininteligíveis** (...) para terceiros não autorizados a acessá-los.

Teto da multa.

> **Lei seca:** Art. 52, II - multa simples, de até **2%** (dois por cento) do faturamento da pessoa jurídica **de direito privado**, grupo ou conglomerado no Brasil no seu último exercício, excluídos os tributos, limitada, no total, a **R$ 50.000.000,00** (cinquenta milhões de reais) por infração;

Pegadinhas da banca

- **"O dado pseudonimizado deixa de ser dado pessoal."** Errado: só o anonimizado (irreversível com esforço razoável) sai da LGPD.
- **"Todo dado tratado por IA, inclusive nome e CPF, vira sensível."** Errado: o que define o sensível é o assunto.
- **"Sessões públicas: os dados dos oradores ficam fora da LGPD."** Errado: dado público continua pessoal; observam-se finalidade, boa-fé e interesse público.
- **"Legítimo interesse ampara biometria de voz sem consentimento."** Errado: legítimo interesse não está no art. 11.
- **"Biometria vocal em sessão pública dispensa base legal."** Errado: é dado sensível e precisa de base do art. 11.
- **"Órgão público que trata sensível sem consentimento fica dispensado de dar publicidade."** Errado: deve dar publicidade.
- **"A necessidade permite coletar o máximo para treinar IA no futuro."** Errado: necessidade é o mínimo.
- **"Transparência é a consulta gratuita sobre a integralidade dos dados."** Errado: isso é livre acesso.
- **"Autorização genérica é válida em cláusula destacada, se revogável."** Errado: é nula.
- **"O consentimento só se revoga por decisão judicial ou procedimento oneroso, com efeito retroativo."** Errado: revoga-se a qualquer tempo, de graça; o passado fica ratificado.
- **"Órgão público só informa as hipóteses de tratamento a quem pedir."** Errado: divulgação ativa, de preferência no site.
- **"O encarregado substitui as autoridades da LAI."** Errado: a LGPD não dispensa essas autoridades.

- **"Órgão público pode transferir livremente dados a empresas, bastando avisar o titular."** Errado: é vedado, salvo exceções, e os contratos vão à ANPD.
- **"O repasse do público ao privado depende sempre de consentimento, sem exceção."** Errado: o art. 27 tem três exceções.
- **"A ANPD pode multar órgão público em até 2% do faturamento."** Errado: a multa é para o setor privado.
- **"O teto da multa é R$ 5 milhões."** Errado: R$ 50 milhões por infração.
- **"A ANPD só pode exigir relatório de impacto se houver dado sensível."** Errado: "inclusive" de dados sensíveis.
- **"O encarregado define finalidades e meios, funções do operador."** Errado: quem decide é o controlador; o operador executa; o encarregado é canal.
- **"A revisão de decisão automatizada é sempre feita por pessoa natural."** Errado: essa exigência foi vetada.
- **"Terminado o tratamento, elimina-se tudo, sem exceção."** Errado: há conservação para obrigação legal e outras hipóteses.
- **"O titular pode exigir a eliminação de tudo, até do que é guardado por obrigação legal."** Errado: o art. 16 ressalva.
- **"Segurança só na fase de execução."** Errado: desde a concepção.
- **"Prazo de 72 horas corridas da ocorrência do incidente."** Errado: 3 dias úteis do conhecimento.
- **"A criptografia é irrelevante para a gravidade do incidente."** Errado: é avaliada e pode reduzi-la.
- **"A LGPD proíbe transferência internacional; nada de nuvem no exterior."** Errado: permite nas hipóteses do art. 33.
- **"Operador contratado pode transferir para o exterior livremente."** Errado: precisa de hipótese do art. 33.
- **"O operador jamais responde; só o controlador."** Errado: responde solidariamente se descumprir a lei ou as instruções lícitas.
- **"A ANPD sanciona sem processo, pelo poder de polícia."** Errado: exige processo com contraditório, ampla defesa e recurso.

Itens comentados

- **Item:** Situação hipotética: Em sistema de transcrição com IA, a Câmara dos Deputados substituiu os nomes de cidadãos ouvidos em audiências por códigos, mantendo em arquivo separado e seguro a tabela que permite identificá-los. Assertiva: Nessa situação, o dado pseudonimizado deixa de ser dado pessoal e sai do âmbito de aplicação da LGPD. **Errado.** Com a tabela guardada, a identificação é possível: é pseudonimização, e o dado continua pessoal.
- **Item:** Como as sessões do Plenário são públicas, os dados pessoais dos oradores contidos nas gravações e nas transcrições ficam excluídos do âmbito de incidência da LGPD, que não se

aplica a dados de acesso público. **Errado.** Dado de acesso público continua sob a LGPD (art. 7º, § 3º).

- **Item:** O legítimo interesse do controlador figura entre as hipóteses legais que autorizam o tratamento de dados pessoais sensíveis, de modo que um sistema que identifica falantes por biometria de voz pode se amparar nele sem consentimento do titular. **Errado.** O legítimo interesse está no art. 7º (dados comuns), não no art. 11 (sensíveis).
- **Item:** O princípio da transparência consiste na garantia, aos titulares, de consulta facilitada e gratuita sobre a forma e a duração do tratamento, bem como sobre a integralidade de seus dados pessoais. **Errado.** Essa é a definição do livre acesso.
- **Item:** Segundo a LGPD, as autorizações genéricas para o tratamento de dados pessoais são válidas quando constam de cláusula destacada de termo de uso, desde que o titular possa revogá-las depois. **Errado.** Autorizações genéricas são nulas (art. 8º, § 4º).
- **Item:** A LGPD dispensa as pessoas jurídicas de direito público de instituir as autoridades previstas na Lei de Acesso à Informação, pois a figura do encarregado substitui integralmente essas autoridades de monitoramento. **Errado.** O art. 23, § 2º, diz o contrário.
- **Item:** Se um órgão público descumprir a LGPD, a ANPD poderá lhe aplicar multa simples de até 2% do seu faturamento no último exercício, limitada a R$ 50 milhões por infração. **Errado.** A multa vale para pessoa jurídica de direito privado; a órgão público cabem outras sanções.
- **Item:** A LGPD assegura ao titular que a revisão de decisões tomadas unicamente com base em tratamento automatizado seja sempre realizada por pessoa natural, e não por outro sistema automatizado. **Errado.** O texto vigente garante a revisão, mas não exige pessoa natural.
- **Item:** Segundo o regulamento de comunicação de incidente de segurança da ANPD, a comunicação à autoridade e aos titulares deve ser feita em até 72 horas corridas, contadas do momento em que ocorreu o incidente, ainda que o controlador só o tenha descoberto depois. **Errado.** São 3 dias úteis do conhecimento de que o incidente afetou dados pessoais.
- **Item:** Pelo regulamento da ANPD, o controlador deve registrar todo incidente de segurança, inclusive aqueles que não foram comunicados à autoridade, e manter o registro por, no mínimo, cinco anos, contados da data do registro. **Certo.** Todo incidente é registrado, e o registro fica por pelo menos 5 anos.
- **Item:** Situação hipotética: Uma casa legislativa contratou serviço de transcrição em nuvem cujos servidores estão localizados em outro país e passou a enviar para lá os áudios das reuniões. O departamento entendeu que, por se tratar de operador contratado, a transferência internacional dos dados pessoais contidos nos áudios é livre, dispensando hipótese legal específica. Nessa situação, o entendimento está correto. **Errado.** A transferência só é permitida nas hipóteses do art. 33.
- **Item:** A empresa contratada como operadora para transcrever áudios jamais responde pelos danos decorrentes do tratamento, atribuindo-se a responsabilidade exclusivamente ao controlador, ainda que ela descumpra as instruções lícitas recebidas. **Errado.** O operador responde solidariamente e se equipara ao controlador nesses casos.

- **Item:** Situação hipotética: Uma casa legislativa contratou empresa para operar, em seu nome, o serviço de transcrição automática das sessões, e a empresa tratou os áudios exatamente segundo as instruções fornecidas pela Casa. Nessa situação, a empresa atua como operadora, e a Casa, como controladora, cabendo à última verificar a observância das instruções e das normas de proteção de dados. **Certo.** É o art. 39: o operador segue instruções e o controlador verifica.

Resumo para revisar

- Voz e transcrição identificada são dados pessoais; a LGPD vale também para o Poder Público.
- Tratamento é toda operação: coletar, enviar, armazenar e até eliminar.
- Dado de acesso público continua protegido: finalidade, boa-fé e interesse público.
- Sensível depende do assunto (religião, opinião política, saúde, biometria...), não do uso de IA.
- Voz que identifica alguém é biometria, logo dado sensível (ANPD, Radar Tecnológico).
- Consentimento é uma base entre várias; políticas públicas e obrigação legal dispensam consentimento.
- Legítimo interesse não serve para dado sensível.
- Órgão que trata sensível sem consentimento (obrigação legal ou políticas públicas) dá publicidade.
- Consentimento: finalidades determinadas; genérico é nulo; ônus da prova do controlador; vício proíbe; revogação gratuita e a qualquer tempo, passado ratificado.
- Necessidade = mínimo; livre acesso = consulta gratuita e integralidade; transparência = informação clara sobre tratamento e agentes.
- Anonimizado sai da LGPD (salvo reversão razoável); pseudonimizado continua dado pessoal.
- Controlador decide; operador executa em nome dele; encarregado é canal, com contato publicado de preferência no site.
- Operador que descumpre a lei ou as instruções lícitas responde solidariamente.
- Revisão de decisão automatizada: direito garantido, sem exigir pessoa natural; ANPD audita se houver recusa por segredo.
- Art. 23: finalidade pública, divulgação ativa das hipóteses, encarregado; autoridades da LAI continuam; prazos pelas leis do habeas data, do processo administrativo e da LAI.
- Repasse a privados é vedado, salvo exceções; contratos e convênios comunicados à ANPD; art. 27 tem exceções ao consentimento.
- ANPD pede informações a qualquer momento, envia informe ao órgão infrator, pede publicação de RIPD; RIPD "inclusive" de sensíveis.
- Término: finalidade alcançada, fim do prazo, pedido do titular (interesse público resguardado), determinação da ANPD.
- Eliminação com exceções: obrigação legal, pesquisa, transferência a terceiro, uso exclusivo anonimizado.
- Segurança desde a concepção até a execução e mesmo após o término.

- Incidente relevante: comunica ANPD e titular em 3 dias úteis do conhecimento; registra todos por 5 anos; criptografia pesa na gravidade.
- Transferência internacional permitida só nas hipóteses do art. 33; ser operador não libera.
- Multa até 2% do faturamento, teto de R$ 50 milhões; não se aplica a órgão público.
- Sanção só com processo administrativo, contraditório, ampla defesa e recurso.

TEMA 19 DE 20

Direitos autorais e ética no conteúdo gerado por IA

57 perguntas no app · Proteção e ética

O que cai

O edital pede "Direitos autorais e ética no uso de IA para conteúdo gerado" (item 4.2). As perguntas misturam três frentes:

- **Lei de Direitos Autorais (Lei nº 9.610/1998)**: quem é autor (só a pessoa física), o que é e o que não é protegido (discursos e conferências sim; leis, ideias, títulos isolados e calendários não), direitos morais x patrimoniais, prazos de 70 anos, cessão (escrita, 5 anos, interpretação restritiva), limitações (discurso em reunião pública, citação com nome do autor, prova judicial), domínio público, obra coletiva, sanções.
- **IA e autoria**: obra gerada só pela máquina não tem proteção automática; o Escritório de Direitos Autorais dos EUA (comandos não bastam) e o caso Thaler v. Perlmutter; o PL 2.338/2023 (aprovado no Senado, em análise na Câmara).
- **Ética da IA**: humano no circuito, transparência sobre o uso de IA, alucinação, viés (estudo de Koenecke), Princípios da OCDE (cinco) x Recomendação da UNESCO (dez princípios, não vinculante), a política de IA da Câmara (Ato da Mesa nº 225/2025).

Ideia central: **a máquina não é autora nem responsável; a pessoa revisa, assina e responde**.

Entenda o tema

Quem é autor

Para a Lei 9.610/1998, **autor é a pessoa física** criadora de obra literária, artística ou científica (art. 11). A proteção pode se aplicar a **pessoas jurídicas** só **nos casos previstos na lei**, como na obra coletiva, em que o organizador fica com os direitos patrimoniais do conjunto.

Obras protegidas são as **criações do espírito**, expressas **por qualquer meio** ou fixadas em **qualquer suporte, tangível ou intangível** (art. 7º). Não precisa estar gravada nem escrita. Entre os exemplos, a lei cita **conferências, alocuções, sermões** e obras da mesma natureza. Uma conferência improvisada e não gravada **é obra protegida**.

> **Exemplo:** o discurso de um Deputado no Plenário pode ser obra protegida, como **alocução**. Mesmo assim, a lei permite que jornais e revistas o reproduzam, porque foi pronunciado em reunião pública (veja as limitações, mais abaixo).

IA e autoria

Como a proteção autoral pressupõe **criação do espírito humano**, o conteúdo produzido **autonomamente** por IA, **sem participação criativa humana**, **não se encaixa com naturalidade** na tutela autoral. A lei brasileira **não protege de forma expressa e automática** essas obras. Também **não** é verdade que a empresa desenvolvedora vira "autora" do que a máquina gera; o tema está em **debate**, não é pacífico.

Estados Unidos.

- O **Escritório de Direitos Autorais dos EUA** (U.S. Copyright Office), em relatório de **janeiro de 2025** (Copyright and Artificial Intelligence, Parte 2), concluiu que o **simples fornecimento de comandos** (prompts) a um sistema de IA generativa **não basta, em regra**, para tornar o usuário autor do resultado. Pode ser protegido o que a pessoa **cria, seleciona ou organiza com criatividade**.
- No caso **Thaler v. Perlmutter**, o **tribunal federal de apelação** (D.C. Circuit) decidiu em **março de 2025** que obra criada **de forma autônoma** por IA **não pode ser registrada**: **exige-se autor humano**. Indicar o sistema como autor não resolve.

PL 2.338/2023: a regulação da IA no Brasil

- **Origem: Senado Federal**, apresentado pelo senador **Rodrigo Pacheco**. Foi aprovado em **votação simbólica** pelo Plenário do Senado em **10 de dezembro de 2024** e **remetido à Câmara dos Deputados** para revisão. Não começou na Câmara.
- No Senado, o relator em Plenário foi o senador **Eduardo Gomes**.
- Na Câmara, foi para uma **comissão especial** instalada em **20 de maio de 2025**, presidida pela deputada **Luisa Canziani**, com relatoria do deputado **Aguinaldo Ribeiro**, em **regime de prioridade**. Senador não relata em comissão da Câmara.

O que diz o texto aprovado pelo Senado (ainda não é lei):

- classifica os sistemas por **níveis de risco**: regras **mais rígidas para os de alto risco** e **proibição dos de risco excessivo**;
- **direitos autorais**: quando sistemas de IA **disponibilizados comercialmente** usam conteúdo protegido em **mineração de textos, treinamento ou desenvolvimento**, os titulares têm **direito a remuneração**. A mineração **não é livre para qualquer fim**: o uso sem fins comerciais fica reservado a instituições como **universidades, museus e bibliotecas**; fora disso, o **titular pode proibir** o uso de suas obras;
- **imagem e voz**: o uso da imagem e da voz de pessoas em sistemas de IA exige **consentimento prévio** e não pode causar dano à **honra, à reputação ou à intimidade**;
- **sanções**: além de advertência e suspensão do sistema, há **multa** de valor elevado; a autoridade competente é a **ANPD**, que coordenaria o sistema nacional de regulação e governança da IA. Não é o TCU, e não é "só advertência".

Direitos morais x direitos patrimoniais

Direitos morais ligam a obra à pessoa do autor. Estão no art. 24: reivindicar a autoria; ter o nome indicado; conservar a obra inédita; assegurar sua integridade; **modificar** a obra; **retirar de**

circulação; ter acesso a exemplar único e raro. São **inalienáveis e irrenunciáveis** (art. 27): não se vendem, nem com contrato escrito e pagamento. A transmissão total de direitos nunca inclui os morais (art. 49, I).

Por morte do autor, passam aos sucessores **só os quatro primeiros** (incisos I a IV): reivindicar autoria, ter o nome indicado, conservar inédita e defender a integridade. **Modificar a obra** e **retirá-la de circulação não** passam aos herdeiros.

Direitos patrimoniais são os de **explorar economicamente** a obra. Regra: **depende de autorização prévia e expressa do autor** a utilização da obra por quaisquer modalidades (art. 29), como reprodução, edição, adaptação, **tradução para qualquer idioma**, **inclusão em fonograma ou produção audiovisual**, inclusão em base de dados e armazenamento em computador.

- **Comprar o original ou um exemplar** (um quadro, um livro) **não dá** ao comprador os direitos patrimoniais, salvo acordo em contrário (art. 37).
- **Ninguém pode reproduzir** obra que não esteja em domínio público **a pretexto de anotá-la, comentá-la ou melhorá-la**, sem permissão do autor. Os comentários podem ser publicados **separadamente**, sem a obra (art. 33).

Prazos e domínio público

- **Regra**: os direitos patrimoniais duram **70 anos**, contados de **1º de janeiro do ano seguinte ao falecimento** do autor; o mesmo prazo vale para **obras póstumas** (art. 41).
- **Obras audiovisuais e fotográficas**: **70 anos** (não 50), contados de 1º de janeiro do ano seguinte ao da **divulgação** (art. 44).

Domínio público (art. 45): além das obras cujo prazo acabou, pertencem ao domínio público as de **autores falecidos sem sucessores** e as de **autor desconhecido**, ressalvada a proteção legal aos **conhecimentos étnicos e tradicionais**. Cabe ao Estado defender a integridade e a autoria da obra em domínio público.

Transferência dos direitos (art. 49)

- Os direitos podem ser transferidos total ou parcialmente, mas **a transmissão total e definitiva** só se admite por **contrato escrito**;
- **sem contrato escrito**, o prazo máximo é de **5 anos**;
- a cessão vale **só para o país** em que se firmou o contrato, salvo estipulação em contrário;
- vale **só para modalidades de uso já existentes** na data do contrato;
- sem especificação de modalidade, interpreta-se **restritivamente**.

E a regra geral do art. 4º: **interpretam-se restritivamente** os negócios sobre direitos autorais. Na dúvida, protege-se o **autor**, não quem adquire os direitos.

Omissão do nome. Se o nome do autor ou coautor for omitido na divulgação, **não se presume** o anonimato nem a cessão de direitos (art. 52).

Obra coletiva

Obra coletiva é a criada por iniciativa, organização e responsabilidade de uma pessoa física ou jurídica, que a publica sob seu nome ou marca, com contribuições de vários autores fundidas numa criação autônoma (uma enciclopédia, por exemplo). Nela:

- **o organizador** tem a **titularidade dos direitos patrimoniais sobre o conjunto** (art. 17, § 2º);
- cada participante tem **proteção à sua contribuição individual** e pode até proibir que seu nome apareça, sem perder a remuneração.

O que não é protegido (art. 8º)

- **ideias**, procedimentos normativos, sistemas, métodos, projetos ou conceitos matemáticos **como tais**. Protege-se a **forma de expressão**, não a ideia;
- esquemas, planos ou regras para atos mentais, jogos ou negócios;
- formulários em branco;
- **textos de tratados, leis, decretos, regulamentos, decisões judiciais e demais atos oficiais**. Não pertencem ao órgão que os edita; qualquer um pode reproduzi-los;
- **informações de uso comum**, como **calendários, agendas, cadastros ou legendas** (uma coletânea criativa dessas informações pode ter proteção própria);
- **nomes e títulos isolados**. O título só é protegido se for **original e inconfundível** com o de obra do mesmo gênero divulgada antes (art. 10);
- o aproveitamento industrial ou comercial das ideias contidas nas obras.

Limitações: usos permitidos sem autorização (art. 46)

Não constitui ofensa aos direitos autorais, entre outros:

- a reprodução **em diários ou periódicos de discursos pronunciados em reuniões públicas** de qualquer natureza. **Não precisa de autorização do orador**; ele continua autor, a lei só libera esse uso;
- a **citação** de passagens de qualquer obra, em livros, jornais, revistas ou outro meio, para **estudo, crítica ou polêmica**, na medida justificada, **indicando-se o nome do autor e a origem da obra**. Ser curta não dispensa a indicação;
- a utilização de obras **para produzir prova judiciária ou administrativa**;
- a reprodução de pequenos trechos para uso privado do copista, sem lucro; a reprodução em Braille para deficientes visuais, sem fins comerciais; entre outras.

Definições úteis (art. 5º)

- **Reprodução**: cópia de um ou vários exemplares, de qualquer forma tangível, **incluindo armazenamento permanente ou temporário por meios eletrônicos**.
- **Contrafação**: a **reprodução não autorizada**.

Intérpretes, voz e imagem

A proteção aos **artistas intérpretes ou executantes** estende-se à **reprodução da voz e imagem**, quando associadas às suas atuações (art. 90, § 2º). A **Constituição** assegura, nos termos da lei, a

proteção às participações individuais em obras coletivas e **à reprodução da imagem e voz humanas** (art. 5º, XXVIII, a), e dá aos autores o **direito exclusivo** de utilização, publicação ou reprodução de suas obras, **transmissível aos herdeiros** pelo tempo que a lei fixar (art. 5º, XXVII).

Sanções civis

- O titular cuja obra seja **fraudulentamente reproduzida** pode pedir a **apreensão dos exemplares** ou a **suspensão da divulgação**, **sem prejuízo da indenização** (art. 102). As medidas se somam.
- Quem usa a obra **sem indicar o nome do autor ou do intérprete** responde por **danos morais** e é obrigado a **divulgar a identidade** deles (art. 108).

Ética no uso de IA

Humano no circuito (human in the loop): uma pessoa **revisa e valida efetivamente** o que o sistema produziu **antes da publicação**. É o oposto da automação completa.

Transparência sobre o uso de IA. Usar IA para gerar o resumo de uma sessão **não dispensa** a indicação de que o conteúdo teve apoio automatizado, **mesmo que haja revisão**. Em material oficial, avisar é boa prática.

Alucinação. É a geração de conteúdo **plausível na forma, mas incorreto ou sem base** nos dados de entrada. Justifica a **revisão humana** de resumos e atas antes da publicação.

Taxa de acerto alta não dispensa revisão. Os erros **não se distribuem de modo uniforme**: **nomes, números e datas** são justamente os pontos em que o sistema mais falha e em que o erro mais prejudica. Esses trechos precisam de revisão.

Viés. O estudo de **Koenecke e colaboradores** (PNAS, 2020) testou **cinco sistemas comerciais** de reconhecimento de fala e encontrou **taxa média de erro de palavras maior para falantes negros** do que para falantes brancos. O viés pode vir dos **dados de treinamento** pouco diversos, não só do algoritmo. Dados de treino **não são sempre** representativos da população.

Decisão automatizada e LGPD. O titular pode **pedir revisão** de decisões tomadas **unicamente** por tratamento automatizado que afetem seus interesses, e o controlador deve dar, quando solicitado, **informações claras sobre critérios e procedimentos** (LGPD, art. 20).

Documentos internacionais

Princípios de IA da OCDE (adotados em **2019**, atualizados em **maio de 2024**). São **cinco** princípios baseados em valores:

1. crescimento inclusivo, desenvolvimento sustentável e bem-estar;
2. direitos humanos e valores democráticos, incluindo equidade e privacidade;
3. **transparência e explicabilidade**;
4. **robustez, segurança e proteção**;
5. **responsabilização** (accountability).

Pela responsabilização, respondem pelos danos **os atores** que **desenvolvem, implantam ou operam** o sistema. O sistema **não** é tratado como agente responsável.

Recomendação sobre a Ética da IA da UNESCO (adotada em **novembro de 2021** pelos **193 Estados-membros**). Tem **dez princípios**, entre eles **proporcionalidade e não causar dano**, **supervisão e determinação humanas** e **conscientização e alfabetização em IA**. É uma **recomendação**: orienta, mas **não é tratado vinculante**, e a UNESCO **não aplica sanções** a quem não a segue.

> **Pegadinha:** "Princípios da OCDE são dez e incluem proporcionalidade e alfabetização em IA." Errado: a OCDE tem **cinco**; a lista de **dez**, com proporcionalidade e alfabetização, é da **UNESCO**.

A política de IA da Câmara

O **Ato da Mesa nº 225/2025** (política de governança de IA da Câmara dos Deputados) traz como diretrizes, entre outras: **supervisão humana**, **transparência**, **observância da LGPD** e o **dever de informar o usuário** quando ele interagir com agentes de IA. A IA é **complemento** do trabalho humano; a **responsabilidade pela versão final** continua com as **pessoas**, mesmo quando há monitoramento contínuo de falhas e vieses. Ela nunca se transfere ao sistema.

Quadros para memorizar

Lei 9.610/1998 em números

Ponto	Regra	Artigo
Prazo geral	70 anos de 1º/1 do ano seguinte à morte; vale para póstumas	art. 41
Audiovisual e fotografia	70 anos de 1º/1 do ano seguinte à divulgação	art. 44
Cessão sem contrato escrito	no máximo 5 anos	art. 49, III
Território da cessão	só o país do contrato, salvo estipulação	art. 49, IV
Modalidades	só as existentes na data do contrato	art. 49, V
Interpretação	restritiva	arts. 4º e 49, VI

Direitos morais

Direito moral	Passa aos herdeiros?
Reivindicar a autoria	sim
Ter o nome indicado	sim
Conservar a obra inédita	sim
Assegurar a integridade	sim
Modificar a obra	não
Retirar de circulação	não

Protegido x não protegido

Protegido	Não protegido
conferências, alocuções, sermões (mesmo sem gravação)	ideias, métodos, conceitos matemáticos
traduções e adaptações como criação nova	leis, decretos, decisões judiciais, atos oficiais
coletâneas criativas, bases de dados organizadas	calendários, agendas, cadastros, legendas
título original e inconfundível	nomes e títulos isolados

OCDE x UNESCO

	OCDE	UNESCO
Ano	2019, atualizados em 2024	novembro de 2021
Quantos princípios	5	10
Exemplos	transparência e explicabilidade; robustez e segurança; responsabilização	proporcionalidade e não causar dano; supervisão humana; alfabetização em IA
Natureza	princípios	recomendação, não vinculante

PL 2.338/2023

Ponto	Fato
Origem	Senado (Rodrigo Pacheco)
Aprovação no Senado	10/12/2024, votação simbólica; relator Eduardo Gomes
Na Câmara	comissão especial (20/05/2025), presidente Luisa Canziani, relator Aguinaldo Ribeiro, prioridade
Risco	alto risco com regras rígidas; risco excessivo proibido
Treino com obras	remuneração no uso comercial; titular pode proibir; exceção sem fim comercial para universidades, museus, bibliotecas
Imagem e voz	consentimento prévio; sem dano à honra, reputação, intimidade
Sanções	advertência, multa, suspensão; ANPD

Conceitos e autores que caem

Quem é autor.

> **Lei seca:** Art. 11. Autor é a **pessoa física** criadora de obra literária, artística ou científica. Parágrafo único. A proteção concedida ao autor poderá aplicar-se às **pessoas jurídicas nos casos previstos nesta Lei**. (Lei 9.610/1998)

Obra protegida não precisa de suporte físico.

> **Lei seca:** Art. 7º São obras intelectuais protegidas as criações do espírito, expressas **por qualquer meio** ou fixadas em qualquer suporte, **tangível ou intangível** (...), tais como: (...) II - as **conferências, alocuções, sermões** e outras obras da mesma natureza;

Discurso em reunião pública pode ser reproduzido pela imprensa.

> **Lei seca:** Art. 46. Não constitui ofensa aos direitos autorais: I - a reprodução: (...) b) em diários ou periódicos, de **discursos pronunciados em reuniões públicas** de qualquer natureza;

Citação exige nome e origem.

> **Lei seca:** Art. 46, III - a citação (...) de passagens de qualquer obra, para fins de estudo, crítica ou polêmica, na medida justificada para o fim a atingir, **indicando-se o nome do autor e a origem da obra**;

Atos oficiais não são protegidos.

> **Lei seca:** Art. 8º Não são objeto de proteção como direitos autorais (...): I - as **idéias**, procedimentos normativos, sistemas, métodos, projetos ou conceitos matemáticos como tais; (...) IV - os textos de tratados ou convenções, **leis, decretos, regulamentos, decisões judiciais** e demais atos oficiais; V - as informações de uso comum tais como **calendários, agendas, cadastros ou legendas**; VI - os **nomes e títulos isolados**;

Morais não se vendem.

> **Lei seca:** Art. 27. Os direitos morais do autor são **inalienáveis e irrenunciáveis**.

Cessão sem contrato escrito.

> **Lei seca:** Art. 49, II - somente se admitirá transmissão total e definitiva dos direitos mediante **estipulação contratual escrita**; III - na hipótese de não haver estipulação contratual escrita, o prazo máximo será de **cinco anos**;

Conceitos de ética e autores:

- **Humano no circuito**: revisão e validação humanas efetivas antes de publicar.
- **Alucinação**: conteúdo plausível, mas incorreto ou sem base na entrada.
- **Viés**: erro desigual entre grupos; pode vir dos dados de treino.
- **Koenecke et al. (PNAS, 2020)**: cinco sistemas comerciais de ASR erraram mais com falantes negros.
- **U.S. Copyright Office (jan. 2025)**: prompt sozinho não faz do usuário autor.
- **Thaler v. Perlmutter (D.C. Circuit, mar. 2025)**: sem autor humano, sem registro.

Pegadinhas da banca

- **"Se houver revisão, não precisa avisar que o resumo foi feito com IA."** Errado: a transparência continua.
- **"A lei protege expressa e automaticamente obras feitas só por IA."** Errado: a proteção pressupõe criação humana.
- **"A empresa desenvolvedora é autora do que a IA gera; tema pacificado."** Errado: autor é pessoa física, e o tema é debatido.
- **"A política de IA da Câmara transfere ao sistema a responsabilidade pela versão final."** Errado: a responsabilidade é humana.
- **"Leis e decisões judiciais são protegidas e pertencem ao órgão que as edita."** Errado: não são protegidas.
- **"Só obras fixadas em suporte tangível são protegidas; conferência improvisada não."** Errado: qualquer meio, tangível ou intangível.
- **"Direitos morais podem ser transferidos por contrato escrito e remunerado."** Errado: são inalienáveis.
- **"Reproduzir discurso de reunião pública em periódico exige autorização do orador."** Errado: é limitação legal, sem autorização.
- **"Títulos isolados são protegidos."** Errado: só o título original e inconfundível.
- **"Citação curta dispensa nome do autor e origem."** Errado: a indicação é obrigatória.
- **"Sem contrato escrito, a cessão vale 10 anos, em qualquer país, para usos futuros."** Errado: 5 anos, só o país do contrato, só modalidades existentes.
- **"Negócios autorais se interpretam de forma ampliativa, a favor do adquirente."** Errado: restritivamente.
- **"Comprar o livro ou o quadro dá todos os direitos patrimoniais."** Errado: dá só o objeto.
- **"Todos os direitos morais passam aos herdeiros, inclusive modificar e retirar de circulação."** Errado: só os incisos I a IV.
- **"Pode-se reproduzir obra protegida para comentá-la, se os comentários saírem em separado."** Errado: reproduzir exige permissão; só os comentários podem sair em separado.
- **"Na obra coletiva, cada participante é titular do conjunto."** Errado: o organizador é.
- **"Na contrafação, cabe só indenização, sem apreensão nem suspensão."** Errado: cabem as três.
- **"Audiovisual e fotografia: 50 anos."** Errado: 70 anos da divulgação.
- **"Omissão do nome presume anonimato e cessão."** Errado: não presume.
- **"Thaler v. Perlmutter admitiu registro com a IA como autora."** Errado: exigiu autor humano.
- **"O PL 2.338/2023 nasceu na Câmara."** Errado: nasceu no Senado.
- **"O relator na comissão especial da Câmara é o senador Eduardo Gomes."** Errado: é o deputado Aguinaldo Ribeiro.
- **"Pelo texto do Senado, a mineração é livre para qualquer fim, inclusive comercial."** Errado: titular pode proibir e o uso comercial gera remuneração.

- **"Pelo texto do Senado, só há advertência, aplicada pelo TCU."** Errado: há multa e outras sanções, aplicadas pela ANPD.
- **"Os Princípios da OCDE são dez."** Errado: são cinco; os dez são da UNESCO.
- **"A Recomendação da UNESCO é tratado vinculante com sanções."** Errado: é recomendação.
- **"Pela OCDE, o próprio sistema de IA responde pelo dano."** Errado: respondem os atores humanos e organizações.
- **"Alta taxa de acerto dispensa revisão de nomes, números e datas, pois os erros são uniformes."** Errado: os erros se concentram justamente aí.
- **"O viés vem só do algoritmo; os dados são sempre representativos."** Errado: os dados podem ser enviesados.

Itens comentados

- **Item:** O uso de ferramenta de inteligência artificial para gerar o resumo de uma sessão dispensa a indicação de que o conteúdo foi produzido com apoio automatizado, desde que haja revisão posterior. **Errado.** A revisão não elimina o dever de transparência.
- **Item:** O discurso proferido por parlamentar no Plenário pode configurar obra intelectual protegida como alocução, sem que isso impeça a reprodução do discurso em periódicos, permitida pela Lei 9.610/1998 quando pronunciado em reunião pública. **Certo.** É alocução protegida (art. 7º, II), e a reprodução em periódicos é limitação legal (art. 46, I, b).
- **Item:** A Lei 9.610/1998 protege apenas as obras fixadas em suporte tangível, de modo que uma conferência improvisada e não gravada não pode ser considerada obra intelectual protegida. **Errado.** Protege criações expressas por qualquer meio, tangível ou intangível.
- **Item:** Os direitos morais do autor, previstos na Lei 9.610/1998, podem ser livremente transferidos a terceiros por meio de contrato escrito, desde que haja remuneração. **Errado.** São inalienáveis e irrenunciáveis.
- **Item:** Na falta de estipulação contratual escrita, a cessão de direitos de autor vale por até dez anos, em qualquer país, para todas as modalidades de utilização da obra, existentes ou futuras. **Errado.** Cinco anos, só no país do contrato, só modalidades existentes.
- **Item:** Por morte do autor, transmitem-se a seus sucessores todos os direitos morais previstos na Lei 9.610/1998, inclusive o de modificar a obra e o de retirá-la de circulação. **Errado.** Só passam os incisos I a IV do art. 24.
- **Item:** O prazo de proteção dos direitos patrimoniais sobre obras audiovisuais e fotográficas é de cinquenta anos, contados de 1º de janeiro do ano subsequente ao da divulgação. **Errado.** São setenta anos.
- **Item:** No caso Thaler v. Perlmutter, o tribunal de apelação federal dos Estados Unidos decidiu, em 2025, que uma obra criada de forma autônoma por sistema de IA pode ser registrada, desde que o sistema seja indicado como autor. **Errado.** O tribunal manteve a exigência de autor humano.

- **Item:** O Projeto de Lei 2.338/2023, que dispõe sobre o uso da inteligência artificial, foi aprovado em votação simbólica pelo Plenário do Senado Federal em 10 de dezembro de 2024 e remetido à Câmara dos Deputados para revisão. **Certo.** O projeto nasceu no Senado e foi à Câmara.
- **Item:** Os Princípios de IA da OCDE, atualizados em 2024, são dez e incluem a proporcionalidade e a vedação de causar dano, a conscientização e a alfabetização em IA. **Errado.** A OCDE tem cinco princípios; os dez citados são da UNESCO.
- **Item:** A Recomendação sobre a Ética da Inteligência Artificial da UNESCO, de 2021, é tratado internacional de natureza vinculante, cuja violação sujeita os Estados-membros a sanções aplicadas pela própria organização. **Errado.** É recomendação, sem força vinculante nem sanções.
- **Item:** Uma transcrição automática com alta taxa de acerto geral dispensa revisão humana dos trechos que citam nomes, números e datas, pois os erros do sistema se distribuem de modo uniforme ao longo do texto. **Errado.** Os erros se concentram em nomes, números e datas.
- **Item:** Segundo estudo de Koenecke e outros, publicado na PNAS em 2020, cinco sistemas comerciais de reconhecimento de fala apresentaram taxa média de erro de palavras maior para falantes negros do que para falantes brancos. **Certo.** É o achado central do estudo sobre viés no reconhecimento de fala.

Resumo para revisar

- Autor é a pessoa física; pessoa jurídica só nos casos da lei (ex.: organizador de obra coletiva).
- Obra feita só por IA não tem proteção expressa e automática; empresa desenvolvedora não vira autora; tema em debate.
- EUA: prompt não basta para autoria (Copyright Office, jan. 2025); Thaler v. Perlmutter (mar. 2025) exige autor humano.
- Obra protegida: qualquer meio, tangível ou intangível; conferências, alocuções e sermões entram.
- Discurso em reunião pública pode ser reproduzido em periódicos sem autorização.
- Não protegidos: ideias e métodos, atos oficiais (leis, decisões), calendários e cadastros, títulos isolados.
- Citação para estudo, crítica ou polêmica: sempre com nome do autor e origem.
- Prova judicial ou administrativa: uso livre.
- Direitos morais inalienáveis e irrenunciáveis; aos herdeiros passam só os incisos I a IV (não modificar nem retirar de circulação).
- Uso da obra (tradução, fonograma, audiovisual...) depende de autorização prévia e expressa.
- Comprar exemplar não dá direitos patrimoniais. Reproduzir para comentar exige permissão.
- 70 anos após a morte (inclusive póstumas); audiovisual e fotografia: 70 anos da divulgação.
- Domínio público: prazo vencido, autor sem sucessores, autor desconhecido (ressalva aos conhecimentos tradicionais).

- Cessão: definitiva só por escrito; sem escrito, 5 anos; só o país; só modalidades existentes; interpretação restritiva.
- Obra coletiva: patrimoniais do conjunto com o organizador.
- Reprodução inclui armazenamento eletrônico, até temporário; contrafação = reprodução não autorizada.
- Intérprete: proteção alcança voz e imagem; CF protege a reprodução da imagem e voz humanas.
- Contrafação: apreensão, suspensão e indenização. Omitir o nome do autor gera dano moral e dever de divulgar a identidade; não presume anonimato.
- PL 2.338/2023: Senado (Pacheco), aprovado em 10/12/2024; na Câmara, comissão especial (Canziani presidente, Aguinaldo Ribeiro relator).
- Texto do Senado: níveis de risco, risco excessivo proibido; remuneração por treino comercial; consentimento para imagem e voz; ANPD aplica sanções.
- OCDE: 5 princípios (2019, atualizados em 2024); respondem os atores, não o sistema.
- UNESCO: 10 princípios, nov. 2021, 193 países, recomendação não vinculante; supervisão humana.
- Humano no circuito = revisão efetiva antes de publicar. Transparência: avisar o uso de IA.
- Alucinação: plausível e errado. Nomes, números e datas sempre revisados.
- Koenecke (PNAS, 2020): mais erros para falantes negros; viés pode vir dos dados.
- Câmara (Ato da Mesa 225/2025): supervisão humana, transparência, LGPD, avisar quem interage com IA; responsabilidade final humana.

TEMA 20 DE 20

Segurança da informação em pipelines de áudio

55 perguntas no app · Proteção e ética

O que cai

O edital pede "Segurança da informação em pipelines de áudio e transcrição" (item 4.3). **Pipeline** é a linha de produção do áudio: gravação, armazenamento, envio ao serviço de transcrição, devolução do texto, revisão, publicação e arquivo. As perguntas cobram:

- **Fundamentos**: a tríade confidencialidade, integridade e disponibilidade (e qual ataque fere qual), hash para conferir integridade, criptografia em trânsito x em repouso, simétrica x assimétrica, menor privilégio, autenticação em dois fatores, trilhas de auditoria, backup.
- **Serviços de nuvem**: o que a documentação do Amazon Transcribe, do Azure AI Speech, do Google Speech-to-Text e da API da OpenAI diz sobre criptografia, retenção e uso dos dados.
- **Ameaças**: spoofing e deepfake de voz (ASVspoof, regras do TSE), falhas de API (OWASP API Top 10), URLs pré-assinadas.
- **Normas**: ISO/IEC 27001 (certificável) x 27002 (guia de controles: 93 controles em 4 temas na edição de 2022).
- **LGPD aplicada à segurança**: arts. 44 a 49, incidentes (3 dias úteis do conhecimento, complementação em 20 dias úteis), operador que responde, eliminação depois do fim do tratamento.

Entenda o tema

A tríade da segurança da informação

Toda proteção de áudios e transcrições se orienta por três propriedades (a "tríade CID"), definidas na família ISO/IEC 27000:

- **Confidencialidade**: só quem tem autorização **vê** o conteúdo. Ameaça típica: vazamento de áudio de reunião reservada.
- **Integridade**: o conteúdo **não é alterado** de forma indevida. Ameaça típica: alguém edita a gravação ou a transcrição de um discurso.
- **Disponibilidade**: o dado e o serviço **estão à mão** quando se precisa. Ameaça típica: **ataque de negação de serviço** (DoS) que derruba a API de transcrição durante uma sessão deliberativa.

A tríade vale para o **áudio** e para o **texto**, em **todas as etapas** do fluxo.

> **Pegadinha:** a banca troca integridade e confidencialidade. "Só autorizados acessam" é **confidencialidade**; "não é alterado indevidamente" é **integridade**.

Hash: a impressão digital do arquivo

Uma **função hash criptográfica** pega um arquivo de qualquer tamanho e gera um código curto e fixo. Qualquer mudança no arquivo, mesmo de um único bit, gera um **hash diferente**.

> **Exemplo:** no momento em que grava cada sessão, o departamento de registro calcula o hash do arquivo de áudio e guarda esse código em local separado. Meses depois, recalcula o hash do arquivo. Se os dois códigos forem iguais, o áudio é o original; se forem diferentes, foi alterado.

O hash serve para **verificar integridade**. Ele **não é reversível**: não dá para reconstruir o áudio a partir do hash. Por isso **não serve de backup**. Para recuperar um arquivo perdido, é preciso ter uma **cópia** dele.

Criptografia

Criptografar é embaralhar os dados com uma chave para que só quem tem a chave certa consiga lê-los.

Em trânsito x em repouso.

- **Em trânsito**: protege o dado **enquanto viaja** pela rede, do cliente até o serviço de transcrição e de volta (por exemplo, com **TLS**).
- **Em repouso**: protege o dado **enquanto está guardado** no disco ou no servidor.

Uma **não substitui** a outra. Áudio enviado por canal criptografado, mas guardado em disco sem criptografia, fica desprotegido no disco.

Simétrica x assimétrica.

- **Simétrica**: a **mesma chave** cifra e decifra. É a usada, por exemplo, para cifrar em repouso a saída das transcrições com chave do cliente.
- **Assimétrica**: usa **duas chaves diferentes**, uma pública e uma privada.

> **Dica:** "simétrica" = as duas pontas iguais = a mesma chave.

Controle de acesso, autenticação e auditoria

Menor privilégio: cada usuário e cada sistema recebe **só as permissões estritamente necessárias** às suas tarefas. Se uma conta for invadida ou alguém errar, o estrago fica pequeno.

Autenticação em dois fatores. Senha longa, sozinha, **não basta** para contas de administrador de serviços em nuvem que guardam áudios: a senha pode vazar ou ser descoberta. O segundo fator (código no celular, chave física) é **proteção importante e recomendada**.

Trilhas de auditoria (logs): registram **quem acessou, alterou ou excluiu** arquivos e **quando**. Permitem **apurar responsabilidades** e **investigar incidentes**. A LGPD manda controlador e operador manterem **registro das operações de tratamento** (art. 37).

> **Atenção:** o log registra **quem fez o quê e quando**, e **não o conteúdo integral das falas**. Copiar as falas para os logs aumenta o risco de vazamento e contraria a **necessidade** (mínimo de dados) e a **segurança** da LGPD.

Backup

A Cartilha de Segurança para Internet do **CERT.br** recomenda:

- manter **pelo menos duas cópias** de segurança, **em locais diferentes**;
- **testar periodicamente** os backups, **inclusive logo depois de gerados**. Backup que nunca foi testado pode falhar na hora da restauração.

Uma única cópia guardada **no mesmo servidor** dos originais **não garante** a disponibilidade: uma falha de equipamento ou um ataque leva os dois.

Contrato com o fornecedor de nuvem

Usar serviço de transcrição em nuvem **não dispensa** formalizar as obrigações de segurança, **mesmo que o fornecedor seja famoso**. O contrato deve fixar finalidade, prazo de retenção, medidas de segurança e **proibição de outros usos** dos dados.

Pela LGPD, o provedor que transcreve em nome do órgão é **operador**: segue as **instruções do controlador** e **não pode** definir finalidades nem usar os dados para objetivos próprios. Se fizer isso, descumpre as instruções e passa a responder **como se fosse controlador**.

Antes de contratar uma API de IA, o órgão deve **ler a política de uso e retenção de dados**: mesmo quando os dados **não são usados para treinar modelos**, o fornecedor pode **reter registros temporariamente**, por exemplo para **monitorar abusos**.

O que dizem os grandes serviços

Amazon Transcribe (AWS).

- **Em trânsito**: protegido por **TLS 1.2** com certificados da AWS, **inclusive** na transcrição em fluxo contínuo (**streaming**).
- **Em repouso**: a transcrição gravada no bucket do cliente é criptografada **mesmo que o cliente não indique chave própria**, com a **chave padrão do S3**. A chave do **AWS KMS** é uma **opção** para mais controle, e não condição para haver criptografia.
- **Redação de informações pessoais (PII)**: o serviço **mascara** dados pessoais na transcrição, mas, por depender de **aprendizado de máquina**, **pode não identificar todas as ocorrências**. Recomenda-se **revisar a saída**.

Azure AI Speech (Microsoft).

- **Tempo real**: o áudio é processado **só na memória** dos servidores; **nada fica armazenado em repouso**.

- **Lote (batch)**: o cliente **pode excluir** os dados e **definir prazo de retenção** (parâmetro **timeToLive**). Não ficam por prazo indeterminado.
- **Contêineres**: quando o cliente roda o serviço de fala **no próprio ambiente**, áudios e transcrições **ficam lá** e **não vão** para o serviço em nuvem. Em compensação, a segurança desse ambiente é responsabilidade do cliente.

Google Cloud Speech-to-Text.

- O **registro de dados** (data logging), em que o Google guarda áudios e transcrições para **melhorar o serviço**, **não ocorre por padrão**: depende de **adesão** do cliente.
- **Excluir o projeto não apaga** o que já foi registrado pelo programa; para isso, é preciso **pedir a exclusão** por formulário próprio.

API da OpenAI.

- A **retenção zero de dados** (ZDR, zero data retention) **não é automática**: o cliente **precisa pedir** e a empresa **precisa aprovar**.
- Sem ZDR, os **registros de monitoramento de abuso** podem ficar retidos por **até 30 dias**.

Ameaças: voz falsa

Spoofing de voz é enganar um sistema de **verificação automática de locutor** (que reconhece quem fala). Não se limita a tocar uma gravação. As três formas clássicas:

- **fala sintetizada** (gerada por programa a partir de texto);
- **voz convertida** (a voz de uma pessoa transformada para imitar outra);
- **replay** (reprodução de gravação autêntica do alvo).

A série de desafios **ASVspoof** (Todisco e colaboradores) avalia **contramedidas** contra esses três tipos de ataque. Fala sintetizada e voz convertida também são formas de **deepfake de voz**.

TSE e deepfake na propaganda eleitoral (Resolução 23.732/2024, que alterou a Resolução 23.610/2019): o conteúdo sintético deve ser **rotulado** como gerado por IA, mas o **rótulo não torna lícito** o conteúdo fabricado ou manipulado para difundir **fatos notoriamente inverídicos** com potencial de **dano ao equilíbrio do pleito**. Esse uso continua **proibido**.

Ameaças: APIs e links

OWASP API Security Top 10 (2023) é a lista das falhas mais graves em APIs.

- **1º lugar: falha de autorização em nível de objeto** (BOLA, Broken Object Level Authorization). A API não confere se o usuário pode mesmo acessar **aquele** objeto; basta **trocar um identificador** na requisição (por exemplo, de "audio/1001" para "audio/1002") para ver o dado de outra pessoa.
- **Consumo de recursos sem restrição**: sem **limite de requisições** (quantidade e tamanho), alguém pode **sobrecarregar** a API e gerar **conta enorme**. O provedor de nuvem **não bloqueia automaticamente** todo tráfego excessivo sem prejuízo ao cliente; os limites precisam ser configurados.

URL pré-assinada (Amazon S3): é um link temporário que dá acesso a um arquivo. **Qualquer pessoa que tenha o link** consegue acessar o arquivo enquanto ele vale, não só quem o pediu. Por isso o link deve ser **protegido** e ter **validade curta**.

Normas ISO/IEC 27001 e 27002

- **ABNT NBR ISO/IEC 27001**: especifica os **requisitos** para estabelecer, implementar, manter e melhorar continuamente um **sistema de gestão da segurança da informação (SGSI)**. É a norma **em relação à qual a organização pode ser certificada**.
- **ABNT NBR ISO/IEC 27002**: é um **guia de controles** e orientações. **Não** serve de base para certificação.

A **27002 de 2022** organiza **93 controles** em **4 temas**: **organizacionais, de pessoas, físicos e tecnológicos**. A edição de **2013** tinha **114 controles em 14 domínios**.

A LGPD aplicada à segurança do pipeline

A voz é dado pessoal, mesmo falada em sessão pública: permite identificar a pessoa. O caráter público muda a base legal e a publicidade, mas não tira a proteção. Quando a voz é usada para **reconhecer o locutor**, vira **dado biométrico**, logo **dado sensível**.

Dever de segurança (art. 46): os agentes de tratamento adotam **medidas técnicas e administrativas** contra acessos não autorizados e situações acidentais ou ilícitas de destruição, perda, alteração, comunicação ou tratamento inadequado. As medidas valem **desde a concepção** do produto ou serviço **até a execução** (§ 2º), e os **sistemas devem ser estruturados** para atender à segurança, às boas práticas e à governança (art. 49).

O dever alcança **qualquer pessoa que intervenha** no tratamento e continua **mesmo após o término** (art. 47).

Tratamento irregular (art. 44): quando **descumpre a lei** ou **não fornece a segurança que o titular pode esperar**, consideradas as circunstâncias, entre elas o modo de tratamento, os riscos razoavelmente esperados e as **técnicas disponíveis à época**. Responde pelos danos da violação de segurança **o controlador ou o operador** que, deixando de adotar as medidas do art. 46, **der causa ao dano**. Não é só o controlador.

Incidente de segurança (art. 48): se puder acarretar **risco ou dano relevante**, o controlador comunica **à ANPD e aos titulares**. Não basta avisar só um dos dois, e **não é preciso esperar** dano efetivo comprovado: o **risco relevante** já obriga. No juízo de gravidade, conta a comprovação de que os dados estavam **ininteligíveis** para terceiros (por exemplo, criptografados).

Regulamento de Comunicação de Incidente (Resolução CD/ANPD nº 15/2024):

- prazo de **3 dias úteis**, contados do **conhecimento**, pelo controlador, de que o incidente **afetou dados pessoais**, ressalvado prazo diferente em legislação específica. Não conta da data do ataque;
- as informações podem ser **complementadas**, de forma fundamentada, em **20 dias úteis** da comunicação (não 60).

Fim do tratamento e eliminação. O tratamento termina, entre outros casos, quando a **finalidade foi alcançada** ou os dados **deixaram de ser necessários** (art. 15). Aí a regra é **eliminar**, ressalvadas as hipóteses legais de conservação, como **obrigação legal** (art. 16). A eliminação **não depende de pedido** do titular. Guardar o áudio bruto **por tempo indeterminado, por precaução**, depois de a ata ser validada, contraria o princípio da **necessidade**.

Anonimização. Dado anonimizado não é dado pessoal, **salvo** se a anonimização for revertida por meios próprios ou puder ser revertida **com esforços razoáveis** (art. 12).

Quadros para memorizar

Tríade CID

Propriedade	Garante que	Exemplo de ataque	Proteção típica
Confidencialidade	só autorizados veem	vazamento de áudio reservado	criptografia, menor privilégio, 2FA
Integridade	ninguém altera indevidamente	edição da gravação	hash, trilhas de auditoria
Disponibilidade	está à mão quando preciso	negação de serviço, falha de disco	backup em outro local, limites de requisição

Criptografia

Tipo	O que protege ou como funciona
Em trânsito	dado viajando pela rede (TLS)
Em repouso	dado guardado em disco ou servidor
Simétrica	mesma chave cifra e decifra
Assimétrica	chave pública e chave privada, diferentes
Hash	não é criptografia reversível; confere integridade, não recupera o arquivo

Serviços de nuvem

Serviço	Ponto que cai
Amazon Transcribe	TLS 1.2 em trânsito, inclusive streaming; saída criptografada com chave padrão do S3 mesmo sem KMS; redação de PII pode falhar
Azure AI Speech	tempo real só em memória; lote com exclusão e timeToLive; contêiner não envia dados à nuvem
Google Speech-to-Text	data logging só com adesão; apagar o projeto não apaga os registros
API da OpenAI	ZDR só com pedido e aprovação; logs de abuso até 30 dias
Amazon S3	URL pré-assinada: quem tem o link acessa; proteger e dar validade curta

Normas e listas

Referência	Fato
ISO/IEC 27001	requisitos do SGSI; certificável
ISO/IEC 27002:2022	guia; 93 controles; 4 temas (organizacionais, pessoas, físicos, tecnológicos)
ISO/IEC 27002:2013	114 controles; 14 domínios
OWASP API Top 10 2023	1º lugar: autorização em nível de objeto (BOLA)
ASVspoof	contramedidas contra fala sintetizada, voz convertida e replay
CERT.br (backup)	ao menos 2 cópias, em locais diferentes, testadas

Incidente de segurança

Ponto	Regra
Quando comunicar	risco ou dano relevante (não precisa dano comprovado)
A quem	ANPD e titulares
Prazo	3 dias úteis do conhecimento de que afetou dados pessoais
Complementação	20 dias úteis da comunicação
Gravidade	conta se os dados estavam ininteligíveis (criptografia)

Conceitos e autores que caem

- **Confidencialidade, integridade, disponibilidade**: a tríade da ISO/IEC 27000.
- **Hash criptográfico**: impressão digital do arquivo; qualquer alteração muda o valor; irreversível.
- **Menor privilégio**: só as permissões estritamente necessárias.
- **Autenticação em dois fatores**: senha mais um segundo elemento.
- **Trilha de auditoria**: registro de quem acessou, alterou ou excluiu, e quando.
- **SGSI**: sistema de gestão da segurança da informação (ISO/IEC 27001).
- **Spoofing de voz**: ataque com fala sintetizada, voz convertida ou replay; **Todisco et al.**, ASVspoof 2019.
- **BOLA**: falha de autorização em nível de objeto, 1º lugar do OWASP API Top 10 2023.
- **ZDR**: retenção zero de dados, mediante pedido e aprovação.

Tratamento irregular e responsabilidade por falha de segurança.

> **Lei seca:** Art. 44, parágrafo único. Responde pelos danos decorrentes da violação da segurança dos dados **o controlador ou o operador** que, ao deixar de adotar as medidas de segurança previstas no art. 46 desta Lei, der causa ao dano. (LGPD)

Segurança desde o projeto.

> **Lei seca:** Art. 46, § 2º As medidas de que trata o caput deste artigo deverão ser observadas **desde a fase de concepção** do produto ou do serviço **até a sua execução**. (LGPD)

Comunicação de incidente.

> **Lei seca:** Art. 48. O controlador deverá comunicar **à autoridade nacional e ao titular** a ocorrência de incidente de segurança que **possa acarretar risco ou dano relevante** aos titulares. (LGPD)

Pegadinhas da banca

- **"A voz em sessão pública não é dado pessoal."** Errado: identifica a pessoa; é dado pessoal.
- **"Fornecedor de nuvem renomado dispensa formalizar obrigações de segurança."** Errado: o contrato é necessário.
- **"Integridade = só autorizados acessam; confidencialidade = não alterar."** Errado: trocados.
- **"Em repouso protege o tráfego; em trânsito protege o disco."** Errado: trocados.
- **"O hash é reversível e serve de backup."** Errado: é irreversível; backup é cópia.
- **"No Transcribe, só há criptografia em repouso se o cliente informar chave KMS."** Errado: usa a chave padrão do S3.
- **"No Azure, as transcrições em lote ficam para sempre, sem exclusão."** Errado: há exclusão e timeToLive.
- **"Apagar o projeto no Google apaga os dados do data logging."** Errado: é preciso pedir por formulário.
- **"O ZDR da OpenAI é automático para todos."** Errado: depende de pedido e aprovação.
- **"Senha longa dispensa o segundo fator para administradores."** Errado: o 2FA é recomendado.
- **"Logs devem guardar o conteúdo integral das falas."** Errado: registram quem, o quê e quando; o mínimo de dados.
- **"Segurança só na fase de execução."** Errado: desde a concepção.
- **"Incidente se comunica só ao titular."** Errado: à ANPD e ao titular.
- **"O prazo de 3 dias úteis conta da ocorrência."** Errado: conta do conhecimento de que afetou dados pessoais.
- **"A complementação da comunicação pode ser feita em 60 dias úteis."** Errado: 20 dias úteis.
- **"Só se comunica depois de comprovado dano efetivo."** Errado: basta risco relevante.
- **"Pela falha de segurança responde só o controlador."** Errado: responde também o operador que deu causa ao dano.
- **"O operador de nuvem define finalidades e usa os dados para si."** Errado: segue as instruções do controlador.
- **"Terminado o tratamento, conserva-se por tempo indeterminado; eliminar é faculdade."** Errado: a regra é eliminar, salvo hipóteses legais.
- **"Pela necessidade, guarda-se o áudio bruto para sempre, por precaução."** Errado: necessidade é o mínimo.

- **"Spoofing é só replay de gravação."** Errado: inclui fala sintetizada e voz convertida.
- **"Para o TSE, basta rotular o deepfake mentiroso para ser lícito."** Errado: continua proibido.
- **"Sem limite de requisições não há risco, pois o provedor bloqueia tudo."** Errado: é preciso configurar limites.
- **"URL pré-assinada só funciona para quem a pediu."** Errado: quem tem o link acessa.
- **"A 27002 é a norma certificável."** Errado: certificável é a 27001.
- **"A 27002:2022 manteve 114 controles em 14 domínios."** Errado: 93 controles em 4 temas.
- **"Uma cópia no mesmo servidor basta."** Errado: ao menos duas, em locais diferentes.
- **"Na criptografia simétrica, uma chave cifra e outra decifra."** Errado: isso é a assimétrica.

Itens comentados

- **Item:** Em segurança da informação, a integridade é a propriedade que garante que somente pessoas autorizadas tenham acesso ao conteúdo de um arquivo de áudio, enquanto a confidencialidade garante que o arquivo não seja alterado de forma indevida. **Errado.** Os conceitos foram trocados.
- **Item:** Um ataque de negação de serviço que torna indisponível a API de transcrição em nuvem durante uma sessão deliberativa compromete a disponibilidade, uma das propriedades da tríade da segurança da informação. **Certo.** Derrubar o serviço fere a disponibilidade.
- **Item:** Como a função hash é reversível, é possível recuperar integralmente o conteúdo original de um arquivo de áudio a partir do valor de hash armazenado, o que o torna um mecanismo adequado de backup. **Errado.** O hash é irreversível; só confere integridade.
- **Item:** No Amazon Transcribe, as transcrições gravadas no bucket do cliente só são criptografadas em repouso se o usuário informar uma chave do AWS KMS na criação do trabalho de transcrição. **Errado.** Sem chave própria, usa-se a chave padrão do S3.
- **Item:** Segundo a Microsoft, na transcrição em tempo real do Azure AI Speech, o áudio é processado apenas na memória dos servidores e nenhum dado é armazenado em repouso. **Certo.** Em tempo real, nada fica guardado.
- **Item:** O programa de retenção zero de dados (ZDR) da API da OpenAI é ativado automaticamente para todo cliente, dispensando solicitação ou aprovação prévia da empresa. **Errado.** É preciso pedir e ser aprovado.
- **Item:** Para facilitar a auditoria, os logs de um sistema de transcrição devem registrar o conteúdo integral das falas dos oradores, ainda que contenham dados pessoais, já que a coleta mínima prejudica a rastreabilidade. **Errado.** Auditoria precisa de quem, o quê e quando, não das falas.
- **Item:** De acordo com o regulamento da ANPD, o prazo de três dias úteis para a comunicação de incidente de segurança é contado da data em que o incidente ocorreu, ainda que o controlador não tivesse conhecimento dele. **Errado.** Conta do conhecimento de que dados pessoais foram afetados.

- **Item:** Pelo regulamento da ANPD, as informações da comunicação de incidente de segurança podem ser complementadas, de maneira fundamentada, no prazo de sessenta dias úteis, contado da data da comunicação. **Errado.** O prazo é de 20 dias úteis.
- **Item:** O spoofing de voz limita-se ao ataque em que o invasor reproduz uma gravação autêntica do locutor-alvo, não abrangendo a fala sintetizada por programas nem a voz convertida por sistemas de conversão de voz. **Errado.** Replay é só um dos três tipos.
- **Item:** Na lista OWASP API Security Top 10 de 2023, a falha de autorização em nível de objeto, que permite a um usuário acessar dados de outro apenas alterando um identificador na requisição, ocupa o primeiro lugar. **Certo.** BOLA é o primeiro da lista.
- **Item:** A edição de 2022 da ISO/IEC 27002 manteve os 114 controles da edição de 2013, distribuídos em 14 domínios de segurança da informação. **Errado.** A de 2022 tem 93 controles em 4 temas.
- **Item:** Situação hipotética: Um departamento de registro armazena os áudios das reuniões em disco sem criptografia, sob o argumento de que a transmissão desses arquivos para o serviço de transcrição é feita por canal criptografado (criptografia em trânsito), o que também protegeria os arquivos enquanto estão armazenados. Nessa situação, o argumento está correto. **Errado.** Em trânsito não protege o disco; são proteções diferentes.
- **Item:** Situação hipotética: Um acesso indevido a áudios de reuniões reservadas, armazenados pelo departamento de registro de uma casa legislativa, foi identificado, com potencial de causar risco relevante aos titulares. O departamento entendeu que a comunicação à autoridade nacional e aos titulares só seria exigida depois de comprovado dano efetivo a algum deles. Nessa situação, o entendimento está correto. **Errado.** O risco relevante já obriga a comunicar.

Resumo para revisar

- Tríade CID: confidencialidade (só autorizados veem), integridade (sem alteração indevida), disponibilidade (à mão quando preciso). DoS fere a disponibilidade.
- Hash: impressão digital; muda com qualquer alteração; irreversível; confere integridade, não é backup.
- Em trânsito (rede, TLS) x em repouso (disco); uma não substitui a outra.
- Simétrica: mesma chave. Assimétrica: chaves pública e privada.
- Menor privilégio; 2FA para administradores; trilhas de auditoria com quem, o quê e quando (sem as falas).
- Backup: ao menos duas cópias, em locais diferentes, testadas (CERT.br).
- Nuvem: formalizar obrigações de segurança mesmo com fornecedor renomado; ler política de retenção.
- Transcribe: TLS 1.2 (inclusive streaming); saída criptografada com chave padrão do S3; KMS opcional; redação de PII pode falhar.
- Azure: tempo real só em memória; lote com exclusão e timeToLive; contêiner mantém dados no cliente.

- Google: data logging só com adesão; apagar projeto não apaga registros.
- OpenAI: ZDR só com pedido e aprovação; logs de abuso até 30 dias.
- Spoofing: sintetizada, convertida, replay; ASVspoof avalia contramedidas.
- TSE: rótulo de IA obrigatório, mas deepfake mentiroso continua proibido.
- OWASP API 2023: BOLA em 1º; sem limite de requisições há risco de sobrecarga e custo.
- URL pré-assinada: quem tem o link acessa; proteger e validade curta.
- 27001: requisitos do SGSI, certificável. 27002:2022: guia, 93 controles em 4 temas (2013: 114 em 14 domínios).
- Voz é dado pessoal; usada para reconhecer o locutor, é biométrica e sensível.
- LGPD: segurança técnica e administrativa, desde a concepção, sistemas estruturados para isso, dever que segue após o término.
- Tratamento irregular: descumpre a lei ou não dá a segurança esperada (técnicas da época). Controlador ou operador que deu causa responde.
- Incidente com risco relevante: ANPD e titulares; 3 dias úteis do conhecimento; complementação em 20 dias úteis; criptografia reduz a gravidade.
- Fim do tratamento: eliminar, salvo hipóteses legais; não guardar áudio bruto por precaução.
- Anonimizado não é dado pessoal, salvo reversão com esforço razoável.